Au-delà des heuristiques de dispatching statiques : une évaluation comparative de l'apprentissage par renforcement profond face aux perturbations dans l'exploitation minière à ciel ouvert

Jean-Luc Mupasa Kalunga[1,*] Olfa Ferchichi[2]

[1]Faculté d'Informatique, Université Don Bosco de Lubumbashi (UDBL), Lubumbashi, RDC

[2]Laboratoire RIADI, ENSI, Université de la Manouba, Tunis, Tunisie

16mk293@esisalama.org; olfaferchichi@yahoo.fr

*Auteur correspondant : Jean-Luc Mupasa Kalunga[m27]

[À VALIDER AVEC LA DIRECTRICE : adresse électronique : 16mk293@esisalama.org ne correspond pas à l'affiliation UDBL ; utiliser une adresse institutionnelle UDBL si possible.]

Résumé

[m1, m2, M1, M3] Le transport par camions et pelles peut représenter jusqu'à 60 % des coûts d'exploitation d'une mine à ciel ouvert et reste très sensible aux perturbations. Les travaux d'apprentissage par renforcement appliqués au dispatching des camions évaluent généralement les politiques dans un seul régime, si bien que leur comportement sous perturbation reste mal connu. Cet article compare huit politiques de dispatching dans un simulateur stochastique : quatre règles heuristiques, deux agents d'apprentissage par renforcement tabulaire, Q-Learning et State–Action–Reward–State–Action, et deux agents d'apprentissage par renforcement profond, Deep Q-Network et Proximal Policy Optimization. Trois régimes sont étudiés : conditions nominales, flotte augmentée de moitié et pannes fréquentes des camions. Chaque combinaison de politique et de régime est évaluée sur 30 réplications appariées, avec des tests non paramétriques corrigés pour les comparaisons multiples. Le classement des politiques change avec le régime : Proximal Policy Optimization obtient la productivité la plus élevée en conditions nominales, l'affectation fixe lorsque la flotte est augmentée et Deep Q-Network lorsque les pannes sont fréquentes, et l'interaction entre politique et régime est significative. Les deux règles fondées sur la seule distance concentrent toute la flotte sur une pelle et sont dominées dans les trois régimes. Évalués sans réentraînement en pannes fréquentes, les agents profonds entraînés en conditions nominales conservent une productivité proche de celle des agents entraînés dans ce régime. Ces résultats suggèrent que la performance nominale prédit mal le comportement sous perturbation et plaident pour une évaluation des politiques de gestion de flotte sur plusieurs régimes contrastés.

Mots-clés : Apprentissage par renforcement profond ; Exploitation minière à ciel ouvert ; Dispatching de camions ; Gestion de flotte ; Résilience opérationnelle ; Simulation stochastique ; Proximal policy optimization ; Deep Q-network.[m1]

1 Introduction

L'exploitation minière à ciel ouvert constitue une pierre angulaire de la chaîne mondiale d'approvisionnement en matières premières, où la viabilité économique des opérations est indissociable de l'efficacité de systèmes logistiques de grande envergure. Il est par conséquent impératif d'explorer les avancées technologiques récentes pour améliorer la performance et la résilience de ces dispositifs logistiques.

1.1 Contexte industriel

Les mines à ciel ouvert sont des systèmes industriels de très grande échelle dans lesquels le cycle des camions et des pelles constitue l'ossature logistique principale. Ce processus, qui comprend l'excavation, le transport et le déversement des matériaux, n'est pas une simple tâche opérationnelle mais un facteur financier déterminant, représentant jusqu'à 60 % des coûts d'exploitation totaux d'un site minier [2]. Dans l'exploitation minière moderne, la pression pour optimiser ces flux est double : maximiser le débit afin de répondre à la demande mondiale de matières premières, tout en minimisant la consommation d'énergie et les émissions de gaz à effet de serre associées aux flottes de transport diesel.

L'efficacité de ces systèmes est toutefois constamment mise à l'épreuve par une forte variabilité opérationnelle. Dans les environnements miniers réels, les conditions sont loin d'être déterministes. Les pannes d'équipements, les fluctuations de charge utile, les temps de trajet aléatoires causés par la dégradation des pistes et les congestions soudaines du trafic créent ensemble un environnement très instable. La gestion de cette complexité exige une prise de décision en temps réel, capable de concilier la productivité immédiate et la résilience de la flotte.

1.2 Notions utilisées

[m3, m4] Cette étude repose sur quelques notions utilisées tout au long de l'article. L'apprentissage par renforcement (Reinforcement Learning, RL) désigne une branche de l'intelligence artificielle dans laquelle un agent autonome apprend un comportement par essais et erreurs, au fil de ses interactions avec un environnement dynamique, de façon à maximiser un signal de récompense cumulée. L'apprentissage par renforcement profond (Deep Reinforcement Learning, DRL) étend le RL en utilisant des réseaux de neurones pour approximer les fonctions de valeur ou les politiques, ce qui permet de traiter des espaces d'états de grande dimension. Le dispatching de camions désigne le processus opérationnel en temps réel consistant à affecter des camions à des points de chargement et de déversement afin d'assurer la synchronisation de la flotte et la productivité ; il est mis en œuvre dans les mines par des systèmes de gestion de flotte (Fleet Management Systems, FMS).

Quatre algorithmes d'apprentissage sont étudiés. Q-Learning et State–Action–Reward–State–Action (SARSA) sont des méthodes tabulaires qui stockent une valeur pour chaque couple état–action. Deep Q-Network (DQN) remplace cette table par un réseau de neurones. Proximal Policy Optimization (PPO) apprend directement une politique au moyen d'une méthode acteur–critique. Les quatre règles de référence sont désignées dans la suite par premier arrivé, premier servi (First-In-First-Out, FIFO), Affectation fixe, Pelle la plus proche et Plus court chemin ; leur définition exacte est donnée dans la Section 5.7. Enfin, le problème de décision est formulé comme un processus de décision markovien (Markov Decision Process, MDP), plus précisément comme un processus de décision semi-markovien (Semi-Markov Decision Process, SMDP), puisque les décisions sont séparées par des durées variables (Section 5.4).

1.3 Objectif et organisation de l'article

[M23, M24] L'objectif de ce travail est de déterminer dans quels régimes de fonctionnement une politique de dispatching apprise est préférable à une règle industrielle, et d'expliquer les écarts observés à partir du comportement des politiques. La contribution est évaluative : aucun nouvel algorithme n'est proposé, et l'apport réside dans un protocole de comparaison contrôlé, appliqué à huit politiques et à trois régimes.

Le reste de l'article est organisé comme suit. La Section 2 (Travaux connexes) passe en revue la littérature sur le dispatching de camions selon trois paradigmes. La Section 3 (Positionnement et problématique) synthétise cette littérature dans un tableau de positionnement et en déduit la lacune de recherche, le problème étudié, les questions de recherche et les hypothèses. La Section 4 (Contributions et cadre méthodologique) présente les contributions et le cadre méthodologique. La Section 5 (Approche proposée : modèle, simulateur et agents étudiés) décrit le système modélisé, le simulateur, la formulation du problème de décision et les agents étudiés. La Section 6 (Plan

expérimental) détaille le protocole expérimental et la Section 7 (Résultats) les résultats. La Section 8 (Discussion) discute ces résultats et leurs limites, et la Section 9 (Conclusion et travaux futurs) conclut l'article.

[À VALIDER AVEC LA DIRECTRICE : nouvelle structure de l'article (M24) : à faire valider avant la traduction anglaise.]

2 Travaux connexes

L'optimisation des systèmes camions–pelles est au cœur de l'ingénierie minière et de la recherche opérationnelle depuis plus de six décennies. Comme le soulignent Newman et al.[m22] [24], l'évolution de ces systèmes est passée de la planification manuelle à des systèmes de gestion de flotte (FMS) automatisés complexes. Cette section passe en revue la littérature autour de trois grands paradigmes : les heuristiques statiques, la programmation mathématique et le domaine émergent de l'apprentissage par renforcement.

2.1 Dispatching de camions statique et à base de règles

Le dispatching à base de règles demeure le paradigme dominant dans les mines en exploitation, car il est transparent, peu coûteux en calcul et facile à intégrer dans les logiciels FMS commerciaux. Les premières revues des stratégies de dispatching informatisées [22] et l'aperçu ultérieur des stratégies de résolution proposé par Alarie et Gamache [5] identifient un petit ensemble de règles de décision récurrentes qui structurent encore aujourd'hui la pratique industrielle.

[M25, Dir. corr. 1] Quatre règles sont particulièrement pertinentes pour la présente étude. La règle premier arrivé, premier servi (FIFO) sert en priorité l'unité de chargement qui attend un camion depuis le plus longtemps ; elle équilibre la charge des pelles mais ignore la configuration spatiale de la fosse. L'Affectation fixe attribue chaque camion à une pelle prédéterminée pour toute la durée du poste ; elle stabilise le facteur d'appariement et reste une référence industrielle répandue, mais ne peut pas réallouer la capacité en réponse à des déséquilibres de files. La Pelle la plus proche envoie le camion vers l'unité de chargement la plus proche, ce qui minimise la distance parcourue à vide au prix d'une optimisation purement locale. Le Plus court chemin généralise cette idée en choisissant la destination qui minimise un coût de cycle estimé sur le graphe des pistes. Les définitions exactes retenues dans cette étude figurent dans le Table 6.

La performance pratique de ces règles a été évaluée aussi bien sur le terrain qu'en simulation. Subtil et al. [37] rapportent une mise en œuvre pratique du dispatching dans une mine à ciel ouvert en exploitation, tandis que Mohtasham et Mirzaei-Nasirabad [21] évaluent un progiciel de dispatching commercial dans la mine de cuivre de Sungun et soulignent la sensibilité de la logique à base de règles aux conditions opérationnelles. La simulation à événements discrets a été l'instrument standard de ce type d'évaluation [50, 12, 47, 1]. Elle montre de façon constante que les règles gloutonnes se dégradent fortement dès que la taille de la flotte dépasse la capacité de chargement de la fosse, car les files d'attente se concentrent sur un sous-ensemble de pelles. Les quatre règles retenues ici représentent des logiques différentes : FIFO tient compte de l'état des files, l'Affectation fixe impose une répartition statique et équilibrée, tandis que Pelle la plus proche et Plus court chemin s'appuient sur la proximité spatiale sans tenir compte des files. Les systèmes commerciaux utilisent en outre des règles combinant files et temps de trajet, telles que le temps d'attente minimal des camions [47], ou une couche d'optimisation linéaire en amont [35, 34], qui ne sont pas incluses dans la présente étude.[M25, m5]

2.2 Optimisation mathématique et métaheuristiques

Pour dépasser les limites des règles simples, les chercheurs se sont tournés vers la programmation mathématique. Soumis et al. [35] ont proposé une approche à plusieurs étapes combinant la programmation linéaire (PL) pour la planification de la production et des modèles d'affectation pour le dispatching en temps réel. Cette structure modulaire reste l'ossature de nombreux FMS modernes.

Ahangaran et al. [4] ont étendu cette approche en développant des modèles spécifiquement dédiés aux flottes de camions de capacités hétérogènes, en utilisant des réseaux de flots pour équilibrer la production.

Cependant, la nature déterministe de la programmation linéaire en nombres entiers mixtes (MILP) entre souvent en conflit avec la réalité stochastique de l'exploitation minière. Ta et al. [41] ont tenté de combler cet écart en incorporant des probabilités d'inactivité des pelles dans des modèles linéaires, en recourant à la théorie des files d'attente pour obtenir de meilleures estimations de production. Malgré ces avancées, les modèles MILP souffrent fréquemment de la malédiction de la dimensionnalité lorsqu'ils sont appliqués à de grandes mines exploitant des dizaines de camions [34, 44].

Pour gérer cette complexité, les métaheuristiques ont été largement appliquées au dispatching et à l'acheminement des camions. Souza et al. [36] ont démontré qu'une heuristique hybride combinant GRASP et VNS pouvait obtenir des solutions quasi optimales en des temps de calcul réduits. Liu et Chai [19] ont utilisé un algorithme génétique pour minimiser la consommation d'énergie liée au transport tout en tenant compte de la résistance variable des pistes dans le temps. Les algorithmes d'optimisation par colonies de fourmis, qui modélisent la sélection probabiliste d'itinéraires par les insectes sociaux au moyen de mécanismes de mise à jour des phéromones, ont été appliqués aux problèmes d'affectation multi-véhicules dans l'exploitation minière de surface, car leur sélection stochastique s'adapte naturellement aux demandes concurrentes sur des tronçons de piste partagés [43]. Le recuit simulé, qui accepte des mouvements sous-optimaux avec une probabilité contrôlée par une température afin d'échapper aux optima locaux, a de même été utilisé pour l'ordonnancement dans les environnements à ciel ouvert [26]. Bien que puissantes, les métaheuristiques sont souvent formulées pour optimiser un état donné du système ou un horizon de planification donné. Lorsque des perturbations importantes modifient les conditions de fonctionnement sous-jacentes, le processus d'optimisation doit être répété ou réoptimisé, ce qui peut limiter la réactivité lorsque les décisions doivent être mises à jour à de courtes échelles de temps dans des environnements miniers dynamiques.

2.3 Approches par apprentissage par renforcement

Le passage à l'apprentissage par renforcement représente un changement de paradigme : au lieu de résoudre un nouveau problème d'optimisation à chaque époque de décision, un agent apprend une politique qui associe les états du système à des actions optimales [38, 18]. Les premières applications du RL en logistique, comme celles de Nazari et al. [23] pour le problème de tournées de véhicules (VRP) et de Zhang et al. [48] pour l'ordonnancement d'atelier, ont démontré que le DRL pouvait surpasser les heuristiques classiques en apprenant à partir de milliers d'interactions simulées.

Au sein de la famille de l'apprentissage par renforcement, les méthodes diffèrent substantiellement par leur puissance de représentation et leur paradigme d'apprentissage. Les méthodes tabulaires, telles que Q-Learning et SARSA [38],[m5] construisent des fonctions de valeur sur des tables d'états-actions discrets, ce qui les rend transparentes et légères en calcul, mais leur expressivité se dégrade fortement lorsque l'espace d'observation croît avec la taille de la flotte. Les agents DQN répondent à ce problème en approximant la fonction Q par un réseau de neurones et en stabilisant l'entraînement grâce au rejeu d'expériences et au gel du réseau cible, ce qui permet de généraliser à des entrées continues de grande dimension. PPO [33] appartient à la famille acteur-critique : elle optimise directement la politique via un objectif de substitution dont la contrainte d'écrêtage empêche les mises à jour catastrophiques des paramètres. Ces quatre algorithmes, du tabulaire au profond et de l'approche fondée sur la valeur au gradient de politique, forment un spectre comparatif naturel et constituent précisément la composante RL du banc d'essai conçu dans cette étude.

Dans le secteur minier, cette transition est plus récente. Hazrathosseini et Afrapoli [15] proposent une revue critique, soulignant que, bien que le RL présente un potentiel considérable pour les FMS intelligents, la plupart des études restent au stade de la preuve de concept. de Carvalho et Dimitrakopoulos [9] ont appliqué un cadre acteur–critique à la planification de la production, montrant que le RL peut traiter efficacement la dynamique de la flotte tout en mettant à jour les objectifs de production.

Des bancs d'essai récents, tels que Mining-Gym [6], ont commencé à fournir des environnements standardisés pour tester ces algorithmes. Zhao et al. [49] ont proposé une approche hiérarchique d'apprentissage par renforcement multi-agent (MARL) pour un dispatching durable, avec un accent sur l'efficacité énergétique, tandis que Pei et al. [27] et Rosales et Diaz [30] ont exploré le dispatching par apprentissage et le dispatching interprétable pour le transport minier autonome. L'usage d'une aide à la décision fondée sur le RL pour l'ordonnancement industriel hiérarchique dépasse le secteur minier : Szatmari et al. [40] démontrent des architectures multi-niveaux similaires dans la conduite de procédés chimiques, ce qui suggère que les schémas de conception émergeant dans la recherche sur le dispatching minier ont une large pertinence inter-domaines. Une limite commune à ces études est toutefois leur focalisation sur les conditions nominales. La plupart des agents RL sont entraînés et testés dans des environnements stables ; peu d'études évaluent explicitement le comportement d'un agent DQN ou PPO face à des pannes d'équipements fréquentes ou à des pics de congestion inattendus.

3 Positionnement et problématique

[M24] Cette section rassemble ce qui était auparavant réparti entre l'introduction, la synthèse des travaux connexes et une section de positionnement séparée. Le Table 1 situe l'étude par rapport aux familles de travaux examinées dans la Section 2 ; les sous-sections suivantes en déduisent la lacune de recherche, le problème étudié, les questions de recherche et les hypothèses.

Table 1 – Positionnement de l'étude proposée par rapport à des approches représentatives de dispatching de camions.

Approche	Optimisation formelle	Apprentissage	Tests de perturbation	Références	Protocole de réplication	Objet de l'évaluation
Revues sur le dispatching et la gestion de flotte [24, 22, 5, 15, 2]	s.o.	s.o.	Non	s.o.	s.o.	Panorama des modèles et algorithmes
Dispatching à base de règles, terrain et simulation [37, 21, 50, 12, 1]	Non	Non	Non	Pratique actuelle	Limité	Validation sur le terrain ou par événements discrets
Comparaison de règles selon la taille de la flotte [47]	Algorithme génétique	Non	Congestion	4 à 6 règles	Limité	Comparaison de stratégies d'allocation
Programmation mathématique [35, 4, 41, 34, 44]	Oui (PL / MILP)	Non	Non	0 à 2	Limité	Optimalité en conditions stables
Métaheuristiques et simulation-optimisation [36, 19, 43, 26]	Oui (recherche heuristique)	Non	Fondé sur des scénarios	MILP ou 1 à 2 règles	Limité	Solutions de planification quasi optimales
Dispatching par apprentissage, autres domaines [23, 48, 40]	Non	RL profond et hiérarchique	Non	Heuristiques classiques	Oui	Performance en tournées et ordonnancement
Apprentissage par renforcement dans le secteur minier [9, 6, 49, 27, 30]	Non	Acteur–critique, MARL, RL interprétable	Non	0 à 3	Limité	Dispatching de type preuve de concept
Étude proposée	**Non (heuristiques comme références)**[m17]	**RL tabulaire et profond (Q-Learning, SARSA, DQN, PPO)**	**Congestion et pannes**	**8 politiques**	**30 réplications appariées**[M3]	**Résilience opérationnelle sur trois régimes**

3.1 Lacunes de la recherche

[M24 (fusion §1.3, §2.4, §3)] La littérature examinée et le Table 1 font apparaître quatre lacunes complémentaires.

Premièrement, les trois paradigmes passés en revue sont rarement comparés entre eux. Les travaux à base de règles comparent les règles de dispatching entre elles [5, 21, 47], la programmation mathématique compare un optimiseur à une règle ou à une formulation en nombres entiers mixtes [35, 34], et les travaux fondés sur l'apprentissage comparent un agent à un petit nombre de règles de référence [9, 49]. Lorsque des comparaisons entre familles existent, les algorithmes sont évalués sur des environnements, des récompenses ou des configurations de flotte différents, ce qui empêche d'attribuer une différence observée à la logique de dispatching elle-même.

Deuxièmement, le régime de fonctionnement est généralement traité comme un contexte fixe plutôt que comme un facteur expérimental. Les revues sur la gestion de flotte fondée sur le RL observent que la plupart des contributions restent au stade de la preuve de concept et sont évaluées dans des environnements stables [15], et les études qui prennent en compte des perturbations n'en considèrent généralement qu'un seul type, le plus souvent la congestion [47]. Un classement rapporté

est donc conditionnel à un seul point de fonctionnement.

Troisièmement, la solidité des références est souvent insuffisante. Les études fondées sur l'apprentissage rapportent des améliorations par rapport à deux ou trois règles de référence [49], et parfois par rapport à aucune [9]. Lorsque la règle de comparaison est faible, une amélioration n'établit que peu de choses sur la valeur pratique de la politique apprise.

Quatrièmement, le protocole inférentiel est rarement documenté. Le nombre de réplications, le contrôle des graines aléatoires et les corrections pour comparaisons multiples sont rarement rapportés dans la littérature sur le dispatching minier [21, 1, 26], alors que la littérature sur l'évaluation des agents d'apprentissage par renforcement a montré que ces choix modifient les conclusions [16, 3].

3.2 Problème de recherche

[M24] Le défi central du dispatching est l'affectation dynamique, en temps réel, des camions aux points de chargement et de déversement afin d'optimiser un objectif combinant débit, temps d'inactivité et consommation d'énergie. Les systèmes de gestion de flotte sont déployés dans les mines depuis plusieurs décennies [2, 24], et les règles de décision qui les sous-tendent sont bien documentées [22, 5]. Lorsqu'une perturbation survient, telle qu'une panne ou une congestion, elle peut se propager dans le réseau de transport sous forme de files d'attente et de sous-utilisation des équipements ; des études à événements discrets montrent ainsi que l'attente en file augmente avec la taille de la flotte dès que la capacité de chargement est approchée [47, 50].

La question pratique n'est donc pas seulement de savoir si un dispatching adaptatif améliore la productivité en conditions stables, mais si le choix d'une politique reste le bon lorsque le régime de fonctionnement change. Le problème est étudié à deux niveaux.

> **Problème P1 – Décision de dispatching en temps réel.** Étant donné l'état courant de la mine, affecter le camion qui vient de se libérer à un couple pelle–point de déversement, ou le faire patienter, de manière à maximiser le tonnage livré sur un poste tout en limitant l'attente en file et la consommation de carburant.
>
> **Problème P2 – Choix d'une politique selon le régime.** Étant donné un ensemble de politiques de dispatching et un ensemble de régimes de fonctionnement, déterminer quelle politique est la plus performante dans chaque régime, si le classement obtenu en conditions nominales se maintient sous perturbation, et si une politique apprise en conditions nominales conserve sa performance lorsqu'elle est déployée sans réentraînement dans un autre régime.

Le problème P1 est formalisé dans la Section 5.4. Le problème P2 est traité par le protocole expérimental de la Section 6.

3.3 Questions de recherche et hypothèses

[M23] L'évaluation empirique répond à quatre questions de recherche :

QR1 Quelle politique atteint la productivité la plus élevée dans chaque régime, et ce classement se maintient-il d'un régime à l'autre ?

QR2 Comment la productivité et l'attente en file évoluent-elles conjointement selon la politique et le régime ?

QR3 Une politique apprise en conditions nominales conserve-t-elle sa performance lorsqu'elle est déployée sans réentraînement dans un régime perturbé, par rapport à une politique entraînée dans ce régime ?

QR4 Le classement selon la consommation spécifique de carburant suit-il le classement de productivité ?

Les QR1 et QR2 sont traitées dans les Sections 7.1 to 7.4, la QR3 dans la Section 7.5 et la QR4 dans la Section 8.4. La significativité statistique de chaque comparaison est examinée dans la Section 7.6.

Trois hypothèses réfutables, formulées avant l'analyse des résultats, guident l'étude :

— **H1 :** en conditions nominales, les politiques d'apprentissage par renforcement profond obtiennent une productivité supérieure à celle de la meilleure heuristique.

— **H2 :** aucune politique ne domine dans les trois régimes : le classement dépend du régime, ce qui se traduit par une interaction significative entre politique et régime.

— **H3 :** une productivité élevée ne s'accompagne pas nécessairement d'une faible attente en file, de sorte que plusieurs politiques forment un compromis entre ces deux critères.

3.4 Revendications et limites de portée

[M26, M27] La contribution de cet article est évaluative plutôt qu'algorithmique : aucun nouvel algorithme d'apprentissage par renforcement n'est proposé. Elle ne repose pas non plus sur l'existence d'un environnement de simulation minier, puisque des environnements comparables existent déjà, tels que Mining-Gym [6]. Elle réside dans la combinaison de plusieurs éléments rarement réunis : huit politiques de familles différentes dans un même environnement, plusieurs régimes de fonctionnement traités comme un facteur expérimental, une évaluation de politiques apprises sans réentraînement, un protocole de réplication appariée avec des tests corrigés, et une analyse du comportement des politiques qui explique les écarts observés.

Trois limites de portée découlent de ce positionnement et sont discutées dans la Section 8.5. L'évaluation est menée en simulation, de sorte que les ordres de grandeur rapportés décrivent une performance relative dans l'environnement simulé proposé plutôt que des prédictions à l'échelle d'un site. Les agents sont des contrôleurs uniques qui décident pour tous les camions, de sorte que les formulations multi-agents [49] sortent de l'espace comparé. Enfin, les trois régimes représentent des perturbations stylisées, conçues pour être interprétables et reproductibles.

[À VALIDER AVEC LA DIRECTRICE : vérifier ce que propose exactement Mining-Gym (perturbations, références) et ajuster la colonne correspondante du Table 1 (M26).]

4 Contributions et cadre méthodologique

4.1 Contributions

[M23, M24, M26, M16] Ce travail apporte quatre contributions.

— **C1. Un protocole d'évaluation sur plusieurs régimes.** Un simulateur stochastique compatible avec l'interface Gymnasium est associé à un protocole de mesure qui traite le régime de fonctionnement comme un facteur expérimental, évalue chaque politique sur 30 réplications appariées et applique des tests appariés corrigés pour les comparaisons multiples.

— **C2. Une comparaison de huit politiques de familles différentes.** Quatre heuristiques, deux agents d'apprentissage tabulaire et deux agents d'apprentissage profond sont évalués dans le même environnement, avec les mêmes actions, les mêmes graines et les mêmes indicateurs.

— **C3. Une analyse du comportement des politiques.** La répartition des cycles entre les pelles et l'usage de l'action d'attente, mesurés sur toutes les réplications, expliquent les écarts de productivité et d'attente entre politiques.

— **C4. Une mise en évidence de la dépendance au régime.** Le classement des politiques change d'un régime à l'autre, l'interaction entre politique et régime est significative, et une évaluation sans réentraînement montre dans quelle mesure une politique apprise en conditions nominales conserve sa performance sous perturbation.

4.2 Cadre méthodologique

[M24] La Fig. 1 résume les étapes de l'étude. (1) Le système de transport est modélisé et implémenté dans un simulateur stochastique (Sections 5.1 and 5.3). (2) La décision de dispatching est formulée

comme un processus de décision semi-markovien doté d'une récompense multi-objectif (Sections 5.4 and 5.5). (3) Les quatre agents d'apprentissage sont entraînés et les quatre heuristiques sont implémentées (Sections 5.6 and 5.7). (4) Toutes les politiques sont évaluées dans trois régimes sur 30 réplications appariées, et les agents nominaux sont en outre évalués sans réentraînement dans les régimes perturbés (Section 6). (5) Les résultats sont analysés par des tests statistiques appariés et par une analyse du comportement des politiques (Section 7).

Figure à créer : schéma des cinq étapes du cadre méthodologique
(modélisation et simulateur ; formulation et récompense ; entraînement des agents et heuristiques ;
évaluation sur trois régimes ; analyse statistique et comportementale), sans logos.

Figure 1 – Cadre méthodologique de l'étude.

[À VALIDER AVEC LA DIRECTRICE : la directrice a demandé une figure récapitulative des étapes, sans logos (réunions des 16 août et 22 septembre).]

5 Approche proposée : modèle, simulateur et agents étudiés

Cette section décrit le système modélisé, le simulateur, la formulation du problème de décision, la fonction de récompense, les agents d'apprentissage et les heuristiques de référence. Toutes les valeurs indiquées sont celles de l'implémentation évaluée.[M23]

5.1 Système de transport par camions et pelles

La mine est modélisée comme un système de transport en boucle fermée composé de trois entités physiques :

1. **Unités de chargement (pelles) :** ressources fixes caractérisées par leur durée de chargement. Chaque pelle sert un camion à la fois ; un camion qui arrive pendant un chargement attend que la pelle se libère.
2. **Unités de transport (camions) :** une flotte homogène de camions de 140 tonnes, caractérisés par leurs vitesses à vide et en charge et par leur consommation de carburant.
3. **Unités de déversement (verses) :** les destinations des matériaux. Comme les pelles, elles servent un camion à la fois.

Le système est soumis à des pannes de camions. À la fin de chaque cycle, un camion tombe en panne avec une probabilité fixe (2 % ou 10 % selon le régime) et reste immobilisé pendant une durée tirée uniformément entre 10 et 30 minutes. Les pelles et les verses ne tombent pas en panne dans la présente étude.[M11, N5]

5.2 Réseau routier stochastique

L'infrastructure de la mine est représentée par un graphe orienté $G = (V, E)$, où V regroupe le parc de stationnement, une intersection, les pelles et les verses, et où E représente les pistes reliant ces points. Chaque arête porte une distance, une pente et un état de surface. Le temps de trajet $T(e)$ d'une arête e suit une loi log-normale centrée sur le temps moyen $\bar{T}(e)$:[M11]

$$T(e) \sim \text{Lognormal}(\mu_e, \sigma^2), \qquad \mu_e = \ln \bar{T}(e) - \frac{\sigma^2}{2}, \qquad \sigma = 0{,}12, \tag{1}$$

où $\bar{T}(e)$ dépend de la distance, de la vitesse de base (26 km/h en charge, 32 km/h à vide), d'une pénalité de 3 % par point de pente et de l'état de la piste. À chaque passage sur une arête, l'état de la piste se dégrade de 0,02 avec une probabilité de 5 % (plancher de 0,6) ; les pistes sont remises à neuf au début de chaque poste. L'ensemble des paramètres est rassemblé dans le Table 2.[M11]

5.3 Environnement de simulation

Le simulateur est conforme à l'interface Gymnasium [42], ce qui garantit sa compatibilité avec Stable-Baselines3 [29]. L'architecture logicielle est illustrée dans la Fig. 2.

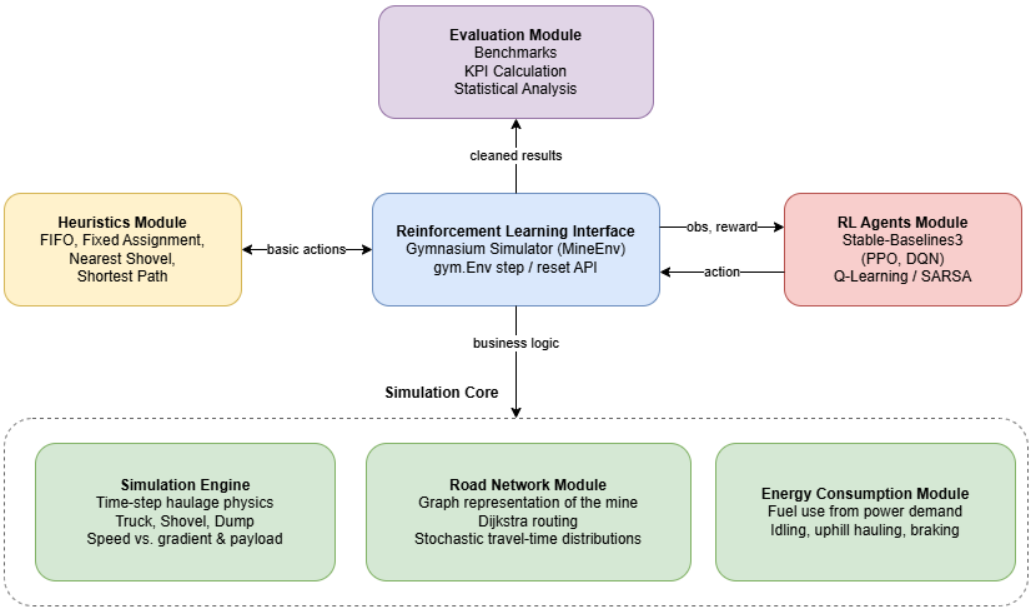


Figure 2 – Architecture logicielle modulaire du cadre d'évaluation.

[FIGURE À RÉGÉNÉRER : dans draw.io, corriger le module « Simulation Engine » (« Time-step haulage physics » devient « Event-driven cycle simulation ») et le module « Energy Consumption » (« Fuel use from power demand ; idling, uphill hauling, braking » devient « Distance-based fuel model with slope factor ; idling at 10 L/h »), pour rester cohérent avec le texte (M11).]

[M11, A] L'architecture comprend cinq modules :

- **Moteur de simulation piloté par les événements :** une décision est demandée chaque fois qu'un camion devient disponible. Le cycle complet de ce camion (trajet vers la pelle, attente éventuelle, chargement, trajet en charge, attente éventuelle, déversement, retour à vide vers la pelle, panne éventuelle) est alors simulé d'un seul tenant, et la pelle et la verse sont réservées jusqu'à la fin de leur service. L'horloge avance ensuite jusqu'au prochain camion disponible. Les pelles et les verses servent donc les camions dans l'ordre des décisions, ce qui approxime une file premier arrivé, premier servi.
- **Module de réseau routier :** représentation de la mine sous forme de graphe, calcul des itinéraires par l'algorithme de Dijkstra et tirage des temps de trajet.
- **Module de consommation de carburant :** consommation proportionnelle à la distance parcourue (0,65 L/km en charge, 0,45 L/km à vide), majorée selon la pente et l'état de la piste, et consommation au ralenti de 10 L/h pendant les attentes, les chargements, les déversements et les pannes. Ce modèle simplifié n'est pas calibré sur des données de constructeur (Section 8.5).

— **Interface d'apprentissage :** l'API `reset`–`step` de Gymnasium, par laquelle l'agent observe l'état, choisit une action et reçoit une récompense.

— **Modules d'indicateurs et de banc d'essai :** calcul des indicateurs de la Section 6.3 pour toutes les politiques, avec les mêmes graines.

Table 2 – Paramètres du simulateur.[M11]

Élément	Valeur
Topologie	7 nœuds : parc, intersection, 3 pelles, 2 verses ; arêtes orientées, liaisons directes pelle–verse
Distances	parc–intersection 0,8 km ; intersection–pelles 1,5 / 1,8 / 2,2 km ; intersection–verses 2,8 / 3,2 km ; pelle–verse 0,8× (somme des deux distances précédentes)
Pentes	accès aux pelles 4 / 5 / 6 % ; accès aux verses 6 / 8 % ; pente de retour réduite de 2 à 3 points (minimum 1 %)
Vitesses	26 km/h en charge, 32 km/h à vide ; facteur $\max(0{,}55\,;\, 1 - 0{,}03 \times \text{pente})\times$ état de la piste ; minimum 5 km/h
Temps de trajet	log-normal autour du temps moyen, $\sigma = 0{,}12$; minimum 0,2 min
Chargement	log-normal, moyenne 2,0 min, écart-type 0,3 min (capacité d'une pelle ≈ 30 chargements/h, soit ≈ 4 200 t/h)
Déversement	log-normal, moyenne 1,0 min, écart-type 0,2 min
Dégradation des pistes	probabilité 5 % par passage de perdre 0,02 d'état (plancher 0,6) ; remise à neuf à chaque poste
Pannes	camions uniquement ; probabilité par cycle 2 % (nominal, forte charge) ou 10 % (fortes pannes) ; réparation $\mathcal{U}(10, 30)$ min
Camions, poste	140 t par camion ; poste de 480 min ; un cycle n'est compté que s'il se termine avant la fin du poste
Carburant	0,65 (en charge) ou 0,45 (à vide) L/km $\times(1 + 0{,}03 \times \text{pente}) \times (1 + 0{,}5 \times (1 - \text{état}))$; ralenti 10 L/h

5.4 Formulation sous forme de processus de décision semi-markovien

[M9, M24, Dir. 30/09] Le problème P1 est formulé comme un processus de décision markovien [28, 38] défini par le n-uplet (S, A, P, R, γ). Comme les décisions sont déclenchées par des événements (la libération d'un camion) et séparées par des durées variables, il s'agit plus précisément d'un processus de décision semi-markovien [7, 39]. La Fig. 3 illustre la boucle d'interaction ; le Table 4 résume les composantes.

5.4.1 Espace d'états

[M1, N1, N2, N3] L'état S_t est un vecteur normalisé dans $[0, 1]$ dont la taille vaut $15 + 11N$, où N est le nombre de camions : 147 composantes pour $N = 12$ et 213 pour $N = 18$. Sa composition exacte est donnée dans le Table 3. Comme la taille de l'état dépend de N, un réseau de neurones entraîné avec 12 camions ne peut pas recevoir l'état d'une flotte de 18 camions : ce point détermine le protocole d'évaluation décrit dans la Section 6.2.

Dans l'implémentation évaluée, 54 des 147 composantes (78 des 213) sont constantes. Le statut de chaque camion vaut toujours 0, car le cycle est simulé d'un seul tenant et le camion est de nouveau disponible au moment où l'état est construit ; la position d'un camion n'est jamais l'intersection ni une verse, puisqu'un cycle se termine à la pelle ; enfin, les six distances entre pelles et verses ne changent pas. Ces composantes n'apportent aucune information à l'agent. Par ailleurs, le tonnage cumulé par camion est normalisé par 2 000 t et atteint la valeur maximale avant la fin du poste pour les politiques les plus productives. L'agent ne reçoit pas explicitement l'identité du camion pour lequel il décide : il peut la déduire de la composante « temps avant disponibilité », nulle pour ce camion.

[EXPÉRIENCE À FAIRE : supprimer ou corriger les composantes constantes (statut, positions jamais occupées, distances fixes) et revoir la normalisation du tonnage avant

les nouveaux entraînements (rapport d'audit, N1 à N3).]

Table 3 – Composition du vecteur d'état (N : nombre de camions).[M1, N1, N2]

Bloc	Taille	Contenu et normalisation
Pelles	3	temps restant avant que chaque pelle soit libre, divisé par 480 min
Verses	2	temps restant avant que chaque verse soit libre, divisé par 480 min
Camions	$4N$	statut / 5 (constant, voir le texte) ; temps avant disponibilité / 480 ; tonnage cumulé / 2 000 ; carburant cumulé / 500
Positions	$7N$	position de chaque camion codée sur les 7 nœuds du graphe (seuls le parc et les pelles sont occupés)
Camion courant	3	distance du camion qui décide à chaque pelle, divisée par 10 km
Pelles–verses	6	distance de chaque pelle à chaque verse, divisée par 10 km (constante)
Temps	1	temps écoulé dans le poste, divisé par 480 min
Total	$15 + 11N$	147 pour $N = 12$; 213 pour $N = 18$

5.4.2 Espace d'actions

L'action A_t est demandée chaque fois qu'un camion devient disponible. Chaque action code une affectation de cycle complète : un couple pelle–verse $(\text{Pelle}_j, \text{Verse}_k)$, ou une action d'attente (ATTENDRE). Avec $S = 3$ pelles et $D = 2$ verses :

$$|A| = S \times D + 1 = 7, \quad A_t \in \{0, 1, \ldots, 6\}, \tag{2}$$

où l'action $a \in \{0, \ldots, 5\}$ correspond à $\text{Pelle}_{\lfloor a/D \rfloor}$ et $\text{Verse}_{a \bmod D}$. L'action 6 immobilise le camion jusqu'au prochain événement du système (libération d'un camion, d'une pelle ou d'une verse), dans la limite de 5 minutes et pendant au moins 0,2 minute.[M11]

5.4.3 Fonction de transition et actualisation

La fonction de transition $P(S_{t+1} \mid S_t, A_t)$ est définie implicitement par le simulateur : temps de trajet, durées de chargement et de déversement, dégradation des pistes et pannes. La même action prise dans le même état peut donc conduire à des états successeurs différents.
[M9] Le facteur d'actualisation $\gamma = 0{,}99$ est appliqué à chaque décision, comme dans l'implémentation standard de Stable-Baselines3, et non à chaque minute simulée. L'intervalle moyen entre deux décisions dépend de la politique et de la taille de la flotte : avec l'Affectation fixe, il vaut 1,96 min avec 12 camions et 1,36 min avec 18 camions. L'horizon effectif $1/(1-\gamma) = 100$ décisions correspond donc à environ 196 min en conditions nominales et 136 min en forte charge. Une actualisation en temps continu, de la forme $\gamma^{\Delta t}$ [7, 39], rendrait cet horizon indépendant de la taille de la flotte ; elle n'a pas été retenue ici, et ce choix est discuté comme une limite. Enfin, un agent unique décide successivement pour tous les camions ; la récompense de chaque décision porte sur le cycle du camion concerné, à l'exception du terme d'équilibre, qui dépend de l'état de toutes les pelles. L'attribution du mérite d'une décision à un camion particulier n'est donc pas explicite.

Table 4 – Composantes du processus de décision semi-markovien.

Composante	Notation	Description
Environnement	$\mathcal{E}$	Simulateur piloté par les événements : 3 pelles, 2 verses, N camions, poste de 480 min (Table 2).[M11]
État	$S_t \in [0,1]^{15+11N}$	Files aux pelles et aux verses, disponibilité, tonnage, carburant et position des camions, distances, temps du poste (Table 3).[M1]
Action	$A_t \in \{0,\dots,6\}$	Affectation à l'un des 6 couples pelle–verse ou ATTENDRE (indice 6).
Transition	$P(S_{t+1} \mid S_t, A_t)$	Simulateur stochastique : trajets log-normaux, chargements et déversements, dégradation des pistes, pannes.
Récompense	R_t	Production, équilibre des pelles, distance parcourue et attente (Eq. (3)).
Actualisation	$\gamma = 0{,}99$	Appliquée à chaque décision ; horizon effectif d'environ 100 décisions.[M9]

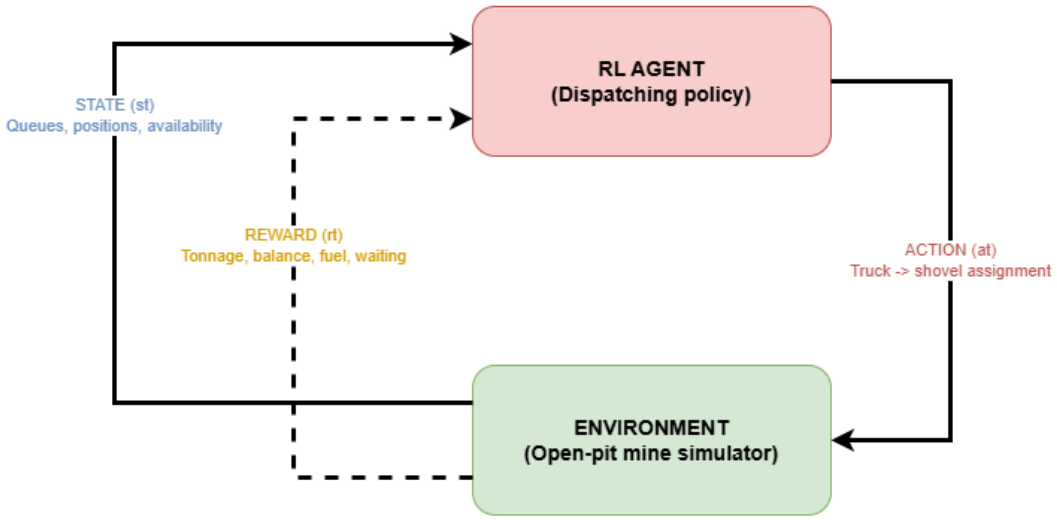


Figure 3 – Formulation du problème de dispatching de camions sous forme de processus de décision.

Fichier renommé `mdp_formulation.png` ; son contenu est déjà en anglais.[m6]

5.5 Fonction de récompense multi-objectif

[M10] L'objectif de l'agent est de maximiser la récompense cumulée sur un poste. La récompense associée à la décision prise à l'instant t pour le camion i vaut :

$$R_t = w_1\, r_t^{\text{prod}} - w_2\, p_t^{\text{éq}} - w_3\, c_t^{\text{dist}} - w_4\, p_t^{\text{att}}, \tag{3}$$

avec $w_1 = 1$, $w_2 = 0{,}1$, $w_3 = 0{,}05$ et $w_4 = 0{,}3$, et où :

— $r_t^{\text{prod}} = q_t/Q$ est la production du cycle décidé, rapportée à la capacité $Q = 140$ t ; elle vaut 1 si ce cycle se termine avant la fin du poste et 0 sinon ;

— $p_t^{\text{éq}} = \frac{1}{100}\,\mathrm{Var}_j(\omega_j(t))$ pénalise le déséquilibre entre pelles, où $\omega_j(t)$ est le temps restant, en minutes, avant que la pelle j soit libre au moment de la décision ;

— $c_t^{\text{dist}} = \big(d(x_i, j) + d(j, k) + d(k, j)\big)/5$ est la distance du cycle en kilomètres, divisée par 5, où x_i est la position du camion, j la pelle et k la verse choisies ;

— $p_t^{\text{att}} = \min\left((W_t^{\text{pelle}} + W_t^{\text{verse}})/30\,;\,1\right)$ pénalise l'attente en file du cycle, en minutes, divisée par 30 et plafonnée à 1.

Pour l'action ATTENDRE, $r_t^{\text{prod}} = 0$, $c_t^{\text{dist}} = 0$ et $p_t^{\text{att}} = \min(\delta_t/30\,;\,1)$, où δ_t est la durée de l'attente. La récompense est attribuée au moment de la décision, puisque le cycle correspondant est simulé en entier à cet instant. Avec ces normalisations, la récompense cumulée d'un poste est proche du nombre de cycles terminés, diminué principalement du coût de distance : pour l'Affectation fixe en conditions nominales, 233 cycles donnent une récompense de 210,7, dont −19,2 pour la distance, −2,7 pour l'attente et −0,1 pour l'équilibre. Cela explique l'ordre de grandeur des récompenses rapportées dans le Table 9.

Les poids privilégient la production tout en conservant une pénalité d'attente. La sensibilité des agents à w_4 est examinée dans l'étude d'ablation (Section 7.9).

5.6 Agents d'apprentissage étudiés

5.6.1 Proximal Policy Optimization

PPO [33] est un algorithme acteur–critique qui optimise directement la politique. Son objectif utilise une fonction de substitution écrêtée afin d'éviter des mises à jour de politique trop importantes :

$$L^{\text{CLIP}}(\theta) = \hat{\mathbb{E}}_t\Big[\min\left(r_t(\theta)\hat{A}_t,\ \text{clip}(r_t(\theta), 1-\epsilon, 1+\epsilon)\hat{A}_t\right)\Big], \qquad r_t(\theta) = \frac{\pi_\theta(a_t \mid s_t)}{\pi_{\theta_{\text{old}}}(a_t \mid s_t)}, \tag{4}$$

où l'avantage $\hat{A}_t$ est estimé par la méthode d'estimation généralisée de l'avantage (Generalized Advantage Estimation, GAE) [32].[Bibliographie] L'acteur et le critique sont deux perceptrons multicouches distincts comportant chacun deux couches cachées de 128 neurones et une activation tangente hyperbolique, valeur par défaut de Stable-Baselines3 pour PPO ; la couche de sortie de l'acteur définit une distribution sur les 7 actions.

[M12] Les hyperparamètres sont rassemblés dans le Table 5. Ils reprennent pour l'essentiel les valeurs par défaut de Stable-Baselines3 et les réglages usuels de PPO [33], à l'exception du coefficient d'entropie (0,02), retenu à l'issue d'essais préliminaires décrits dans la Section 7.9. La taille de lot (64) équilibre la stabilité du gradient et le temps de calcul ; l'horizon $n_{\text{steps}} = 1\,024$ fixe la longueur des déroulements utilisés pour chaque mise à jour ; le paramètre $\lambda = 0{,}95$ réduit la variance des estimations d'avantage ; la plage d'écrêtage de 0,2 limite l'écart entre deux politiques successives. Les budgets d'entraînement sont exprimés dans des unités différentes : les méthodes tabulaires sont entraînées pendant 30 000 épisodes, chaque épisode comptant environ 200 à 250 décisions, et les agents profonds pendant 2 millions de décisions. Les deux budgets ne sont pas directement comparables.

Table 5 – Hyperparamètres des algorithmes d'apprentissage.

Hyperparamètre	PPO	DQN	Tabulaire (Q / SARSA)
Architecture du réseau	MLP [128, 128]	MLP [128, 128]	Table Q (6 var., 8 int.)[M8]
Fonction d'activation	Tanh[a]	ReLU[a]	s.o.
Taux d'apprentissage α	3×10^{-4}	3×10^{-4}	0,2
Taille de lot	64	64	s.o.
n_{steps} / horizon	1 024	s.o.	s.o.
n_{epochs} par déroulement	10	s.o.	s.o.
GAE λ	0,95	s.o.	s.o.
Plage d'écrêtage ϵ	0,2	s.o.	s.o.
Coefficient d'entropie	0,02	s.o.	s.o.
Facteur d'actualisation γ	0,99	0,99	0,99
Taille du tampon de rejeu	s.o.	200 000	s.o.
Début de l'apprentissage (échauffement)	s.o.	1 000	s.o.
Mise à jour du réseau cible	s.o.	tous les 1 000 pas	s.o.
Exploration (ε-greedy)	s.o.	1,0 → 0,02 (fraction de 30 %)	1,0 → 0,01 (linéaire)
Pas / épisodes d'entraînement totaux	2 000 000 pas	2 000 000 pas	30 000 épisodes

[a] Valeur par défaut de la bibliothèque SB3 : Tanh pour les algorithmes on-policy (PPO) ; ReLU pour les algorithmes off-policy (DQN).

5.6.2 Deep Q-Network

DQN [20] approxime la fonction de valeur action $Q(s, a)$ par un réseau de neurones, et stabilise l'apprentissage par un tampon de rejeu d'expériences et un réseau cible mis à jour périodiquement. La mise à jour vise la cible[Bibliographie, M14]

$$y = r + \gamma \max_{a'} Q_{\theta^-}(s', a'). \tag{5}$$

Le réseau comporte deux couches cachées de 128 neurones avec une activation ReLU. L'exploration suit une stratégie ε-gloutonne dont le taux décroît linéairement de 1,0 à 0,02 sur les 30 % premiers pas d'entraînement.

5.6.3 Agents tabulaires : Q-Learning et SARSA

[M8] Q-Learning [45] et SARSA [31] stockent une valeur pour chaque couple état–action dans une table. L'état complet étant trop grand pour une table, il est réduit à six variables : les temps d'attente estimés aux 3 pelles et aux 2 verses, multipliés par 50 puis découpés en 8 intervalles (ce qui sature au-delà d'environ 9,6 min), et l'indice de la pelle la plus proche du camion qui décide. L'espace discrétisé compte donc $8^5 \times 3 = 98\,304$ états, dont environ 17 000 sont visités pendant l'entraînement ; lors de l'évaluation, tous les états rencontrés figurent dans la table. Lorsqu'un état est absent de la table, l'action 0 est jouée par défaut. Cette représentation ne dépend pas du nombre de camions, ce qui permet d'évaluer les agents tabulaires sans réentraînement en forte charge.

Q-Learning met à jour la valeur de l'action à partir de la meilleure action suivante (méthode hors politique), tandis que SARSA utilise l'action effectivement choisie ensuite (méthode sur politique) :

$$Q(s, a) \leftarrow Q(s, a) + \alpha\big[r + \gamma Q(s', a') - Q(s, a)\big]. \tag{6}$$

Les deux agents utilisent $\alpha = 0{,}2$, $\gamma = 0{,}99$ et une exploration ε-gloutonne décroissant linéairement de 1,0 à 0,01 sur 30 000 épisodes. La comparaison entre agents tabulaires et profonds doit donc être lue avec la représentation et le budget de calcul retenus ici.

Les Algorithmes 1, 2 et 3 formalisent les méthodes d'apprentissage sous forme de pseudocode ; la ligne qui distingue SARSA de Q-Learning est indiquée à la fin de l'Algorithme 3.

Algorithm 1 PPO pour le dispatching de camions miniers

Entrée : Environnement minier $\mathcal{E}$; acteur π_θ et critique V_ϕ (MLP $[128, 128]$, Tanh)
Entrée : α=3×10^{-4}, γ=0,99, λ_{GAE}=0,95, ϵ_{clip}=0,2, N=1024, $T_{\max}$=2×10^{6}

Initialiser θ, ϕ aléatoirement
for $k = 1, 2, \ldots, \lfloor T_{\max}/N \rfloor$ **do**
  for $t = 1, \ldots, N$ **do** ▷ Collecter le déroulement
    Observer s_t (Table 3)
    Échantillonner $a_t \sim \pi_\theta(\cdot \mid s_t)$, $a_t \in \{0, \ldots, 6\}$ (couple pelle–déversement ou WAIT)
    Exécuter a_t ; recevoir $r_t = w_1 R_{\text{prod}} - w_2 P_{\text{imb}} - w_3 C_{\text{op}} - w_4 P_{\text{wait}}$, s_{t+1}
    Stocker $(s_t,\ a_t,\ r_t,\ s_{t+1},\ \log \pi_\theta(a_t \mid s_t))$
  end for
  Calculer les avantages : $\hat{A}_t = \sum_{l \geq 0} (\gamma \lambda_{\text{GAE}})^l \, \delta_{t+l}$, $\delta_t = r_t + \gamma V_\phi(s_{t+1}) - V_\phi(s_t)$
  for chaque époque, mini-lots de taille 64 **do**
    $r_t(\theta) \leftarrow \pi_\theta(a_t \mid s_t) / \pi_{\theta_k}(a_t \mid s_t)$
    Maximiser $L^{\text{CLIP}}(\theta) = \mathbb{E}\big[\min\big(r_t \hat{A}_t,\ \text{clip}(r_t, 1{-}\epsilon_{\text{clip}}, 1{+}\epsilon_{\text{clip}}) \hat{A}_t\big)\big]$
    Minimiser $L^V(\phi) = \mathbb{E}\big[(V_\phi(s_t) - R_t^{\text{target}})^2\big]$
  end for
end for
Sortie : Politique entraînée π_θ^*

Algorithm 2 DQN pour le dispatching de camions miniers

Entrée : $\mathcal{E}$; réseaux Q_θ, Q_{θ^-} (MLP $[128, 128]$, ReLU) ; tampon de rejeu $\mathcal{B}$ (200 000)
Entrée : α=3×10^{-4}, γ=0,99, ε: 1,0 → 0,02 (linéaire sur 30 % des pas)

Initialiser θ aléatoirement ; $\theta^- \leftarrow \theta$; $\mathcal{B} \leftarrow \emptyset$
for chaque pas de temps $t = 1, 2, \ldots, T_{\max}$ **do**
  Avec prob. ε : $a_t \sim \text{Uniform}(\mathcal{A})$; sinon $a_t \leftarrow \arg\max_a Q_\theta(s_t, a)$
  Exécuter a_t ; observer r_t, s_{t+1} ; stocker (s_t, a_t, r_t, s_{t+1}) dans $\mathcal{B}$
  Échantillonner un mini-lot $\{(s_i, a_i, r_i, s_i')\}$ depuis $\mathcal{B}$
  $y_i \leftarrow r_i + \gamma \max_{a'} Q_{\theta^-}(s_i', a')$ ▷ Cible de Bellman via le réseau gelé
  Minimiser $\frac{1}{B} \sum_i \big(Q_\theta(s_i, a_i) - y_i\big)^2$
  if $t \bmod 1000 = 0$ **then** $\theta^- \leftarrow \theta$
  end if ▷ Synchroniser le réseau cible
end for
Sortie : $\pi(s) = \arg\max_a Q_\theta(s, a)$

Algorithm 3 Q-Learning pour le dispatching de camions miniers (référence tabulaire)

Entrée : $\mathcal{E}$; α=0,2, γ=0,99, ε: 1,0 → 0,01 (linéaire sur 30 000 épisodes)

Initialiser $Q(s,a) \leftarrow 0$ pour tout (s,a) (état réduit à 6 variables, 8 intervalles)
for épisode $= 1, \ldots, 30\,000$ **do**
    $s_0 \leftarrow \texttt{reset}(\mathcal{E})$
    while l'épisode n'est pas terminé **do**
        Avec prob. ε : $a_t \sim \text{Uniform}(\mathcal{A})$; sinon $a_t \leftarrow \arg\max_a Q(s_t, a)$
        Exécuter a_t ; observer r_t, s_{t+1}
        $Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha\big[r_t + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t)\big]$
        $s_t \leftarrow s_{t+1}$
    end while
    Décroître ε linéairement
end for

Sortie : $\pi^*(s) = \arg\max_a Q(s,a)$

Note (SARSA) : remplacer $\max_{a'} Q(s_{t+1}, a')$ par $Q(s_{t+1}, a_{t+1})$ pour des mises à jour on-policy.

5.7 Heuristiques de référence

[M25, M16, Dir. corr. 1, A] Les quatre règles de référence sont définies dans le Table 6 telles qu'elles sont implémentées. Deux propriétés de ces implémentations sont importantes pour l'interprétation des résultats. D'une part, la règle appelée FIFO choisit la pelle qui sera libre le plus tôt : elle tient donc compte des files d'attente, mais pas des temps de trajet, ce qui conduit les camions à changer fréquemment de pelle. D'autre part, comme un cycle se termine à la pelle qui vient d'être servie, la Pelle la plus proche est toujours celle où se trouve déjà le camion. Au début du poste, tous les camions partent du parc, d'où la pelle 1 est la plus proche ; la Pelle la plus proche affecte donc toute la flotte à la pelle 1 pendant tout le poste, et le Plus court chemin aboutit au même résultat. Ces deux règles constituent ainsi des bornes basses plutôt que des représentants de la pratique industrielle, qui utilise des règles tenant compte des files et des temps de trajet, telles que le temps d'attente minimal des camions, ou une couche d'optimisation linéaire en amont [47, 35, 34].

[EXPÉRIENCE À FAIRE : ajouter au moins une règle tenant compte des files et des trajets, telle que le temps d'attente minimal des camions, et une politique fondée sur un programme linéaire de taux de flux cibles (M25).]

[À VALIDER AVEC LA DIRECTRICE : conserver Pelle la plus proche et Plus court chemin comme bornes basses, ou les corriger (par exemple calcul de la distance depuis la verse) et relancer l'évaluation.]

Table 6 – Définition des heuristiques de référence telles qu'implémentées.[M25, Dir. corr. 1]

Politique	Règle appliquée lorsque le camion i devient disponible
FIFO	Affecter le camion à la pelle qui sera libre le plus tôt et à la verse qui sera libre le plus tôt, indépendamment des distances.
Affectation fixe	Affecter le camion i à la pelle $i \bmod 3$ et à la verse $i \bmod 2$ pendant tout le poste, sans réaffectation.
Pelle la plus proche	Affecter le camion à la pelle la plus proche de sa position courante sur le graphe, puis à la verse la plus proche de cette pelle, sans tenir compte des files.
Plus court chemin	Affecter le camion au couple pelle–verse qui minimise le coût du cycle $C = 0{,}5\,T + 0{,}3\,D + 0{,}2\,E$, où T, D et E sont le temps moyen, la distance et la consommation des trajets camion–pelle, pelle–verse et verse–pelle, calculés par l'algorithme de Dijkstra.

5.8 Architecture du système et coût de calcul

L'architecture découple la logique d'apprentissage de la simulation, ce qui permet de tester différents agents de manière interchangeable (Fig. 4). L'agent sélectionne une action a_t à partir de l'état s_t ; l'environnement applique l'affectation et renvoie l'état suivant et la récompense ; le module d'évaluation calcule les indicateurs pour les huit politiques dans les trois régimes.

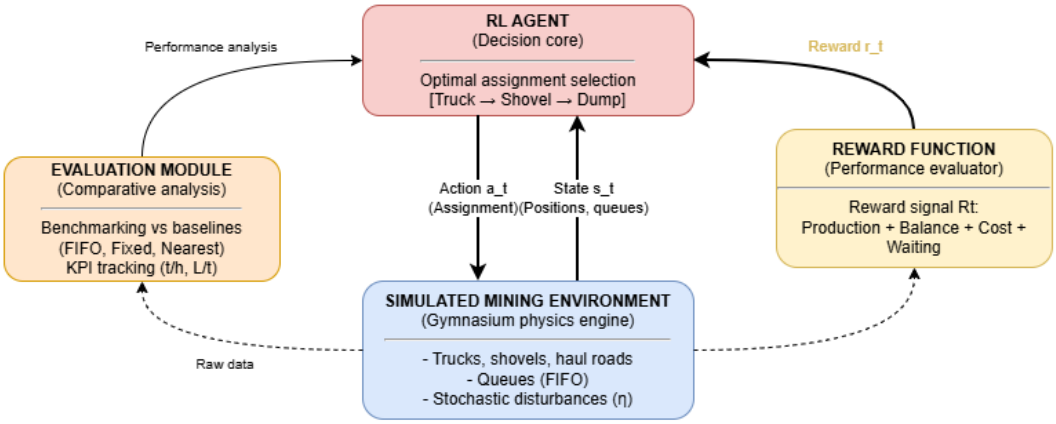


Figure 4 – Boucle d'interaction entre l'agent et l'environnement.

Fichier renommé `functional_architecture.png` ; son contenu est déjà en anglais.[m6]
[M28, m20, m24]

— **Entraînement :** sur le processeur d'un ordinateur portable standard, un entraînement de 2 millions de pas dure environ 2 h 15 min pour PPO et 1 h 52 min pour DQN, avec un seul environnement simulé. Les méthodes tabulaires sont plus rapides, faute de rétropropagation dans un réseau de neurones. L'entraînement est déterministe pour une graine donnée : relancer un entraînement avec la même graine reproduit exactement le même comportement de l'agent.

— **Évaluation :** le banc d'essai principal comprend $8 \times 3 \times 30 = 720$ épisodes indépendants, exécutés séquentiellement. Comme chaque réplication est indépendante, l'évaluation se prête directement à une exécution parallèle, de même que les entraînements de graines différentes.

— **Inférence :** la latence d'une décision, mesurée sur l'appel de la politique de Stable-Baselines3 et sans la construction de l'état, est d'environ 10 millisecondes, valeur maximale inférieure à 20 millisecondes. Ce temps est dominé par la conversion des données et non par le réseau lui-même ; il est faible devant la durée d'un cycle de transport, mais son adéquation aux contraintes d'un système de gestion de flotte commercial n'a pas été évaluée.

— **Mémoire :** les fichiers des modèles entraînés occupent moins de 1,2 Mo.

[EXPÉRIENCE À FAIRE : mesurer le temps total de calcul, le gain obtenu en parallélisant réplications et entraînements, et l'évolution du temps par décision avec la taille de la flotte, pour la dimension calcul attendue par Cluster Computing (M28).]

[À VALIDER AVEC LA DIRECTRICE : adéquation de la revue cible (Cluster Computing) si la dimension calcul reste limitée (M28).]

6 Plan expérimental

Cette section détaille les régimes de fonctionnement, le protocole d'entraînement et d'évaluation, les indicateurs et le cadre statistique.

6.1 Régimes de fonctionnement

Trois régimes sont définis (Table 7 and Fig. 5). Chaque épisode correspond à un poste de 8 heures (480 minutes).

[M15] Pour situer chaque régime par rapport à la capacité de chargement, nous utilisons le facteur d'appariement [8] :

$$\mathrm{MF} = \frac{N \times t_{\text{chargement}}}{S \times t_{\text{cycle}}}, \tag{7}$$

où N est le nombre de camions, S le nombre de pelles, $t_{\text{chargement}} = 2$ min la durée moyenne de chargement et $t_{\text{cycle}} \approx 22{,}7$ min la durée moyenne d'un cycle hors attente et hors panne, mesurée avec l'Affectation fixe. Un facteur inférieur à 1 indique que les pelles attendent les camions. Il vaut environ 0,35 en conditions nominales et 0,52 en forte charge : même avec 18 camions, la flotte reste en dessous de la capacité des trois pelles, qui peuvent charger ensemble environ 12 600 t/h. Le régime de forte charge augmente donc la pression sur les files, mais ne constitue pas une sursaturation de la flotte ; seule une politique qui concentre les camions sur une seule pelle peut saturer celle-ci.

Table 7 – Paramètres des trois régimes de fonctionnement.

Régime	Camions	Pelles	Verses	Pannes par cycle	MF	Caractéristique
Nominal	12	3	2	2 %	0,35[M15]	Conditions de référence
Forte charge	18	3	2	2 %	0,52[M15]	Flotte augmentée de 50 %[M15]
Fortes pannes	12	3	2	10 %	0,35[M15]	Pannes de camions fréquentes

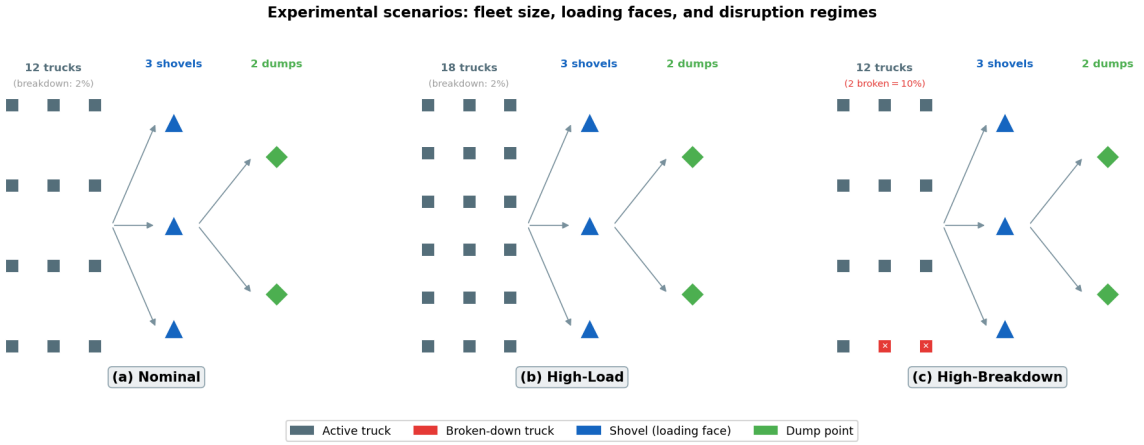


Figure 5 – Configuration des trois régimes de fonctionnement.

6.2 Protocole d'entraînement et d'évaluation

[M1, M7, m19, A] **Agents spécialisés.** Chaque agent d'apprentissage est entraîné une fois dans chaque régime, avec la graine d'entraînement 42 : 2 millions de pas pour PPO et DQN, 30 000 épisodes pour Q-Learning et SARSA. Ce choix est imposé par la représentation de l'état : sa taille dépend du nombre de camions (Section 5.4), de sorte qu'un réseau entraîné avec 12 camions ne peut pas être appliqué à une flotte de 18 camions. Les résultats principaux comparent donc, dans chaque régime, des agents entraînés dans ce régime aux quatre heuristiques.

Évaluation sans réentraînement. Pour mesurer la capacité d'une politique apprise à supporter un changement de régime, les agents entraînés en conditions nominales sont en outre évalués, sans aucun réentraînement, dans le régime de fortes pannes, dont l'état a la même taille. Les agents tabulaires, dont l'état réduit ne dépend pas du nombre de camions, sont également évalués de cette façon en forte charge. Cette évaluation n'est pas possible pour PPO et DQN en forte charge avec la représentation actuelle.

Évaluation. Toutes les politiques sont évaluées sur 30 réplications, correspondant aux graines 42 à 71. Les agents choisissent l'action de plus grande valeur, sans exploration : mode déterministe pour PPO, $\varepsilon = 0$ pour DQN et choix glouton pour les agents tabulaires. Les 30 réplications mesurent donc la variabilité due à l'environnement pour un agent entraîné donné, et non la variabilité due à l'entraînement, puisqu'une seule graine d'entraînement est utilisée par agent.

[EXPÉRIENCE À FAIRE : entraîner PPO et DQN avec 5 graines d'entraînement différentes de 42 (l'entraînement étant déterministe, la graine 42 redonne le même modèle) et rapporter moyenne interquartile et intervalles bootstrap stratifiés [3] (M7).]

[EXPÉRIENCE À FAIRE : évaluer sur des graines disjointes de celles de l'entraînement, par exemple 10 000 à 10 029 : les graines 42 à 71 correspondent aux premiers épisodes d'entraînement (rapport d'audit, M7).]

6.3 Indicateurs

[M2, M21, M15, m18] Dans cette étude, la résilience opérationnelle désigne la capacité d'une politique à conserver son débit et à contenir l'attente en file lorsque le système passe des conditions nominales à des conditions perturbées. Elle est mesurée par les indicateurs suivants, calculés pour chaque réplication.

1. **Productivité :** tonnage livré par heure (t/h), et productivité par camion (t/h/camion), qui permet de comparer des régimes dont la flotte n'a pas la même taille.
2. **Attente en file :** temps total passé par un camion en file d'attente aux pelles et aux verses pendant le poste, moyenné sur les camions (min par camion et par poste). Ce n'est pas une attente par cycle : avec environ 19 cycles par camion en conditions nominales, 22 min d'attente en file par poste correspondent à environ 1,1 min par cycle.
3. **Temps d'immobilisation total :** somme, par camion et par poste, de l'attente en file, de l'immobilisation pour panne et du temps passé à attendre volontairement par l'action ATTENDRE. C'est l'indicateur rapporté sous le nom de « temps d'attente » dans la version précédente de cet article.
4. **Utilisation des camions :** part du poste pendant laquelle les camions roulent, chargent ou déversent (%). Le temps d'activité du dernier cycle qui dépasse la fin du poste est exclu.
5. **Utilisation des pelles :** part du poste pendant laquelle les pelles chargent (%).
6. **Consommation spécifique :** carburant consommé par tonne livrée (L/t).
7. **Nombre de cycles terminés** et **récompense cumulée** avec les poids de référence.
8. **Ratio de robustesse :** rapport entre la performance dans un régime perturbé et la performance nominale :

$$\mathrm{RR}(p, s) = \frac{\mathrm{Performance}(p, s)}{\mathrm{Performance}(p, \mathrm{nominal})}. \tag{8}$$

   En forte charge, ce ratio est calculé sur la productivité par camion, faute de quoi il refléterait surtout l'ajout de camions.

6.4 Protocole statistique

[M3, M4, M5, M6, M22] **Unité statistique.** L'unité d'analyse est la réplication : chaque couple (politique, régime) fournit exactement 30 valeurs, une par graine.

Appariement. La même graine est utilisée par toutes les politiques dans une réplication donnée. Les observations sont donc appariées par graine, et les réplications sont traitées comme des blocs. Le simulateur utilise toutefois un seul générateur aléatoire pour tous les processus stochastiques : dès que deux politiques prennent des décisions différentes, elles consomment les nombres aléatoires dans un ordre différent, de sorte que les aléas ne sont pas synchronisés événement par événement. L'appariement reste justifié, puisque les productivités de deux politiques sur une même graine sont corrélées (coefficient de corrélation compris entre 0,55 et 0,82 pour les comparaisons rapportées,

à l'exception de PPO en forte charge), mais il ne garantit pas qu'une panne survienne au même instant pour toutes les politiques.

Tests. Dans chaque régime, le test de Friedman [13] vérifie l'existence d'un effet de la politique. Les comparaisons par paires utilisent le test des rangs signés de Wilcoxon [46], bilatéral, avec une correction de Holm [17] sur la famille des comparaisons rapportées dans chaque régime [10]. La dépendance du classement au régime (H2) est testée par un modèle linéaire de la productivité par camion comprenant la politique, les blocs (régime, graine) et l'interaction entre politique et régime.

Tailles d'effet et intervalles. Les différences sont rapportées en unités physiques, avec un intervalle de confiance bootstrap apparié à 95 % (10 000 rééchantillonnages des différences par graine) [11]. Le d de Cohen est rapporté à titre descriptif ; dans un simulateur, la variabilité entre réplications est faible, si bien qu'un d élevé ne signifie pas un effet pratique important. Les valeurs p inférieures à 0,001 sont rapportées sous la forme $p < 0{,}001$; avec 30 paires, la plus petite valeur atteignable par le test de Wilcoxon est d'environ 2×10^{-9}.

6.5 Paramètres de reproductibilité

[M3, A] La simulation est implémentée en Python 3.11.11 avec Gymnasium 1.2.3 [42], Stable-Baselines3 2.8.0 [29] et PyTorch 2.5.1, sur processeur. Les poids de récompense ($w_1 = 1$, $w_2 = 0{,}1$, $w_3 = 0{,}05$, $w_4 = 0{,}3$) sont constants dans toutes les expériences, sauf dans l'étude d'ablation. Les résultats par réplication, à raison d'une ligne par politique, régime et graine, sont fournis avec le code. Une version antérieure de l'analyse statistique avait été calculée sur un fichier de résultats dans lequel chaque réplication figurait deux fois, par suite de deux exécutions successives du banc d'essai ; toutes les valeurs p, tous les intervalles et tous les tests de cette version sont recalculés sur les 30 réplications uniques.

[À VALIDER AVEC LA DIRECTRICE : la phrase sur la version antérieure de l'analyse est utile pour la directrice ; la retirer de la version soumise.]

[À VALIDER AVEC LA DIRECTRICE : vérifier que DQN (modèles enregistrés fin mai 2026) a été entraîné avec la même version de la récompense que PPO (début août 2026) ; sinon, réentraîner DQN (rapport d'audit, N11).]

7 Résultats

Cette section présente la productivité, l'attente, le comportement des politiques, les compromis entre ces critères, la robustesse et le transfert sans réentraînement, puis la significativité statistique, la variabilité, la convergence et l'étude d'ablation. Toutes les statistiques sont calculées sur les 30 réplications uniques de chaque couple (politique, régime).[M3]

7.1 Productivité

Le Table 8 rapporte la productivité moyenne des huit politiques dans les trois régimes, ainsi que la productivité par camion. Les consommations de carburant figurent dans le Table 19.[m16]

Table 8 – Productivité (moyenne ± écart-type sur 30 réplications) et productivité par camion. N : nominal ; FC : forte charge ; FP : fortes pannes.

	Productivité (t/h)			Par camion (t/h/camion)[M15]		
Politique	**N**	**FC**	**FP**	**N**	**FC**	**FP**
FIFO	3 285,9 ± 41	4 754,8 ± 63	3 117,9 ± 62	273,8	264,2	259,8
Affectation fixe	4 071,7 ± 43	**5 873,6 ± 76**	3 818,5 ± 67	339,3	**326,3**	318,2
Pelle la plus proche	3 824,9 ± 67	3 948,0 ± 39	3 661,6 ± 67	318,7	219,3	305,1
Plus court chemin	3 868,1 ± 46	3 962,0 ± 38	3 692,5 ± 59	322,3	220,1	307,7
Q-Learning	3 586,3 ± 99	4 769,3 ± 102	3 180,9 ± 92	298,9	265,0	265,1
SARSA	3 085,3 ± 62	4 044,8 ± 76	2 980,8 ± 78	257,1	224,7	248,4
DQN	4 134,7 ± 68	5 651,3 ± 74	**3 949,2 ± 72**	344,6	314,0	**329,1**
PPO	**4 176,7 ± 64**	5 149,1 ± 325	3 899,6 ± 85	**348,1**	286,1	325,0

[M15, M16, m12] En conditions nominales, PPO obtient la productivité la plus élevée (4 177 t/h), devant DQN (4 135 t/h) et l'Affectation fixe (4 072 t/h). En forte charge, l'Affectation fixe est en tête (5 874 t/h), devant DQN (5 651 t/h) et PPO (5 149 t/h), dont la productivité varie fortement d'une réplication à l'autre. En fortes pannes, DQN est en tête (3 949 t/h), devant PPO (3 900 t/h) et l'Affectation fixe (3 819 t/h). Pelle la plus proche et Plus court chemin restent entre 3 660 et 3 960 t/h dans les trois régimes : comme elles concentrent toute la flotte sur la pelle 1 (Section 7.3), leur productivité est plafonnée par la capacité d'une seule pelle, d'environ 4 200 t/h.

Ramenée au nombre de camions, la productivité baisse pour toutes les politiques entre les conditions nominales et la forte charge. La baisse est faible pour l'Affectation fixe (−3,8 %) et FIFO (−3,5 %), plus marquée pour DQN (−8,9 %) et PPO (−17,8 %), et maximale pour les deux règles fondées sur la distance (−31 %).

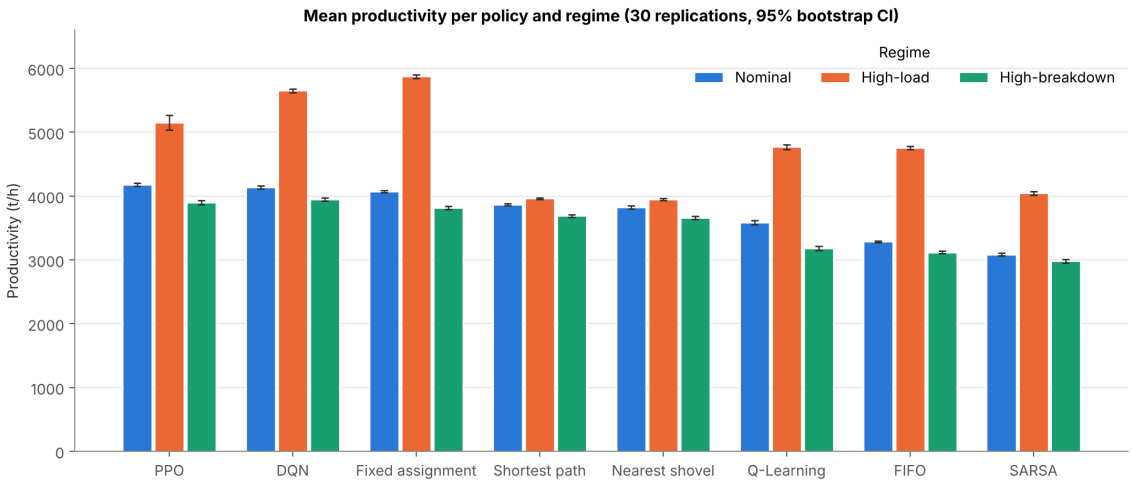


Figure 6 – Productivité moyenne par politique et par régime. Les barres d'erreur indiquent les intervalles de confiance bootstrap à 95 % sur les 30 réplications uniques.

Figure régénérée à partir des 30 réplications uniques.[M3]

Le Table 9 rapporte le nombre de cycles terminés et la récompense cumulée. Le classement selon la récompense cumulée coïncide avec celui de la productivité en conditions nominales et en fortes pannes ; en forte charge, deux paires sont inversées (FIFO et Q-Learning, Pelle la plus proche et Plus court chemin).[M18] La faible récompense de Pelle la plus proche et de Plus court chemin en forte charge (161,4 et 160,5) reflète à la fois un nombre de cycles plus faible et les pénalités d'attente et de déséquilibre entre pelles.

Table 9 – Nombre moyen de cycles terminés et récompense cumulée par politique et par régime, sur 30 réplications (N : nominal, FC : forte charge, FP : fortes pannes).

Politique	Cycles terminés			Récompense cumulée		
	N	**FC**	**FP**	**N**	**FC**	**FP**
FIFO	187,8	271,7	178,2	163,1	234,0	155,0
Affectation fixe	232,7	**335,6**	218,2	210,7	**301,3**	197,7
Pelle la plus proche	218,6	225,6	209,2	193,0	161,4	185,7
Plus court chemin	221,0	226,4	211,0	194,7	160,5	187,0
Q-Learning	204,9	272,5	181,8	178,9	230,6	155,6
SARSA	176,3	231,1	170,3	147,3	179,7	143,2
DQN	236,3	322,9	**225,7**	213,8	288,9	**204,4**
PPO	**238,7**	294,2	222,8	**216,6**	253,0	201,5

7.2 Attente en file et immobilisation

[M2, M17, m13, m14] Le Table 10 distingue l'attente en file, qui mesure la congestion, du temps d'immobilisation total, qui y ajoute les pannes et l'attente volontaire. Les deux indicateurs sont exprimés en minutes par camion et par poste.

En conditions nominales, l'Affectation fixe présente l'attente en file la plus faible (22,2 min par camion et par poste, soit environ 1,1 min par cycle), suivie de PPO (24,5 min) et de FIFO (27,1 min). En forte charge, DQN présente l'attente en file la plus faible (31,6 min), devant l'Affectation fixe (35,6 min), PPO (38,2 min) et FIFO (39,6 min). Les deux règles fondées sur la distance atteignent environ 195 à 199 min de file, car toute la flotte attend devant la même pelle. Le temps d'immobilisation total de PPO en forte charge (99,3 min) provient pour plus de la moitié d'attentes volontaires : PPO choisit l'action ATTENDRE dans 87 % de ses décisions et cumule ainsi 54,7 min d'attente volontaire par camion, contre 38,2 min de file et 6,4 min de panne.

En fortes pannes, l'attente en file diminue pour la plupart des politiques par rapport aux conditions nominales, puisque moins de camions sont disponibles en même temps. L'augmentation du temps d'immobilisation total dans ce régime provient essentiellement des réparations, de 30 à 38 min par camion et par poste selon la politique, et non de la congestion.

Table 10 – Attente en file et temps d'immobilisation total, en minutes par camion et par poste (moyenne ± écart-type de l'attente en file sur 30 réplications). Immobilisation totale = attente en file + panne + attente volontaire (action ATTENDRE).[M2]

Politique	Nominal		Forte charge		Fortes pannes	
	File	**Totale**	**File**	**Totale**	**File**	**Totale**
FIFO	27,1 ± 3,4	33,5	39,6 ± 3,2	45,2	23,4 ± 2,9	55,1
Affectation fixe	**22,2 ± 2,3**	**29,4**	35,6 ± 3,2	**43,2**	**19,5 ± 2,2**	57,2
Pelle la plus proche	68,3 ± 6,9	75,1	194,6 ± 9,4	199,6	57,0 ± 5,8	93,8
Plus court chemin	69,8 ± 6,5	76,6	199,3 ± 7,2	204,3	57,6 ± 5,5	94,7
Q-Learning	52,6 ± 5,9	58,1	63,8 ± 3,7	69,3	56,6 ± 4,7	87,9
SARSA	62,0 ± 6,0	68,2	114,2 ± 12,1	119,9	49,1 ± 5,5	81,8
DQN	29,0 ± 3,7	43,7	**31,6 ± 2,5**	47,8	29,7 ± 3,0	71,8
PPO	24,5 ± 2,7	33,5	38,2 ± 6,1	99,3	23,9 ± 3,5	69,9

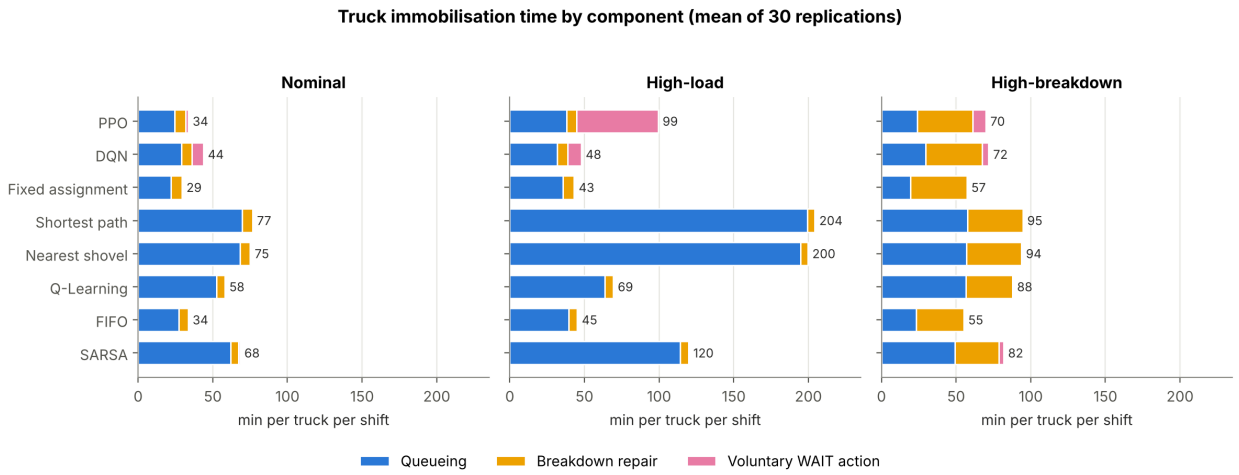


Figure 7 – Décomposition du temps d'immobilisation des camions en attente en file, réparation après panne et attente volontaire (action ATTENDRE), en minutes par camion et par poste, pour les huit politiques et les trois régimes (moyennes sur 30 réplications).[M2]

7.3 Comportement d'affectation des politiques

[M16, C3] Le Table 11 décrit, sur les 30 réplications, la répartition des cycles entre les trois pelles et la part des décisions consacrées à l'action ATTENDRE. Il explique plusieurs des écarts observés.

— Pelle la plus proche et Plus court chemin réalisent 100 % de leurs cycles à la pelle 1, dans les trois régimes. La pelle 1 charge alors presque en permanence, tandis que les deux autres restent inutilisées. La congestion de ces deux règles n'est donc pas propre à la forte charge : elle existe dans tous les régimes et s'aggrave avec le nombre de camions qui attendent devant la même pelle.

— FIFO et l'Affectation fixe répartissent les cycles presque uniformément entre les pelles. L'Affectation fixe y parvient sans changer les camions de pelle, alors que FIFO déplace fréquemment les camions, ce qui allonge ses cycles (29,8 min contre 24,1 min en conditions nominales).

— En forte charge, PPO et DQN utilisent les trois pelles de façon équilibrée, mais choisissent très souvent d'attendre (87 % et 64 % des décisions). L'usage intensif de l'action ATTENDRE par PPO explique son temps d'immobilisation total élevé et sa grande variabilité dans ce régime.

— En fortes pannes, les deux agents profonds entraînés dans ce régime n'utilisent jamais la pelle 3, la plus éloignée, alors que les agents nominaux évalués sans réentraînement dans ce même régime utilisent les trois pelles (Section 7.5).

Table 11 – Répartition des cycles entre les pelles 1, 2 et 3 (%) et part des décisions ATTENDRE (%), moyennes sur 30 réplications.[M16]

	Nominal		Forte charge		Fortes pannes	
Politique	**P1 / P2 / P3**	**Att.**	**P1 / P2 / P3**	**Att.**	**P1 / P2 / P3**	**Att.**
FIFO	36 / 34 / 30	0	36 / 34 / 30	0	35 / 34 / 32	0
Affectation fixe	35 / 33 / 31	0	35 / 33 / 32	0	35 / 33 / 32	0
Pelle la plus proche	100 / 0 / 0	0	100 / 0 / 0	0	100 / 0 / 0	0
Plus court chemin	100 / 0 / 0	0	100 / 0 / 0	0	100 / 0 / 0	0
Q-Learning	17 / 52 / 31	0	28 / 30 / 41	1	42 / 37 / 21	0
SARSA	9 / 50 / 41	5	5 / 60 / 34	1	5 / 29 / 66	10
DQN	63 / 16 / 21	35	26 / 41 / 33	64	59 / 41 / 0	31
PPO	43 / 41 / 16	10	34 / 34 / 32	87	63 / 37 / 0	48

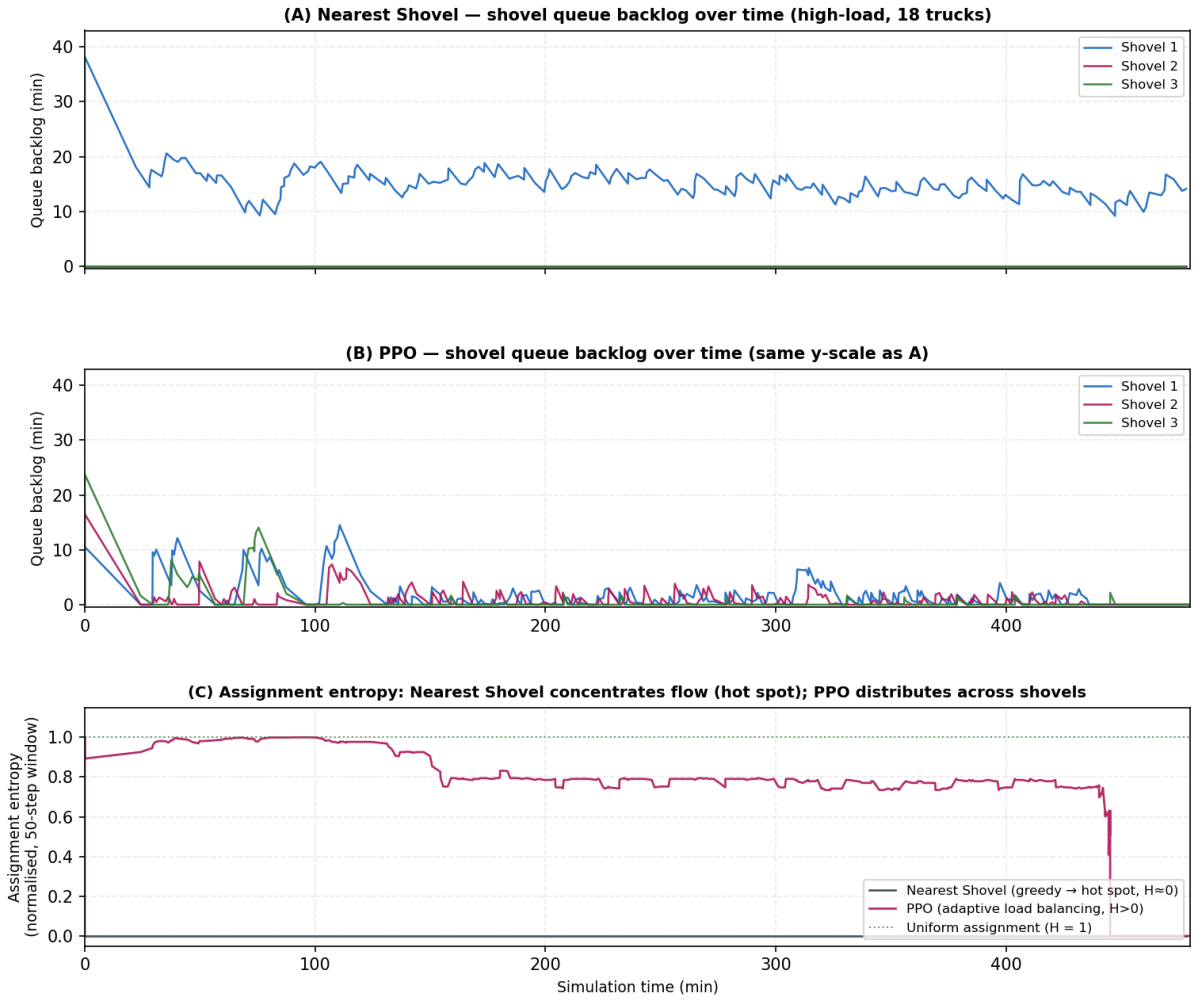


Figure 8 – Illustration sur un seul épisode (forte charge, 18 camions, graine 42) : file résiduelle aux trois pelles pour Pelle la plus proche (A) et PPO (B), et entropie de Shannon normalisée de la répartition des affectations entre pelles sur une fenêtre glissante de 50 décisions (C), où 1 correspond à une répartition uniforme. Les valeurs agrégées sur 30 réplications figurent dans le Table 11.[M16]

[FIGURE À RÉGÉNÉRER : dans le panneau (C), retirer les mentions interprétatives de la légende (« adaptive load balancing », « greedy → hot spot ») : en forte charge, PPO choisit ATTENDRE dans 87 % de ses décisions, ce que la figure ne montre pas (M16).]

7.4 Compromis entre productivité et attente en file

[M19, H3] Le Table 12 indique, pour chaque régime, les politiques non dominées au sens de Pareto lorsque l'on cherche à maximiser la productivité et à minimiser l'attente en file. Dans chaque régime, deux ou trois politiques forment le front : l'Affectation fixe et PPO en conditions nominales, l'Affectation fixe et DQN en forte charge, et DQN, PPO et l'Affectation fixe en fortes pannes. Le compromis entre les deux critères reste donc limité : les politiques les plus productives sont aussi, dans l'ensemble, celles qui attendent le moins, tandis que Pelle la plus proche et Plus court chemin sont dominées dans les trois régimes. Ces fronts sont définis à l'intérieur de chaque régime ; une comparaison entre régimes mélangerait des flottes de tailles différentes.

Table 12 – Politiques non dominées au sens de Pareto dans chaque régime (productivité maximale, attente en file minimale).[M19]

Régime	Front de Pareto
Nominal	Affectation fixe (4 072 t/h ; 22,2 min), PPO (4 177 t/h ; 24,5 min)
Forte charge	Affectation fixe (5 874 t/h ; 35,6 min), DQN (5 651 t/h ; 31,6 min)
Fortes pannes	Affectation fixe (3 819 t/h ; 19,5 min), PPO (3 900 t/h ; 23,9 min), DQN (3 949 t/h ; 29,7 min)

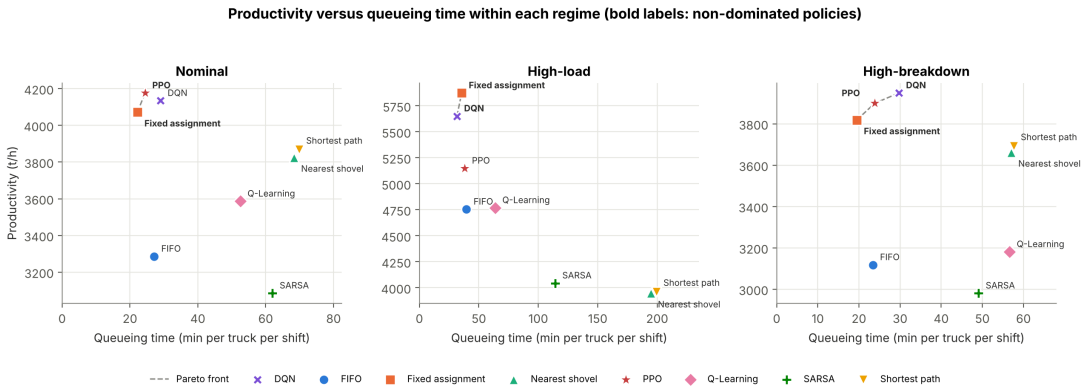


Figure 9 – Productivité en fonction de l'attente en file, dans chaque régime. Les politiques non dominées sont indiquées en gras et reliées par le front de Pareto en pointillés.[M19]

7.5 Robustesse et transfert sans réentraînement

[M1, M15, M17, QR3] Les agents d'apprentissage comparés dans chaque régime ayant été entraînés dans ce régime, les ratios de robustesse du Table 13 comparent, pour ces agents, deux modèles différents : ils mesurent la performance obtenue après adaptation, et non la capacité d'un même agent à supporter un changement de régime. Cette seconde question est traitée par l'évaluation sans réentraînement du Table 14.

L'indice d'augmentation de l'attente en file dans le régime s est défini par :

$$\Delta^{s}_{\text{file}} = \frac{W_s - W_{\text{nominal}}}{W_{\text{nominal}}} \times 100, \tag{9}$$

où W est l'attente en file moyenne par camion et par poste.

Table 13 – Robustesse par rapport aux conditions nominales. En forte charge (FC), le ratio est calculé sur la productivité par camion ; en fortes pannes (FP), sur la productivité. Les augmentations sont calculées sur l'attente en file, et, pour comparaison, sur le temps d'immobilisation total.[M15, M2, M17]

	Ratio de robustesse		Δ_{file} (%)		Immob. totale
Politique	**FC (par camion)**	**FP**	**FC**	**FP**	**FC (%)**
FIFO	**0,965**	0,949	+45,9	−13,8	+35,0
Affectation fixe	0,962	0,938	+60,5	−12,2	+47,0
Pelle la plus proche	0,688	0,957	+184,8	−16,6	+165,9
Plus court chemin	0,683	0,955	+185,4	−17,5	+166,7
Q-Learning	0,887	0,887	+21,4	+7,8	+19,4
SARSA	0,874	**0,966**	+84,2	−20,9	+75,9
DQN	0,911	0,955	**+9,1**	+2,5	**+9,3**
PPO	0,822	0,934	+56,0	−2,6	+196,4

[M15, M17, M18] En forte charge, une fois la productivité ramenée au nombre de camions, FIFO et l'Affectation fixe sont les politiques les plus robustes (ratios de 0,965 et 0,962), devant DQN (0,911) et PPO (0,822) ; les deux règles fondées sur la distance perdent près d'un tiers de leur productivité par camion. Les ratios supérieurs à 1 rapportés dans la version précédente reflétaient seulement l'ajout de 50 % de camions. Sur l'attente en file, DQN est la politique dont l'attente augmente le moins (+9,1 %), mais à partir d'un niveau nominal plus élevé que celui de l'Affectation fixe ; en valeur absolue, l'attente en file de DQN en forte charge (31,6 min) reste proche de celle de l'Affectation fixe (35,6 min). L'augmentation de 196 % du temps d'immobilisation total de PPO ne traduit pas une congestion, puisque son attente en file n'augmente que de 56 %, mais l'usage massif de l'action ATTENDRE.

En fortes pannes, toutes les politiques perdent entre 3 et 11 % de productivité. Les ratios les plus élevés de SARSA et des règles fondées sur la distance s'expliquent par leur productivité nominale déjà basse ; en valeur absolue, DQN, PPO et l'Affectation fixe restent les trois politiques les plus productives.

Table 14 – Évaluation sans réentraînement : agents entraînés en conditions nominales et évalués dans un régime perturbé, comparés aux agents entraînés dans ce régime (productivité en t/h, moyenne ± écart-type sur 30 réplications ; Δ = transféré − spécialisé, test de Wilcoxon apparié corrigé par Holm sur les six comparaisons). Référence : Affectation fixe, 3 818,5 t/h en fortes pannes et 5 873,6 t/h en forte charge.[M1, QR3]

Régime	Agent	Spécialisé	Nominal transféré	Δ (t/h)	p (Holm)
Fortes pannes	PPO	3 899,6 ± 85	3 926,4 ± 62	+26,8	0,062
	DQN	3 949,2 ± 72	3 882,1 ± 69	−67,1	< 0,001
	Q-Learning	3 180,9 ± 92	3 410,8 ± 127	+229,8	< 0,001
	SARSA	2 980,8 ± 78	2 923,1 ± 59	−57,8	0,005
Forte charge	Q-Learning	4 769,3 ± 102	4 702,3 ± 195	−67,1	0,18
	SARSA	4 044,8 ± 76	4 136,4 ± 87	+91,6	0,002

[M1, QR3] Le Table 14 montre que réentraîner les agents dans le régime perturbé n'apporte qu'un gain limité, voire aucun. En fortes pannes, l'agent PPO nominal transféré obtient une productivité au moins égale à celle de l'agent spécialisé (+26,8 t/h, différence non significative après correction), et l'agent DQN nominal transféré perd 67,1 t/h par rapport à l'agent spécialisé. Les deux agents profonds transférés restent nettement plus productifs que l'Affectation fixe (+107,9 et +63,6 t/h, $p < 0{,}001$). Leurs ratios de robustesse sont de 0,940 pour PPO et 0,939 pour DQN, contre 0,938 pour l'Affectation fixe. L'agent PPO transféré utilise les trois pelles et n'attend presque jamais (1 % des décisions), alors que l'agent spécialisé attend dans 48 % de ses décisions. Pour les agents tabulaires, les écarts entre agent transféré et agent spécialisé sont de signes variables, ce qui est cohérent avec la non-convergence de leur entraînement (Section 7.8). Ces résultats ont été obtenus en rejouant les agents nominaux, sans modification, dans le simulateur de l'étude.

[EXPÉRIENCE À FAIRE : reproduire le Table 14 avec la fonction `run_benchmark` et l'argument `model_scenario="nominal"` pour le régime de fortes pannes, et prévoir une observation de taille fixe (remplissage jusqu'à 18 camions avec masque, ou variables agrégées par pelle) pour évaluer PPO et DQN sans réentraînement en forte charge (M1).]

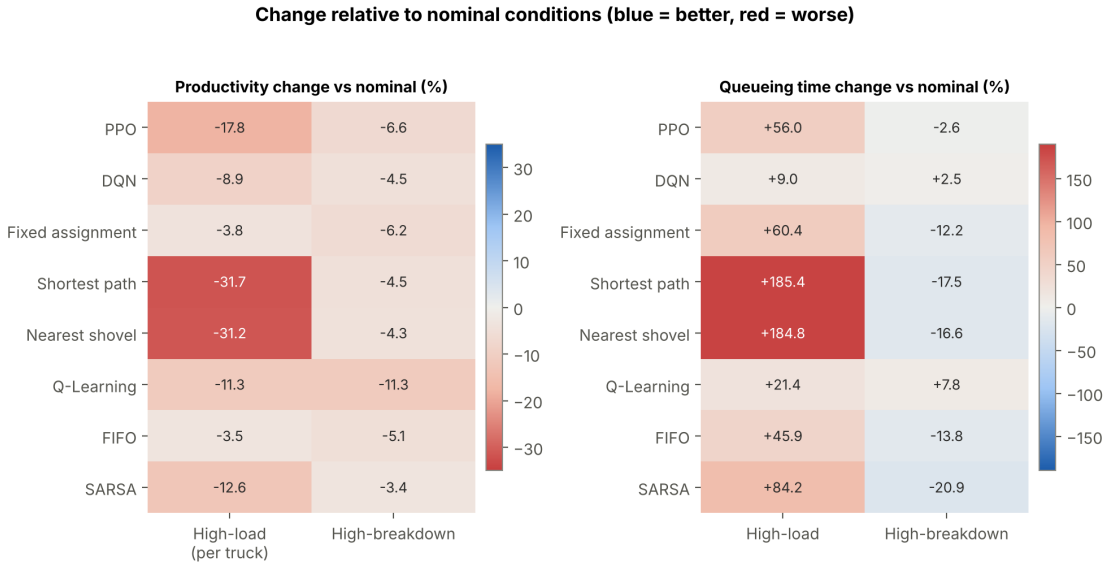


Figure 10 – Variation par rapport aux conditions nominales, en %. Gauche : productivité (par camion en forte charge). Droite : attente en file. Le bleu indique une amélioration et le rouge une dégradation.[M15, M2]

7.6 Significativité statistique

[M3, M4, M5, M6] Le test de Friedman met en évidence un effet de la politique sur la productivité dans chacun des trois régimes ($\chi^2(7) = 207{,}6$ en conditions nominales, 200,7 en forte charge et 202,6 en fortes pannes ; $p < 0{,}001$ dans les trois cas). Le modèle linéaire de la productivité par camion révèle une interaction significative entre politique et régime ($F(14, 609) = 430{,}4$, $p < 0{,}001$, $\eta_p^2 = 0{,}91$) : l'effet de la politique dépend du régime, ce qui constitue la preuve principale de l'hypothèse H2.

Le Table 15 rapporte les comparaisons par paires entre les deux agents profonds et l'Affectation fixe, meilleure heuristique dans les trois régimes, ainsi qu'entre PPO et DQN. Toutes ces différences sont significatives après correction de Holm. En particulier, l'avantage de l'Affectation fixe sur DQN en forte charge, celui de PPO sur l'Affectation fixe en fortes pannes et celui de DQN sur PPO en fortes pannes, que le test de Dunn utilisé dans la version précédente ne détectait pas, apparaissent clairement avec le test apparié. Ces comparaisons portent toutefois sur un modèle entraîné par algorithme : elles opposent deux agents entraînés, et non deux algorithmes (Section 8.5).

Table 15 – Comparaisons par paires de la productivité : différence moyenne appariée (t/h) avec intervalle de confiance bootstrap à 95 %, d de Cohen et valeur p du test de Wilcoxon apparié, bilatéral, corrigée par Holm sur les trois comparaisons de chaque régime.[M3, M4, M6]

Régime	Comparaison	Différence [IC 95 %]	d	p (Holm)
Nominal	PPO − Aff. fixe	+105,0 [88,1 ; 120,8]	1,93	< 0,001
	DQN − Aff. fixe	+63,0 [45,5 ; 81,1]	1,10	< 0,001
	PPO − DQN	+42,0 [28,6 ; 56,6]	0,64	< 0,001
Forte charge	PPO − Aff. fixe	−724,5 [−836,5 ; −606,1]	−3,07	< 0,001
	DQN − Aff. fixe	−222,2 [−242,7 ; −200,7]	−2,98	< 0,001
	PPO − DQN	−502,2 [−617,8 ; −380,9]	−2,13	< 0,001
Fortes pannes	PPO − Aff. fixe	+81,1 [54,3 ; 106,2]	1,06	< 0,001
	DQN − Aff. fixe	+130,7 [112,0 ; 148,8]	1,88	< 0,001
	PPO − DQN	−49,6 [−74,1 ; −26,3]	−0,63	< 0,001

7.7 Variabilité entre réplications d'évaluation

[M7] Le coefficient de variation de la productivité sur les 30 réplications mesure la variabilité due à l'environnement pour un agent entraîné donné. Plus court chemin présente le coefficient moyen le plus

faible sur les trois régimes (1,25 %), suivi de l'Affectation fixe (1,37 %), de FIFO (1,52 %) et de Pelle la plus proche (1,53 %). DQN est l'agent d'apprentissage le moins variable (1,59 %). PPO présente la variabilité la plus élevée (3,34 %), due presque entièrement à la forte charge (6,31 %, écart-type de 325 t/h), régime dans lequel il recourt massivement à l'action ATTENDRE. Les agents tabulaires présentent également une variabilité élevée (Q-Learning : 2,59 %, SARSA : 2,18 %). Cette analyse ne renseigne pas sur la variabilité due à l'entraînement, qui exigerait plusieurs graines d'entraînement par agent.

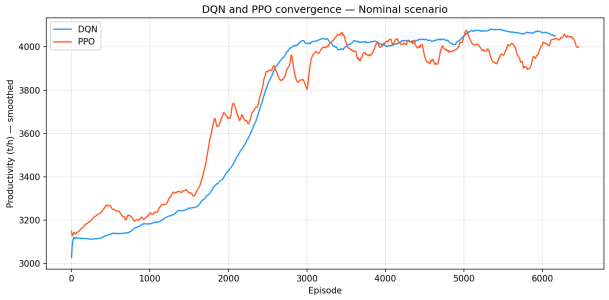
7.8 Convergence

[M7, m24] Les courbes d'entraînement des quatre agents sont présentées dans la Fig. 11. Chaque courbe correspond à un seul entraînement, lissé par une moyenne mobile ; aucune bande de confiance ne peut donc être tracée.

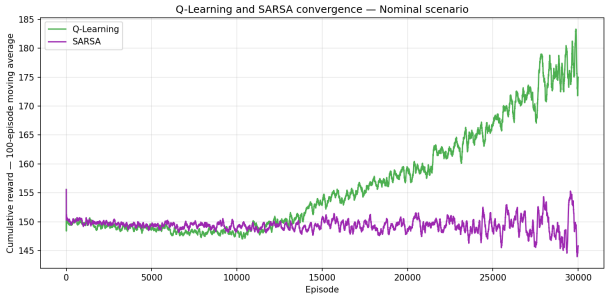
— **Agents profonds :** PPO et DQN atteignent un plateau dans leur budget de 2 millions de pas. La productivité de PPO augmente de façon monotone jusqu'à un plateau d'environ 4 000 à 4 200 t/h ; DQN présente des oscillations initiales plus importantes, liées à son exploration, avant de se stabiliser à un niveau similaire.

— **Agents tabulaires :** Q-Learning stagne pendant environ 12 000 épisodes, puis s'améliore régulièrement jusqu'à la fin du budget sans atteindre de plateau ; sa performance rapportée doit donc être lue comme une borne inférieure. SARSA ne montre pas d'amélioration mesurable sur le même budget. Ces résultats indiquent que la représentation réduite à six variables discrétisées ne suffit pas, dans le budget retenu, à apprendre une politique compétitive.

Les agents profonds et tabulaires sont tracés sur des panneaux séparés, car ils sont enregistrés sur des grandeurs différentes : la productivité pour les agents profonds, la récompense cumulée par épisode pour les agents tabulaires.



(a) Agents profonds (DQN, PPO), régime nominal



(b) Agents tabulaires (Q-Learning, SARSA), régime nominal

Figure 11 – Courbes d'entraînement dans le régime nominal, un seul entraînement par agent. Gauche : productivité des agents profonds. Droite : récompense cumulée par épisode des agents tabulaires, moyenne mobile sur 100 épisodes.

[EXPÉRIENCE À FAIRE : tracer les courbes de convergence en moyenne ± intervalle sur 5 graines d'entraînement (M7, Dir. plan).]

7.9 Étude d'ablation

[M13, A] L'étude d'ablation porte sur le poids de la pénalité d'attente w_4, les autres poids étant constants. Pour chaque valeur de w_4, PPO et DQN ont été entraînés une fois, avec la graine 42 ; la moyenne et l'écart-type sont calculés sur les 30 réplications d'évaluation de chaque modèle. L'entraînement étant déterministe, le modèle obtenu pour $w_4 = 0{,}3$ est identique à celui des résultats principaux.

Pour PPO, la relation entre w_4 et la performance n'est pas monotone : la productivité vaut 4 161 t/h pour $w_4 = 0$, chute à 3 932 t/h pour $w_4 = 0{,}1$, remonte à 4 177 t/h pour $w_4 = 0{,}3$ et chute

à 3 684 t/h pour $w_4 = 0{,}5$, avec une variabilité nettement plus grande (écart-type de 158 t/h). Pour DQN, la productivité diminue légèrement et régulièrement avec w_4 (de 4 174 à 4 092 t/h), tandis que le temps d'immobilisation est le plus faible pour $w_4 = 0{,}5$. Comme chaque configuration repose sur un seul entraînement, la dégradation observée pour PPO à $w_4 = 0{,}1$ est compatible avec un compromis de récompense défavorable, mais plusieurs entraînements indépendants seraient nécessaires pour la distinguer de la variabilité de l'entraînement. Le choix $w_4 = 0{,}3$ donne la meilleure productivité pour PPO, mais pas pour DQN, qui obtient sa meilleure productivité sans pénalité d'attente.

Table 16 – Étude d'ablation sur le poids de la pénalité d'attente w_4, régime nominal. Productivité (t/h) et temps d'immobilisation total (min par camion et par poste), moyenne ± écart-type sur 30 réplications d'un seul modèle entraîné par configuration.[M13]

	PPO		DQN	
w_4	**Productivité**	**Immobilisation**	**Productivité**	**Immobilisation**
0,0	4 160,9 ± 64	41,5 ± 4,8	**4 174,3 ± 55**	44,2 ± 5,1
0,1	3 931,7 ± 52	74,8 ± 4,6	4 156,3 ± 63	39,2 ± 4,3
0,3 (réf.)	**4 176,7 ± 64**	**33,5 ± 4,8**	4 134,7 ± 68	43,7 ± 5,2
0,5	3 683,8 ± 158	79,3 ± 20,3	4 091,5 ± 61	**31,0 ± 4,2**

[EXPÉRIENCE À FAIRE : entraîner 3 à 5 graines par valeur de w_4 pour distinguer l'effet de la récompense de la variabilité de l'entraînement (M13).]

Sensibilité aux hyperparamètres. [M12] La configuration de PPO suit les réglages usuels de l'algorithme [33] et les valeurs par défaut de Stable-Baselines3. Des essais préliminaires sur le coefficient d'entropie ($c_H \in \{0\,;\,0{,}01\,;\,0{,}02\,;\,0{,}05\}$) ont conduit à retenir $c_H = 0{,}02$. DQN a été utilisé avec ses valeurs par défaut, à l'exception de la taille du tampon et du calendrier d'exploration indiqués dans le Table 5. L'effort de réglage n'a donc pas été le même pour les deux agents profonds, ce qui constitue une limite de la comparaison entre PPO et DQN.

[À VALIDER AVEC LA DIRECTRICE : les essais préliminaires sur c_H ne figurent dans aucun script du projet : fournir un tableau chiffré (valeurs testées, régime, critère, graines distinctes de l'évaluation) ou supprimer cette mention (M12).]

8 Discussion

Cette section interprète les résultats au regard des questions de recherche, discute les implications pour l'exploitation et la durabilité, puis les limites de l'étude.

8.1 Réponses aux questions de recherche

[M18, M23] **QR1.** Aucune politique n'atteint la productivité la plus élevée dans les trois régimes : PPO est en tête en conditions nominales, l'Affectation fixe en forte charge et DQN en fortes pannes. Le classement dépend donc de l'interaction entre la logique de dispatching et le régime, et non de la seule famille d'algorithmes.

QR2. Dans chaque régime, productivité et attente en file évoluent globalement dans le même sens : les politiques les plus productives sont aussi celles qui attendent le moins, et le front de Pareto ne compte que deux ou trois politiques. Le type de logique de dispatching compte davantage que la distinction entre apprentissage et règles : les deux règles qui ignorent les files concentrent la flotte sur une pelle et sont dominées partout, tandis que l'Affectation fixe, qui répartit les camions de façon équilibrée et stable, reste compétitive dans les trois régimes.

QR3. En fortes pannes, les agents profonds entraînés en conditions nominales conservent, sans réentraînement, une productivité proche de celle des agents entraînés dans ce régime et supérieure à celle de l'Affectation fixe. Dans cette étude, la robustesse aux pannes de camions ne dépend donc pas

d'un réentraînement spécifique. La question reste ouverte pour la forte charge, où la représentation de l'état empêche le transfert des agents profonds.

QR4. Le classement selon la consommation spécifique ne suit pas exactement celui de la productivité (Section 8.4) : DQN consomme le moins par tonne en conditions nominales et en fortes pannes, sans être le plus productif en conditions nominales.

Le Table 17 résume le statut des trois hypothèses.

Table 17 – Validation des hypothèses de recherche.[M23, M3]

Hyp.	Énoncé	Éléments clés	Verdict
H1	En conditions nominales, les agents profonds dépassent la meilleure heuristique en productivité.	PPO : +105 t/h (+2,6 %) et DQN : +63 t/h (+1,6 %) par rapport à l'Affectation fixe, $p < 0{,}001$ (Table 15). Résultat obtenu avec un seul entraînement par agent.	**Validée**
H2	Aucune politique ne domine dans les trois régimes.	Meilleure politique différente dans chaque régime ; interaction entre politique et régime significative ($F(14, 609) = 430{,}4$, $p < 0{,}001$).	**Validée**
H3	Une productivité élevée ne s'accompagne pas nécessairement d'une faible attente en file.	Compromis limité entre l'Affectation fixe et PPO en conditions nominales, entre l'Affectation fixe et DQN en forte charge ; dans l'ensemble, productivité et faible attente vont de pair, et les règles fondées sur la distance sont mauvaises sur les deux critères.	Partiellement validée

8.2 Interprétation

[M14, M16, M18, M27]

— **L'équilibre de la répartition explique une grande part des écarts.** Les trois politiques les plus productives répartissent les cycles entre plusieurs pelles, alors que les deux règles fondées sur la distance les concentrent sur une seule. L'Affectation fixe, qui fige une répartition équilibrée, est ainsi très difficile à battre lorsque la flotte augmente, car elle évite à la fois la congestion et les déplacements inutiles entre pelles.

— **PPO et DQN.** En conditions nominales, PPO devance DQN de 42 t/h ; en fortes pannes, DQN devance PPO de 50 t/h. Ces écarts opposent deux modèles entraînés une fois chacun, et non deux algorithmes. Une explication possible de l'avantage de DQN en fortes pannes est la réutilisation, par son tampon de rejeu, des transitions impliquant des pannes ; aucune expérience de cette étude ne permet toutefois de l'établir, et le transfert sans réentraînement montre que l'agent PPO nominal fait aussi bien que l'agent PPO spécialisé dans ce régime.

— **L'action ATTENDRE.** En forte charge, PPO a appris à faire patienter les camions dans la grande majorité de ses décisions. Cette stratégie limite peu l'attente en file mais réduit la productivité par camion et rend la performance très variable d'une réplication à l'autre. Elle montre que la conception de l'espace d'actions et de la récompense, et pas seulement l'algorithme, détermine le comportement appris.

— **Un problème multi-objectif et stochastique.** Le dispatching doit être évalué sur plusieurs critères et plusieurs régimes : une évaluation limitée aux conditions nominales aurait désigné PPO comme la politique à déployer, alors qu'il est troisième en forte charge.

8.3 Implications pour l'exploitation

[M27] Les résultats portent sur la performance relative des politiques dans l'environnement simulé proposé, et leur transposition à un site réel exigerait une calibration et une validation préalables. Sous cette réserve, trois enseignements se dégagent. Premièrement, un agent d'apprentissage devrait d'abord être utilisé comme aide à la décision, ses recommandations étant validées par un répartiteur,

plutôt que comme un remplacement des systèmes de gestion de flotte. Deuxièmement, une politique candidate devrait être évaluée sur plusieurs régimes contrastés, à l'aide d'un jumeau numérique, avant tout déploiement. Troisièmement, une règle simple et bien équilibrée, telle que l'Affectation fixe, constitue une référence exigeante qu'une politique apprise doit dépasser dans tous les régimes pertinents.

Le passage à de grandes flottes de 50 à 200 camions et l'exploitation des données de télémétrie que produisent ces flottes constituent une perspective importante. La représentation de l'état utilisée ici, dont la taille croît avec le nombre de camions, ne s'y prête pas ; des représentations indépendantes de la taille de la flotte, telles que des réseaux de neurones sur graphe, et des formulations multi-agents [49] pourraient le permettre. Un préentraînement sur des historiques de dispatching suivi d'un ajustement en simulation pourrait réduire l'écart entre simulation et réalité ; ces pistes restent à évaluer.

8.4 Durabilité

Le Table 18 rapporte l'utilisation des camions et des pelles, et le Table 19 la consommation spécifique de carburant.

Table 18 – Utilisation des camions (temps d'activité dans le poste) et des pelles (temps de chargement), en %, moyennes sur 30 réplications.[M2, m18]

	Utilisation des camions (%)			Utilisation des pelles (%)		
Politique	**N**	**FC**	**FP**	**N**	**FC**	**FP**
FIFO	93,0	90,6	**88,5**	27,9	40,3	26,4
Affectation fixe	**93,9**	**91,0**	88,1	34,0	**49,2**	32,0
Pelle la plus proche	84,4	58,4	80,5	32,0	33,8	30,8
Plus court chemin	84,0	57,4	80,3	32,4	34,0	31,0
Q-Learning	87,9	85,6	81,7	30,2	40,4	26,9
SARSA	85,8	75,0	83,0	26,2	34,6	25,4
DQN	91,1	90,1	85,1	33,4	45,6	**32,1**
PPO	93,1	79,4	85,5	**34,4**	41,0	31,4

Table 19 – Consommation spécifique de carburant (L/t), moyenne ± écart-type sur 30 réplications.[M20, m16]

Politique	**N**	**FC**	**FP**
FIFO	0,0534 ± 0,0006	0,0546 ± 0,0004	0,0555 ± 0,0007
Affectation fixe	0,0431 ± 0,0003	**0,0444 ± 0,0004**	0,0453 ± 0,0006
Pelle la plus proche	0,0430 ± 0,0004	0,0582 ± 0,0006	0,0445 ± 0,0005
Plus court chemin	0,0432 ± 0,0004	0,0588 ± 0,0005	0,0447 ± 0,0006
Q-Learning	0,0482 ± 0,0012	0,0537 ± 0,0010	0,0534 ± 0,0014
SARSA	0,0555 ± 0,0009	0,0612 ± 0,0008	0,0571 ± 0,0014
DQN	**0,0408 ± 0,0006**	0,0445 ± 0,0005	**0,0419 ± 0,0006**
PPO	0,0415 ± 0,0006	0,0475 ± 0,0023	0,0427 ± 0,0008

[M2, M18, M20, M22]

— **Utilisation.** L'utilisation des camions de Pelle la plus proche et de Plus court chemin chute à environ 58 % en forte charge, contre 91 % pour l'Affectation fixe : leurs camions passent une grande partie du poste en file devant la pelle 1. L'utilisation des pelles reste inférieure à 50 % pour toutes les politiques, ce qui confirme que la flotte n'atteint pas la capacité de chargement, même en forte charge.

— **Consommation spécifique.** DQN consomme le moins de carburant par tonne en conditions nominales et en fortes pannes. Par rapport à l'Affectation fixe, l'écart vaut −0,0024 L/t (−5,5 %)

en conditions nominales et $-0{,}0033$ L/t ($-7{,}3\,\%$) en fortes pannes, soit environ 2,4 et 3,3 litres pour 1 000 tonnes transportées ; PPO présente des écarts de $-3{,}9\,\%$ et $-5{,}6\,\%$. Ces quatre différences sont significatives (test de Wilcoxon apparié, $p < 0{,}001$). En forte charge, DQN et l'Affectation fixe sont presque à égalité (écart de $0{,}2\,\%$), tandis que PPO consomme $7{,}0\,\%$ de plus que l'Affectation fixe ($p < 0{,}001$).

— **Portée de ces chiffres.** Les tailles d'effet sont très grandes ($|d| > 3$) parce que la consommation varie très peu d'une réplication à l'autre dans le simulateur ; elles ne signifient pas un effet pratique important. Surtout, le modèle de carburant est simplifié et n'a pas été calibré : une consommation d'environ 6 litres par cycle pour un camion de 140 tonnes paraît faible au regard des consommations publiées pour cette classe de camions. Les valeurs absolues ne doivent donc pas être interprétées, et seuls les écarts relatifs entre politiques ont un sens. Comme la combustion du diesel est la principale source d'émissions directes des flottes de transport, une réduction de la consommation par tonne se traduirait en principe par une réduction proportionnelle des émissions ; aucune émission n'a cependant été mesurée.

[EXPÉRIENCE À FAIRE : confronter le modèle de carburant à une donnée de constructeur ou de terrain (consommation horaire du camion de référence) avant toute interprétation en valeur absolue (M20).]

8.5 Limites

[M7, M8, M9, M11, M12, M25, N1–N5]

— **Simulation et absence de validation sur site :** l'étude repose entièrement sur un simulateur non calibré sur des données réelles. Les conditions météorologiques, le comportement des opérateurs, les incidents routiers et les décisions de maintenance ne sont pas représentés.

— **Une seule graine d'entraînement :** chaque agent a été entraîné une fois. Les 30 réplications mesurent la variabilité due à l'environnement, pas celle due à l'entraînement ; les comparaisons entre PPO et DQN opposent donc deux modèles, et non deux algorithmes [16, 3]. Par ailleurs, les graines d'évaluation coïncident avec celles des premiers épisodes d'entraînement.

— **Représentation de l'état :** sa taille dépend du nombre de camions, ce qui empêche le transfert des agents profonds entre flottes de tailles différentes, et plus d'un tiers de ses composantes sont constantes. Les agents tabulaires n'utilisent qu'une représentation réduite à six variables et n'atteignent pas la convergence dans le budget retenu ; leur performance est une borne inférieure.

— **Modèle de simulation :** les cycles sont simulés d'un seul tenant au moment de la décision, et les pelles et les verses servent les camions dans l'ordre des décisions plutôt que dans l'ordre exact d'arrivée. Seuls les camions tombent en panne, au plus une fois par cycle, selon un processus stationnaire ; les pannes de pelles, souvent les plus pénalisantes, ne sont pas représentées. Le modèle de carburant n'est pas calibré.

— **Aléas non synchronisés :** un seul générateur aléatoire est utilisé ; les aléas ne sont donc identiques entre politiques que jusqu'à leur première décision différente.

— **Actualisation par décision :** l'horizon effectif en minutes dépend de la politique et de la taille de la flotte (Section 5.4).

— **Références et réglage :** deux des quatre heuristiques sont dégénérées dans l'implémentation évaluée, et aucune règle tenant compte à la fois des files et des temps de trajet ni aucune politique fondée sur l'optimisation n'est incluse. L'effort de réglage des hyperparamètres n'a pas été identique pour PPO et DQN.

— **Espace d'actions et algorithmes :** l'agent choisit parmi un ensemble discret de couples pelle–verse ; d'autres algorithmes, tels que Soft Actor-Critic [14, 25], Advantage Actor-Critic ou des approches multi-agents [49], n'ont pas été comparés.

— **Taille du système :** trois pelles, deux verses et 12 à 18 camions sont loin des grandes exploitations. Les résultats décrivent une performance relative dans ce cadre.

9 Conclusion et travaux futurs

[M18, M23] Cette étude a examiné si des politiques de dispatching apprises par renforcement conservent leur avantage sur des règles industrielles lorsque le régime de fonctionnement d'une mine à ciel ouvert change. Huit politiques, quatre heuristiques et quatre agents d'apprentissage, ont été comparées dans un même simulateur stochastique et dans trois régimes, sur 30 réplications appariées et avec des tests appariés corrigés pour les comparaisons multiples.

Trois résultats principaux se dégagent. Premièrement, le classement des politiques dépend du régime : PPO est le plus productif en conditions nominales (4 177 t/h, soit 2,6 % de plus que l'Affectation fixe), l'Affectation fixe lorsque la flotte augmente de moitié, et DQN lorsque les pannes sont fréquentes, et l'interaction entre politique et régime est significative. Deuxièmement, les écarts s'expliquent en grande partie par la répartition des camions entre les pelles : les deux règles fondées sur la seule distance concentrent toute la flotte sur une pelle et sont dominées dans tous les régimes, tandis qu'une affectation fixe et équilibrée reste très compétitive ; en forte charge, l'agent PPO recourt massivement à l'action d'attente, ce qui réduit sa productivité par camion et la rend très variable. Troisièmement, en cas de pannes fréquentes, les agents profonds entraînés en conditions nominales et déployés sans réentraînement conservent une productivité proche de celle des agents entraînés dans ce régime et supérieure à celle de l'Affectation fixe.

Ces résultats suggèrent que la performance nominale prédit mal le comportement d'une politique sous perturbation, et que les politiques de gestion de flotte devraient être évaluées sur plusieurs régimes contrastés avant toute recommandation. Ils restent conditionnels au simulateur utilisé, qui n'a pas été calibré sur des données de site, et reposent sur un seul entraînement par agent.

Les travaux futurs porteront d'abord sur la consolidation de ces résultats : plusieurs graines d'entraînement par agent, une représentation de l'état indépendante de la taille de la flotte permettant l'évaluation sans réentraînement en forte charge, des références industrielles plus fortes, telles qu'une règle fondée sur le temps d'attente minimal des camions et une politique issue d'un programme linéaire, ainsi que la représentation des pannes de pelles. À plus long terme, des formulations multi-agents et une validation sur un jumeau numérique calibré avec des données opérationnelles permettront d'évaluer le passage à l'échelle et l'effet réel sur la consommation de carburant.

Disponibilité des données

Les résultats par réplication (une ligne par politique, régime et graine), ainsi que les journaux de simulation, sont disponibles auprès de l'auteur correspondant sur demande raisonnable et seront déposés avec le code.[M3]

Disponibilité du code

Le code source du simulateur, les scripts d'entraînement et d'évaluation et la liste des graines utilisées pour les 30 réplications (graines 42 à 71) sont accessibles sur GitHub à l'adresse `https://github.com/Juan-Lucas/memoire-master-rl-logistique`.

[À VALIDER AVEC LA DIRECTRICE : la version précédente mentionnait des fichiers YAML d'hyperparamètres dans un répertoire `configs/`, absent du code analysé : ajouter ce répertoire ou retirer la mention ; nettoyer les références internes au mémoire dans les commentaires du code avant publication (rapport d'audit, N10).]

Contributions des auteurs

Jean-Luc MUPASA KALUNGA : conceptualisation, méthodologie, logiciel, validation, analyse formelle, investigation, rédaction (première version), visualisation.

Dr Olfa FERCHICHI : supervision, conceptualisation, méthodologie, rédaction (relecture et édition), administration du projet.

Conflit d'intérêts

Les auteurs déclarent n'avoir aucun intérêt financier concurrent connu ni aucune relation personnelle susceptible d'avoir influencé les travaux rapportés dans cet article.

Références

[1] Milad Abolghasemian, Armin Ghane Kanafi, and Maryam Daneshmandmehr. A two-phase simulation-based optimization of hauling system in open-pit mine. *Iranian Journal of Management Studies (IJMS)*, 13:705–732, 5 2020.

[2] A.M. Afrapoli and H. Askari-Nasab. Mining fleet management systems: a review of models and algorithms. *International Journal of Mining, Reclamation and Environment*, pages 1–20, 6 2017.

[3] Rishabh Agarwal, Max Schwarzer, Pablo Samuel Castro, Aaron Courville, and Marc G. Bellemare. Deep reinforcement learning at the edge of the statistical precipice. In *Advances in Neural Information Processing Systems 34*, pages 29304–29320, 2021.

[4] D.K. Ahangaran, A.B. Yasrebi, A. Wetherelt, and P. Foster. Real-time dispatching modelling for trucks with different capacities in open pit mines. *Archives of Mining Sciences*, 52:39–52, 2012.

[5] S. Alarie and M. Gamache. Overview of solution strategies used in truck dispatching systems for open pit mines. *International Journal of Surface Mining, Reclamation and Environment*, 16:59–76, 2002.

[6] C. Banerjee, K. Nguyen, and C. Fookes. Mining-gym: A configurable rl benchmarking environment for truck dispatch scheduling. 2025.

[7] Steven J. Bradtke and Michael O. Duff. Reinforcement learning methods for continuous-time Markov decision problems. In *Advances in Neural Information Processing Systems 7*, pages 393–400. MIT Press, 1995.

[8] Christina N. Burt and Louis Caccetta. Equipment selection for surface mining: A review. *Interfaces*, 44(2):143–162, 2014.

[9] J. P. de Carvalho and R. Dimitrakopoulos. Production planning updating with mining fleet management in industrial mining complexes: an actor-critic reinforcement learning approach. *Applied Intelligence*, 2023.

[10] Janez Demšar. Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, 7:1–30, 2006.

[11] Bradley Efron and Robert J. Tibshirani. *An Introduction to the Bootstrap*. Chapman & Hall, New York, 1993.

[12] Marcelo Moretti Fioroni, Luiz Augusto G. Franzese, Tales Jefferson Bianchi, Luiz Ezawa, Luiz Ricardo Pinto, and Gilberto de Miranda Jr. Concurrent simulation and optimization models for mining planning. *Winter Simulation Conference*, 2008.

[13] Milton Friedman. The use of ranks to avoid the assumption of normality implicit in the analysis of variance. *Journal of the American Statistical Association*, 32(200):675–701, 1937.

[14] Tuomas Haarnoja, Aurick Zhou, Pieter Abbeel, and Sergey Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *Proceedings of the 35th International Conference on Machine Learning*, volume 80 of *Proceedings of Machine Learning Research*, pages 1861–1870. PMLR, 2018.

[15] A. Hazrathosseini and A. M. Afrapoli. Transition to intelligent fleet management systems in open pit mines: A critical review on application of reinforcement-learning-based systems. *Mining Technology*, 2024.

[16] Peter Henderson, Riashat Islam, Philip Bachman, Joelle Pineau, Doina Precup, and David Meger. Deep reinforcement learning that matters. In *Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence*, pages 3207–3214, 2018.

[17] Sture Holm. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2):65–70, 1979.

[18] Moez Krichen. Apprentissage par renforcement profond. 2022.

[19] Guangwei Liu and Senlin Chai. Optimizing open-pit truck route based on minimization of time-varying transport energy consumption. *Mathematical Problems in Engineering*, 2019:1–12, 8 2019.

[20] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A. Rusu, Joel Veness, Marc G. Bellemare, Alex Graves, Martin Riedmiller, Andreas K. Fidjeland, Georg Ostrovski, et al. Human-level control through deep reinforcement learning. *Nature*, 518(7540):529–533, 2015.

[21] Mehrnaz Mohtasham and Hossein Mirzaei-Nasirabad. Evaluating the performance of the dispatch algorithm, a commercial software, in the sungun copper mine. *Journal of Geomines*, pages 117–122, 2023.

[22] Mohan Munirathinam and Jon C.Yingling. A review of computer-based truck dispatching strategies for surface mining operations. *International Journal of Surface Mining, Reclamation and Environment*, 1994.

[23] Mohammadreza Nazari, Afshin Oroojlooy, Martin Taká˘c, and Lawrence V. Snyder. Reinforcement learning for solving the vehicle routing problem. *NeurIPS*, 5 2018.

[24] Alexandra M. Newman, Enrique Rubio, Andrés Weintraub Rodrigo Caro, and Kelly Eurek. A review of operations research in mine planning. *Interfaces*, 40:222–245, 4 2010.

[25] Sampson E. Nwachukwu, Komla A. Folly, and Kehinde O. Awodele. A comparative study between soft actor-critic (SAC) and deep deterministic policy gradient (DDPG) algorithms for solar PV MPPT control under partial shading conditions. *IEEE Access*, 13:71738–71754, 2025.

[26] Burak Ozdemir and Mustafa Kumral. Simulation based optimization of truck shovel material handling systems in multi pit surface mines. *Simulation Modelling Practice and Theory*, 95:36–48, 4 2019.

[27] S. Pei, J. Yang, and Z. Gong. Learning-based dispatching system with trajectory optimisation for autonomous mining transportation. *International Journal of Mining, Reclamation and Environment*, 2025.

[28] Martin L. Puterman. *Markov Decision Processes: Discrete Stochastic Dynamic Programming*. John Wiley & Sons, New York, 1994.

[29] Antonin Raffin, Ashley Hill, Adam Gleave, Anssi Kanervisto, Maximilian Ernestus, and Noah Dormann. Stable-baselines3: Reliable reinforcement learning implementations. *Journal of Machine Learning Research*, 22(268):1–8, 2021.

[30] Francisco ROSALES and Angelo DIAZ. Interpretable deep reinforcement learning for dynamic truck dispatching in open-pit mining. *International Journal of Mining, Reclamation and Environment*, 2025.

[31] Gavin A. Rummery and Mahesan Niranjan. On-line Q-learning using connectionist systems. Technical Report CUED/F-INFENG/TR 166, Cambridge University Engineering Department, 1994.

[32] John Schulman, Philipp Moritz, Sergey Levine, Michael I. Jordan, and Pieter Abbeel. High-dimensional continuous control using generalized advantage estimation. In *Proceedings of the 4th International Conference on Learning Representations (ICLR)*, 2016. arXiv:1506.02438.

[33] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.

[34] Amanda Smith, Jeff Linderoth, and Jim Luedtke. Optimization-based dispatching policies for open-pit mining. *Springer*, pages 1–39, 2 2020.

[35] F. Soumis, J. Ethier, and J. Elbrond. Truck dispatching in an open pit mine. *International Journal of Surface Mining, Reclamation and Environment*, 3:115–119, 1989.

[36] M.J.F. Souza, I.M. Coelho, S. Ribas, H.G. Santos, and L.H.C. Merschmann. A hybrid heuristic algorithm for the open-pit-mining operational planning problem. *European Journal of Operational Research*, pages 1041–1051, 6 2010.

[37] R.F. Subtil, D M Silva, and J C Alves. A practical approach to truck dispatch for open pit mines. *Proceedings of the 35th International Symposium on the Application of Computers and Operations Research in the Mineral Industry (APCOM)*, 2011.

[38] Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. 2018.

[39] Richard S. Sutton, Doina Precup, and Satinder Singh. Between MDPs and semi-MDPs: A framework for temporal abstraction in reinforcement learning. *Artificial Intelligence*, 112(1–2):181–211, 1999.

[40] Kinga Szatmari, Tibor Chovan, Sandor nemeth, and Alex Kummer. How to support decision making with reinforcement learning in hierarchical chemical process control? *Chemical Engineering Journal Advances*, 22:100753, 2025.

[41] Chung H. Ta, Armann Ingolfsson, and John Doucette. A linear model for surface mining haul truck allocation incorporating shovel idle probabilities. *European Journal of Operational Research*, pages 770–778, 6 2013.

[42] Mark Towers, Ariel Kwiatkowski, Jordan Terry, John U. Balis, Gianluca De Cola, Tristan Deleu, Manuel Goulão, Andreas Kallinteris, Markus Krimmel, Arjun KG, Rodrigo Perez-Vicente, Andrea Pierré, Sander Schulhoff, Jun Jet Tai, Hannah Tan, and Omar G. Younis. Gymnasium: A standard interface for reinforcement learning environments. *NeurIPS*, 2025.

[43] Shiv Prakash Upadhyay and Hooman Askari-Nasab. Simulation and optimization approach for uncertainty-based short-term planning in open pit mines. *International Journal of Mining Science and Technology*, 28:153–166, 12 2017.

[44] Zhongxin Wang, Jinjin Wang, Ming Zhao, Qiang Guo, Xiangyu Zeng, Fengyang Xin, and Hao Zhou. Truck dispatching optimization model and algorithm based on 0-1 decision variables. *Mathematical Problems in Engineering*, 2022:1–9, 2 2022.

[45] Christopher J. C. H. Watkins and Peter Dayan. Q-learning. *Machine Learning*, 8(3–4):279–292, 1992.

[46] Frank Wilcoxon. Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80–83, 1945.

[47] W. Zeng, E.Y. Baafi, and H. Fan. A simulation model to study truck- allocation options. *School of Civil, Mining and Environmental Engineering, University of Wollongong, Australia*, 122:741–750, 12 2022.

[48] Cong Zhang, Wen Song, Zhiguang Cao, Jie Zhang, Puay Siew Tan, and Chi Xu. Learning to dispatch for job shop scheduling via deep reinforcement learning. *NeurIPS*, pages 1–17, 10 2020.

[49] K. Zhao, Z. Liu, W. Du, H. Lu, B. Zhou, and G. Yu. Hierarchical multiagent reinforcement learning for sustainable truck dispatching in open-pit mining. *Transportmetrica A: Transport Science*, 2025.

[50] Necmettin Çetin. *Open Pit Truck/Shovel Haulage System Simulation*. PhD thesis, Middle East Technical University, 9 2004.

[À VALIDER AVEC LA DIRECTRICE : style bibliographique : utiliser le modèle de la revue cible (sn-jnl pour Springer) ; corriger les entrées de `RL_references.bib` signalées dans le rapport de relecture (section 5.4).]

Annexe de travail : journal des modifications de la version 2

Cette annexe disparaît dans la version propre (`\revmarksfalse`). Elle relie chaque modification aux points du rapport de relecture (M, m) et du rapport d'audit du code (N, A).

Point	Où	Modification
M1	Résumé, §6.2, §7.5, tableaux 3 et 14	Le protocole « sans réentraînement » était faux : chaque agent est entraîné dans chaque régime. Protocole décrit tel qu'il est, et ajout d'une vraie évaluation sans réentraînement en fortes pannes (et en forte charge pour les agents tabulaires).
M2	§6.3, §7.2, tableau 10	L'« attente par cycle » était une immobilisation cumulée par camion et par poste, pannes et attentes volontaires comprises. Séparation de l'attente en file et de l'immobilisation totale.
M3	§6.4, §7.6, tableau 15	Chaque réplication figurait deux fois dans le fichier de résultats. Toutes les valeurs p, intervalles et tests recalculés sur 30 réplications.
M4, M6	§6.4	Tests appariés (Friedman, Wilcoxon, Holm) à la place de Welch, Kruskal–Wallis et Dunn ; suppression de l'affirmation erronée sur Games–Howell ; description honnête des graines communes.
M5	§7.6	Test de l'interaction entre politique et régime.
M7	§6.2, §7.7, §7.8, limites	Une seule graine d'entraînement : QR5 supprimée, comparaisons présentées comme entre modèles. Expériences à faire signalées.
M8	§5.6.3	Description exacte de la représentation tabulaire (6 variables, 98 304 états).
M9	§5.4	Formulation semi-markovienne, horizon effectif chiffré, attribution du mérite, références.
M10	§5.5	Formules exactes de la récompense et explication de son ordre de grandeur.
M11	§5.1 à §5.3, tableau 2	Paramètres du simulateur ; moteur décrit comme piloté par les événements ; pannes limitées aux camions.
M12	§5.6, §7.9	Suppression de « soigneusement réglés » ; inégalité de réglage reconnue.
M13	§7.9, tableau 16	Interprétation prudente ; ajout de DQN ; déterminisme de l'entraînement.
M14	§5.6.2, §8.2	Hypothèse du tampon de rejeu mentionnée une seule fois.
M15	§6.1, §7.1, §7.5	Facteur d'appariement ; suppression de « sursaturation » ; productivité et ratio de robustesse par camion.
M16, C3	§5.7, §7.3, tableau 11	Pelle la plus proche et Plus court chemin envoient 100 % des cycles à la pelle 1 dans tous les régimes ; analyse sur 30 réplications.
M17, M18	§7.1, §7.5, §8, §9	Affirmations corrigées (classement par récompense, résilience de DQN, appel à abandonner les règles statiques, « confirme »).
M19	§7.4, tableau 12	Fronts de Pareto par régime.
M20, M22	§8.4	Économie de carburant corrigée (2,4 L et non 53 L pour 1 000 t) ; mise en garde sur les tailles d'effet et la calibration.
M21	§6.3	Définition de la résilience opérationnelle.
M23	§3.3, §4.1, §5	Quatre questions de recherche et trois hypothèses ; contributions recentrées ; section 5 renommée.
M24	Structure	Problématique après la revue de littérature ; contributions et cadre méthodologique séparés ; formulation intégrée à l'approche.
M25, Dir. corr. 1	§5.7, tableau 6	Heuristiques décrites telles qu'implémentées ; l'Affectation fixe n'a pas de réaffectation de secours.
M26	§3.4	Nouveauté formulée comme une combinaison ; Mining-Gym cité.
M27	§3.4, §8.3	Portée industrielle réduite et au conditionnel.
M28	§5.8	Coût de calcul et parallélisation.

Point	Où	Modification
m1, m2	Résumé, mots-clés	Résumé d'environ 240 mots, sans abréviation, sans valeur p ; mots-clés sans PPO ni DQN.
m3, m4, m5	Ensemble	Abréviations définies dans l'introduction ; italiques supprimées dans le texte courant ; parenthèses d'exemples remplacées par « tels que ».
m6, m7	Figures	Noms de fichiers sans espaces ; figures 6, 7, 9 et 10 régénérées à partir des 30 réplications uniques ; textes des figures 2 et 8 à corriger.
m12, m13, m14	§7	Chiffres arrondis dans le texte ; chiffres du texte alignés sur les tableaux.
m15, m16, m17	Tableaux	Abréviation PCC supprimée ; colonne L/t retirée du tableau de productivité ; ligne « Étude proposée » du tableau de positionnement corrigée.
m19, m20	§6.2, §5.8	Mode d'évaluation déterministe ; latence précisée.
m21, m22	§1, §2	Renvois croisés ; accord « Comme le soulignent Newman et al. ».
m24	§5.8, §7.8	« stagne » ; phrase sur les cycles de 1 024 pas et « standards de la recherche à fort impact » supprimées.
m26, m27	Source, auteurs	Commentaires internes retirés ; auteur correspondant identifié.
N1–N3	§5.4	Composantes constantes de l'état et saturation du tonnage signalées.
N5	§5.1, limites	Pas de panne de pelle.
N11	§6.5	Version de la récompense de DQN à vérifier.
Bibliographie	RL_references_ajouts.bib	Ajout de Mnih 2015, Watkins et Dayan 1992, Rummery et Niranjan 1994, Schulman 2016, Puterman 1994, Bradtke et Duff 1995, Sutton, Precup et Singh 1999, Henderson 2018, Agarwal 2021, Demšar 2006, Friedman 1937, Wilcoxon 1945, Holm 1979, Efron et Tibshirani 1993, Burt et Caccetta 2014.