# Beyond Static Dispatching Heuristics: A Comparative Evaluation of Deep Reinforcement Learning under Disruptions in Open-Pit Mining

**Abstract**

Les systèmes de camions-pelles constituent la colonne vertébrale des exploitations minières à ciel ouvert, représentant jusqu'à 60 % des coûts d'exploitation totaux. Malgré leur importance cruciale, la gestion traditionnelle des flottes repose encore sur des heuristiques de répartition statiques qui, bien souvent, ne parviennent pas à s'adapter aux aléas du monde réel. De plus, les recherches existantes en apprentissage par renforcement (RL) évaluent fréquemment les performances dans des conditions simplifiées ou stables, négligeant ainsi l'impact des perturbations opérationnelles. Cet article présente une évaluation comparative des politiques d'apprentissage par renforcement profond (DRL) — en particulier PPO et DQN — par rapport aux heuristiques industrielles traditionnelles dans un contexte de perturbations stochastiques. Nous avons développé un environnement de simulation haute-fidélité à l'aide de Gymnasium, intégrant un espace d'observation à 147 dimensions et une fonction de récompense multi-objectifs. Huit politiques de répartition ont été comparées dans trois régimes opérationnels : des scénarios nominaux, de forte charge (congestion) et de pannes fréquentes. Les résultats statistiques montrent que, si le PPO atteint une productivité supérieure dans des conditions nominales (4 208,8 t/h), le DQN fait preuve d'une plus grande résilience opérationnelle en cas de pannes fréquentes des équipements (3 991,8 t/h). Nous soulignons notamment un effondrement systémique des heuristiques myopes en cas de surcharge de la flotte, où les temps d'attente dépassent 200 minutes par cycle, tandis que les politiques DRL maintiennent la fluidité du système. Cette étude conclut que, si les architectures DRL améliorent considérablement la résilience de la planification, leurs performances dépendent fortement du régime. Ces résultats soulignent la nécessité d'aller au-delà des règles statiques pour s'orienter vers des agents adaptatifs, entraînés sur plusieurs scénarios, afin de garantir la productivité et la durabilité de l'exploitation minière en situation d'incertitude.

**Keywords:** Deep reinforcement learning, Open-pit mining, Truck dispatching, Fleet management, Operational resilience, Stochastic simulation, PPO, DQN.

1. Introduction
   1.1 Industrial context

Les exploitations minières à ciel ouvert sont des systèmes industriels à très grande échelle où le cycle « camion-pelle » constitue l'épine dorsale logistique principale. Ce processus, qui implique l'excavation, le transport et le déversement des matériaux, n'est pas seulement une tâche opérationnelle, mais un facteur financier essentiel, représentant jusqu'à 60 % des coûts d'exploitation totaux d'un site minier \cite{Afrapoli2017}. Dans l'exploitation minière moderne, la pression pour optimiser ces flux est double : maximiser le débit afin de répondre à la demande mondiale en matières premières tout en minimisant la consommation d'énergie et les émissions de gaz à effet de serre associées aux flottes de véhicules diesel.

Cependant, l'efficacité de ces systèmes est constamment remise en cause par une forte variabilité opérationnelle. Dans les environnements miniers réels, les conditions sont loin d'être déterministes. Les pannes d'équipements, les fluctuations de la charge utile, les temps de trajet aléatoires dus à la dégradation des routes et les embouteillages soudains créent un environnement extrêmement instable. La gestion de cette complexité nécessite une prise de décision en temps réel capable de trouver un équilibre entre la productivité immédiate et la résilience à long terme de la flotte.

### 1.2 Research problem

Le principal défi de la planification des trajets de camions réside dans l'affectation dynamique des camions aux points de chargement et de déchargement afin d'optimiser un objectif spécifique, tel que la maximisation du tonnage ou la minimisation du temps d'inactivité des pelles mécaniques. Bien que les systèmes de gestion de flotte (FMS) soient en place depuis des décennies, ils peinent à gérer les non-linéarités causées par des perturbations soudaines. Lorsqu'une pelle mécanique tombe en panne ou qu'une route est encombrée, ces perturbations locales se répercutent sur l'ensemble du réseau. La logique de répartition traditionnelle ne parvient souvent pas à anticiper ces répercussions, ce qui entraîne de graves goulots d'étranglement, une sous-utilisation des équipements à forte intensité capitalistique et un gaspillage excessif de carburant pendant les temps d'inactivité dans les files d'attente.

### 1.3 Research gap

La littérature actuelle sur la planification des tournées de camions peut être classée en trois grands courants. Premièrement, les \textit{*heuristiques statiques*} (par exemple, « Nearest Shovel », FIFO) restent la norme dans le secteur en raison de leur simplicité, mais elles sont intrinsèquement myopes et ne tiennent pas compte de l'état global du système. Deuxièmement, l'\textit{*optimisation mathématique*} (MILP) et les \textit{*méta-heuristiques*} fournissent des solutions de haute qualité pour des environnements stables, mais sont souvent trop gourmandes en ressources de calcul pour permettre des ajustements en temps réel ou sont appliquées hors ligne. Troisièmement, bien que l'\textit{*apprentissage par renforcement (RL)*} soit apparu comme une alternative prometteuse, les études existantes évaluent souvent les politiques dans des conditions simplifiées, à scénario unique, ou ne proposent pas de comparaison de référence exhaustive.

Les études existantes proposent rarement une comparaison contrôlée multi-scénarios entre les heuristiques statiques, l'apprentissage par renforcement tabulaire et l'apprentissage par renforcement profond (DRL) dans des conditions de congestion et de panne d'équipement. Il existe un manque notable de données sur la manière dont ces politiques passent d'une performance nominale à des états perturbés, ce qui laisse une lacune importante dans la compréhension de la résilience opérationnelle dans la logistique minière.

### 1.4 Objectives and hypotheses

Cette étude vise à combler cette lacune en menant une évaluation comparative rigoureuse des architectures DRL (PPO et DQN) par rapport aux heuristiques classiques et à l'apprentissage par renforcement tabulaire au sein d'un simulateur stochastique d'exploitation minière. Nous nous intéressons plus particulièrement au compromis entre la productivité brute et la robustesse opérationnelle. Pour orienter cette recherche, nous formulons les hypothèses suivantes :

- **H1 :** Les politiques issues de l'apprentissage par renforcement dynamique (DRL) offrent une productivité supérieure à celle des heuristiques industrielles statiques dans tous les scénarios.
- **H2 :** Les politiques issues de l'apprentissage par renforcement dynamique (DRL) présentent une dégradation de performance moindre (une résilience plus élevée) lors du passage de conditions nominales à des conditions perturbées.
- **H3 :** La politique de répartition optimale dépend du régime ; aucun algorithme unique ne domine dans tous les états opérationnels (nominal, forte charge et nombreuses pannes).
- **H4 :** Une productivité élevée n'est pas nécessairement corrélée à une faible congestion, ce qui suggère l'existence d'un front de Pareto complexe entre le débit et les temps d'attente.

### 1.5 Contributions

Les contributions de ce travail au domaine du génie minier et des systèmes autonomes sont triples :

- **Développement d'un environnement de référence stochastique :** Un simulateur sur mesure basé sur Gymnasium qui reproduit la dynamique minière, notamment les temps de trajet log-normaux, la dégradation des routes et les modèles de défaillance des équipements.
- **Évaluation exhaustive multi-scénarios :** Une comparaison systématique de huit politiques de répartition distinctes, fournissant une hiérarchie claire des performances sous diverses contraintes opérationnelles.
- **Analyse de robustesse :** Une quantification détaillée de la manière dont les agents DRL adaptent leur logique de prise de décision lorsqu'ils sont confrontés à des pannes à haute fréquence et à une sursaturation de la flotte.

## 2. Related Work

L'optimisation des systèmes « camion-pelle » est au cœur de l'ingénierie minière et de la recherche opérationnelle depuis plus de six décennies. Comme l'ont souligné **Alexandra M. Newman et al. [2010]**, l'évolution de ces systèmes est passée d'une planification manuelle à des systèmes automatisés complexes de gestion de flotte (FMS). Cette section passe en revue la littérature autour de trois grands paradigmes : les heuristiques statiques, la programmation mathématique et le domaine émergent de l'apprentissage par renforcement.

### 2.1 Static dispatching heuristics

L'optimisation des systèmes « camion-pelle » est au cœur de l'ingénierie minière et de la recherche opérationnelle depuis plus de six décennies. Comme le soulignent **Alexandra M. Newman et al. [2010]**, l'évolution de ces systèmes est passée d'une planification manuelle à des systèmes automatisés complexes de gestion de flotte (FMS). Cette section passe en revue la littérature autour de trois grands paradigmes : les heuristiques statiques, la programmation mathématique et le domaine émergent de l'apprentissage par renforcement.

### 2.2 Mathematical optimization and metaheuristics

Pour dépasser les limites des règles simples, les chercheurs se sont tournés vers la programmation mathématique. **F. Soumis et al. [1989]** ont proposé une approche en plusieurs étapes combinant la programmation linéaire (PL) pour la planification de la production et des modèles d'affectation pour la répartition en temps réel. Cette structure modulaire reste la colonne vertébrale de nombreux systèmes de gestion de fabrication (FMS) modernes. **Ahangaran et al. [2012]** ont étendu cette approche en développant des modèles spécifiquement destinés aux flottes de camions aux capacités hétérogènes, en utilisant des réseaux de flux pour équilibrer la production.

Cependant, la nature déterministe de la programmation linéaire en nombres entiers mixtes (MILP) se heurte souvent à la réalité stochastique de l'exploitation minière. **Chung H. Ta et al. [2013]** ont tenté de combler ce fossé en intégrant les probabilités d'inactivité des pelles dans des modèles linéaires, en utilisant la théorie des files d'attente pour mieux estimer la production. Malgré ces avancées, les modèles MILP souffrent souvent de la « malédiction de la dimensionnalité » lorsqu'ils sont transposés à de grandes mines comptant des dizaines de camions.

Pour gérer cette complexité, des **métaheuristiques** telles que les **algorithmes génétiques (AG)**, l'**optimisation par colonie de fourmis (ACO)** et l'**recuit simulé** ont été largement explorées. **M.J.F. Souza et al. [2010]** ont démontré qu'une heuristique hybride combinant GRASP et VNS permettait d'obtenir des solutions quasi-optimales en un temps de calcul réduit. **Guangwei Liu [2019]** a utilisé une approche par AG pour minimiser la consommation d'énergie liée au transport en tenant compte de la résistance routière variable dans le temps. Bien que puissantes, les métaheuristiques sont généralement appliquées sous la forme d'un « instantané statique » ; elles trouvent un planning optimal pour un moment précis, mais doivent être réexécutées chaque fois qu'une perturbation survient, ce qui limite leur réactivité dans des environnements hautement dynamiques [BurakOzdemir2019, ShivPrakashUpadhyay2017].

### 2.3 Reinforcement learning approaches

L'évolution vers l'**apprentissage par renforcement (RL)** représente un changement de paradigme : au lieu de résoudre un nouveau problème d'optimisation à chaque étape, un agent apprend une *politique* qui associe les états du système à des actions optimales. Les premières applications de l'apprentissage par renforcement en logistique, telles que celles de **Mohammadreza Nazari et al. [2018]** pour le problème de routage des véhicules (VRP) et de **Cong Zhang et al. [2020]** pour l'ordonnancement dans les ateliers de fabrication, ont démontré que l'apprentissage par renforcement profond (DRL) pouvait surpasser les heuristiques classiques en apprenant à partir de milliers d'interactions simulées.

Dans le secteur minier, cette transition est plus récente. **Hazrathosseini et Afrapoli [2024]** proposent une analyse critique, soulignant que si l'apprentissage par renforcement présente un immense potentiel pour les systèmes de gestion de flottes intelligents (FMS), la plupart des études en sont encore au stade de la validation de principe. **de Carvalho et Dimitrakopoulos [2023]** ont appliqué un cadre « acteur-critique » à la planification de la production, démontrant que l'apprentissage par renforcement pouvait gérer efficacement la dynamique de la flotte tout en actualisant les objectifs de production.

Des benchmarks récents, tels que **Mining-Gym** de **Banerjee et al. [2025]**, ont commencé à fournir des environnements standardisés pour tester ces algorithmes. **Zhao et al. [2025]** ont proposé une approche d'apprentissage par renforcement multi-agents hiérarchique (MARL) pour une répartition durable, en mettant l'accent sur le rendement énergétique. Cependant, une limite commune à ces études réside dans le fait qu'elles se concentrent sur des conditions « nominales ». La plupart des agents d'apprentissage par renforcement sont entraînés et testés dans des environnements stables ; rares sont les études qui évaluent explicitement le comportement d'un agent utilisant un réseau Q profond (DQN) ou l'optimisation de politique proximale (PPO) face à des pannes d'équipement fréquentes ou à des pics inattendus de congestion.

### 2.4 Critical synthesis and research gap

Malgré une longue tradition de recherche, une lacune importante subsiste. Les heuristiques traditionnelles sont robustes mais inefficaces ; les modèles mathématiques sont optimaux mais rigides ; et les études récentes sur l'apprentissage par renforcement (RL) sont innovantes mais ne font souvent pas l'objet d'un « test de résistance » face aux perturbations. Il manque des recherches comparatives évaluant la **résilience opérationnelle** des politiques d'apprentissage par renforcement — en comparant notamment l'apprentissage par renforcement tabulaire, le DQN et le PPO — par rapport à un large éventail de références industrielles, dans un cadre unique, contrôlé et multi-scénarios.

Le tableau suivant résume le positionnement de cette étude par rapport à la littérature existante :

| Étude | Domaine | Méthode | Perturbations | Baselines | Réplications | Tests statistiques |
|---|---|---|---|---|---|---|
| **Alarie [2002]** | Mines | Heuristiques | Non | 2-3 | Non | Non |
| **Souza [2010]** | Mines | Metaheuristics | Non | MILP | Limitées | Non |
| **Zeng [2022]** | Mines | Heuristics + GA | Congestion | 4 | Limitées | Non |
| **Nazari [2018]** | VRP | DRL | Non | Heuristiques | Oui | Oui |
| **Proposed study** | **Open-pit mining** | **Heuristics + RL + DRL** | **Congestion + Pannes** | **8 politiques** | **10 à 30** | **Oui (Welch/Tukey)** |

## 3. Problem Formulation

Pour évaluer les politiques de répartition en situation d'incertitude, il est nécessaire de définir formellement l'environnement minier et le cadre décisionnel. Cette étude modélise la logistique de l'exploitation à ciel ouvert sous la forme d'un processus décisionnel séquentiel dans lequel un agent autonome interagit avec une simulation stochastique d'un système composé de camions et de pelles mécaniques.

### 3.1 Truck-shovel system

L'exploitation minière est modélisée comme un système de transport en boucle fermée composé de trois entités physiques principales :

1. **Unités de chargement (pelles) :** Ressources fixes ou semi-mobiles caractérisées par leur cadence de chargement et leur capacité. Chaque pelle est associée à une file d'attente où les camions attendent si la ressource est occupée.

2. **Unités de transport (camions) :** une flotte hétérogène ou homogène de camions chargée de transporter les matériaux. Les camions sont définis par leur capacité, leurs profils de vitesse (à vide ou en charge) et leurs taux de consommation de carburant.

3. **Unités de déchargement (décharges/concasseurs) :** les destinations finales des matériaux. À l'instar des pelles, ces sites peuvent être sujets à des encombrements et ont des horaires de service spécifiques.

Le système est soumis à des **perturbations opérationnelles**, notamment des pannes d'équipement. Un événement de panne suit une distribution stochastique (par exemple, de Poisson ou de Bernoulli), ce qui retire temporairement un camion ou une pelleteuse de la flotte active, obligeant le système de répartition à réaffecter les ressources restantes afin de maintenir les objectifs de production.

### 3.2 Stochastic Road network

L'infrastructure de la mine est représentée sous la forme d'un graphe orienté **G = (V, E)**, où :

- **V (nœuds)** représente les points de chargement, les sites de déchargement, les intersections et les aires de stationnement.
- **E (arêtes)** représente les routes de transport reliant ces points.

Contrairement aux modèles déterministes, nous définissons le temps de trajet **T(e)** pour toute arête **e** comme une variable aléatoire suivant une **distribution log-normale**. Cela permet de rendre compte de la variabilité inhérente aux temps de trajet, due à l'état des routes, au comportement des conducteurs et aux interactions entre les véhicules. De plus, le modèle intègre la **dégradation des routes**, selon laquelle l'état d'un tronçon routier peut se détériorer au fil du temps, affectant ainsi les vitesses moyennes de circulation jusqu'à ce que des travaux d'entretien soient effectués.

### 3.3 Markov decision process

Le problème de répartition des camions est formulé sous la forme d'un processus de décision markovien (MDP), défini par le tuple **(S, A, P, R, γ)**.

#### 3.3.1 Espace d'états (S)

L'état **S_t** à l'instant **t** fournit un aperçu complet de l'état de la mine. Il est représenté par un vecteur de grande dimension comprenant :

- **État de la flotte :** positions, tâches en cours (transport, retour, mise en file d'attente) et charges utiles restantes pour tous les camions.
- **Disponibilité des équipements :** état opérationnel des pelles et des sites de déversement (actifs ou en panne).
- **Dynamique des files d'attente :** la longueur actuelle et les temps d'attente estimés pour tous les points de chargement et de déchargement.
- **Contexte temporel :** l'instant actuel de la simulation et l'état du réseau routier.
- **Événements opérationnels :** indicateurs de perturbations récentes ou de pannes d'équipement.

#### 3.3.2 Espace d'action (A)

L'action **A_t** se produit chaque fois qu'un camion devient « disponible pour être affecté » (généralement après le déchargement ou au début d'un quart de travail). L'agent doit sélectionner une destination parmi un ensemble de pelles ou de décharges admissibles. L'espace d'action est discret, chaque action représentant une affectation spécifique : **Camion_i → Pelle_j** ou **Camion_i → Décharge_k**.

#### 3.3.3 Fonction de transition (P)

La fonction de transition **P(S_{t+1} | S_t, A_t)** décrit l'évolution du système. Dans cette étude, la transition est régie par le moteur de simulation stochastique sous-jacent. Elle tient compte des temps de trajet, des durées de chargement/déchargement et de l'apparition de perturbations aléatoires (pannes). La transition est non

déterministe, ce qui signifie qu'une même action dans un même état peut conduire à des états futurs différents en raison de la nature stochastique de l'environnement.

### 3.4 Multi-objective reward function

L'objectif de l'agent est de maximiser la récompense cumulée sur une période de travail. Afin de trouver un équilibre entre productivité et efficacité opérationnelle, nous proposons une fonction de récompense multi-objectifs **R_t** :

$$R_t = w_1 R_{production} - w_2 P_{imbalance} - w_3 C_{operation} - w_4 P_{waiting}$$

Où :

- **R_production** : le tonnage total livré aux sites de déversement au cours de l'étape. Il s'agit du principal moteur du système.
- **P_imbalance** : une pénalité liée au manque de pelles ou à des files d'attente excessives. Elle incite l'agent à répartir les camions de manière homogène dans la mine afin de maintenir un « facteur d'adéquation » élevé.
- **C_operation** : le coût opérationnel, calculé en fonction de la consommation de carburant et de la distance parcourue. Il pénalise les itinéraires longs et inefficaces.
- **P_waiting** : une pénalité spécifique liée au temps d'inactivité des camions dans les files d'attente. Ce terme est crucial pour l'apprentissage de politiques qui privilégient le « flux » du système plutôt que le tonnage brut.

**Calibrage des poids**

Les poids initiaux suivants ont été sélectionnés pour refléter les priorités industrielles, en mettant fortement l'accent sur la production tout en conservant une pénalité significative pour l'attente afin de garantir la résilience :

- $w_1 = 1{,}0$ (Priorité à la production)
- $w_2 = 0{,}1$ (Pénalité de déséquilibre)
- $w_3 = 0{,}05$ (Optimisation des coûts)
- $w_4 = 0{,}3$ (Pénalité liée au temps d'attente)

Cette formulation garantit que l'agent n'apprend pas simplement à déplacer des marchandises, mais qu'il apprend à le faire de manière à minimiser la congestion et à rester robuste même en cas de défaillance des équipements.

## 4. Proposed DRL Framework

Cette section présente en détail le cadre intégré mis au point pour évaluer et comparer des agents d'apprentissage par renforcement dans le domaine minier. Ce cadre comprend un environnement de simulation haute-fidélité, une suite d'algorithmes hétérogènes et un module d'évaluation des performances.

### 4.1 Simulation environment

Afin de combler le fossé entre la recherche abstraite en apprentissage par renforcement (RL) et les applications industrielles, nous avons développé un

environnement de simulation sur mesure respectant l'interface **OpenAI Gymnasium**. Cette normalisation garantit la compatibilité de l'environnement avec les bibliothèques RL de pointe et facilite la reproductibilité.

L'architecture est organisée en plusieurs modules fonctionnels :

- **Moteur de simulation :** un moteur fonctionnant par pas de temps qui gère la physique du transport, y compris les vitesses variables en fonction de la pente de la route et de la charge utile du camion.

- **Module de réseau routier :** met en œuvre une représentation sous forme de graphe de la mine. Il utilise l'algorithme de Dijkstra pour le calcul d'itinéraires et intègre des distributions stochastiques des temps de trajet.

- **Module de consommation d'énergie :** calcule la consommation de carburant en fonction des besoins instantanés en puissance, en tenant compte de la marche au ralenti, du transport en montée et du freinage.

- **Modules KPI et de référence :** ces composants suivent les indicateurs opérationnels en temps réel, permettant une comparaison directe entre les agents RL actifs et les heuristiques industrielles prédéfinies.

## 4.2 PPO policy

L'agent principal étudié repose sur l'**optimisation par politique proximale (PPO)**, un algorithme de type « acteur-critique » apprécié pour sa stabilité et sa fiabilité dans les espaces d'états continus et discrets. La fonction objectif de la PPO utilise un objectif de substitution « clippé » afin d'éviter des mises à jour de politique importantes et déstabilisantes, ce qui est essentiel compte tenu de la nature stochastique des perturbations minières.

### 4.2.1 Architecture du réseau neuronal

Les réseaux **Acteur** (politique) et **Critique** (fonction de valeur) partagent tous deux une architecture de perceptron multicouche (MLP) :

- **Couches cachées :** deux couches denses comportant chacune 128 neurones.

- **Fonction d'activation :** unité linéaire rectifiée (ReLU) pour les couches cachées, garantissant une propagation efficace du gradient.

- **Couche de sortie :** une distribution Softmax sur l'espace d'action discret (pelles/bennes disponibles).

### 4.2.2 Configuration des hyperparamètres

Afin d'assurer la convergence dans un environnement minier bruité, les paramètres suivants ont été minutieusement ajustés :

- **Taille de lot :** 64, pour trouver un équilibre entre la stabilité du gradient et la vitesse de calcul.

- **n_steps :** 1 024 (horizon pour les mises à jour de la politique).

- **λ de l'estimation généralisée de l'avantage (GAE) :** 0,95, afin de réduire la variance des estimations d'avantage.

- **Plage de limitation :** 0,2, limitant le taux de changement de politique à un intervalle de 20 %.

- **Coefficient d'entropie :** 0,02, favorisant une exploration suffisante pendant les premières phases d'apprentissage afin d'éviter les optima locaux dans les réseaux routiers complexes.

### 4.3 Comparative algorithms

Afin d'évaluer les avantages de l'apprentissage par renforcement dynamique (DRL), nous avons mis en œuvre trois modèles d'apprentissage comparatifs :

1. **Deep Q-Network (DQN) :** une approche de DRL basée sur la valeur qui utilise un tampon de relecture et un réseau cible pour stabiliser l'apprentissage de la fonction Q :
    - $Q(s, a) \leftarrow r + \gamma \max Q(s', a')$.
2. **Q-Learning tabulaire :** un algorithme hors-politique fondamental qui stocke les valeurs état-action dans un tableau discret. Il sert de référence pour comprendre la nécessité des approximations neuronales dans les états d'exploration à haute dimension.
3. **SARSA (État-Action-Récompense-État-Action) :** une méthode tabulaire « on-policy » qui met à jour les valeurs en fonction de l'action réellement effectuée :
    - $Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma Q(s', a') - Q(s, a)]$.

### 4.4 System architecture

L'architecture du système repose sur une conception découplée, séparant la logique d'apprentissage de la simulation opérationnelle. Cette modularité permet de tester différents agents selon le principe « plug-and-play ».

#### 4.4.1 Efficacité de calcul

Le cadre est optimisé tant pour l'entraînement que pour le déploiement :

- **Complexité de l'entraînement :** La convergence est généralement atteinte au bout de cycles de mise à jour de 1 024 étapes. La durée totale de l'entraînement reste gérable sur du matériel standard, ce qui permet des itérations rapides sur les configurations minières.

- **Inférence en temps réel :** Une fois entraîné, le modèle ne nécessite qu'une charge de calcul minimale. Une décision (affectation d'un camion) est calculée en moins de 10 millisecondes, ce qui rend le système parfaitement compatible avec les exigences de latence de l'ordre de la milliseconde des systèmes industriels de gestion de flotte (FMS).

- **Utilisation de la mémoire :** L'empreinte mémoire totale de l'agent entraîné est extrêmement faible (moins de 50 Mo), ce qui garantit que le système peut être intégré à des dispositifs locaux d'informatique en périphérie situés sur les pelles mécaniques ou au sein des centres de communication à l'échelle du site.

## 5. Experimental Design

Afin de garantir une évaluation rigoureuse et équitable, nous avons élaboré un protocole de comparaison standardisé. Cette section présente en détail les scénarios opérationnels, les politiques de référence, les indicateurs de performance et le cadre statistique utilisés pour valider les résultats.

### 5.1 Scenarios

Nous définissons trois scénarios distincts afin d'évaluer l'adaptabilité et la résilience des politiques de répartition. Chaque épisode de simulation correspond à un quart de travail standard de 8 heures dans une mine (480 minutes). Les camions ont une capacité de 140 tonnes et une vitesse moyenne de 32 km/h à vide et de 26 km/h en charge.

| **Scenario** | **Trucks** | **Shovels** | **Dump Sites** | **Breakdown Rate** | **Operational Characteristic** |
|---|---|---|---|---|---|
| Nominal | 12 | 3 | 2 | 2% | Standard, balanced conditions |
| High-load | 18 | 3 | 2 | 2% | Fleet oversaturation and congestion |
| High-breakdown | 12 | 3 | 2 | 10% | Frequent equipment failures |

Le scénario « **High-load** » teste la capacité de l'agent à gérer des files d'attente importantes, tandis que le scénario « **High-breakdown** » évalue la résilience opérationnelle dans un contexte de forte incertitude.

### 5.2 Baselines

Afin d'établir une référence exhaustive, nous comparons l'agent PPO à sept autres politiques, regroupées en trois familles :

- **Heuristiques statiques :** FIFO, affectation fixe, « Nearest Shovel » et « Shortest Path ». Celles-ci représentent les normes industrielles actuelles.
- **Apprentissage par renforcement tabulaire :** Q-Learning et SARSA, utilisés pour évaluer l'impact de l'approximation neuronale par rapport aux tables d'états discrets.
- **Apprentissage par renforcement basé sur la valeur (DRL) :** DQN, pour comparer les méthodes de gradient de politique (PPO) à l'apprentissage profond basé sur la valeur.

### 5.3 Metrics

Nous utilisons cinq indicateurs clés de performance (KPI) pour évaluer l'efficacité de chaque politique :

1. **Productivité :** mesurée en tonnes totales livrées par heure (t/h).
2. **Temps d'attente moyen :** temps moyen pendant lequel les camions restent à l'arrêt dans les files d'attente par cycle.
3. **Utilisation des équipements :** pourcentage de temps pendant lequel les pelles et les camions effectuent des tâches productives.
4. **Consommation spécifique :** carburant ou énergie consommée par tonne transportée, reflétant la durabilité.
5. **Ratio de robustesse :** Pour quantifier la résilience, nous calculons le rapport entre la performance dans des scénarios perturbés et celle dans des conditions nominales :
    - *Ratio de robustesse(p,s) = Performance(p,s) / Performance(p,nominal)*

5.4 Statistical protocol

Conformément aux normes de recherche à fort impact, nous ne nous appuyons pas sur des simulations uniques.

- **Réplications :** Chaque politique est évaluée au cours de 30 réplications indépendantes afin de garantir la puissance statistique et la validité des intervalles de confiance.
- **Contrôle des graines aléatoires :** Des graines aléatoires identiques sont utilisées pour toutes les politiques au cours de chaque réplication. Cela garantit que chaque algorithme est confronté à la séquence exacte des mêmes événements stochastiques (par exemple, une panne survient à la même minute pour la méthode PPO que pour la méthode FIFO).
- **Normalité et variance :** Nous appliquons le **test de Shapiro-Wilk** pour vérifier la normalité et le **test de Levene** pour évaluer l'homogénéité des variances (homoscédasticité).

**Statistiques inférentielles**

Sur la base des résultats des tests de normalité, nous appliquons :

- **ANOVA à un facteur** (ou **ANOVA de Welch** si les variances sont inégales) pour déterminer s'il existe des différences significatives entre les politiques.
- **Tests post-hoc : HSD de Tukey** (pour les données normales) ou **test de Dunn** (pour les données non paramétriques) afin d'identifier des différences spécifiques par paires.
- **Correction de Holm-Bonferroni :** appliquée à toutes les valeurs p afin de contrôler les erreurs de type I dans les comparaisons multiples.
- **Taille de l'effet :** nous calculons le **d de Cohen** ou le **delta de Cliff** pour mesurer l'ampleur pratique des améliorations de performance.
- **Intervalles de confiance :** des intervalles à 95 % sont générés à l'aide de la **méthode du bootstrap** afin de fournir une fourchette robuste pour la performance moyenne.

### 5.5 Reproducibility settings

Afin de garantir la reproductibilité de cette étude, tous les paramètres et hyperparamètres de simulation sont fixes. La simulation est implémentée en Python 3.10 à l'aide de Gymnasium 0.26. L'entraînement des agents PPO et DQN a été réalisé sur une configuration matérielle standardisée, tous les générateurs de nombres aléatoires (RNG) étant initialisés avec une graine globale. Les poids de récompense spécifiques ($w_1$=1, $w_2$=0,1, $w_3$=0,05, $w_4$=0,3) ont été maintenus constants tout au long des expériences d'apprentissage par renforcement.

## 6. Results

Cette section présente les résultats empiriques issus de nos simulations multi-scénarios. Nous nous intéressons plus particulièrement à la hiérarchie des performances des politiques évaluées et à l'évolution de leur comportement en situation de contrainte opérationnelle.

### 6.1 Productivity

L'indicateur de performance principal, à savoir la productivité (tonnes par heure), a été mesuré pour tous les scénarios. Le tableau 3 présente les valeurs moyennes et les écarts-types pour les algorithmes de base.

| **Policy** | **Nominal (t/h)** | **High-load (t/h)** | **High-breakdown (t/h)** |
|---|---|---|---|
| FIFO | 3,290.00 ± 42 | 4,747.80 ± 70 | 3,115.00 ± 74 |
| Fixed Assignment | 4,074.00 ± 40 | 5,874.80 ± 53 | 3,860.50 ± 38 |
| DQN (Deep RL) | 4,168.50 ± 66 | **5,664.80 ± 65** | **3,991.75 ± 56** |
| PPO (Deep RL) | **4,208.75 ± 49** | 5,244.80 ± 350 | 3,946.25 ± 63 |

*Remarque : les valeurs en gras indiquent la meilleure performance dans chaque scénario.*

Dans des conditions nominales, **PPO** a atteint la productivité la plus élevée (4 208,75 t/h), surpassant la norme industrielle (affectation fixe) de 3,3 %. Cependant, dans le scénario « **High-breakdown** », **DQN** s'est révélé plus résilient, en maintenant un débit de 3 991,75 t/h, tandis que les performances de PPO sont tombées légèrement en dessous de celles de DQN.

### 6.2 Waiting time and congestion

L'une des observations clés de cette étude est le découplage entre la productivité et la fluidité du système. Dans le scénario **« High-load »**, alors que la productivité augmente en raison du volume considérable de camions, la congestion devient le facteur limitant.

Nous avons observé un **« effondrement dû à la congestion »** pour les heuristiques myopes (par exemple, « Nearest Shovel » et « FIFO »), où les temps d'attente moyens ont grimpé à plus de **200 minutes par cycle**. En revanche, les agents PPO et DQN ont appris à répartir de manière proactive les camions vers les pelles sous-utilisées, maintenant ainsi les temps d'attente en dessous de 95 minutes, même en cas de saturation extrême de la flotte. Cela démontre que les politiques DRL ne se contentent pas de maximiser le tonnage ; elles optimisent le « flux » de la mine.

### 6.3 Robustness under disruptions

Afin de quantifier la résilience de chaque stratégie, nous avons calculé l'**indice de dégradation en cas de panne (Δ*panne*)**, qui représente le pourcentage de perte de productivité lors du passage d'un état nominal à un état de pannes fréquentes.

- Stratégie à affectation fixe : perte de 5,24 %.
- **PPO :** perte de 6,23 %.
- **DQN : perte de 4,24 %.**

Les résultats indiquent que **DQN est la politique la plus robuste**, celle qui subit la plus faible baisse de performance en cas de pannes fréquentes des équipements. Alors que PPO est la plus efficace dans des conditions stables, sa plus grande sensibilité aux perturbations suggère que les méthodes basées sur la valeur (DQN) pourraient mieux prendre en compte la nature stochastique des pannes pendant le processus d'apprentissage.

### 6.4 Statistical significance

Afin de valider ces résultats, une **ANOVA de Welch** a été réalisée, révélant un effet significatif de la politique de répartition sur la productivité ($p<0,001$).

- **Comparaisons par paires :** Les tests post-hoc de Tukey HSD ont confirmé que la supériorité de la PPO par rapport à l'affectation fixe dans des conditions nominales est statistiquement significative ($p=0,0024$, $d$de Cohen = 2,1).
- **Taux de défaillance élevé :** La différence entre le DQN et l'affectation fixe était également significative ($p< 0,001$), tandis que la différence entre le DQN et le PPO était marginale ($p= 0,081$), ce qui indique que les deux méthodes DRL offrent une résilience comparable.

### 6.5 Convergence

Les courbes de convergence des agents d'apprentissage par renforcement (Q-Learning, SARSA, DQN et PPO) révèlent des comportements d'apprentissage distincts.

- **Le PPO et le DQN** ont affiché une convergence stable en moins de 2 millions d'étapes, la variance du signal de récompense diminuant à mesure que l'entraînement progressait.
- **Les méthodes tabulaires** ont convergé plus rapidement, mais vers des plateaux nettement plus bas, ce qui prouve que les représentations d'états discrets sont insuffisantes pour saisir les interdépendances complexes d'un environnement impliquant plusieurs camions.

### 6.6 Ablation study

L'étude d'ablation s'est concentrée sur le poids de la pénalité liée au temps d'attente ($w4$) dans la fonction de récompense.

Lorsque ***w4=0***, l'agent est devenu « avide de tonnage », ce qui a conduit à une productivité élevée mais à des files d'attente catastrophiques (>150 min).

Avec **w4=0,5**, l'agent devenait trop prudent, privilégiant les files d'attente vides au détriment des opérations de chargement, ce qui entraînait une baisse de 12 % de la productivité.

L'équilibre optimal a été trouvé à w4=0,3, ce qui offrait le meilleur compromis entre débit et fluidité opérationnelle.

## 7. Discussion

Les résultats présentés dans la section précédente offrent une évaluation exhaustive de l'apprentissage par renforcement dans le domaine de la logistique minière. Cette section interprète ces résultats sous l'angle scientifique, industriel et environnemental, tout en reconnaissant les limites inhérentes à cette étude.

### 7.1 Scientific interpretation

L'une des principales conclusions de cette recherche est qu'**aucune politique de répartition n'est universellement dominante**.

- **PPO vs DQN :** La supériorité de la PPO dans des conditions nominales (4 208 t/h) peut être attribuée à sa nature de gradient de politique, qui permet une exploration plus fluide et des mises à jour plus stables dans des espaces d'états de haute dimension. Cependant, la robustesse du DQN face à des pannes fréquentes (scénario à forte fréquence de pannes) suggère que les méthodes basées sur la valeur, utilisant un tampon de relecture d'expérience, peuvent mieux prendre en compte les « chocs » discrets de l'environnement, tels que les pannes soudaines d'équipements.

- **L'échec des heuristiques :** Les heuristiques traditionnelles telles que « Nearest Shovel » échouent dans les scénarios à forte charge car elles procèdent à une optimisation locale. Ce comportement « glouton » crée des « points chauds » ou des goulots d'étranglement, où une seule pelle se retrouve surchargée tandis que d'autres restent sous-utilisées. Cette étude démontre que **l'optimisation locale conduit à une congestion globale**, tandis que les agents DRL apprennent à sacrifier la proximité immédiate au profit du flux global du système à long terme.

- **Indépendance de la robustesse :** Nos résultats confirment que **la performance nominale est distincte de la résilience opérationnelle**. Une politique hautement efficace dans des conditions stables n'est pas nécessairement la plus robuste en situation de contrainte. Cela suggère que les futurs systèmes de gestion de flottes (FMS) miniers doivent être évalués selon plusieurs « régimes » plutôt que sur la seule base de leur performance moyenne.

### 7.2 Industrial implications

L'intégration du DRL dans les flottes minières doit être considérée comme une **couche décisionnelle complémentaire** plutôt que comme un remplacement total des systèmes de gestion de flotte (FMS) existants.

- **Mode de recommandation :** Dans un premier temps, les agents DRL devraient fonctionner en « mode de recommandation », en fournissant des suggestions d'affectation optimisées aux répartiteurs humains ou aux contrôleurs de transport autonomes. Cela permet une approche hybride où l'IA gère la complexité tandis que les humains assurent la supervision.

- **Validation préalable au déploiement :** Les écarts de performance significatifs observés dans certains scénarios soulignent la nécessité d'une validation hors ligne rigoureuse à l'aide de « jumeaux numériques » avant toute mise en œuvre en conditions réelles.

- **Intervention humaine :** Il reste essentiel de maintenir un contrôle humain, en particulier pendant la période de transition, afin de gérer les cas limites que la simulation n'aurait pas pu couvrir.

### 7.3 Sustainability

Bien que cette étude se concentre principalement sur la productivité, ses retombées sur la durabilité sont significatives.

- **Réduction des temps d'inactivité :** En réduisant les temps d'attente des camions (en les maintenant en dessous de 95 minutes contre 200 minutes selon l'approche heuristique), les politiques DRL diminuent directement la « marche au ralenti », une source majeure de gaspillage de carburant dans les mines à ciel ouvert.

- **Consommation spécifique :** La réduction des temps de cycle et l'optimisation des itinéraires laissent entrevoir une réduction potentielle de la consommation de carburant par tonne transportée. Nous soulignons toutefois que **les améliorations environnementales doivent être mesurées directement lors de futurs essais sur le terrain** avant de pouvoir affirmer de manière définitive une réduction des émissions de $CO_2$. Néanmoins, la tendance à une plus grande fluidité du système est une condition préalable à une exploitation minière plus durable.

### 7.4 Limitations

Malgré la rigueur de cette étude, plusieurs limites doivent être prises en compte :

- **Lacunes de la simulation :** L'étude s'appuie sur un environnement simulé. Bien qu'il soit très fidèle à la réalité, il peut ne pas rendre compte de toutes les subtilités d'une mine physique, telles que les effets imprévisibles des conditions météorologiques ou les variations dans le comportement des conducteurs.

- **Homogénéité de la flotte :** Notre modèle suppose une flotte largement homogène. En réalité, les mines exploitent souvent des camions d'âges et de capacités variés, ce qui ajoute une couche supplémentaire de complexité à la logique de répartition.

- **Espace d'action discret :** L'agent est limité à un ensemble discret de pelles et de sites de déversement. Des travaux futurs devraient explorer des espaces d'action continus ou hiérarchiques afin de mieux modéliser les intersections complexes et les opérations multi-carrières.

- **Sélection des algorithmes :** Cette étude s'est concentrée sur les algorithmes PPO, DQN et l'apprentissage par renforcement tabulaire. Les recherches futures pourraient intégrer des algorithmes « off-policy » plus avancés, tels que **Soft Actor-Critic (SAC)** ou **l'apprentissage par renforcement multi-agents (MARL)**, afin de gérer la coordination décentralisée des camions.

- **Échelle :** Les expériences ont utilisé un nombre limité de pelles et de camions. L'adaptation de ces politiques à des « méga-mines » comptant des centaines de véhicules reste un défi majeur pour les recherches futures.

## 8. Conclusion and Future Work

Cette étude s'est penchée sur la question cruciale de savoir si les politiques d'apprentissage par renforcement profond (DRL) peuvent améliorer la productivité et la résilience opérationnelle des systèmes « camion-pelle » par rapport aux heuristiques industrielles traditionnelles. En comparant huit politiques de répartition distinctes dans trois régimes opérationnels stochastiques — nominal, forte charge et nombreuses pannes —, nous avons fourni une évaluation complète de la logistique adaptative dans l'exploitation minière à ciel ouvert.

La méthodologie a utilisé un simulateur haute-fidélité basé sur Gymnasium, intégrant des temps de trajet stochastiques et des modèles de défaillance des équipements. Les principaux résultats démontrent que les architectures DRL surpassent largement les heuristiques statiques dans des environnements complexes. Plus précisément, l'agent PPO a atteint une productivité maximale de 4 208,75 t/h dans des conditions nominales, ce qui représente une amélioration de 3,3 % par rapport à la norme industrielle. Plus important encore, l'étude a quantifié un « effondrement dû à la congestion » des heuristiques myopes en cas de sursaturation de la flotte, où les temps d'attente dépassaient 200 minutes, tandis que les agents DRL maintenaient la fluidité du système. De plus, le DQN s'est révélé être la politique la plus résiliente, présentant la plus faible dégradation des performances (4,24 %) lors de pannes d'équipements à haute fréquence.

La principale contribution scientifique de cette recherche est de démontrer que la résilience opérationnelle constitue une dimension distincte de la performance, distincte de l'efficacité nominale. Nous avons montré que la stratégie de répartition optimale dépend du régime ; une stratégie qui excelle dans des conditions stables n'est pas nécessairement la plus robuste en cas de perturbation. Ce résultat souligne la nécessité pour les systèmes de gestion de flotte (FMS) de s'éloigner des règles d'optimisation locales et statiques pour s'orienter vers des agents adaptatifs, ayant une vision globale, capables d'anticiper la propagation des retards à travers le réseau de transport.

La principale limite de ce travail réside dans le fait qu'il repose sur un environnement simulé et un espace d'action discret. Bien que le simulateur soit d'haute-fidélité, l'écart entre la simulation et la réalité persiste, notamment en ce qui concerne l'imprévisibilité du comportement des opérateurs humains et la variabilité de l'environnement.

Par conséquent, les travaux à mener dans un avenir proche devraient se concentrer sur le développement de cadres d'apprentissage par renforcement hiérarchique ou multi-agents (MARL), dans lesquels chaque camion fonctionne comme un agent décentralisé doté de capteurs locaux et d'une coordination globale. La prochaine étape de validation consistera à tester ces politiques sur un « jumeau numérique » calibré à l'aide de données opérationnelles réelles provenant d'un site minier en activité. Une telle transition sera essentielle pour vérifier l'évolutivité des agents DRL à l'échelle de centaines de véhicules et pour quantifier leur impact direct sur la consommation de carburant et les émissions de carbone dans un environnement minier physique. À terme, cette recherche ouvre la voie à la prochaine génération de logistique minière autonome, résiliente et durable.

**Disponibilité des données**

Les ensembles de données synthétiques générés au cours de la présente étude, y compris les journaux de simulation et les indicateurs de performance pour les différents scénarios opérationnels, sont disponibles auprès de l'auteur correspondant sur simple demande raisonnable.

**Disponibilité du code**

Le code source du simulateur d'exploitation minière stochastique (environnement basé sur Gymnasium) ainsi que les implémentations des agents d'apprentissage par renforcement de type PPO, DQN et tabulaire sont hébergés sur GitHub et peuvent être fournis à des fins d'évaluation par les pairs ou de recherche sur simple demande.

**Contributions des auteurs**

**Jean-Luc MUPASA KALUNGA :** Conceptualisation, méthodologie, logiciel, validation, analyse formelle, recherche, rédaction du premier jet, visualisation.

**Dr Olfa FERCHICHI :** Supervision, conceptualisation, méthodologie, rédaction – révision et correction, gestion du projet.

**Conflit d'intérêts**

Les auteurs déclarent n'avoir aucun conflit d'intérêts financier ni aucune relation personnelle connus qui auraient pu sembler influencer les travaux présentés dans cet article.

References