REMARQUES DE CORRECTION SCIENTIFIQUE

Beyond Static Dispatching Heuristics: A Comparative Evaluation of Deep Reinforcement Learning under Disruptions in Open-Pit Mining

Objet : synthèse des principales corrections méthodologiques, statistiques et rédactionnelles à effectuer avant soumission de l'article.

1. Contradiction dans la définition de « Fixed Assignment »

Priorité élevée

Constat. Dans la section consacrée aux heuristiques statiques, le texte indique que l'affectation n'est jamais révisée, y compris lorsque l'équipement devient indisponible. En revanche, le Tableau 5 précise qu'une réaffectation est réalisée si la pelle initialement affectée est indisponible à cause d'une panne.

Correction recommandée. Choisir une seule définition opérationnelle et l'appliquer de façon cohérente dans tout le manuscrit. Si une réaffectation de secours est autorisée, il faut la décrire explicitement dans la définition principale de Fixed Assignment.

2. Incohérence entre le test global et le post-hoc

Priorité critique

Constat. La méthodologie statistique indique correctement : Welch ANOVA → Games–Howell ; Kruskal–Wallis → test de Dunn ; puis correction de Holm–Bonferroni. Toutefois, le Tableau 10 associe Kruskal–Wallis à Games–Howell dans les scénarios High-load et High-breakdown.

Correction recommandée. Recalculer les comparaisons post-hoc avec Dunn + Holm lorsque Kruskal–Wallis est retenu, ou modifier le test global si les analyses réellement exécutées relèvent du cadre Welch/Games–Howell. Le tableau, le texte et les scripts doivent être strictement alignés.

3. Référence interne non résolue « Section ?? »

Priorité élevée

Constat. Dans la section Convergence, le manuscrit contient une référence non résolue : « described in Section ?? ».

Correction recommandée. Corriger la référence LaTeX. Elle semble devoir renvoyer à la section décrivant le protocole de réplication/statistique (probablement Section 5.4 ou 5.5 selon l'intention exacte). Vérifier toutes les références croisées avant soumission.

4. Budget d'apprentissage incohérent

Priorité critique

Constat. Le Tableau 3 indique 2 000 000 de pas pour PPO et DQN, mais 30 000 épisodes pour Q-Learning et SARSA. Plus loin, la section Reproducibility settings affirme que PPO, DQN, Q-Learning et SARSA ont tous été entraînés pendant 2 000 000 de timesteps.

Correction recommandée. Harmoniser la description du budget d'entraînement. Indiquer pour chaque méthode l'unité réellement utilisée (timesteps ou épisodes), la durée effective et, si nécessaire, expliquer pourquoi les budgets ne sont pas directement comparables.

5. Interprétation trop causale du replay buffer de DQN

Priorité élevée

Constat. Le manuscrit affirme que le replay buffer permet à DQN de « sur-échantillonner » les transitions rares de panne et attribue ensuite à ce mécanisme un avantage de robustesse. Un replay buffer standard réutilise les transitions, mais ne les sur-échantillonne pas nécessairement en l'absence de prioritized replay ou d'un mécanisme explicite de stratification.

Correction recommandée. Remplacer l'affirmation causale par une formulation prudente : « Experience replay allows DQN to reuse transitions involving equipment failures during multiple gradient updates, which may contribute to its robustness under breakdown conditions. » Éviter de conclure que le replay buffer est la cause démontrée de la meilleure robustesse sans expérience d'ablation spécifique.

6. Clarifier la nature des 30 réplications dans l'ablation study

Priorité élevée

Constat. Le Tableau 11 indique 30 réplications, mais le manuscrit ne précise pas clairement s'il s'agit de 30 entraînements indépendants avec des seeds différentes ou d'un seul modèle entraîné puis évalué sur 30 seeds de simulation.

Correction recommandée. Préciser le protocole exact. Si un seul modèle est évalué 30 fois, l'écart-type mesure surtout la variabilité d'évaluation sous stochasticité et ne permet pas, à lui seul, de conclure à une « convergence instable ». Pour analyser la stabilité d'apprentissage, plusieurs seeds d'entraînement sont nécessaires.

7. Sensibilité des hyperparamètres insuffisamment documentée

Priorité moyenne à élevée

Constat. Le texte affirme avoir testé plusieurs valeurs du coefficient d'entropie, du learning rate et du clip range et conclut que la performance de PPO n'est pas un artefact d'une configuration particulière. Cependant, les résultats détaillés de ce sweep ne sont pas fournis.

Correction recommandée. Ajouter un tableau synthétique indiquant les valeurs testées, la meilleure configuration, la productivité, le temps d'attente et éventuellement l'écart-type/intervalle de confiance. À défaut, réduire la force de la conclusion.

8. Conclusion de l'abstract trop générale sur la supériorité du DRL

Priorité élevée

Constat. La formulation « DRL policies improve dispatching resilience relative to static heuristics » est trop générale. Les résultats montrent au contraire une forte dépendance au régime : PPO domine en nominal, Fixed Assignment est très compétitif en High-load, et DQN domine en High-breakdown.

Correction recommandée. Reformuler pour insister sur le caractère dépendant du régime et sur l'absence de domination universelle. Proposition : « These results demonstrate that the benefits of deep reinforcement learning for truck dispatching are strongly regime-dependent rather than universally superior to those of conventional heuristics. »

9. Expression « high-fidelity simulator » à modérer

Priorité moyenne

Constat. Le manuscrit qualifie le simulateur de « high-fidelity » alors qu'aucune validation sur une mine réelle n'est présentée et que la section Limitations reconnaît explicitement un sim-to-real gap.

Correction recommandée. Employer une formulation plus défendable : « custom stochastic open-pit mining simulator » ou « detailed stochastic simulation environment ». Réserver « high-fidelity » à un simulateur calibré et validé sur des données terrain.

10. Partie Sustainability : renforcer l'appui statistique

Priorité élevée

Constat. Le texte rapporte notamment une réduction d'environ 5,5 % de la consommation spécifique de DQN par rapport à Fixed Assignment en nominal avec $p < 0{,}001$. Le Tableau 13 présente toutefois principalement les moyennes, sans dispersion ni tableau statistique correspondant.

Correction recommandée. Ajouter mean ± SD ou IC 95 % pour la consommation spécifique, préciser le test statistique appliqué et fournir les p-values corrigées / tailles d'effet pour les comparaisons énergétiques principales. Maintenir une formulation prudente sur les émissions car les résultats sont issus de simulation et aucune mesure directe de CO2/NOx n'a été effectuée.

Proposition de reformulation du dernier paragraphe de l'abstract

> *These results demonstrate that the benefits of deep reinforcement learning for truck dispatching are strongly regime-dependent rather than universally superior to those of conventional heuristics. PPO provides the highest productivity under nominal conditions, whereas Fixed Assignment remains highly competitive under fleet oversaturation and DQN exhibits the strongest absolute throughput under frequent equipment failures. The observed reversal in policy rankings across operating regimes highlights the limitations of single-scenario evaluation and supports the use of multi-regime stress-testing when assessing the operational resilience of intelligent fleet-management policies.*