PLAN DÉTAILLÉ D'UN ARTICLE SCIENTIFIQUE POUR UNE REVUE Q1

Apprentissage par renforcement profond pour le dispatching dynamique dans les mines à ciel ouvert

Document de structuration scientifique à partir du mémoire de Jean-Luc MUPASA KALUNGA

1. Positionnement scientifique recommandé

L'article ne doit pas être présenté comme une simple application de PPO à la logistique minière. Un tel positionnement serait trop général pour une revue Q1 et risquerait d'être perçu comme une étude d'application sans contribution méthodologique suffisamment forte.

Le positionnement recommandé est le suivant :

Robustesse et adaptabilité des politiques de Deep Reinforcement Learning pour le dispatching dynamique de camions dans des mines à ciel ouvert soumises à des perturbations opérationnelles.

La contribution scientifique centrale consistera à démontrer que :

- les meilleures politiques ne sont pas nécessairement les mêmes selon le scénario opérationnel ;
- PPO peut être supérieur dans des conditions nominales ;
- DQN peut présenter une meilleure robustesse dans certaines conditions de panne ;
- les politiques statiques peuvent provoquer une congestion sévère lorsque la flotte est surdimensionnée ;
- une politique adaptative doit être évaluée sur plusieurs régimes opérationnels, et non seulement sur sa performance moyenne.

2. Titres possibles

- Robust Deep Reinforcement Learning for Dynamic Truck Dispatching in Stochastic Open-Pit Mining Operations
- Beyond Static Dispatching Heuristics: A Comparative Evaluation of Deep Reinforcement Learning under Disruptions in Open-Pit Mining
- Resilient Truck Dispatching in Open-Pit Mines: Benchmarking PPO and DQN under Congestion and Equipment Breakdowns
- A Multi-Scenario Benchmark of Reinforcement Learning Policies for Dynamic Truck–Shovel Dispatching in Open-Pit Mines

Le deuxième et le troisième titres sont les plus attractifs pour une revue de haut niveau, car ils mettent directement en avant la comparaison, les perturbations et la résilience opérationnelle.

3. Question centrale de recherche

To what extent can deep reinforcement learning policies improve the productivity and operational resilience of truck–shovel systems compared with static industrial dispatching heuristics under nominal, congested and breakdown-prone conditions?

Questions secondaires

- Quelle politique offre la meilleure productivité dans chaque scénario ?
- Quel est le compromis entre productivité et temps d'attente ?
- Les écarts observés sont-ils statistiquement significatifs ?
- Les politiques apprises restent-elles robustes lorsque les conditions d'exploitation diffèrent de celles de l'entraînement ?
- Quelle politique présente la meilleure stabilité entre plusieurs graines aléatoires ?

4. Contributions scientifiques à annoncer

4.1. Environnement de simulation stochastique

Développement d'un environnement de simulation représentant un système camion-pelle avec :

- pelles et points de déchargement ;
- files d'attente ;
- temps de déplacement stochastiques ;
- pannes et dégradation des routes ;
- congestion ;
- décisions dynamiques de dispatching.

Le simulateur est structuré sous Gymnasium et mobilise un espace d'observation de 147 dimensions ainsi que sept actions possibles.

4.2. Benchmark expérimental étendu

Comparaison de huit politiques :

- FIFO
- Fixed Assignment
- Nearest Shovel
- Shortest Path
- Q-Learning
- SARSA
- DQN
- PPO

L'évaluation doit couvrir trois scénarios : nominal, surcharge de flotte et fréquence élevée de pannes.

4.3. Évaluation multi-indicateurs

- productivité en tonnes par heure ;
- temps d'attente moyen ;
- taux d'utilisation ;
- consommation spécifique ;
- nombre de cycles ;

- récompense cumulée.

4.4. Analyse de robustesse

Cette contribution doit constituer le cœur de l'article. Elle consistera à étudier la dégradation des performances lorsque le système passe d'un scénario nominal vers des scénarios congestionnés ou fortement perturbés.

5. Plan détaillé de l'article

5.1. Abstract — 200 à 250 mots

Contexte : Les systèmes camion-pelle représentent une composante critique des coûts et de la productivité des mines à ciel ouvert.

Limite de la littérature : Les règles statiques et plusieurs travaux RL sont souvent évalués dans des environnements simplifiés ou sous un seul régime d'exploitation.

Objectif : Évaluer la performance et la robustesse de plusieurs politiques RL et DRL dans des conditions nominales et perturbées.

Méthode : Comparer huit politiques sur trois scénarios, avec plusieurs réplications indépendantes et des indicateurs de productivité, d'attente, d'utilisation et de consommation.

Résultats principaux : Mentionner seulement deux ou trois résultats majeurs, par exemple la meilleure productivité de PPO en conditions nominales, la robustesse de DQN en présence de pannes et l'effondrement de certaines heuristiques sous surcharge.

Conclusion : Les politiques DRL améliorent la résilience du dispatching, mais leur performance dépend du régime opérationnel.

5.2. Mots-clés

- Deep reinforcement learning
- Open-pit mining
- Truck dispatching
- Fleet management
- Operational resilience
- Stochastic simulation
- PPO
- DQN

5.3. Introduction — 900 à 1 200 mots

5.3.1. Contexte industriel

- importance du système camion-pelle ;
- pertes associées aux files d'attente ;
- coûts énergétiques et opérationnels ;
- variabilité des conditions réelles.

5.3.2. Limites des approches existantes

- les heuristiques sont faciles à déployer mais restent myopes ;
- les méthodes déterministes supposent souvent des conditions stables ;
- les métaheuristiques sont fréquemment utilisées hors ligne ;
- les travaux RL existants sont parfois limités à un seul scénario ou à peu de baselines.

5.3.3. Lacune scientifique

Formulation proposée : *Existing studies rarely provide a controlled multi-scenario comparison between static heuristics, tabular reinforcement learning and deep reinforcement learning under both congestion and equipment breakdown conditions*.

5.3.4. Hypothèses

- H1 : les politiques DRL produisent une productivité supérieure aux heuristiques statiques ;
- H2 : les politiques DRL présentent une dégradation de performance plus faible sous perturbation ;
- H3 : la meilleure politique dépend du régime opérationnel ;
- H4 : une productivité élevée ne garantit pas nécessairement une faible congestion.

5.4. Related Work — 1 000 à 1 300 mots

5.4.1. Static and rule-based truck dispatching

- FIFO
- Fixed Assignment
- Nearest Shovel
- Shortest Path

5.4.2. Mathematical optimization and metaheuristics

- programmation linéaire et MILP
- algorithmes génétiques
- colonies de fourmis
- recuit simulé

5.4.3. Reinforcement learning for fleet and dispatching problems

- Q-Learning
- SARSA
- DQN
- actor-critic
- PPO
- multi-agent reinforcement learning

5.4.4. Research gap

La revue doit se terminer par un tableau comparatif démontrant clairement la valeur ajoutée de l'étude proposée.

Étude	Domaine	Méthode	Perturbations	Baselines	Réplications	Tests statistiques
Études antérieures	À compléter	À compléter	Oui/Non	À compléter	À compléter	Oui/Non

Proposed study	Open-pit mining	Heuristics + RL + DRL	Congestion + pannes	8 politiques	10 à 30	Oui

5.5. Problem Formulation — 700 à 900 mots

5.5.1. Truck–shovel system

- camions ;
- pelles ;
- points de déchargement ;
- réseau routier ;
- files d'attente ;
- pannes.

5.5.2. Markov Decision Process

État S_t : position ou statut des camions, disponibilité des pelles, longueur des files, état des routes, temps courant et événements de panne.

Actions A_t : affectation d'un camion à une pelle ou à une destination admissible.

Transition : évolution simulée des trajets, chargements, déchargements, files d'attente et pannes.

Récompense : fonction multiobjectif combinant production, déséquilibre, coût opérationnel et pénalité d'attente.

Fonction de récompense proposée :

$$R_t = w_1 R_production - w_2 P_imbalance - w_3 C_operation - w_4 P_waiting$$

Poids initiaux : $w_1 = 1$; $w_2 = 0,1$; $w_3 = 0,05$; $w_4 = 0,3$.

5.6. Proposed Framework — 900 à 1 100 mots

5.6.1. Architecture de simulation

- environnement Gymnasium ;
- moteur de simulation ;
- graphe routier ;
- calcul des consommations ;
- module RL ;
- module benchmark ;
- module de calcul des KPI.

5.6.2. Agent PPO

- architecture MLP [128, 128] ;
- activation ReLU ;
- batch size 64 ;
- n_steps = 1024 ;
- GAE $\lambda = 0,95$;
- clip range = 0,2 ;

- coefficient d'entropie = 0,02.

5.6.3. DQN et méthodes tabulaires

Présenter DQN, Q-Learning et SARSA comme modèles de comparaison. Les équations classiques doivent rester concises et directement reliées au problème de dispatching.

5.6.4. Heuristiques de référence

Définir précisément les quatre politiques statiques afin de garantir la reproductibilité de la comparaison.

5.6.5. Complexité computationnelle

- temps d'entraînement ;
- temps d'inférence par décision ;
- mémoire utilisée ;
- compatibilité avec une décision en temps réel.

5.7. Experimental Design

5.7.1. Scénarios

Scénario	Camions	Pelles	Déchargements	Taux de panne	Caractéristique
Nominal	12	3	2	2 %	Conditions normales
High-load	18	3	2	2 %	Surcharge de flotte
High-breakdown	12	3	2	10 %	Pannes fréquentes

Chaque épisode dure 480 minutes. Les camions ont une capacité de 140 tonnes, avec une vitesse de 32 km/h à vide et de 26 km/h en charge.

5.7.2. Protocole d'évaluation

- au moins dix réplications indépendantes ;
- graines aléatoires identiques pour toutes les politiques ;
- mêmes scénarios et mêmes distributions stochastiques ;
- idéalement 30 réplications pour renforcer la validité statistique.

5.7.3. Métriques

- productivité ;
- temps d'attente moyen ;
- utilisation des équipements ;
- consommation spécifique ;
- robustesse entre scénarios.

Indicateur de robustesse recommandé :

$$\text{Robustness Ratio}_{(p,s)} = \text{Performance}_{(p,s)} / \text{Performance}_{(p,\text{nominal})}$$

5.7.4. Analyse statistique

- test de Shapiro-Wilk ;
- test de Levene ;

- ANOVA ou Welch-ANOVA ;
- Kruskal-Wallis si nécessaire ;
- tests post-hoc de Tukey ou Dunn ;
- correction de Holm ;
- taille d'effet : Cohen's d, Hedges' g ou Cliff's delta ;
- intervalles de confiance à 95 % par bootstrap.

5.8. Results

5.8.1. Productivité globale

Présenter les résultats sous la forme moyenne ± écart-type avec des intervalles de confiance.

Policy	Nominal	High-load	High-breakdown
FIFO	…	…	…
Fixed Assignment	4 074,00	…	3 860,50
DQN	4 168,50	…	3 991,75
PPO	4 208,75	…	3 946,25

5.8.2. Congestion et temps d'attente

Analyser explicitement les cas où certaines politiques maintiennent une productivité acceptable tout en générant des temps d'attente excessifs. Les valeurs supérieures à 200 minutes sous surcharge constituent un résultat important.

5.8.3. Robustesse sous perturbations

$$\Delta_breakdown = [(P_nominal - P_breakdown) / P_nominal] \times 100$$

Cette analyse permettra de distinguer la meilleure politique nominale, la politique la plus robuste et la politique offrant le meilleur compromis global.

5.8.4. Significativité statistique

Présenter les valeurs p, les intervalles de confiance et les tailles d'effet. Une simple comparaison de moyennes ne sera pas suffisante pour une revue Q1.

5.8.5. Convergence

Présenter les courbes de convergence de Q-Learning, SARSA, DQN et PPO sous la forme moyenne ± intervalle de confiance.

5.8.6. Ablation study

Tester la fonction de récompense avec différentes valeurs de la pénalité d'attente :

- $w_4 = 0$;
- $w_4 = 0{,}1$;
- $w_4 = 0{,}3$;
- $w_4 = 0{,}5$.

5.9. Discussion

5.9.1. Résultats principaux

- expliquer pourquoi PPO domine en scénario nominal ;

- analyser pourquoi DQN peut être plus robuste sous forte fréquence de pannes ;
- montrer pourquoi les heuristiques se dégradent en surcharge ;
- expliquer comment une optimisation locale peut provoquer une congestion globale.

5.9.2. Apports théoriques

- aucune politique n'est universellement dominante ;
- l'adaptabilité est distincte de la performance nominale ;
- la robustesse doit être considérée comme une dimension indépendante ;
- le dispatching minier est un problème multiobjectif et stochastique.

5.9.3. Implications industrielles

- intégration du RL comme couche décisionnelle complémentaire ;
- utilisation en mode recommandation avant un pilotage autonome ;
- validation hors ligne préalable ;
- maintien d'un contrôle humain.

5.9.4. Durabilité

- réduction du temps d'attente ;
- diminution de la marche au ralenti ;
- réduction potentielle de la consommation par tonne ;
- réduction potentielle des émissions.

Aucune amélioration environnementale ne doit être affirmée sans mesure directe.

5.9.5. Limites

- environnement simulé ;
- flotte principalement homogène ;
- nombre limité de pelles et de destinations ;
- absence de validation sur une mine réelle ;
- modèle de panne simplifié ;
- espace d'action discret ;
- réseau routier relativement statique ;
- nombre limité de réplications ;
- absence éventuelle de comparaison avec SAC, A2C, IMPALA ou MARL.

5.10. Conclusion — 400 à 500 mots

La conclusion doit contenir :

- la question de recherche ;
- la méthode ;
- le principal résultat ;
- l'apport scientifique ;
- la limite majeure ;
- la perspective immédiate.

Perspective recommandée : développer une politique multi-agent ou hiérarchique, puis la tester sur des données opérationnelles ou sur un jumeau numérique calibré à partir d'une mine réelle.

6. Figures recommandées

1. Architecture globale du système.
2. Formulation du MDP et interaction agent-environnement.
3. Scénarios expérimentaux.
4. Productivité moyenne avec intervalles de confiance.
5. Temps d'attente moyen avec intervalles de confiance.
6. Heatmap de dégradation entre scénarios.
7. Courbes de convergence ou étude d'ablation.

7. Tableaux recommandés

8. Synthèse critique de la littérature.
9. Définition des états, actions et récompenses.
10. Paramètres des scénarios.
11. Hyperparamètres des algorithmes.
12. Résultats moyenne ± écart-type.
13. Résultats des tests statistiques.
14. Étude d'ablation.

8. Renforcements nécessaires avant soumission Q1

- actualiser la revue bibliographique avec des articles internationaux récents ;
- formuler clairement le research gap ;
- augmenter le nombre de réplications à 30 si possible ;
- ajouter des intervalles de confiance et des tailles d'effet ;
- réaliser une étude d'ablation ;
- effectuer une analyse de sensibilité des hyperparamètres ;
- tester des scénarios non vus pendant l'entraînement ;
- mesurer le temps d'inférence ;
- approfondir l'analyse de la consommation énergétique ;
- mettre à disposition le code, les configurations et les graines ;
- obtenir idéalement une validation par données réelles ou calibration industrielle.

9. Structure finale condensée

```
Title

Abstract
Keywords

1. Introduction
   1.1 Industrial context
   1.2 Research problem
   1.3 Research gap
   1.4 Objectives and hypotheses
   1.5 Contributions

2. Related Work
```

```
   2.1 Static dispatching heuristics
   2.2 Mathematical optimization and metaheuristics
   2.3 Reinforcement learning approaches
   2.4 Critical synthesis and research gap

3. Problem Formulation
   3.1 Truck–shovel system
   3.2 Stochastic road network
   3.3 Markov decision process
   3.4 Multi-objective reward function

4. Proposed DRL Framework
   4.1 Simulation environment
   4.2 PPO policy
   4.3 Comparative algorithms
   4.4 System architecture

5. Experimental Design
   5.1 Scenarios
   5.2 Baselines
   5.3 Metrics
   5.4 Statistical protocol
   5.5 Reproducibility settings

6. Results
   6.1 Productivity
   6.2 Waiting time and congestion
   6.3 Robustness under disruptions
   6.4 Statistical significance
   6.5 Convergence
   6.6 Ablation study

7. Discussion
   7.1 Scientific interpretation
   7.2 Industrial implications
   7.3 Sustainability
   7.4 Limitations

8. Conclusion and Future Work

Data Availability
Code Availability
Author Contributions
Conflict of Interest
References
```

10. Recommandation finale

Le point décisif pour viser une revue Q1 consiste à transformer ce travail d'une simple comparaison d'algorithmes en une véritable étude sur la robustesse opérationnelle du dispatching minier sous perturbations. L'article doit démontrer non seulement quelle politique obtient la meilleure performance, mais aussi pourquoi cette performance varie selon les régimes d'exploitation et comment elle se maintient face à la congestion, aux pannes et à l'incertitude.