

UNIVERSITÉ DON BOSCO DE LUBUMBASHI

FACULTÉ DES SCIENCES INFORMATIQUES

Lubumbashi

www.udbl.ac.cd



Au-delà des heuristiques statiques :

Conception et mise en œuvre d'un agent d'apprentissage par renforcement pour l'optimisation holistique et dynamique de la logistique minière

Présenté par : **Jean-Luc MUPASA KALUNGA**

Dirigé par : **Dr. Olfa FERCHICHI**

Master 2 Data Science — Spécialité Logistique

Année académique 2025–2026

AVRIL, 2026

Dédicace

À compléter...

Remerciements

À compléter...

Résumé

Dans le secteur minier, l'optimisation des coûts opérationnels et la réduction de l'empreinte environnementale sont des enjeux majeurs. Les systèmes de gestion de flotte industriels, bien qu'efficaces dans des conditions stables, montrent leurs limites face à la variabilité des conditions réelles (trafic, météo, état des routes). Ce mémoire propose de dépasser ces limites en développant un agent autonome basé sur l'apprentissage par renforcement, capable d'apprendre une politique de navigation adaptative pour optimiser simultanément l'itinéraire et le rythme de déplacement des véhicules. L'approche est validée par une comparaison rigoureuse avec des heuristiques classiques, en s'appuyant sur une modélisation réaliste de l'environnement minier et des métriques quantitatives pertinentes. Les résultats attendus sont une réduction de la consommation de carburant, des temps d'attente et une meilleure adaptation aux perturbations dynamiques.

Mots-clés : Apprentissage par renforcement, logistique minière, optimisation dynamique, fleet management system, dispatching, mine à ciel ouvert.

Abstract

In the mining sector, optimizing operational costs and reducing environmental impact are major challenges. Industrial Fleet Management Systems, while effective under stable conditions, show limitations when facing real-world variability (traffic, weather, road conditions). This thesis proposes to overcome these limits by developing an autonomous agent based on Reinforcement Learning, able to learn an adaptive navigation policy to simultaneously optimize vehicle routing and speed. The approach is validated through rigorous comparison with classical heuristics, relying on realistic mining environment modeling and relevant quantitative metrics. Expected results include reduced fuel consumption, waiting times, and improved adaptation to dynamic disturbances.

Keywords : Reinforcement learning, mining logistics, dynamic optimization, fleet management system, dispatching, open-pit mining.

Table des matières

Remerciements	II
Résumé	III
Abstract	IV
Liste des figures	VIII
Liste des tableaux	IX
Introduction générale	1
1 Concepts fondamentaux de la logistique minière	3
1.1 Logistique minière et transport en mine à ciel ouvert	3
1.2 Systèmes de gestion de flotte minière	4
1.3 Concepts de dispatching et de routage minier	4
1.4 Principes opérationnels et contraintes du transport minier	4
1.5 Conclusion	5
2 État de l’art des méthodes d’optimisation	6
2.1 Les heuristiques classiques	6
2.2 Les méta-heuristiques	6
2.3 Les approches basées sur l’apprentissage par renforcement	7
2.4 Synthèse critique et positionnement du travail	7
2.5 Conclusion	9
3 Modélisation du problème de transport minier	11
3.1 Description du système de transport minier	11
3.2 Hypothèses et contraintes de modélisation	12
3.3 Modélisation du réseau routier minier	14
3.4 Formulation du problème en tant que processus de décision markovien	16
3.5 Conclusion	20
4 Méthodologie et conception de la solution	21
4.1 Paradigme méthodologique : Le cadre CRISP-RL	21

4.1.1	Justification du choix	21
4.1.2	Cycle de vie du projet d'apprentissage par renforcement	22
4.2	Conception de l'environnement de simulation	22
4.2.1	Architecture du simulateur	23
4.2.2	Modélisation logicielle des entités	24
4.2.3	Implémentation de la stochasticité	24
4.3	Architecture technique de l'agent d'apprentissage	25
4.3.1	Passage au Deep Reinforcement Learning	25
4.3.2	Structure du réseau de neurones	25
4.3.3	Prétraitement des observations	25
4.4	Sélection et configuration de l'algorithme	26
4.4.1	Justification du choix de PPO et rejet des alternatives	26
4.4.2	Paramètres d'apprentissage	27
4.4.3	Pseudocode de l'algorithme proposé	28
4.5	Stratégie d'évaluation et modèles de référence (Baselines)	30
4.5.1	Heuristiques de comparaison	30
4.5.2	Indicateurs de performance (KPIs)	30
4.6	Conclusion	30
5	Implémentation et expérimentation	31
5.1	Architecture globale du système proposé	31
5.2	Détails d'implémentation de l'environnement	31
5.3	Paramètres et protocoles d'entraînement	31
5.4	Scénarios expérimentaux	31
5.5	Métriques d'évaluation	31
5.6	Conclusion	31
6	Résultats et analyse	32
6.1	Résultats expérimentaux	32
6.2	Comparaison avec les approches de référence	32
6.3	Analyse critique des résultats	32
6.4	Discussion	32
6.5	Conclusion	32
	Conclusion générale et perspectives	33
	Glossaire	34
	Bibliographie	35
	Annexes	37
A	Détails d'implémentation	38
B	Hyperparamètres des modèles	39

C Scénarios de simulation	40
D Architecture logicielle et structure du projet	41
E Interfaces et démonstrations	42

Table des figures

3.1	Cycle opérationnel du système camion-pelle et point d'intervention de l'agent de dispatching.	12
3.2	Représentation du réseau routier sous forme de graphe stochastique.	15
3.3	Schéma d'interaction entre l'agent RL (politique) et l'environnement (simulateur minier).	18
3.4	Structure multi-objectif de la fonction de récompense globale.	19
4.1	Cycle de vie CRISP-RL adapté à la logistique minière.	22
4.2	Architecture modulaire du simulateur Gymnasium	23
4.3	Architecture du réseau de neurones (MLP) de l'agent PPO.	25
4.4	Pipeline du flux de données entre la mine et l'agent DRL.	26

Liste des tableaux

2.1	Synthèse des grandes familles d’approches et opportunités pour l’apprentissage par renforcement	8
2.2	Détail des contributions et limites des articles majeurs de l’état de l’art . . .	9
3.1	Synthèse des hypothèses	14
4.1	Correspondance entre les classes logicielles et les variables du MDP	24
4.2	Comparaison multidimensionnelle des algorithmes DRL (adapté de [1, 2]) . .	27
4.3	Hyperparamètres de l’agent PPO	28

Introduction générale

La logistique du transport constitue l'un des piliers financiers et environnementaux les plus critiques de l'industrie minière moderne. Bien que son optimisation puisse générer des économies se chiffrant en millions de dollars, elle représente souvent une part prépondérante, pouvant atteindre 60%, des coûts opérationnels totaux d'une mine à ciel ouvert [3]. C'est dans ce cadre que ce mémoire analyse l'apport de l'apprentissage par renforcement pour l'optimisation dynamique de la logistique minière. Malgré l'adoption généralisée des systèmes de gestion de flotte, les exploitations minières se heurtent à la complexité croissante et à la variabilité des environnements réels [3, 4]. La logistique minière englobe l'ensemble des opérations visant à assurer le transport efficace des matériaux, du site d'extraction jusqu'aux zones de traitement ou de stockage. Dans ce contexte, la gestion des flux de camions, la coordination avec les équipements de chargement et le respect des contraintes de production sont déterminants pour la rentabilité et la durabilité [3]. L'optimisation des flottes consiste à affecter dynamiquement les camions aux tâches de chargement, transport et déchargement tout en minimisant les temps d'attente, la consommation de carburant et l'usure des équipements [5]. Cette problématique est difficile en raison de la variabilité des conditions réelles (trafic, météo, état des routes), de la multiplicité des contraintes opérationnelles et de la nécessité d'adapter les décisions en temps réel pour maintenir la productivité globale [6]. Les approches industrielles dominantes reposent encore largement sur des heuristiques statiques et des règles prédéfinies [5] qui, bien qu'efficaces dans des contextes stables, montrent des limites marquées face à l'incertitude du terrain [7]. Elles peinent à anticiper les congestions, à réagir aux perturbations et à optimiser la flotte de manière holistique, ce qui entraîne des pertes d'efficacité et une sous-utilisation des ressources [8, 9]. Face à ces limites, l'objectif de ce mémoire est de concevoir un agent autonome capable d'adapter ses décisions en temps réel afin de réduire les coûts, améliorer l'efficacité opérationnelle et limiter l'impact environnemental.

L'étude s'articule autour des questions suivantes :

Q1 : Comment modéliser l'environnement minier complexe (réseau routier, zones tampons, événements stochastiques) dans un cadre d'apprentissage par renforcement compatible avec les standards industriels ?

Q2 : Quelle architecture d'agent d'apprentissage par renforcement est la plus adaptée pour apprendre une politique de navigation holistique intégrant à la fois le choix d'itinéraire et le contrôle de vitesse ?

Q3 : Comment concevoir une fonction de récompense qui capture fidèlement les coûts réels (carburant, usure, temps) tout en pénalisant les comportements non souhaitables ?

Q4 : Quelles métriques et quels protocoles d'évaluation permettront de démontrer quan-

titativement la supériorité de l'approche d'apprentissage par renforcement par rapport aux approches classiques, notamment dans des scénarios de perturbation ?

Q5 : Comment intégrer un tel système d'apprentissage par renforcement comme couche d'intelligence additionnelle dans l'écosystème des systèmes de gestion de flotte existants, sans nécessiter un remplacement complet de l'infrastructure ?

Les réponses détaillées à ces problématiques seront développées tout au long des chapitres suivants, à travers la modélisation, l'expérimentation et l'analyse des résultats obtenus.

L'hypothèse centrale est qu'un agent autonome basé sur l'apprentissage par renforcement peut surpasser les approches heuristiques classiques pour l'optimisation dynamique de la logistique minière, en réduisant la consommation de carburant, les temps d'attente et en améliorant l'adaptabilité aux perturbations [10–12]. Les objectifs principaux de ce travail sont les suivants :

- Concevoir un environnement de simulation réaliste pour la logistique minière à ciel ouvert ;
- Développer un agent d'apprentissage par renforcement capable d'optimiser les décisions de dispatching et de routage ;
- Comparer les performances de l'agent d'apprentissage par renforcement avec celles des heuristiques classiques sur des scénarios variés ;
- Analyser l'impact de l'approche d'apprentissage par renforcement sur les indicateurs clés (coût, temps, consommation, robustesse).

La méthodologie suivie s'appuie sur le cadre CRISP-RL au contexte de l'apprentissage par renforcement : compréhension du problème et des données [4], modélisation de l'environnement, conception et entraînement de l'agent, expérimentation et analyse comparative [10, 12]. Chaque étape est guidée par une validation rigoureuse des hypothèses et une évaluation quantitative des résultats. Ce mémoire est organisé en six chapitres et une conclusion générale :

- Le premier chapitre présente le contexte général de la logistique minière et ses concepts fondamentaux, afin de poser le cadre métier et les notions clés mobilisées dans ce mémoire.
- Le deuxième chapitre propose un état de l'art des approches d'optimisation existantes, des heuristiques classiques aux méthodes avancées, et met en évidence le positionnement des approches basées sur l'apprentissage par renforcement.
- Le troisième chapitre détaille la modélisation du problème de transport minier, les hypothèses retenues et la formulation du système dans un cadre de décision séquentielle.
- Le quatrième chapitre décrit la méthodologie adoptée et la conception de la solution proposée, en précisant les choix de modélisation, d'architecture et d'apprentissage.
- Le cinquième chapitre présente l'implémentation, le protocole expérimental et les résultats obtenus sur les scénarios étudiés.
- Le sixième chapitre analyse et discute les résultats, en évaluant les performances, les limites et la robustesse de l'approche.
- Ce mémoire se conclut par un dernier chapitre de conclusion générale, qui synthétise les principaux apports et ouvre sur des perspectives de recherche et d'application.

Chapitre 1

Concepts fondamentaux de la logistique minière

Introduction

La compréhension rigoureuse de la logistique minière nécessite un cadre conceptuel clair, capable d'articuler les dimensions opérationnelles, décisionnelles et méthodologiques du problème étudié. Dans le contexte du transport en mine à ciel ouvert, la précision des notions utilisées conditionne la qualité de la modélisation, l'interprétation des résultats et la pertinence des choix d'optimisation.

1.1 Logistique minière et transport en mine à ciel ouvert

La logistique minière regroupe l'ensemble des activités de planification, d'organisation et de pilotage des flux de matériaux, d'équipements et d'informations nécessaires à l'exploitation d'une mine. Dans une mine à ciel ouvert, elle est centrée sur le système camion-pelle, où les matériaux sont extraits, chargés, transportés puis déchargés vers des destinations opérationnelles [3, 4].

Les concepts fondamentaux de ce système sont les suivants :

- **Mine à ciel ouvert** : Exploitation dans laquelle le minerai est extrait par gradins successifs depuis la surface.
- **Système camion-pelle** : Organisation de production où les pelles/chargeuses alimentent des camions qui assurent le transport du matériau.
- **Cycle camion-pelle** : Séquence *affectation* $\rightarrow$ *chargement* $\rightarrow$ *transport* $\rightarrow$ *déchargement* $\rightarrow$ *retour*.
- **Point de chargement** : Zone de prélèvement du matériau (pelle, chargeuse, front de taille).
- **Point de déchargement** : Destination de livraison (concasseur, halde, stock intermédiaire).
- **Zone tampon** : Espace de régulation des flux où les camions attendent avant affectation ou service.

1.2 Systèmes de gestion de flotte minière

Les systèmes de gestion de flotte sont des plateformes de supervision et d'aide à la décision qui orchestrent les opérations de transport en temps réel. Leur rôle est d'assurer la coordination entre ressources mobiles (camions) et ressources fixes (pelles, points de déchargement), tout en respectant les contraintes de production et de sécurité [3, 5].

Dans ce cadre, les notions de base sont :

- **Disponibilité des ressources** : Capacité effective d'un équipement à réaliser une tâche à un instant donné.
- **Affectation** : Décision d'envoyer un camion vers une destination donnée selon les priorités opérationnelles.
- **File d'attente** : Ensemble des camions en attente de service à une ressource contrainte.
- **Synchronisation camion-pelle** : Ajustement des arrivées de camions au rythme de chargement pour réduire l'attente improductive.

1.3 Concepts de dispatching et de routage minier

Le dispatching et le routage constituent les deux leviers décisionnels centraux du transport minier. Le dispatching détermine *la destination* d'un camion, alors que le routage détermine *l'itinéraire* suivi pour y parvenir. Leur couplage conditionne la performance globale du système [5, 6, 13].

Leur formalisation conceptuelle s'appuie sur les éléments suivants :

- **Dispatching** : Règle d'affectation dynamique des camions aux points de chargement ou déchargement.
- **Routage** : Choix du chemin entre deux nœuds en fonction de critères de coût, de temps et de risque.
- **Réseau routier minier** : Structure de transport du site, modélisable sous forme de graphe orienté pondéré.
- **Nœud** : Entité du réseau (pelle, concasseur, halte, intersection, zone tampon).
- **Arc** : Segment orienté reliant deux nœuds et porteur d'attributs (distance, pente, état de route).
- **Congestion** : Saturation locale des capacités de service provoquant une hausse des temps d'attente.

1.4 Principes opérationnels et contraintes du transport minier

Le transport minier est gouverné par des contraintes opérationnelles, énergétiques et de sécurité qui doivent être représentées explicitement dans le modèle conceptuel du système. La variabilité des temps de service et les perturbations imposent en outre une vision stochastique de l'exploitation [3, 7, 9].

Les concepts fondamentaux associés sont :

- **Temps de cycle** : Durée totale d'un cycle camion-pelle.
- **Temps d'attente** : Temps improductif passé en file ou en attente de ressource.

- **Taux d'utilisation** : Part du temps pendant lequel un équipement est effectivement productif.
- **Match Factor** : Indicateur d'équilibre entre capacité de transport et capacité de chargement.
- **Consommation spécifique** : Litres de carburant consommés par tonne transportée.
- **Coût opérationnel par tonne** : Coût total de transport rapporté au tonnage utile.

Enfin, la base conceptuelle du sujet inclut aussi le cadre décisionnel séquentiel de l'apprentissage par renforcement :

- **Processus de décision markovien (MDP)** : Formalisation d'un problème séquentiel par un quadruplet (S, A, P, R) .
- **État** : Représentation synthétique de la situation opérationnelle observée.
- **Action** : Décision admissible appliquée à l'état courant.
- **Récompense** : Signal scalaire traduisant la qualité immédiate d'une décision au regard des objectifs métier.
- **Politique** : Règle de décision associant des actions aux états.

1.5 Conclusion

Ce chapitre a posé un socle conceptuel complet pour le sujet traité, en clarifiant les notions métier de la logistique minière, les mécanismes opérationnels du système camion-pelle, les principes de dispatching et de routage, les contraintes et indicateurs clés de performance, ainsi que le cadre décisionnel séquentiel mobilisé par l'apprentissage par renforcement. Cette base terminologique et conceptuelle sert de référence pour la revue de littérature du chapitre suivant.

Chapitre 2

État de l’art des méthodes d’optimisation

Introduction

L’optimisation de la logistique minière a connu une évolution progressive, portée par des approches de plus en plus élaborées pour répondre à la complexité des environnements d’exploitation. L’examen critique des travaux existants est indispensable pour identifier les acquis de la littérature, mais aussi les limites qui freinent encore une optimisation robuste et dynamique en conditions réelles.

Dans ce mémoire, cette revue ne sert pas seulement à inventorier les méthodes existantes, mais à faire apparaître le besoin d’un cadre de décision centré sur le dispatching, explicite sur ses hypothèses et suffisamment souple pour rester exploitable dans un environnement stochastique.

2.1 Les heuristiques classiques

L’histoire de l’optimisation de la logistique minière débute avec des heuristiques simples, telles que l’assignation du camion le plus proche ou la règle du premier arrivé, premier servi [5, 14]. Si ces méthodes sont faciles à mettre en œuvre, elles restent « myopes » : elles optimisent localement sans anticiper les conséquences globales sur la flotte. Cette limitation a conduit à l’émergence de systèmes industriels comme DISPATCH, Caterpillar MineStar ou Komatsu Jigsaw, qui intègrent des modules de planification et de suivi en temps réel [3, 15]. Ces systèmes ont permis d’augmenter la productivité et de réduire les temps d’attente, mais restent largement déterministes et rigides, peinant à s’adapter aux perturbations et à la dynamique réelle du terrain.

2.2 Les méta-heuristiques

L’apparition des systèmes industriels comme DISPATCH marque une première rupture, en intégrant la planification et le suivi en temps réel. Cependant, ces solutions restent déterministes et peu flexibles face à la variabilité du terrain.

Pour dépasser les limites des systèmes industriels, la recherche académique a proposé des approches plus sophistiquées : méta-heuristiques (algorithmes génétiques, colonies de fourmis, recuit simulé) [16, 17], modèles MILP ou programmation par contraintes [18–21]. Ces méthodes offrent de meilleures performances sur des cas complexes, mais leur capacité d'adaptation en temps réel reste limitée, notamment face à l'incertitude et à la variabilité opérationnelle [6, 7, 9].

2.3 Les approches basées sur l'apprentissage par renforcement

Face aux limites persistantes de ces approches, un nouveau paradigme issu de l'intelligence artificielle s'est imposé : l'apprentissage par renforcement. L'apprentissage par renforcement permet à un agent d'apprendre une politique de décision séquentielle en interagissant avec un environnement simulé ou réel, optimisant ainsi la flotte de manière holistique et adaptative [12, 22]. Les travaux récents montrent que l'apprentissage par renforcement peut surpasser les heuristiques classiques pour le routage de véhicules, la gestion dynamique des files d'attente et l'optimisation des ressources, même en présence d'incertitude [8, 11].

2.4 Synthèse critique et positionnement du travail

La littérature montre que, malgré les avancées des systèmes de gestion de flotte industriels et des heuristiques, l'optimisation globale et dynamique de la flotte minière reste un défi [6, 9]. Les approches d'apprentissage par renforcement offrent un potentiel inédit pour dépasser ces limites, en permettant une adaptation en temps réel, une optimisation holistique et une meilleure gestion de l'incertitude [11, 12]. Ce mémoire s'inscrit dans cette dynamique, en proposant une solution d'apprentissage par renforcement adaptée aux contraintes et aux spécificités de la logistique minière moderne.

L'analyse de la littérature permet de classer les travaux existants en trois catégories majeures. Premièrement, les heuristiques classiques, basées sur des règles métier simples, offrent une solution rapide mais manquent de flexibilité. Deuxièmement, les méta-heuristiques (algorithmes génétiques, colonies de fourmis) permettent de traiter des problèmes plus complexes, au prix d'une puissance de calcul plus élevée. Enfin, les approches par apprentissage par renforcement émergent comme une solution prometteuse pour une optimisation dynamique et robuste face aux aléas. Le tableau 2.1 synthétise les opportunités offertes par cette dernière famille d'approches par rapport aux méthodes conventionnelles.

TABLE 2.1 – Synthèse des grandes familles d'approches et opportunités pour l'apprentissage par renforcement

Référence	Approche	Limites principales / Opportunité pour l'apprentissage par renforcement
[5]	Heuristiques statiques	Approche myope, peu adaptative, ne gère pas l'incertitude. Opportunité : L'apprentissage par renforcement peut apprendre une politique globale et adaptative.
[3, 15]	Systèmes industriels	Déterministes, rigides, peu réactifs aux perturbations. Opportunité : L'apprentissage par renforcement permet l'adaptation dynamique.
[16, 17]	Méta-heuristiques	Performantes mais peu robustes en temps réel, optimisation hors-ligne. Opportunité : L'apprentissage par renforcement gère l'incertitude et l'adaptation continue.
[18, 19]	MILP, optimisation avancée	Complexité computationnelle, difficilement scalable, peu flexible. Opportunité : L'apprentissage par renforcement offre une solution scalable et flexible.
[12, 22]	apprentissage par renforcement pour VRP/JSSP	Complexité de la modélisation, besoin de simulateur. Inspiration : Fournit un cadre état/action/récompense pour l'apprentissage par renforcement minier.
[8, 11]	apprentissage par renforcement appliqué à la logistique minière	L'apprentissage par renforcement montre des gains sur la robustesse et l'adaptation, mais nécessite une modélisation réaliste et des données de simulation.

Afin de positionner précisément notre contribution, il convient d'examiner les apports et les limites des articles scientifiques les plus significatifs du domaine. Ces travaux couvrent aussi bien l'optimisation des flux industriels que l'application d'algorithmes d'apprentissage sur des problèmes de routage. Cette revue critique, synthétisée dans le tableau 2.2, met en évidence le besoin d'une approche holistique intégrant la variabilité stochastique du terrain.

TABLE 2.2 – Détail des contributions et limites des articles majeurs de l'état de l'art

Référence	Domaine / Approche	Principales contributions / Limites
[4]	systèmes de gestion de flotte, optimisation minière	Modélisation des flux, contraintes industrielles, limites des heuristiques
[3]	systèmes de gestion de flotte industriels	Suivi en temps réel, gestion des files, limites en environnement dynamique
[5]	Heuristiques classiques	Règles de dispatching, efficacité en conditions stables, manque d'adaptabilité
[6]	Heuristiques, VRP	Variabilité du trafic, limites des modèles déterministes
[9]	Méta-heuristiques	Colonies de fourmis, optimisation partielle, adaptation limitée
[12]	apprentissage par renforcement pour VRP	apprentissage par renforcement pour routage, surpasse heuristiques, besoin de données, temps d'entraînement
	apprentissage par renforcement appliqué à la logistique	apprentissage par renforcement pour dispatching, robustesse, adaptation aux perturbations
[11]	apprentissage par renforcement en environnement stochastique	Politiques robustes, gestion de l'incertitude, limites pratiques
[7]	Limites des heuristiques	Incapacité à gérer la variabilité, sous-utilisation des ressources
[22]	apprentissage par renforcement : fondements	Concepts MDP, politiques, fonctions de valeur
[16, 17]	Méta-heuristiques	Algorithmes génétiques, recuit simulé, optimisation locale

2.5 Conclusion

Ce chapitre a retracé l'évolution des approches d'optimisation de la logistique minière, depuis les heuristiques simples jusqu'aux systèmes industriels, en passant par les méta-heuristiques et l'optimisation avancée. Il a mis en évidence les limites des méthodes traditionnelles face à la complexité, la variabilité et l'incertitude des environnements miniers. L'apprentissage par renforcement apparaît comme un paradigme innovant, capable d'apporter une adaptation dynamique, une optimisation holistique et une robustesse accrue. Ce

positionnement ouvre la voie à une nouvelle génération de solutions pour la logistique minière. Le chapitre suivant présentera la modélisation du problème de transport minier et les choix méthodologiques pour concevoir un agent d'apprentissage par renforcement adapté à la logistique minière.

Ce positionnement reste néanmoins conditionné par la qualité de la simulation et par la richesse des variables observées : le RL n'est pas une solution universelle, mais une approche pertinente lorsque le compromis entre réalisme, adaptabilité et coût de calcul est correctement maîtrisé.

Chapitre 3

Modélisation du problème de transport minier

Introduction

La modélisation du problème de transport minier constitue une étape centrale pour transformer une problématique industrielle complexe en un cadre formel exploitable par des méthodes d’optimisation et d’apprentissage. Dans le cas du transport minier, cette formalisation doit intégrer à la fois la structure du réseau, les contraintes opérationnelles et la variabilité des conditions de terrain, conformément aux analyses critiques récentes sur l’évolution des systèmes de gestion de flotte [3, 23].

3.1 Description du système de transport minier

Le système de transport minier considéré dans ce mémoire repose sur le modèle classique camion-pelle, largement déployé dans les mines à ciel ouvert [4, 5, 14]. Ce système comprend les éléments suivants :

- **Ressources d’extraction** : Des pelles (excavatrices) positionnées à des points de chargement fixes ou dynamiques, responsables du chargement du matériel brut extrait.
- **Flotte de transport** : Un ensemble de camions hétérogènes circulant entre les points de chargement et les points de déchargement (concasseurs, stockage, etc.).
- **Réseau routier** : Une infrastructure de transport composée de routes principales et secondaires, avec des points de chargement, de déchargement et des jonctions.
- **Opérateurs humains** : Conducteurs de camion et opérateurs de pelle qui exécutent les décisions du système de dispatching.
- **Variabilité environnementale** : Conditions météorologiques, état des routes, dégradation du matériel et autres aléas affectant les temps de cycle.

Le fonctionnement du système repose sur un cycle répétitif : (1) Assignment d’un camion à une pelle par le système de dispatching ; (2) Transport du camion vers la pelle ; (3) Attente à la queue de chargement ; (4) Chargement du matériau ; (5) Transport vers un point de déchargement ; (6) Déchargement ; (7) Retour au point de chargement. L’objectif opérationnel est de maximiser le tonnage transporté par unité de temps (rendement) tout en respectant

les contraintes de sécurité, de maintenance et de disponibilité des ressources, y compris dans des contextes intégrant des flottes partiellement ou totalement autonomes [15, 24].




FIGURE 3.1 – Cycle opérationnel du système camion-pelle et point d'intervention de l'agent de dispatching.

Le défi de modélisation réside dans la capture simultanée de la dynamique des flux, des interactions camion-pelle, des variations stochastiques des temps de cycle et des décisions de dispatching qui influencent globalement le rendement du système.

3.2 Hypothèses et contraintes de modélisation

La modélisation du problème complexe de la logistique minière nécessite un ensemble d'hypothèses simplificatrices pour rendre le système traitable par des algorithmes d'apprentissage par renforcement. Ces hypothèses sont justifiées par les besoins d'efficacité computationnelle et de convergence algorithmique, tout en préservant les éléments essentiels du problème réel, dans une logique cohérente avec les approches actor-critic appliquées aux complexes miniers et les cadres de simulation-optimisation opérationnelle [17, 25].

Ces hypothèses doivent être lues comme des conditions de validité du modèle, et non comme une description exhaustive du terrain. Elles simplifient volontairement la réalité pour rendre l'apprentissage possible, au prix d'une perte de finesse qui devra être discutée lors de l'interprétation des résultats.

Hypothèses de modélisation

- **Horizon temporel** : Le système est modélisé en temps discret avec des pas de décision réguliers (Ex : Une décision toutes les 5 à 10 secondes en temps réel, ou à chaque événement dans un simulateur événementiel).
- **Stationnarité à court terme** : On suppose que la distribution des temps de cycle reste stable sur des horizons court (quelques heures), permettant l'apprentissage avec des données récentes.
- **Observation incomplète** : L'agent ne connaît pas parfaitement l'état complet du système (files d'attente, états des routes), mais dispose d'observations bruitées reflétant

les informations disponibles en condition réelle.

- **Camions homogènes** : Bien que les flottes réelles soient hétérogènes, on regroupe les camions par classe de capacité pour réduire la dimensionnalité de l'espace d'état, une simplification couramment mobilisée face aux contraintes de dispatching de flottes multi-capacités [18].
- **Points de chargement et déchargement fixes** : Les emplacements de pelle et les destinations de déchargement sont fixes pendant une session d'apprentissage.
- **Pas de défaillance majeure** : Le système opère sans défaillance critique des pelles ou des routes principales pendant la durée de l'épisode d'apprentissage.

Contraintes opérationnelles

Le modèle intègre un ensemble de contraintes reflétant les réalités opérationnelles :

- **Capacité des pelles** : Chaque pelle peut accueillir un nombre limité de camions en file d'attente avant que la congestion ne cause une pénalité, ce qui rejoint les modèles intégrant explicitement l'effet des files et de l'inactivité des pelles [20].
- **Disponibilité** : Les pelles ont des périodes de maintenance, les routes peuvent être fermées temporairement, réduisant les options de dispatching.
- **Distance et temps de trajet** : Les trajets ne sont jamais instantanés ; on utilise des matrices de temps calculées à partir du réseau routier.
- **Charge utile** : Les camions ont une capacité maximale et doivent être alimentés avec des matériaux compatibles (un camion ne peut pas être assigné à une pelle produisant un type de minerai que sa destination ne peut pas traiter).
- **Préemption limitée** : Les décisions de dispatching ne peuvent pas être annulées une fois qu'un camion est en route (pas de retournement à mi-parcours).

Ces hypothèses et contraintes délimitent l'espace d'exploration de l'algorithme d'apprentissage par renforcement, assurant que les politiques apprises restent réalistes et applicables en production.

Autrement dit, le modèle conserve les facteurs qui gouvernent réellement la décision, tout en écartant certains détails locaux qui augmenteraient fortement la dimension du problème sans améliorer proportionnellement la qualité de la politique apprise.

Synthèse des hypothèses de modélisation

TABLE 3.1 – Synthèse des hypothèses

Catégorie	Méthodes	Objectif	Inconvénients
Temps discret	Simulation événementielle	Permet une prise de décision séquentielle compatible avec un agent RL et un simulateur événementiel.	Sensible au choix de Δt ; un pas trop grand lisse la dynamique, un pas trop fin augmente le coût de calcul.
Stationnarité à court terme	Découpage temporel	Stabilise l'apprentissage sur des fenêtres opérationnelles réalistes (quelques heures).	Peut se dégrader lors de ruptures de régime (pluie, incidents, changements de plan).
Observation incomplète	Capteurs bruités	Reflète la disponibilité réelle de capteurs et d'informations bruitées en exploitation.	Introduit une part de non-markovianité apparente si l'état observé est trop pauvre.
Regroupement des camions par classes	Classification par capacité	Réduit la dimensionnalité de l'état et de l'action pour accélérer la convergence.	Perte de granularité sur les différences intra-classe (usure, performance individuelle).
Points de chargement/déchargement fixes sur un épisode	Configuration statique	Simplifie le cadre expérimental et la comparaison avec les baselines.	Généralisation limitée aux contextes de repositionnement dynamique des pelles ou destinations.
Absence de défaillance majeure pendant un épisode	Mode nominal	Permet d'évaluer d'abord la politique nominale dans un cadre contrôlé.	Sous-estime le risque opérationnel réel si les pannes ne sont pas ensuite injectées en tests de robustesse.

3.3 Modélisation du réseau routier minier

Le réseau routier minier constitue l'infrastructure d'interaction entre les différentes ressources du système. Sa modélisation est cruciale pour que les décisions de dispatching reflètent

les réalités géographiques et logistiques du site.

Représentation graphique du réseau

Le réseau routier est modélisé comme un graphe pondéré $G = (V, E)$ où :

- V est l'ensemble des nœuds représentant les points d'intérêt : points de chargement (pelles), points de déchargement (concasseurs, stockage), jonctions et intersections.
- E est l'ensemble des arêtes représentant les connexions routières entre nœuds.
- Chaque arête (u, v) est pondérée par la distance euclidienne, le temps de trajet ou un coût composé.

Ce graphe peut être orienté (sens uniques, routes à sens limité) ou non-orienté (routes bidirectionnelles) selon la configuration du site.




FIGURE 3.2 – Représentation du réseau routier sous forme de graphe stochastique.

Matrices de temps et matrices de coût

À partir du graphe, on calcule deux matrices fondamentales :

- **Matrice de temps** T : T_{ij} est le temps de trajet moyen (en minutes) du nœud i au nœud j , calculé via l'algorithme de plus court chemin (Dijkstra ou Floyd-Warshall).
- **Matrice de coût** C : C_{ij} agrège plusieurs dimensions : distance, temps de trajet, consommation de carburant [26], usure du véhicule. On peut utiliser une combinaison linéaire pondérée :

$$C_{ij} = \alpha \cdot T_{ij} + \beta \cdot D_{ij} + \gamma \cdot E_{ij} \quad (3.1)$$

où D_{ij} est la distance, E_{ij} est une estimation de l'usure ou du coût énergétique, et α, β, γ sont des poids de pondération.

Intégration de la variabilité stochastique

Le réseau réel n'est pas déterministe : les temps de trajet varient en fonction de l'état de la route, des conditions météorologiques, et de la charge du camion. On modélise cette

variabilité par :

$$T_{ij}(t) = \bar{T}_{ij} + \eta_{ij}(t) \quad (3.2)$$

où $\bar{T}_{ij}$ est le temps moyen et $\eta_{ij}(t) \sim \mathcal{N}(0, \sigma_{ij}^2)$ est un bruit gaussien reflétant la variabilité observée.

Cette modélisation stochastique est essentielle pour évaluer la robustesse des politiques apprises, car elle oblige l'agent à anticiper les variations plutôt que de se fier à des temps de trajet figés. Cette exigence de robustesse est également mise en avant dans les travaux récents de RL multi-agent appliqués au dispatching minier [27].

3.4 Formulation du problème en tant que processus de décision markovien

La formalisation du problème de dispatching minier en tant que processus de décision markovien est l'étape décisive qui transforme le système opérationnel en un problème d'apprentissage par renforcement. Ce cadrage rejoint les études récentes de dispatching minier fondées sur des formulations explicites de type MDP, ainsi que les travaux fondateurs en apprentissage par renforcement séquentiel appliqué à des problèmes de routage et d'ordonnement [12, 22, 28]. Un processus de décision markovien est défini par le 4-tuple $(\mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R})$ où :

Le choix de cette formulation n'est pas uniquement formel. Il permet de condenser l'information utile à la décision tout en évitant une explosion de la dimension d'état, ce qui serait pénalisant pour l'apprentissage et pour la stabilité des politiques estimées.

- $\mathcal{S}$ est l'ensemble des états possibles du système.
- $\mathcal{A}$ est l'ensemble des actions (décisions de dispatching) disponibles.
- $\mathcal{P}(s'|s, a)$ est la probabilité de transition vers l'état s' en exécutant l'action a depuis l'état s .
- $\mathcal{R}(s, a, s')$ est la récompense reçue lors d'une transition.

Espace d'état $\mathcal{S}$

L'état du système à chaque instant t est représenté par un vecteur de variables d'état contenant les informations essentielles pour la prise de décision :

$$s_t = \left(\{q_p\}_{p \in \text{Pelles}}, \{x_c\}_{c \in \text{Camions}}, \{z_r\}_{r \in \text{Ressources}}, t_{\text{courant}} \right) \quad (3.3)$$

où q_p désigne la longueur de la file d'attente à la pelle p , x_c la localisation du camion c , et z_r l'état de disponibilité de la ressource r .

De manière plus détaillée :

- **Files d'attente aux pelles** : Pour chaque pelle p , on enregistre le nombre de camions en attente et leur temps d'arrivée estimé.
- **Localisation des camions** : Pour chaque camion c , on enregistre son dernier nœud de présence et son statut (libre, en route, en charge, en décharge).

- **Disponibilité des ressources** : Pour chaque pelle ou section de route, on enregistre si elle est disponible, en maintenance ou indisponible.
- **Temps courant** : L'heure de la journée ou l'étape de simulation, qui peut influencer la dynamique (sauf au sein d'un épisode stationnaire).

Espace d'action $\mathcal{A}$

À chaque étape de décision, l'agent doit décider d'assigner certains camions libres à des pelles disponibles. L'espace d'action dépend de l'état courant et est construit comme suit :

$$a_t = \text{Assignment}(c_1 \rightarrow p_j, c_2 \rightarrow p_k, \dots) \quad \text{ou} \quad a_t = \text{ATTENDRE} \quad (3.4)$$

Une action valide est un ensemble d'appariements camion-pelle qui respectent les contraintes :

- Le camion doit être libre (non actuellement en transit, en charge ou en décharge).
- La pelle doit être disponible et produire un type de minerai compatible avec la capacité du camion.
- L'action peut aussi être d'attendre (pas de changement) si attendre est plus profitable à long terme.

L'ensemble $\mathcal{A}(s)$ des actions possibles dans l'état s peut être très large (combinatoire exponentiel). Pour rendre le problème traitable, on peut limiter l'espace à un nombre réduit d'actions par exemple assigner au maximum k camions par étape, ou sélectionner les n meilleures paires candidate selon une heuristique.

Cette restriction constitue un compromis assumé : une action décrite comme une affectation complète de la flotte serait plus expressive, mais elle rendrait l'espace de recherche nettement moins maniable. Le modèle retient donc une granularité suffisante pour capturer l'essentiel du dispatching sans faire basculer le problème dans une complexité disproportionnée.

Modèle de transition $\mathcal{P}(s'|s, a)$

Le modèle de transition décrit comment le système évolue suite à une action. Étant donné un état s et une action a , le nouvel état s' est déterminé par :

$$s'_t = \text{Simuler}(s_t, a_t, \Delta t) \quad (3.5)$$

où Δt est l'intervalle de temps entre deux décisions.

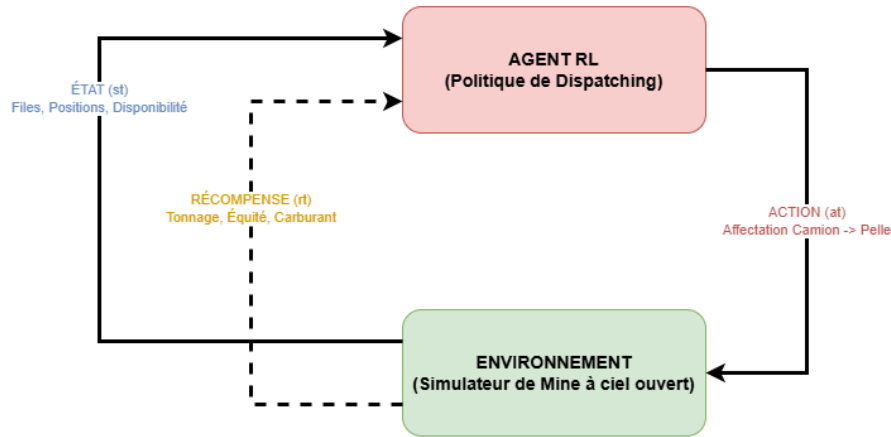


FIGURE 3.3 – Schéma d’interaction entre l’agent RL (politique) et l’environnement (simulateur minier).

La simulation inclut :

- **Avancement des camions en transit** : Les camions se déplacent selon les matrices de temps du réseau, avec perturbations stochastiques.
- **Mise à jour des files d’attente de chargement** : Les camions arrivent aux pelles, se joignent à la file ou commencent le chargement.
- **Événements de déchargement** : Les camions qui atteignent les points de déchargement sont marqués comme déchargés et reviennent en état libre.
- **Dynamique des pelles** : Chaque pelle continue de servir les camions selon un ordre FIFO ou de priorité.

Formellement, le modèle de transition est une fonction déterministe augmentée de sources de stochasticité (variation des temps de trajet). Cette représentation est alignée avec les environnements de benchmark configurables récemment proposés pour le dispatching minier et avec les travaux de simulation dédiés à l’évaluation de règles de dispatching sous incertitude [11, 29] :

$$s'_t = f(s_t, a_t) + \eta_t, \quad \eta_t \sim \mathcal{N}(0, \Sigma) \quad (3.6)$$

où $f(s_t, a_t)$ est la transition déterministe et η_t représente les perturbations stochastiques.

Fonction de récompense $\mathcal{R}(s, a, s')$

La récompense reflète les objectifs opérationnels. Le rendement global du système (tonnage par unité de temps) peut être décomposé en plusieurs objectifs :

$$R_t = w_1 \cdot R_{\text{rendement}}(s_t, s'_t) + w_2 \cdot R_{\text{équité}}(s_t) + w_3 \cdot R_{\text{coût}}(a_t) \quad (3.7)$$

où :

- $R_{\text{rendement}}$: Récompense proportionnelle au tonnage livré à la destination au cours du

pas de temps Δt . C'est l'objectif principal.

$$D_t = \{c \in \text{Camions} \mid c \text{ est déchargé dans } [t, t + \Delta t]\} \quad (3.8)$$

$$R_{\text{rendement}}(s_t, s'_t) = \sum_{c \in D_t} \text{capacité}(c) \quad (3.9)$$

- $R_{\text{équité}}$: Récompense encourageant une utilisation équilibrée des ressources (prévenir la surcharge d'une pelle au détriment d'autres).

$$R_{\text{équité}}(s_t) = -\lambda \cdot \phi(\{q_p\}_{p \in \text{Pelles}}) \quad (3.10)$$

où

$$\phi(\{q_p\}_{p \in \text{Pelles}}) = \begin{cases} \text{Var}(\{q_p\}_{p \in \text{Pelles}}), & \text{si } |\text{Pelles}| \geq 2, \\ 0, & \text{si } |\text{Pelles}| = 1. \end{cases} \quad (3.11)$$

Cette définition garantit que le terme d'équité reste bien défini, même lorsqu'une seule pelle est présente.

- $R_{\text{coût}}$: Pénalité liée aux décisions (Pour décourager les affectations inefficaces ou les trajets excessifs).

$$R_{\text{coût}}(a_t) = - \sum_{(c \rightarrow p) \in a_t} C(\text{pos}(c), \text{pos}(p)) \quad (3.12)$$

Les poids w_1, w_2, w_3 permettent de moduler l'importance relative de chaque objectif selon les priorités métier.




FIGURE 3.4 – Structure multi-objectif de la fonction de récompense globale.

Propriété markovienne et implications

L'hypothèse clé est que l'état s_t contient toute l'information nécessaire pour prédire l'évolution future du système indépendamment du passé (propriété markovienne). Cette hypothèse est raisonnable si :

- Les décisions passées ont déjà eu leur effet sur l'état courant (les camions sont soit en transit, soit en file d'attente, soit libres).

- Les seules sources d’incertitude future sont les variations stochastiques des temps de trajet et les arrivées de nouveaux travaux (qui suivent une distribution connue).

Cette propriété justifie l’application d’algorithmes d’apprentissage par renforcement standards qui supposent un MDP, plutôt que d’exiger une mémoire d’observations passées.

3.5 Conclusion

Ce chapitre a établi le cadre formel de la modélisation du problème de transport minier, depuis la description du système camion-pelle jusqu’à sa formulation en processus de décision markovien. Il a structuré les composantes essentielles du problème, notamment l’état, l’action, la dynamique de transition et la fonction de récompense, afin de représenter de manière cohérente la logique décisionnelle du dispatching en environnement minier.

La modélisation proposée articule réalisme opérationnel et tractabilité algorithmique, en intégrant les contraintes du terrain (congestion, disponibilité des ressources, variabilité des temps de cycle) tout en restant exploitable par des méthodes d’apprentissage par renforcement. Ce socle conceptuel et mathématique sert de base directe au chapitre suivant, consacré à la méthodologie, à la conception de l’environnement de simulation, à l’agent d’apprentissage et au protocole d’évaluation.

Chapitre 4

Méthodologie et conception de la solution

Introduction

Ce chapitre détaille la démarche de conception et d’implémentation de l’agent de dispatching intelligent. Après avoir établi le cadre mathématique du Processus de Décision Markovien (MDP) au chapitre précédent, il s’agit ici de traduire ces concepts en une architecture logicielle et algorithmique fonctionnelle. Nous présentons d’abord le paradigme méthodologique CRISP-RL qui a structuré l’ensemble du projet. Ensuite, nous détaillons la conception du simulateur de mine basé sur le standard Gymnasium, l’architecture du réseau de neurones de l’agent de Deep Reinforcement Learning (DRL), ainsi que la stratégie d’évaluation rigoureuse permettant de valider la performance de notre solution face aux méthodes industrielles classiques.

4.1 Paradigme méthodologique : Le cadre CRISP-RL

Pour garantir la rigueur scientifique et la reproductibilité de nos travaux, nous adoptons le cadre méthodologique CRISP-RL (CRoss-Industry Standard Process for Reinforcement Learning Applications), tel que proposé par [10]. Ce standard est une évolution du CRISP-DM traditionnel, spécifiquement repensée pour les systèmes apprenant par interaction dynamique.

4.1.1 Justification du choix

Le choix du CRISP-RL s’appuie sur la nature interactive et incertaine de la logistique minière. Contrairement à une analyse de données statiques où l’on cherche à prédire une cible, le dispatching minier exige de piloter un système en temps réel. Le CRISP-RL est le seul cadre permettant de gérer efficacement la boucle de rétroaction entre l’agent (le système de dispatching) et son environnement (la mine). Il permet d’intégrer les phases de modélisation du simulateur comme une étape centrale du projet, assurant que l’agent n’apprend pas sur des données mortes, mais sur une dynamique de flux vivante et stochastique.

4.1.2 Cycle de vie du projet d'apprentissage par renforcement

Conformément aux travaux de Szatmári [10], nous suivons un cycle de vie en six étapes itératives :

- **Définition des buts RL** : Cette phase consiste à traduire les objectifs de production (tonnage) et de maintenance (usure) en une fonction de récompense scalaire.
- **Compréhension et modélisation de l'environnement** : Identification des contraintes physiques et temporelles de la mine pour construire un simulateur fidèle.
- **Formulation MDP** : Définition formelle des espaces d'états S et d'actions A , ainsi que de la fonction de transition P (développée au Chapitre 3).
- **Développement de l'agent** : Choix de l'architecture de l'approximateur de fonction (réseau de neurones) et de l'algorithme d'apprentissage.
- **Entraînement et test** : Phase d'apprentissage intensif où l'agent explore des milliers de scénarios de dispatching dans le simulateur.
- **Évaluation de la robustesse** : Vérification de la capacité de l'agent à maintenir ses performances face à des événements non rencontrés durant l'entraînement (pannes, pics de congestion).

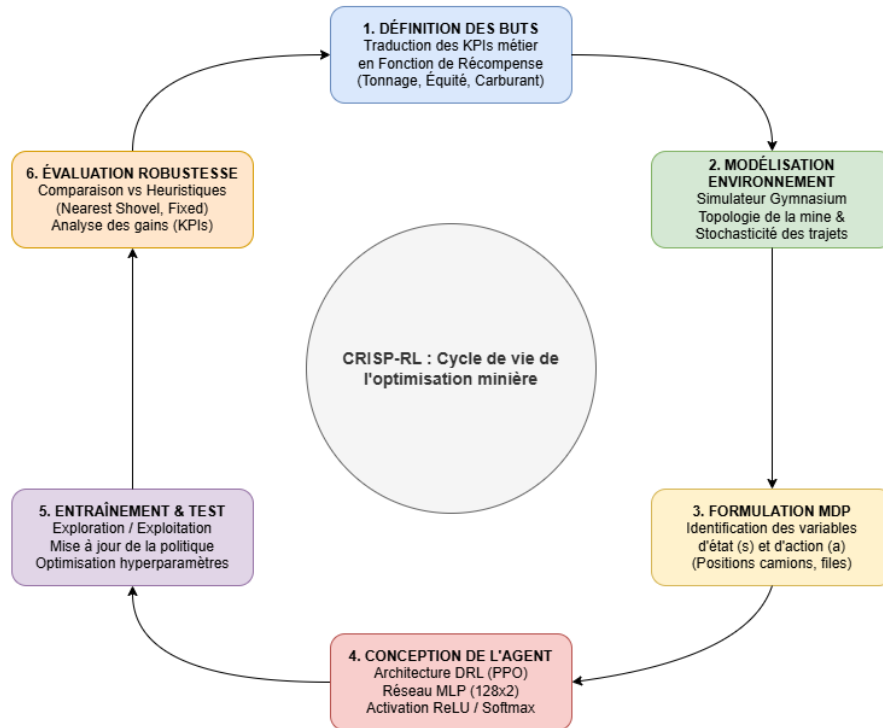


FIGURE 4.1 – Cycle de vie CRISP-RL adapté à la logistique minière.

4.2 Conception de l'environnement de simulation

L'environnement est le monde dans lequel l'agent va évoluer. Sa fidélité par rapport à la réalité minière est indispensable pour la validité des résultats, l'usage de la simulation étant reconnu comme l'approche standard pour évaluer ces systèmes complexes [30].

4.2.1 Architecture du simulateur

Nous avons développé un simulateur adapté en langage Python, en utilisant l'interface standardisée Gymnasium[31]. Gymnasium fournit un cadre rigoureux représentant un processus de décision markovien (MDP) via une classe de haut niveau nommée `Env`. La structure de notre simulateur repose sur quatre fonctions et attributs clés :

- **observation_space & action_space** : Ces attributs définissent le format des données. Nous utilisons l'espace `Box` pour les observations continues (positions, files) et `Discrete` pour les décisions de dispatching.
- **reset(seed, options)** : Initialise la mine pour un nouvel épisode de travail. Cette méthode renvoie l'observation initiale s_0 accompagnée d'un dictionnaire `info` pour le débogage.
- **step(action)** : C'est le cœur de la boucle Agent-Environnement. À partir d'une décision de dispatching, elle fait évoluer la mine de Δt et renvoie cinq valeurs cruciales : l'observation suivante (s_{t+1}), la récompense (r_t), ainsi que les signaux `terminated` (but atteint/échec), `truncated` (limite de temps du poste atteinte) et `info`.
- **render()** : Permet la visualisation de l'état de la flotte et des pelles pour le suivi humain.




FIGURE 4.2 – Architecture modulaire du simulateur Gymnasium

4.2.2 Modélisation logicielle des entités

Le simulateur repose sur une architecture orientée objet (POO) où chaque entité physique est reliée aux variables formelles du MDP défini au Chapitre 3. La correspondance entre les classes logicielles et les composantes de l’espace d’état s_t (Eq. 3.3) est établie dans le Tableau 4.1.

TABLE 4.1 – Correspondance entre les classes logicielles et les variables du MDP

Classe	Rôle dans le MDP	Variable(s) encodée(s)	Eq. de référence
Truck	Entité mobile, collecte KPIs	x_c (localisation, statut)	Eq. 3.3
Shovel	Ressource de chargement	q_p (file d’attente), z_r	Eq. 3.3
DumpSite	Ressource de déchargement	z_r (disponibilité)	Eq. 3.3
Environment	Orchestrateur, logique $f(s_t, a_t)$	Transition s'_t (Eq. 3.6)	Eq. 3.5–3.6

Classe Truck (Camion) : La classe **Truck** encode la composante x_c de l’espace d’état s_t , qui représente la localisation et le statut courant de chaque camion $c \in \text{Camions}$. Elle suit en temps réel l’état de disponibilité, directement lié à la contrainte de préemption limitée formulée en Section 3.2. Les attributs de cette classe servent à calculer les KPIs de rendement (KPI_1) et de consommation spécifique (KPI_3) définis en Section 4.5.2.

Classe Shovel (Pelle) : La classe **Shovel** encode la composante q_p de l’espace d’état, soit la longueur de la file d’attente à chaque pelle $p \in \text{Pelles}$. Sa particularité logicielle réside dans les paramètres $(\bar{T}_{ij})$ et (σ_{ij}) , qui permettent d’échantillonner le bruit stochastique $\eta_{ij}(t) \sim \mathcal{N}(0, \sigma_{ij}^2)$ introduit en (Eq. 3.2). Cette modélisation assure la cohérence entre la théorie du Chapitre 3 et l’implémentation effective.

Classe DumpSite (Point de déchargement) : Similaire à **Shovel**, cette classe encode la disponibilité z_r des ressources de déchargement dans s_t . Les paramètres introduisent la même stochasticité gaussienne, simulant les goulots d’étranglement potentiels en fin de parcours — une source de variabilité identifiée dans les hypothèses de modélisation (Tableau 3.1).

Classe Environment (Orchestrateur) : Cette classe implémente la fonction de transition déterministe $f(s_t, a_t)$ augmentée des perturbations stochastiques η_t (Eq. 3.6). Elle contient l’horloge de simulation (le pas de temps discret Δt défini en Section 3.2), orchestre les interactions entre entités et expose l’interface standardisée `reset()` / `step()` / `render()` de Gymnasium [31], assurant la compatibilité avec PPO via Stable-Baselines3 [32].

4.2.3 Implémentation de la stochasticité

Conformément à l’équation 3.2, la réalité du terrain est injectée via une variabilité des temps de trajet. À chaque fois qu’un camion se déplace sur un arc (u, v) du graphe routier, le simulateur ne se contente pas d’utiliser le temps moyen $\bar{T}_{ij}$. Il échantillonne un bruit η tel que :

$$T_{ij}(t) = \bar{T}_{ij} + \eta_{ij}(t) \quad (4.1)$$

Cela force l'agent à ne pas apprendre un chemin fixe, mais à développer une politique de dispatching capable de compenser les retards imprévus d'un camion sur une route dégradée ou encombrée.

4.3 Architecture technique de l'agent d'apprentissage

L'agent d'apprentissage par renforcement profond est conçu pour interagir dynamiquement avec l'environnement de simulation afin d'acquérir une politique de dispatching optimale. Sa structure technique repose sur l'articulation de plusieurs composants essentiels :

4.3.1 Passage au Deep Reinforcement Learning

Le RL classique par table (Q-Table) devient inefficace lorsque l'espace d'états est trop vaste. Dans notre cas, la combinaison des positions de N camions et des files d'attente de M pelles crée une explosion combinatoire. Nous utilisons donc le Deep Reinforcement Learning (DRL), où le signal de décision est généré par un réseau de neurones profond agissant comme approximateur de fonction universel [2].

4.3.2 Structure du réseau de neurones

L'agent repose sur une architecture de type Perceptron Multicouche (MLP) comprenant :

- **Couche d'entrée** : Sa dimension correspond au nombre de variables dans l'état s_t (positions, charges, temps, files).
- **Couches cachées** : Deux couches denses de 128 neurones chacune, utilisant la fonction d'activation **ReLU** ($f(x) = \max(0, x)$) pour capturer les relations non linéaires complexes entre le trafic et la production.
- **Couche de sortie** : Une couche de dimension $|A|$ utilisant une fonction **Softmax** pour transformer les activations en probabilités d'action (choix de la pelle de destination).




FIGURE 4.3 – Architecture du réseau de neurones (MLP) de l'agent PPO.

4.3.3 Prétraitement des observations

Pour stabiliser l'apprentissage, les données brutes sont normalisées avant d'entrer dans le réseau. Les distances sont ramenées sur une échelle $[0, 1]$ par rapport à la diagonale maximale de la mine, et les longueurs de files d'attente sont divisées par la capacité maximale de

rétenion de la pelle. Cette étape est cruciale pour éviter l’explosion du gradient lors de la rétropropagation [2].




FIGURE 4.4 – Pipeline du flux de données entre la mine et l’agent DRL.

4.4 Sélection et configuration de l’algorithme

Le succès d’un système d’apprentissage par renforcement profond (DRL) repose non seulement sur la qualité de l’environnement, mais aussi sur le choix d’un algorithme capable de naviguer efficacement dans des espaces d’états complexes et stochastiques. Dans le contexte de la logistique minière, l’algorithme doit être capable de gérer la haute dimensionnalité des données tout en garantissant une convergence stable vers une politique de dispatching performante.

4.4.1 Justification du choix de PPO et rejet des alternatives

Pour piloter notre agent de dispatching, nous avons procédé à un arbitrage technologique rigoureux. L’objectif est de sélectionner un algorithme capable de converger vers une politique robuste dans un environnement minier caractérisé par une haute dimensionnalité et une forte stochasticité. Nous comparons ici PPO aux trois autres piliers du Deep Reinforcement Learning : DQN, DDPG/TD3 et SAC.

Rejet de DQN (Deep Q-Network) : Bien que DQN soit l’algorithme fondateur du DRL, il est structurellement limité aux espaces d’actions discrets et de faible dimension. L’utilisation d’une Q-Table approximée par un réseau de neurones se heurte à une explosion combinatoire dès que le nombre de pelles et de camions augmente. Dans notre complexe minier, la gestion simultanée de plusieurs unités de chargement rendrait l’apprentissage via DQN extrêmement instable et sujet à une divergence algorithmique [2].

Rejet de la famille DDPG / TD3 : Le DDPG (Deep Deterministic Policy Gradient) et son évolution le TD3 souffrent de défauts intrinsèques limitant leur applicabilité industrielle. Ces algorithmes présentent une instabilité chronique et une tendance critique à la surestimation des Q-valeurs. Dans un environnement stochastique où les temps de trajet subissent un bruit η (Eq. 3.2), la politique déterministe de cette famille d’algorithmes produit des oscillations persistantes, se traduisant par des décisions de dispatching aléatoires et une sous-utilisation des ressources [1].

Rejet de SAC (Soft Actor-Critic) : SAC est reconnu pour sa performance grâce à l’optimisation de l’entropie, mais il impose un coût computationnel prohibitif. L’étude comparative de [1] quantifie ce surcoût : SAC nécessite en moyenne 40 heures d’entraînement contre 31 heures pour des architectures plus sobres, soit un besoin en ressources supérieur de 30%. Pour une exploitation minière réelle, où l’agent doit être ré-entraîné fréquemment suite à l’évolution géographique de la zone d’extraction, ce manque d’efficacité constitue un obstacle économique majeur.

Avantages déterminants de PPO : L’algorithme Proximal Policy Optimization (PPO) s’impose comme la solution optimale pour ce mémoire selon trois critères validés par la littérature récente :

- **Stabilité par objectif tronqué :** PPO utilise un mécanisme de Clipped Surrogate Objective. Cela limite l’amplitude des mises à jour de la politique à chaque itération, garantissant que l’agent ne diverge pas brutalement suite à un événement stochastique extrême (panne, congestion soudaine) [2].
- **Simplicité d’implémentation et on-policy :** Contrairement aux méthodes off-policy nécessitant un replay buffer massif et complexe à gérer en mémoire, PPO apprend directement de ses interactions actuelles. Cette caractéristique facilite la synchronisation avec le simulateur Gymnasium et réduit l’empreinte logicielle du système.
- **Robustesse industrielle :** PPO est l’algorithme le plus adapté aux environnements de production pour sa moindre sensibilité au réglage fin des hyperparamètres, assurant une reproductibilité des résultats essentielle pour la logistique minière [2, 10]. Le Tableau 4.2 synthétise cette analyse comparative.

TABLE 4.2 – Comparaison multidimensionnelle des algorithmes DRL (adapté de [1, 2])

Critère	DQN	DDPG / TD3	SAC	PPO
Espace d’action	Discret unique- ment	Continu	Continu	Hybride
Stabilité	Moyenne	Faible	Élevée	Optimale
Coût de calcul	Très Faible	Moyen (31h)	Élevé (40h)	Faible
Oscillations (η)	Fortes	Élevées	Faibles	Négligeables
Réglage (Tuning)	Simple	Complexe	Moyen	Simple
Verdict	Limité	Instable	Trop lourd	Retenu

4.4.2 Paramètres d’apprentissage

Les hyperparamètres retenus correspondent aux valeurs par défaut de la bibliothèque Stable-Baselines3 (version 2.x), telles que définies dans la documentation officielle [32]. Ces valeurs ont été choisies comme base de référence car elles ont été optimisées par les auteurs de la bibliothèque pour offrir une convergence stable sur une large gamme d’environnements de type Gymnasium.

TABLE 4.3 – Hyperparamètres de l’agent PPO

Hyperparamètre	Valeur	Justification
Learning Rate	0.0003	Vitesse d’apprentissage par défaut recommandée pour la plupart des problèmes.
Gamma (γ)	0.99	Valeur standard dans le RL pour équilibrer les récompenses immédiates et futures.
Batch Size	64	Taille du lot d’échantillons utilisée pour chaque mise à jour du réseau de neurones.
GAE Lambda (λ)	0.95	Paramètre pour le Generalized Advantage Estimation, utilisé pour réduire la variance.
Clip Range	0.2	Cœur de l’algorithme PPO (le Clipped Objective) qui empêche l’agent de changer trop radicalement de politique d’un coup.

4.4.3 Pseudocode de l’algorithme proposé

L’Algorithme 1 formalise la procédure complète d’entraînement de l’agent PPO appliquée à notre problème de dispatching minier. Ce pseudocode intègre les éléments définis dans les sections précédentes : l’état s_t (Eq. 3.1), l’espace d’action $\mathcal{A}$ (Section 3.4), la récompense pondérée R_t (Eq. 3.8), le réseau MLP 128×128 (Section 4.3.2) et les hyperparamètres du Tableau 4.3.

Algorithm 1 PPO pour le dispatching minier camion-pelle-dump**Require:** Environnement minier $\mathcal{E}$ (graphe G , camions $\mathcal{C}$, pelles $\mathcal{P}$, dumps $\mathcal{D}$)**Require:** Réseau acteur π_θ et critique V_ϕ (MLP 128×128, ReLU)**Require:** Hyperparamètres : $\alpha = 0,0003$, $\gamma = 0,99$, $\lambda_{\text{GAE}} = 0,95$, $\epsilon_{\text{clip}} = 0,2$, T_{max} steps

```

1: Initialiser  $\theta$  et  $\phi$  aléatoirement
2: for  $k = 1, 2, \dots, T_{\text{max}}/N$  do
3:   Collecter  $N$  transitions en suivant  $\pi_{\theta_k}$  :
4:   for  $t = 1, \dots, N$  do
5:     Observer l'état  $s_t = (\{q_p\}, \{x_c\}, \{z_r\}, t_{\text{courant}})$ 
6:     Normaliser  $s_t$  dans  $[0, 1]$  (Section 4.3.3)
7:     Échantillonner l'action  $a_t \sim \pi_\theta(\cdot | s_t)$ 
8:     Décoder  $a_t$  en paire (pelle  $p_i$ , dump  $d_j$ ) :
9:        $i \leftarrow \lfloor a_t / |\mathcal{D}| \rfloor, \quad j \leftarrow a_t \bmod |\mathcal{D}|$ 
10:    Si  $a_t = |\mathcal{P}| \times |\mathcal{D}|$  : ATTENDRE
11:    Simuler le cycle complet du camion courant  $c$  :
12:      Trajet  $c \rightarrow p_i$  (temps log-normal, Eq. 3.2)
13:      Attente + chargement à  $p_i$ 
14:      Trajet chargé  $p_i \rightarrow d_j$ 
15:      Attente + déchargement à  $d_j$ 
16:      Retour à vide  $d_j \rightarrow p_i$ 
17:    Calculer la récompense (Eq. 3.7) :
18:       $R_t = w_1 \cdot R_{\text{rendement}} + w_2 \cdot R_{\text{équité}} + w_3 \cdot R_{\text{coût}}$ 
19:    Observer le nouvel état  $s_{t+1}$ 
20:    Stocker  $(s_t, a_t, R_t, s_{t+1}, \log \pi_\theta(a_t | s_t))$ 
21:   end for
22:   Calculer les avantages GAE :  $\hat{A}_t = \sum_{l=0}^{T-t} (\gamma \lambda_{\text{GAE}})^l \delta_{t+l}$ 
23:   où  $\delta_t = R_t + \gamma V_\phi(s_{t+1}) - V_\phi(s_t)$ 
24:   for chaque époque d'optimisation (mini-batches de taille 64) do
25:     Calculer le ratio :  $r_t(\theta) = \frac{\pi_\theta(a_t | s_t)}{\pi_{\theta_k}(a_t | s_t)}$ 
26:     Mettre à jour l'acteur par l'objectif tronqué :
27:      $L^{\text{CLIP}}(\theta) = \mathbb{E}[\min(r_t \hat{A}_t, \text{clip}(r_t, 1 - \epsilon_{\text{clip}}, 1 + \epsilon_{\text{clip}}) \hat{A}_t)]$ 
28:     Mettre à jour le critique :
29:      $L^V(\phi) = \mathbb{E}[(V_\phi(s_t) - R_t^{\text{cible}})^2]$ 
30:      $\theta \leftarrow \theta + \alpha \nabla_\theta L^{\text{CLIP}}, \quad \phi \leftarrow \phi - \alpha \nabla_\phi L^V$ 
31:   end for
32: end for
33: return Politique entraînée  $\pi_\theta^*$ 

```

Cet algorithme illustre comment les composantes théoriques définies au Chapitre 3 (MDP, récompense pondérée, stochasticité) s'articulent avec les choix techniques du présent chapitre (PPO, architecture réseau, hyperparamètres) pour former une boucle d'apprentissage complète et cohérente. La ligne 9 montre en particulier l'encodage de l'espace d'action

$\mathcal{A} = \text{Discrete}(|\mathcal{P}| \times |\mathcal{D}| + 1)$ qui permet à l’agent de choisir simultanément la pelle et le point de déchargement. Le terme $+1$ représente l’action neutre (ATTENDRE), permettant à l’agent de temporiser si aucune affectation n’est productive à l’instant t .

4.5 Stratégie d’évaluation et modèles de référence (Baselines)

4.5.1 Heuristiques de comparaison

Pour démontrer la plus-value de l’agent DRL, nous le comparons à deux baselines industrielles :

- **Fixed Assignment (Règle statique)** : Chaque camion est dédié à une seule pelle. C’est le niveau zéro de l’optimisation.
- **Nearest Shovel (Greedy)** : Le camion choisit systématiquement la pelle la plus proche géographiquement. C’est l’approche la plus courante en l’absence de système intelligent.

4.5.2 Indicateurs de performance (KPIs)

L’évaluation repose sur la formalisation mathématique de trois indicateurs clés :

- **Productivité Horaire (P_h)** :

$$P_h = \frac{\sum_{c \in \text{Poste}} \text{Tonnage}(c)}{T_{\text{total}}} \quad (4.2)$$

- **Temps d’attente moyen (E_t)** : Temps d’attente moyen en file d’attente par cycle.
- **Consommation spécifique (E_e)** : Métrique de l’efficacité énergétique [26].

4.6 Conclusion

Ce chapitre a détaillé la transformation de notre modèle MDP en une architecture logicielle concrète structurée par le cadre CRISP-RL. Nous avons justifié le passage au Deep Reinforcement Learning (PPO) pour gérer la complexité du système minier et défini un protocole d’évaluation rigoureux basé sur des indicateurs de performance industriels. Le chapitre suivant présentera l’implémentation de ce système dans notre environnement de simulation et analysera les résultats obtenus face aux heuristiques de référence.

Chapitre 5

Implémentation et expérimentation

Introduction

5.1 Architecture globale du système proposé

À compléter...

5.2 Détails d'implémentation de l'environnement

À compléter...

5.3 Paramètres et protocoles d'entraînement

À compléter...

5.4 Scénarios expérimentaux

À compléter...

5.5 Métriques d'évaluation

À compléter...

5.6 Conclusion

Chapitre 6

Résultats et analyse

Introduction

6.1 Résultats expérimentaux

À compléter...

6.2 Comparaison avec les approches de référence

À compléter...

6.3 Analyse critique des résultats

À compléter...

6.4 Discussion

À compléter...

6.5 Conclusion

Conclusion générale et perspectives

Glossaire

RL Reinforcement Learning (apprentissage par renforcement).

MDP Markov Decision Process (processus de décision markovien).

FMS Fleet Management System (système de gestion de flotte).

CRISP-RL CRoss-Industry Standard Process for Reinforcement Learning applications.

FIFO First In, First Out (premier entré, premier sorti).

Bibliographie

- [1] S. E. Nwachukwu, K. A. Folly, and K. O. Awodele, “A comparative study between soft actor-critic (SAC) and deep deterministic policy gradient (DDPG) algorithms for solar PV MPPT control under partial shading conditions,” *IEEE Access*, vol. 13, pp. 71 738–71 754, 2025.
- [2] M. Krichen, “Apprentissage par renforcement profond,” 2022.
- [3] A. Afrapoli and H. Askari-Nasab, “Mining fleet management systems : a review of models and algorithms,” *International Journal of Mining, Reclamation and Environment*, pp. 1–20, 6 2017.
- [4] A. M. Newman, E. Rubio, A. W. R. Caro, and K. Eurek, “A review of operations research in mine planning,” *Interfaces*, vol. 40, pp. 222–245, 4 2010.
- [5] S. Alarie and M. Gamache, “Overview of solution strategies used in truck dispatching systems for open pit mines,” *International Journal of Surface Mining, Reclamation and Environment*, vol. 16, pp. 59–76, 2002.
- [6] M. M. Fioroni, L. A. G. Franzese, T. J. Bianchi, L. Ezawa, L. R. Pinto, and G. de Miranda Jr., “Concurrent simulation and optimization models for mining planning,” *Winter Simulation Conference*, 2008.
- [7] S. P. Upadhyay and H. Askari-Nasab, “Simulation and optimization approach for uncertainty-based short-term planning in open pit mines,” *International Journal of Mining Science and Technology*, vol. 28, pp. 153–166, 12 2017.
- [8] M. Abolghasemian, A. G. Kanafi, and M. Daneshmandmehr, “A two-phase simulation-based optimization of hauling system in open-pit mine,” *Iranian Journal of Management Studies (IJMS)*, vol. 13, pp. 705–732, 5 2020.
- [9] B. Ozdemir and M. Kumral, “Simulation based optimization of truck shovel material handling systems in multi pit surface mines,” *Simulation Modelling Practice and Theory*, vol. 95, pp. 36–48, 4 2019.
- [10] K. Szatmari, T. Chovan, S. nemeth, and A. Kummer, “How to support decision making with reinforcement learning in hierarchical chemical process control?” *Chemical Engineering Journal Advances*, vol. 22, p. 100753, 2025.

- [11] W. Zeng, E. Baafi, and H. Fan, "A simulation model to study truck- allocation options," *School of Civil, Mining and Environmental Engineering, University of Wollongong, Australia*, vol. 122, pp. 741–750, 12 2022.
- [12] M. Nazari, A. Oroojlooy, M. Takáč, and L. V. Snyder, "Reinforcement learning for solving the vehicle routing problem," *NeurIPS*, 5 2018.
- [13] F. Soumis, J. Ethier, and J. Elbrond, "Truck dispatching in an open pit mine," *International Journal of Surface Mining, Reclamation and Environment*, vol. 3, pp. 115–119, 1989.
- [14] M. Munirathinam and J. C. Yingling, "A review of computer-based truck dispatching strategies for surface mining operations," *International Journal of Surface Mining, Reclamation and Environment*, 1994.
- [15] M. Mohtasham and H. Mirzaei-Nasirabad, "Evaluating the performance of the dispatch algorithm, a commercial software, in the sungun copper mine," *Journal of Geomines*, pp. 117–122, 2023.
- [16] M. Souza, I. Coelho, S. Ribas, H. Santos, and L. Merschmann, "A hybrid heuristic algorithm for the open-pit-mining operational planning problem," *European Journal of Operational Research*, pp. 1041–1051, 6 2010.
- [17] R. Subtil, D. M. Silva, and J. C. Alves, "A practical approach to truck dispatch for open pit mines," *Proceedings of the 35th International Symposium on the Application of Computers and Operations Research in the Mineral Industry (APCOM)*, 2011.
- [18] D. Ahangaran, A. Yasrebi, A. Wetherelt, and P. Foster, "Real-time dispatching modelling for trucks with different capacities in open pit mines," *Archives of Mining Sciences*, vol. 52, pp. 39–52, 2012.
- [19] A. Smith, J. Lindereth, and J. Luedtke, "Optimization-based dispatching policies for open-pit mining," *Springer*, pp. 1–39, 2 2020.
- [20] C. H. Ta, A. Ingolfsson, and J. Doucette, "A linear model for surface mining haul truck allocation incorporating shovel idle probabilities," *European Journal of Operational Research*, pp. 770–778, 6 2013.
- [21] Z. Wang, J. Wang, M. Zhao, Q. Guo, X. Zeng, F. Xin, and H. Zhou, "Truck dispatching optimization model and algorithm based on 0-1 decision variables," *Mathematical Problems in Engineering*, vol. 2022, pp. 1–9, 2 2022.
- [22] C. Zhang, W. Song, Z. Cao, J. Zhang, P. S. Tan, and C. Xu, "Learning to dispatch for job shop scheduling via deep reinforcement learning," *NeurIPS*, pp. 1–17, 10 2020.
- [23] A. Hazrathosseini and A. M. Afrapoli, "Transition to intelligent fleet management systems in open pit mines : A critical review on application of reinforcement-learning-based systems," *Mining Technology*, 2024.

- [24] S. Pei, J. Yang, and Z. Gong, “Learning-based dispatching system with trajectory optimisation for autonomous mining transportation,” *International Journal of Mining, Reclamation and Environment*, 2025.
- [25] J. P. de Carvalho and R. Dimitrakopoulos, “Production planning updating with mining fleet management in industrial mining complexes : an actor-critic reinforcement learning approach,” *Applied Intelligence*, 2023.
- [26] G. Liu and S. Chai, “Optimizing open-pit truck route based on minimization of time-varying transport energy consumption,” *Mathematical Problems in Engineering*, vol. 2019, pp. 1–12, 8 2019.
- [27] K. Zhao, Z. Liu, W. Du, H. Lu, B. Zhou, and G. Yu, “Hierarchical multiagent reinforcement learning for sustainable truck dispatching in open-pit mining,” *Transportmetrica A : Transport Science*, 2025.
- [28] F. ROSALES and A. DIAZ, “Interpretable deep reinforcement learning for dynamic truck dispatching in open-pit mining,” *International Journal of Mining, Reclamation and Environment*, 2025.
- [29] C. Banerjee, K. Nguyen, and C. Fookes, “Mining-gym : A configurable rl benchmarking environment for truck dispatch scheduling,” 2025.
- [30] N. Çetin, “Open pit truck/shovel haulage system simulation,” Ph.D. dissertation, Middle East Technical University, 9 2004.
- [31] M. Towers, A. Kwiatkowski, J. Terry, J. U. Balis, G. D. Cola, T. Deleu, M. Goulão, A. Kallinteris, M. Krimmel, A. KG, R. Perez-Vicente, A. Pierré, S. Schulhoff, J. J. Tai, H. Tan, and O. G. Younis, “Gymnasium : A standard interface for reinforcement learning environments,” *NeurIPS*, 2025.
- [32] A. Raffin, A. Hill, A. Gleave, A. Kanervisto, M. Ernestus, and N. Dormann, “Stable-baselines3 : Reliable reinforcement learning implementations,” *Journal of Machine Learning Research*, vol. 22, no. 268, pp. 1–8, 2021. [Online]. Available : <https://jmlr.org/papers/v22/20-1364.html>

Annexe A

Détails d'implémentation

À compléter...

Annexe B

Hyperparamètres des modèles

À compléter...

Annexe C

Scénarios de simulation

À compléter...

Annexe D

Architecture logicielle et structure du projet

À compléter...

Annexe E

Interfaces et démonstrations

À compléter...