

UNIVERSITÉ DON BOSCO DE LUBUMBASHI

FACULTÉ DES SCIENCES INFORMATIQUES

Lubumbashi

www.udbl.ac.cd



Au-delà des heuristiques statiques :

Conception et mise en œuvre d'un agent d'apprentissage par renforcement pour l'optimisation holistique et dynamique de la logistique minière

Présenté par : **Jean-Luc MUPASA KALUNGA**

Dirigé par : **Dr. Olfa FERCHICHI**

Master 2 Data Science — Spécialité Logistique

Année académique 2025–2026

AVRIL, 2026

Dédicace

Je dédie ce travail à...

Remerciements

À compléter...

Résumé

Dans le secteur minier, l'optimisation des coûts opérationnels et la réduction de l'empreinte environnementale sont des enjeux majeurs. Les systèmes de gestion de flotte industriels, bien qu'efficaces dans des conditions stables, montrent leurs limites face à la variabilité des conditions réelles (trafic, météo, état des routes). Ce mémoire propose de dépasser ces limites en développant un agent autonome basé sur l'apprentissage par renforcement, capable d'apprendre une politique de navigation adaptative pour optimiser simultanément l'itinéraire et le rythme de déplacement des véhicules. L'approche est validée par une comparaison rigoureuse avec des heuristiques classiques, en s'appuyant sur une modélisation réaliste de l'environnement minier et des métriques quantitatives pertinentes. Les résultats attendus sont une réduction de la consommation de carburant, des temps d'attente et une meilleure adaptation aux perturbations dynamiques.

Mots-clés : Apprentissage par renforcement, logistique minière, optimisation dynamique, fleet management system, dispatching, mine à ciel ouvert.

Abstract

In the mining sector, optimizing operational costs and reducing environmental impact are major challenges. Industrial Fleet Management Systems, while effective under stable conditions, show limitations when facing real-world variability (traffic, weather, road conditions). This thesis proposes to overcome these limits by developing an autonomous agent based on Reinforcement Learning, able to learn an adaptive navigation policy to simultaneously optimize vehicle routing and speed. The approach is validated through rigorous comparison with classical heuristics, relying on realistic mining environment modeling and relevant quantitative metrics. Expected results include reduced fuel consumption, waiting times, and improved adaptation to dynamic disturbances.

Keywords : Reinforcement learning, mining logistics, dynamic optimization, fleet management system, dispatching, open-pit mining.

Table des matières

Remerciements	II
Résumé	III
Abstract	IV
Liste des figures	VIII
Liste des tableaux	IX
Introduction générale	1
1 Concepts fondamentaux de la logistique minière	3
1.1 Logistique minière et transport en mine à ciel ouvert	3
1.2 Systèmes de gestion de flotte minière	4
1.3 Concepts de dispatching et de routage minier	4
1.4 Principes opérationnels et contraintes du transport minier	4
1.5 Conclusion	5
2 État de l’art des méthodes d’optimisation	6
2.1 Les heuristiques classiques	6
2.2 Les méta-heuristiques	6
2.3 Les approches basées sur l’apprentissage par renforcement	7
2.4 Synthèse critique et positionnement du travail	7
2.5 Conclusion	9
3 Modélisation du problème de transport minier	11
3.1 Description du système de transport minier	11
3.2 Hypothèses et contraintes de modélisation	12
3.3 Modélisation du réseau routier minier	15
3.4 Formulation du problème en tant que processus de décision markovien	16
3.5 Conclusion	20
4 Méthodologie, conception et choix algorithmique de la solution proposée	21
4.1 Méthodologie	21

4.1.1	Justification du choix de CRISP-RL	21
4.1.2	Adaptation des étapes CRISP-RL au contexte minier	22
4.1.3	Positionnement de l'approche proposée dans le cycle CRISP-RL	23
4.2	Présentation générale de l'approche proposée	23
4.2.1	Principe général de la solution	23
4.2.2	Architecture fonctionnelle de l'approche	24
4.2.3	Positionnement de l'agent dans le système de gestion de flotte	25
4.3	Conception de l'environnement de simulation	25
4.3.1	Architecture générale du simulateur	25
4.3.2	Modélisation des entités minières	26
4.3.3	Définition de l'espace d'observation	27
4.3.4	Définition de l'espace d'action	27
4.3.5	Fonction de récompense multi-objectif	28
4.4	Algorithmes classiques d'apprentissage par renforcement	28
4.4.1	Q-Learning pour le dispatching minier	28
4.4.2	Temporal Difference Learning	29
4.4.3	SARSA comme variante TD orientée politique	30
4.4.4	Limites des méthodes tabulaires	31
4.5	Passage au Deep Reinforcement Learning	32
4.5.1	Justification du recours au Deep Learning	32
4.5.2	Deep Q-Network (DQN) comme extension du Q-Learning	32
4.5.3	Architecture du réseau de neurones	33
4.5.4	Choix de l'algorithme final : PPO	34
4.5.5	Justification du choix de PPO par rapport aux alternatives	35
4.6	Configuration expérimentale des modèles d'apprentissage	35
4.6.1	Hyperparamètres du Q-Learning	35
4.6.2	Hyperparamètres du TD Learning / SARSA	36
4.6.3	Hyperparamètres du modèle Deep Reinforcement Learning	36
4.6.4	Stratégie exploration / exploitation	37
4.7	Stratégie d'évaluation comparative	37
4.7.1	Heuristiques de référence	37
4.7.2	Modèles RL classiques de comparaison	38
4.7.3	Modèle Deep Reinforcement Learning proposé	38
4.7.4	Indicateurs de performance (KPIs)	38
4.8	Synthèse de la solution proposée	39
4.8.1	Pseudocode de l'algorithme proposé	39
4.9	Conclusion	41
5	Implémentation et expérimentation	42
5.1	Architecture globale du système proposé	42
5.2	Détails d'implémentation de l'environnement	43
5.2.1	Modélisation physique du simulateur	43
5.2.2	Graphe routier	43

5.2.3	Vecteur d'observation	44
5.2.4	Fonction de récompense implémentée	44
5.3	Paramètres et protocoles d'entraînement	45
5.3.1	Protocole général	45
5.3.2	Paramètres des méthodes tabulaires	45
5.3.3	Paramètres des agents Deep RL	46
5.4	Scénarios expérimentaux	46
5.4.1	Validation du simulateur	47
5.5	Métriques d'évaluation	47
5.6	Conclusion	47
6	Résultats et analyse	48
6.1	Résultats expérimentaux	48
6.1.1	Scénario nominal	48
6.1.2	Scénario high_load	49
6.1.3	Scénario high_breakdown	49
6.2	Comparaison avec les approches de référence	49
6.2.1	Analyse comparative globale	49
6.2.2	Analyse par scénario	50
6.3	Analyse critique des résultats	51
6.3.1	Convergence des agents d'apprentissage	51
6.3.2	Limites identifiées	51
6.4	Discussion	53
6.4.1	Validation de l'hypothèse centrale H1	53
6.4.2	Apports de la progression algorithmique	53
6.4.3	Perspectives d'intégration industrielle	54
6.5	Conclusion	54
	Conclusion générale et perspectives	55
	Glossaire	56
	Bibliographie	57
	Annexes	59
A	Détails d'implémentation	60
B	Hyperparamètres des modèles	61
C	Scénarios de simulation	62
D	Architecture logicielle et structure du projet	63
E	Interfaces et démonstrations	64

Table des figures

3.1	Cycle opérationnel du système camion-pelle et point d'intervention de l'agent de dispatching.	12
3.2	Représentation du réseau routier sous forme de graphe stochastique.	15
3.3	Schéma d'interaction entre l'agent RL (politique) et l'environnement (simulateur minier).	18
3.4	Structure multi-objectif de la fonction de récompense globale.	20
4.1	Cycle de vie CRISP-RL adapté à la logistique minière.	23
4.2	Architecture fonctionnelle de la solution proposée.	24
4.3	Architecture modulaire du simulateur Gymnasium.	26
4.4	Architecture du réseau de neurones (MLP) de l'agent PPO.	34
4.5	Pipeline du flux de données entre la mine et l'agent DRL.	35
5.1	Architecture globale du projet.	43
5.2	Graphe routier du simulateur minier.	45

Liste des tableaux

2.1	Synthèse des grandes familles d’approches et opportunités pour l’apprentissage par renforcement	8
2.2	Détail des contributions et limites des articles majeurs de l’état de l’art . . .	9
3.1	Synthèse des hypothèses	14
4.1	Architecture fonctionnelle de l’approche proposée	24
4.2	Correspondance entre les classes logicielles et les variables du MDP	26
4.3	Correspondance Q-Learning $\leftrightarrow$ dispatching minier	29
4.4	Comparaison DQN et PPO pour le dispatching minier (adapté de [1])	35
4.5	Hyperparamètres du Q-Learning	36
4.6	Hyperparamètres du TD Learning / SARSA	36
4.7	Hyperparamètres de l’agent PPO	37
4.8	Indicateurs de performance pour l’évaluation comparative	39
4.9	Synthèse de la solution proposée	39
5.1	Composition du vecteur d’observation (configuration nominale)	44
5.2	Diagnostic du signal de récompense avant et après ajout de w_4	45
5.3	Paramètres d’entraînement des méthodes tabulaires	46
5.4	Paramètres d’entraînement des agents Deep RL	46
5.5	Paramètres des scénarios expérimentaux	46
6.1	Résultats comparatifs — Scénario nominal	48
6.2	Résultats comparatifs — Scénario high_load (18 camions)	49
6.3	Résultats comparatifs — Scénario high_breakdown ($p_b = 10\%$)	49
6.4	Synthèse comparative multi-scénarios (productivité t/h / attente min)	50

Introduction générale

La logistique du transport constitue l'un des piliers financiers et environnementaux les plus critiques de l'industrie minière moderne. Bien que son optimisation puisse générer des économies se chiffrant en millions de dollars, elle représente souvent une part prépondérante, pouvant atteindre 60%, des coûts opérationnels totaux d'une mine à ciel ouvert [2]. C'est dans ce cadre que ce mémoire analyse l'apport de l'apprentissage par renforcement pour l'optimisation dynamique de la logistique minière. Malgré l'adoption généralisée des systèmes de gestion de flotte, les exploitations minières se heurtent à la complexité croissante et à la variabilité des environnements réels [2, 3]. La logistique minière englobe l'ensemble des opérations visant à assurer le transport efficace des matériaux, du site d'extraction jusqu'aux zones de traitement ou de stockage. Dans ce contexte, la gestion des flux de camions, la coordination avec les équipements de chargement et le respect des contraintes de production sont déterminants pour la rentabilité et la durabilité [2]. L'optimisation des flottes consiste à affecter dynamiquement les camions aux tâches de chargement, transport et déchargement tout en minimisant les temps d'attente, la consommation de carburant et l'usure des équipements [4]. Cette problématique est difficile en raison de la variabilité des conditions réelles (trafic, météo, état des routes), de la multiplicité des contraintes opérationnelles et de la nécessité d'adapter les décisions en temps réel pour maintenir la productivité globale [5]. Les approches industrielles dominantes reposent encore largement sur des heuristiques statiques et des règles prédéfinies [4] qui, bien qu'efficaces dans des contextes stables, montrent des limites marquées face à l'incertitude du terrain [6]. Elles peinent à anticiper les congestions, à réagir aux perturbations et à optimiser la flotte de manière holistique, ce qui entraîne des pertes d'efficacité et une sous-utilisation des ressources [7, 8]. Face à ces limites, l'objectif de ce mémoire est de concevoir un agent autonome capable d'adapter ses décisions en temps réel afin de réduire les coûts, améliorer l'efficacité opérationnelle et limiter l'impact environnemental.

L'étude s'articule autour des questions suivantes :

Q1 : Comment modéliser l'environnement minier complexe (réseau routier, zones tampons, événements stochastiques) dans un cadre d'apprentissage par renforcement compatible avec les standards industriels ?

Q2 : Quelle architecture d'agent d'apprentissage par renforcement est la plus adaptée pour apprendre une politique de navigation holistique intégrant à la fois le choix d'itinéraire et le contrôle de vitesse ?

Q3 : Comment concevoir une fonction de récompense qui capture fidèlement les coûts réels (carburant, usure, temps) tout en pénalisant les comportements non souhaitables ?

Q4 : Quelles métriques et quels protocoles d'évaluation permettront de démontrer quan-

titativement la supériorité de l'approche d'apprentissage par renforcement par rapport aux approches classiques, notamment dans des scénarios de perturbation ?

Q5 : Comment intégrer un tel système d'apprentissage par renforcement comme couche d'intelligence additionnelle dans l'écosystème des systèmes de gestion de flotte existants, sans nécessiter un remplacement complet de l'infrastructure ?

Les réponses détaillées à ces problématiques seront développées tout au long des chapitres suivants, à travers la modélisation, l'expérimentation et l'analyse des résultats obtenus.

L'hypothèse centrale est qu'un agent autonome basé sur l'apprentissage par renforcement peut surpasser les approches heuristiques classiques pour l'optimisation dynamique de la logistique minière, en réduisant la consommation de carburant, les temps d'attente et en améliorant l'adaptabilité aux perturbations [9–11]. Les objectifs principaux de ce travail sont les suivants :

- Concevoir un environnement de simulation réaliste pour la logistique minière à ciel ouvert ;
- Développer un agent d'apprentissage par renforcement capable d'optimiser les décisions de dispatching et de routage ;
- Comparer les performances de l'agent d'apprentissage par renforcement avec celles des heuristiques classiques sur des scénarios variés ;
- Analyser l'impact de l'approche d'apprentissage par renforcement sur les indicateurs clés (coût, temps, consommation, robustesse).

La méthodologie suivie s'appuie sur le cadre CRISP-RL au contexte de l'apprentissage par renforcement : compréhension du problème et des données [3], modélisation de l'environnement, conception et entraînement de l'agent, expérimentation et analyse comparative [9, 11]. Chaque étape est guidée par une validation rigoureuse des hypothèses et une évaluation quantitative des résultats. Ce mémoire est organisé en six chapitres et une conclusion générale :

- Le premier chapitre présente le contexte général de la logistique minière et ses concepts fondamentaux, afin de poser le cadre métier et les notions clés mobilisées dans ce mémoire.
- Le deuxième chapitre propose un état de l'art des approches d'optimisation existantes, des heuristiques classiques aux méthodes avancées, et met en évidence le positionnement des approches basées sur l'apprentissage par renforcement.
- Le troisième chapitre détaille la modélisation du problème de transport minier, les hypothèses retenues et la formulation du système dans un cadre de décision séquentielle.
- Le quatrième chapitre décrit la méthodologie adoptée et la conception de la solution proposée, en précisant les choix de modélisation, d'architecture et d'apprentissage.
- Le cinquième chapitre présente l'implémentation, le protocole expérimental et les résultats obtenus sur les scénarios étudiés.
- Le sixième chapitre analyse et discute les résultats, en évaluant les performances, les limites et la robustesse de l'approche.
- Ce mémoire se conclut par un dernier chapitre de conclusion générale, qui synthétise les principaux apports et ouvre sur des perspectives de recherche et d'application.

Chapitre 1

Concepts fondamentaux de la logistique minière

Introduction

La compréhension rigoureuse de la logistique minière nécessite un cadre conceptuel clair, capable d'articuler les dimensions opérationnelles, décisionnelles et méthodologiques du problème étudié. Dans le contexte du transport en mine à ciel ouvert, la précision des notions utilisées conditionne la qualité de la modélisation, l'interprétation des résultats et la pertinence des choix d'optimisation.

1.1 Logistique minière et transport en mine à ciel ouvert

La logistique minière regroupe l'ensemble des activités de planification, d'organisation et de pilotage des flux de matériaux, d'équipements et d'informations nécessaires à l'exploitation d'une mine. Dans une mine à ciel ouvert, elle est centrée sur le système camion-pelle, où les matériaux sont extraits, chargés, transportés puis déchargés vers des destinations opérationnelles [2, 3].

Les concepts fondamentaux de ce système sont les suivants :

- **Mine à ciel ouvert** : Exploitation dans laquelle le minerai est extrait par gradins successifs depuis la surface.
- **Système camion-pelle** : Organisation de production où les pelles/chargeuses alimentent des camions qui assurent le transport du matériau.
- **Cycle camion-pelle** : Séquence *affectation* $\rightarrow$ *chargement* $\rightarrow$ *transport* $\rightarrow$ *déchargement* $\rightarrow$ *retour*.
- **Point de chargement** : Zone de prélèvement du matériau (pelle, chargeuse, front de taille).
- **Point de déchargement** : Destination de livraison (concasseur, halde, stock intermédiaire).
- **Zone tampon** : Espace de régulation des flux où les camions attendent avant affectation ou service.

1.2 Systèmes de gestion de flotte minière

Les systèmes de gestion de flotte sont des plateformes de supervision et d'aide à la décision qui orchestrent les opérations de transport en temps réel. Leur rôle est d'assurer la coordination entre ressources mobiles (camions) et ressources fixes (pelles, points de déchargement), tout en respectant les contraintes de production et de sécurité [2, 4].

Dans ce cadre, les notions de base sont :

- **Disponibilité des ressources** : Capacité effective d'un équipement à réaliser une tâche à un instant donné.
- **Affectation** : Décision d'envoyer un camion vers une destination donnée selon les priorités opérationnelles.
- **File d'attente** : Ensemble des camions en attente de service à une ressource contrainte.
- **Synchronisation camion-pelle** : Ajustement des arrivées de camions au rythme de chargement pour réduire l'attente improductive.

1.3 Concepts de dispatching et de routage minier

Le dispatching et le routage constituent les deux leviers décisionnels centraux du transport minier. Le dispatching détermine *la destination* d'un camion, alors que le routage détermine *l'itinéraire* suivi pour y parvenir. Leur couplage conditionne la performance globale du système [4, 5, 12].

Leur formalisation conceptuelle s'appuie sur les éléments suivants :

- **Dispatching** : Règle d'affectation dynamique des camions aux points de chargement ou déchargement.
- **Routage** : Choix du chemin entre deux nœuds en fonction de critères de coût, de temps et de risque.
- **Réseau routier minier** : Structure de transport du site, modélisable sous forme de graphe orienté pondéré.
- **Nœud** : Entité du réseau (pelle, concasseur, halte, intersection, zone tampon).
- **Arc** : Segment orienté reliant deux nœuds et porteur d'attributs (distance, pente, état de route).
- **Congestion** : Saturation locale des capacités de service provoquant une hausse des temps d'attente.

1.4 Principes opérationnels et contraintes du transport minier

Le transport minier est gouverné par des contraintes opérationnelles, énergétiques et de sécurité qui doivent être représentées explicitement dans le modèle conceptuel du système. La variabilité des temps de service et les perturbations imposent en outre une vision stochastique de l'exploitation [2, 6, 8].

Les concepts fondamentaux associés sont :

- **Temps de cycle** : Durée totale d'un cycle camion-pelle.
- **Temps d'attente** : Temps improductif passé en file ou en attente de ressource.

- **Taux d'utilisation** : Part du temps pendant lequel un équipement est effectivement productif.
- **Match Factor** : Indicateur d'équilibre entre capacité de transport et capacité de chargement.
- **Consommation spécifique** : Litres de carburant consommés par tonne transportée.
- **Coût opérationnel par tonne** : Coût total de transport rapporté au tonnage utile.

Enfin, la base conceptuelle du sujet inclut aussi le cadre décisionnel séquentiel de l'apprentissage par renforcement :

- **Processus de décision markovien (MDP)** : Formalisation d'un problème séquentiel par un quadruplet (S, A, P, R) .
- **État** : Représentation synthétique de la situation opérationnelle observée.
- **Action** : Décision admissible appliquée à l'état courant.
- **Récompense** : Signal scalaire traduisant la qualité immédiate d'une décision au regard des objectifs métier.
- **Politique** : Règle de décision associant des actions aux états.

1.5 Conclusion

Ce chapitre a posé un socle conceptuel complet pour le sujet traité, en clarifiant les notions métier de la logistique minière, les mécanismes opérationnels du système camion-pelle, les principes de dispatching et de routage, les contraintes et indicateurs clés de performance, ainsi que le cadre décisionnel séquentiel mobilisé par l'apprentissage par renforcement. Cette base terminologique et conceptuelle sert de référence pour la revue de littérature du chapitre suivant.

Chapitre 2

État de l’art des méthodes d’optimisation

Introduction

L’optimisation de la logistique minière a connu une évolution progressive, portée par des approches de plus en plus élaborées pour répondre à la complexité des environnements d’exploitation. L’examen critique des travaux existants est indispensable pour identifier les acquis de la littérature, mais aussi les limites qui freinent encore une optimisation robuste et dynamique en conditions réelles.

Dans ce mémoire, cette revue ne sert pas seulement à inventorier les méthodes existantes, mais à faire apparaître le besoin d’un cadre de décision centré sur le dispatching, explicite sur ses hypothèses et suffisamment souple pour rester exploitable dans un environnement stochastique.

2.1 Les heuristiques classiques

L’histoire de l’optimisation de la logistique minière débute avec des heuristiques simples, telles que l’assignation du camion le plus proche ou la règle du premier arrivé, premier servi [4, 13]. Si ces méthodes sont faciles à mettre en œuvre, elles restent « myopes » : elles optimisent localement sans anticiper les conséquences globales sur la flotte. Cette limitation a conduit à l’émergence de systèmes industriels comme DISPATCH, Caterpillar MineStar ou Komatsu Jigsaw, qui intègrent des modules de planification et de suivi en temps réel [2, 14]. Ces systèmes ont permis d’augmenter la productivité et de réduire les temps d’attente, mais restent largement déterministes et rigides, peinant à s’adapter aux perturbations et à la dynamique réelle du terrain.

2.2 Les méta-heuristiques

L’apparition des systèmes industriels comme DISPATCH marque une première rupture, en intégrant la planification et le suivi en temps réel. Cependant, ces solutions restent déterministes et peu flexibles face à la variabilité du terrain.

Pour dépasser les limites des systèmes industriels, la recherche académique a proposé des approches plus sophistiquées : méta-heuristiques (algorithmes génétiques, colonies de fourmis, recuit simulé) [15, 16], modèles MILP ou programmation par contraintes [17–20]. Ces méthodes offrent de meilleures performances sur des cas complexes, mais leur capacité d'adaptation en temps réel reste limitée, notamment face à l'incertitude et à la variabilité opérationnelle [5, 6, 8].

2.3 Les approches basées sur l'apprentissage par renforcement

Face aux limites persistantes de ces approches, un nouveau paradigme issu de l'intelligence artificielle s'est imposé : l'apprentissage par renforcement. L'apprentissage par renforcement permet à un agent d'apprendre une politique de décision séquentielle en interagissant avec un environnement simulé ou réel, optimisant ainsi la flotte de manière holistique et adaptative [11, 21]. Les travaux récents montrent que l'apprentissage par renforcement peut surpasser les heuristiques classiques pour le routage de véhicules, la gestion dynamique des files d'attente et l'optimisation des ressources, même en présence d'incertitude [7, 10].

2.4 Synthèse critique et positionnement du travail

La littérature montre que, malgré les avancées des systèmes de gestion de flotte industriels et des heuristiques, l'optimisation globale et dynamique de la flotte minière reste un défi [5, 8]. Les approches d'apprentissage par renforcement offrent un potentiel inédit pour dépasser ces limites, en permettant une adaptation en temps réel, une optimisation holistique et une meilleure gestion de l'incertitude [10, 11]. Ce mémoire s'inscrit dans cette dynamique, en proposant une solution d'apprentissage par renforcement adaptée aux contraintes et aux spécificités de la logistique minière moderne.

L'analyse de la littérature permet de classer les travaux existants en trois catégories majeures. Premièrement, les heuristiques classiques, basées sur des règles métier simples, offrent une solution rapide mais manquent de flexibilité. Deuxièmement, les méta-heuristiques (algorithmes génétiques, colonies de fourmis) permettent de traiter des problèmes plus complexes, au prix d'une puissance de calcul plus élevée. Enfin, les approches par apprentissage par renforcement émergent comme une solution prometteuse pour une optimisation dynamique et robuste face aux aléas. Le tableau 2.1 synthétise les opportunités offertes par cette dernière famille d'approches par rapport aux méthodes conventionnelles.

TABLE 2.1 – Synthèse des grandes familles d'approches et opportunités pour l'apprentissage par renforcement

Référence	Approche	Limites principales / Opportunité pour l'apprentissage par renforcement
[4]	Heuristiques statiques	Approche myope, peu adaptative, ne gère pas l'incertitude. Opportunité : L'apprentissage par renforcement peut apprendre une politique globale et adaptative.
[2, 14]	Systèmes industriels	Déterministes, rigides, peu réactifs aux perturbations. Opportunité : L'apprentissage par renforcement permet l'adaptation dynamique.
[15, 16]	Méta-heuristiques	Performantes mais peu robustes en temps réel, optimisation hors-ligne. Opportunité : L'apprentissage par renforcement gère l'incertitude et l'adaptation continue.
[17, 18]	MILP, optimisation avancée	Complexité computationnelle, difficilement scalable, peu flexible. Opportunité : L'apprentissage par renforcement offre une solution scalable et flexible.
[11, 21]	apprentissage par renforcement pour VRP/JSSP	Complexité de la modélisation, besoin de simulateur. Inspiration : Fournit un cadre état/action/récompense pour l'apprentissage par renforcement minier.
[7, 10]	apprentissage par renforcement appliqué à la logistique minière	L'apprentissage par renforcement montre des gains sur la robustesse et l'adaptation, mais nécessite une modélisation réaliste et des données de simulation.

Afin de positionner précisément notre contribution, il convient d'examiner les apports et les limites des articles scientifiques les plus significatifs du domaine. Ces travaux couvrent aussi bien l'optimisation des flux industriels que l'application d'algorithmes d'apprentissage sur des problèmes de routage. Cette revue critique, synthétisée dans le tableau 2.2, met en évidence le besoin d'une approche holistique intégrant la variabilité stochastique du terrain.

TABLE 2.2 – Détail des contributions et limites des articles majeurs de l'état de l'art

Référence	Domaine / Approche	Principales contributions / Limites
[3]	systèmes de gestion de flotte, optimisation minière	Modélisation des flux, contraintes industrielles, limites des heuristiques
[2]	systèmes de gestion de flotte industriels	Suivi en temps réel, gestion des files, limites en environnement dynamique
[4]	Heuristiques classiques	Règles de dispatching, efficacité en conditions stables, manque d'adaptabilité
[5]	Heuristiques, VRP	Variabilité du trafic, limites des modèles déterministes
[8]	Méta-heuristiques	Colonies de fourmis, optimisation partielle, adaptation limitée
[11]	apprentissage par renforcement pour VRP	apprentissage par renforcement pour routage, surpasse heuristiques, besoin de données, temps d'entraînement
	apprentissage par renforcement appliqué à la logistique	apprentissage par renforcement pour dispatching, robustesse, adaptation aux perturbations
[10]	apprentissage par renforcement en environnement stochastique	Politiques robustes, gestion de l'incertitude, limites pratiques
[6]	Limites des heuristiques	Incapacité à gérer la variabilité, sous-utilisation des ressources
[21]	apprentissage par renforcement : fondements	Concepts MDP, politiques, fonctions de valeur
[15, 16]	Méta-heuristiques	Algorithmes génétiques, recuit simulé, optimisation locale

2.5 Conclusion

Ce chapitre a retracé l'évolution des approches d'optimisation de la logistique minière, depuis les heuristiques simples jusqu'aux systèmes industriels, en passant par les méta-heuristiques et l'optimisation avancée. Il a mis en évidence les limites des méthodes traditionnelles face à la complexité, la variabilité et l'incertitude des environnements miniers. L'apprentissage par renforcement apparaît comme un paradigme innovant, capable d'apporter une adaptation dynamique, une optimisation holistique et une robustesse accrue. Ce

positionnement ouvre la voie à une nouvelle génération de solutions pour la logistique minière. Le chapitre suivant présentera la modélisation du problème de transport minier et les choix méthodologiques pour concevoir un agent d'apprentissage par renforcement adapté à la logistique minière.

Ce positionnement reste néanmoins conditionné par la qualité de la simulation et par la richesse des variables observées : le RL n'est pas une solution universelle, mais une approche pertinente lorsque le compromis entre réalisme, adaptabilité et coût de calcul est correctement maîtrisé.

Chapitre 3

Modélisation du problème de transport minier

Introduction

La modélisation du problème de transport minier constitue une étape centrale pour transformer une problématique industrielle complexe en un cadre formel exploitable par des méthodes d’optimisation et d’apprentissage. Dans le cas du transport minier, cette formalisation doit intégrer à la fois la structure du réseau, les contraintes opérationnelles et la variabilité des conditions de terrain, conformément aux analyses critiques récentes sur l’évolution des systèmes de gestion de flotte [2, 22].

3.1 Description du système de transport minier

Le système de transport minier considéré dans ce mémoire repose sur le modèle classique camion-pelle, largement déployé dans les mines à ciel ouvert [3, 4, 13]. Ce système comprend les éléments suivants :

- **Ressources d’extraction** : Des pelles (excavatrices) positionnées à des points de chargement fixes ou dynamiques, responsables du chargement du matériel brut extrait.
- **Flotte de transport** : Un ensemble de camions hétérogènes circulant entre les points de chargement et les points de déchargement (concasseurs, stockage, etc.).
- **Réseau routier** : Une infrastructure de transport composée de routes principales et secondaires, avec des points de chargement, de déchargement et des jonctions.
- **Opérateurs humains** : Conducteurs de camion et opérateurs de pelle qui exécutent les décisions du système de dispatching.
- **Variabilité environnementale** : Conditions météorologiques, état des routes, dégradation du matériel et autres aléas affectant les temps de cycle.

Le fonctionnement du système repose sur un cycle répétitif : (1) Assignment d’un camion à une pelle par le système de dispatching ; (2) Transport du camion vers la pelle ; (3) Attente à la queue de chargement ; (4) Chargement du matériau ; (5) Transport vers un point de déchargement ; (6) Déchargement ; (7) Retour au point de chargement. L’objectif opérationnel est de maximiser le tonnage transporté par unité de temps (rendement) tout en respectant

les contraintes de sécurité, de maintenance et de disponibilité des ressources, y compris dans des contextes intégrant des flottes partiellement ou totalement autonomes [14, 23].




FIGURE 3.1 – Cycle opérationnel du système camion-pelle et point d'intervention de l'agent de dispatching.

Le défi de modélisation réside dans la capture simultanée de la dynamique des flux, des interactions camion-pelle, des variations stochastiques des temps de cycle et des décisions de dispatching qui influencent globalement le rendement du système.

3.2 Hypothèses et contraintes de modélisation

La modélisation du problème complexe de la logistique minière nécessite un ensemble d'hypothèses simplificatrices pour rendre le système traitable par des algorithmes d'apprentissage par renforcement. Ces hypothèses sont justifiées par les besoins d'efficacité computationnelle et de convergence algorithmique, tout en préservant les éléments essentiels du problème réel, dans une logique cohérente avec les approches actor-critic appliquées aux complexes miniers et les cadres de simulation-optimisation opérationnelle [16, 24].

Ces hypothèses doivent être lues comme des conditions de validité du modèle, et non comme une description exhaustive du terrain. Elles simplifient volontairement la réalité pour rendre l'apprentissage possible, au prix d'une perte de finesse qui devra être discutée lors de l'interprétation des résultats.

Hypothèses de modélisation

- **Horizon temporel** : Le système est modélisé en temps discret avec des pas de décision réguliers (Ex : Une décision toutes les 5 à 10 secondes en temps réel, ou à chaque événement dans un simulateur événementiel).
- **Stationnarité à court terme** : On suppose que la distribution des temps de cycle reste stable sur des horizons court (quelques heures), permettant l'apprentissage avec des données récentes.
- **Observation partielle** : L'agent ne connaît pas parfaitement l'état complet du système (positions exactes, états des routes). Dans l'implémentation, le vecteur d'obser-

vation est construit à partir de l'état interne du simulateur (disponibilités des ressources, positions des camions, temps courant) sans injection de bruit additionnel ; la stochasticité provient de la dynamique elle-même (temps de trajet log-normaux, pannes aléatoires).

- **Camions homogènes** : Bien que les flottes réelles soient hétérogènes, on regroupe les camions par classe de capacité pour réduire la dimensionnalité de l'espace d'état, une simplification couramment mobilisée face aux contraintes de dispatching de flottes multi-capacités [17].
- **Points de chargement et déchargement fixes** : Les emplacements de pelle et les destinations de déchargement sont fixes pendant une session d'apprentissage.
- **Pas de défaillance majeure** : Le système opère sans défaillance critique des pelles ou des routes principales pendant la durée de l'épisode d'apprentissage.

Contraintes opérationnelles

Le modèle intègre un ensemble de contraintes reflétant les réalités opérationnelles :

- **Capacité des pelles** : Chaque pelle peut accueillir un nombre limité de camions en file d'attente avant que la congestion ne cause une pénalité, ce qui rejoint les modèles intégrant explicitement l'effet des files et de l'inactivité des pelles [19].
- **Disponibilité** : Les pelles ont des périodes de maintenance, les routes peuvent être fermées temporairement, réduisant les options de dispatching.
- **Distance et temps de trajet** : Les trajets ne sont jamais instantanés ; on utilise des matrices de temps calculées à partir du réseau routier.
- **Charge utile** : Les camions ont une capacité maximale et doivent être alimentés avec des matériaux compatibles (un camion ne peut pas être assigné à une pelle produisant un type de minerai que sa destination ne peut pas traiter).
- **Préemption limitée** : Les décisions de dispatching ne peuvent pas être annulées une fois qu'un camion est en route (pas de retournement à mi-parcours).

Ces hypothèses et contraintes délimitent l'espace d'exploration de l'algorithme d'apprentissage par renforcement, assurant que les politiques apprises restent réalistes et applicables en production.

Autrement dit, le modèle conserve les facteurs qui gouvernent réellement la décision, tout en écartant certains détails locaux qui augmenteraient fortement la dimension du problème sans améliorer proportionnellement la qualité de la politique apprise.

Synthèse des hypothèses de modélisation

TABLE 3.1 – Synthèse des hypothèses

Catégorie	Méthodes	Objectif	Inconvénients
Temps discret	Simulation événementielle	Permet une prise de décision séquentielle compatible avec un agent RL et un simulateur événementiel.	Sensible au choix de Δt ; un pas trop grand lisse la dynamique, un pas trop fin augmente le coût de calcul.
Stationnarité à court terme	Découpage temporel	Stabilise l'apprentissage sur des fenêtres opérationnelles réalistes (quelques heures).	Peut se dégrader lors de ruptures de régime (pluie, incidents, changements de plan).
Observation partielle	Vecteur normalisé sans bruit additionnel	La stochasticité est dans la dynamique (temps log-normaux, pannes) ; l'observation reflète l'état interne du simulateur de manière exacte mais incomplète.	Introduit une part de non-markovianité apparente si l'état observé est trop pauvre.
Regroupement des camions par classes	Classification par capacité	Réduit la dimensionnalité de l'état et de l'action pour accélérer la convergence.	Perte de granularité sur les différences intra-classe (usure, performance individuelle).
Points de charge-déchargement fixes sur un épisode	Configuration statique	Simplifie le cadre expérimental et la comparaison avec les baselines.	Généralisation limitée aux contextes de repositionnement dynamique des pelles ou destinations.
Absence de défaillance majeure pendant un épisode	Mode nominal	Permet d'évaluer d'abord la politique nominale dans un cadre contrôlé.	Sous-estime le risque opérationnel réel si les pannes ne sont pas ensuite injectées en tests de robustesse.

3.3 Modélisation du réseau routier minier

Le réseau routier minier constitue l'infrastructure d'interaction entre les différentes ressources du système. Sa modélisation est cruciale pour que les décisions de dispatching reflètent les réalités géographiques et logistiques du site.

Représentation graphique du réseau

Le réseau routier est modélisé comme un graphe pondéré $G = (V, E)$ où :

- V est l'ensemble des nœuds représentant les points d'intérêt : points de chargement (pelles), points de déchargement (concasseurs, stockage), jonctions et intersections.
- E est l'ensemble des arêtes représentant les connexions routières entre nœuds.
- Chaque arête (u, v) est pondérée par la distance euclidienne, le temps de trajet ou un coût composé.

Ce graphe peut être orienté (sens uniques, routes à sens limité) ou non-orienté (routes bidirectionnelles) selon la configuration du site.




FIGURE 3.2 – Représentation du réseau routier sous forme de graphe stochastique.

Matrices de temps et matrices de coût

À partir du graphe, on calcule deux matrices fondamentales :

- **Matrice de temps** T : T_{ij} est le temps de trajet moyen (en minutes) du nœud i au nœud j , calculé via l'algorithme de plus court chemin (Dijkstra ou Floyd-Warshall).
- **Matrice de coût** C : C_{ij} agrège plusieurs dimensions : distance, temps de trajet, consommation de carburant [25], usure du véhicule. On peut utiliser une combinaison linéaire pondérée :

$$C_{ij} = \alpha \cdot T_{ij} + \beta \cdot D_{ij} + \gamma \cdot E_{ij} \quad (3.1)$$

où D_{ij} est la distance, E_{ij} est une estimation de l'usure ou du coût énergétique, et α, β, γ sont des poids de pondération.

Exemple numérique : Si $\alpha = 0,5$, $\beta = 0,3$, $\gamma = 0,2$, $T_{ij} = 15$ minutes, $D_{ij} = 2,5$ km, $E_{ij} = 0,8$, alors $C_{ij} = 0,5 \times 15 + 0,3 \times 2,5 + 0,2 \times 0,8 = 7,5 + 0,75 + 0,16 = 8,41$.

Intégration de la variabilité stochastique

Le réseau réel n'est pas déterministe : les temps de trajet varient en fonction de l'état de la route, des conditions météorologiques, et de la charge du camion. On modélise cette variabilité par :

$$T_{ij}(t) = \bar{T}_{ij} + \eta_{ij}(t) \quad (3.2)$$

où $\bar{T}_{ij}$ est le temps moyen et $\eta_{ij}(t)$ est un bruit reflétant la variabilité observée. Les durées étant strictement positives, la variabilité est modélisée par une distribution **log-normale**, plus réaliste qu'une gaussienne pour des variables de temps.

Exemple numérique : Si $\bar{T}_{ij} = 12$ minutes et $\eta_{ij}(t) = 2,3$ minutes (échantillon d'une distribution normale avec $\sigma = 2,5$), alors $T_{ij}(t) = 12 + 2,3 = 14,3$ minutes.

Cette modélisation stochastique est essentielle pour évaluer la robustesse des politiques apprises, car elle oblige l'agent à anticiper les variations plutôt que de se fier à des temps de trajet figés. Cette exigence de robustesse est également mise en avant dans les travaux récents de RL multi-agent appliqués au dispatching minier [26].

3.4 Formulation du problème en tant que processus de décision markovien

La formalisation du problème de dispatching minier en tant que processus de décision markovien est l'étape décisive qui transforme le système opérationnel en un problème d'apprentissage par renforcement. Ce cadrage rejoint les études récentes de dispatching minier fondées sur des formulations explicites de type MDP, ainsi que les travaux fondateurs en apprentissage par renforcement séquentiel appliqué à des problèmes de routage et d'ordonnement [11, 21, 27]. Un processus de décision markovien est défini par le 4-tuple $(\mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R})$ où :

Le choix de cette formulation n'est pas uniquement formel. Il permet de condenser l'information utile à la décision tout en évitant une explosion de la dimension d'état, ce qui serait pénalisant pour l'apprentissage et pour la stabilité des politiques estimées.

- $\mathcal{S}$ est l'ensemble des états possibles du système.
- $\mathcal{A}$ est l'ensemble des actions (décisions de dispatching) disponibles.
- $\mathcal{P}(s'|s, a)$ est la probabilité de transition vers l'état s' en exécutant l'action a depuis l'état s .
- $\mathcal{R}(s, a, s')$ est la récompense reçue lors d'une transition.

Espace d'état $\mathcal{S}$

L'état du système à chaque instant t est représenté par un vecteur de variables d'état contenant les informations essentielles pour la prise de décision :

$$s_t = \left(\{q_p\}_{p \in \text{Pelles}}, \{x_c\}_{c \in \text{Camions}}, \{z_r\}_{r \in \text{Ressources}}, t_{\text{courant}} \right) \quad (3.3)$$

où q_p désigne la longueur de la file d'attente à la pelle p , x_c la localisation du camion c , et z_r l'état de disponibilité de la ressource r .

Exemple numérique : Pour une mine avec 3 pelles, 12 camions et 2 dumps à $t_{\text{courant}} = 240$ minutes (4 heures) : $s_t = (\{2, 3, 1\}, \{\text{yard}, \text{shovel}_1, \text{dump}_1, \dots\}, \{0, 5\}, 240)$ où les files d'attente aux pelles sont $\{2, 3, 1\}$ camions respectivement, les camions sont répartis sur le réseau, et les dumps seront disponibles dans $\{0, 5\}$ minutes.

De manière plus détaillée :

- **Files d'attente aux pelles :** Pour chaque pelle p , on enregistre le nombre de camions en attente et leur temps d'arrivée estimé.
- **Localisation des camions :** Pour chaque camion c , on enregistre son dernier nœud de présence et son statut (libre, en route, en charge, en décharge).
- **Disponibilité des ressources :** Pour chaque pelle ou section de route, on enregistre si elle est disponible, en maintenance ou indisponible.
- **Temps courant :** L'heure de la journée ou l'étape de simulation, qui peut influencer la dynamique (sauf au sein d'un épisode stationnaire).

Espace d'action $\mathcal{A}$

À chaque étape de décision, l'agent doit décider d'assigner certains camions libres à des pelles disponibles. L'espace d'action dépend de l'état courant et est construit comme suit :

$$a_t = \text{Assignment}(c_1 \rightarrow p_j, c_2 \rightarrow p_k, \dots) \quad \text{ou} \quad a_t = \text{ATTENDRE} \quad (3.4)$$

Une action valide est un ensemble d'appairements camion-pelle qui respectent les contraintes :

- Le camion doit être libre (non actuellement en transit, en charge ou en décharge).
- La pelle doit être disponible et produire un type de minerai compatible avec la capacité du camion.
- L'action peut aussi être d'attendre (pas de changement) si attendre est plus profitable à long terme.

L'ensemble $\mathcal{A}(s)$ des actions possibles dans l'état s peut être très large (combinatoire exponentiel). Pour rendre le problème traitable, on peut limiter l'espace à un nombre réduit d'actions par exemple assigner au maximum k camions par étape, ou sélectionner les n meilleures paires candidate selon une heuristique.

Cette restriction constitue un compromis assumé : une action décrite comme une affectation complète de la flotte serait plus expressive, mais elle rendrait l'espace de recherche nettement moins maniable. Le modèle retient donc une granularité suffisante pour capturer l'essentiel du dispatching sans faire basculer le problème dans une complexité disproportionnée.

Modèle de transition $\mathcal{P}(s'|s, a)$

Le modèle de transition décrit comment le système évolue suite à une action. Étant donné un état s et une action a , le nouvel état s' est déterminé par :

$$s'_t = \text{Simuler}(s_t, a_t, \Delta t) \quad (3.5)$$

où Δt est l'intervalle de temps entre deux décisions.




FIGURE 3.3 – Schéma d'interaction entre l'agent RL (politique) et l'environnement (simulateur minier).

La simulation inclut :

- **Avancement des camions en transit** : Les camions se déplacent selon les matrices de temps du réseau, avec perturbations stochastiques.
- **Mise à jour des files d'attente de chargement** : Les camions arrivent aux pelles, se joignent à la file ou commencent le chargement.
- **Événements de déchargement** : Les camions qui atteignent les points de déchargement sont marqués comme déchargés et reviennent en état libre.
- **Dynamique des pelles** : Chaque pelle continue de servir les camions selon un ordre FIFO ou de priorité.

Formellement, le modèle de transition est une fonction déterministe augmentée de sources de stochasticité (variation des temps de trajet). Cette représentation est alignée avec les environnements de benchmark configurables récemment proposés pour le dispatching minier et avec les travaux de simulation dédiés à l'évaluation de règles de dispatching sous incertitude [10, 28] :

$$s'_t = f(s_t, a_t) + \eta_t, \quad \eta_t \sim \mathcal{N}(0, \Sigma) \quad (3.6)$$

où $f(s_t, a_t)$ est la transition déterministe et η_t représente les perturbations stochastiques.

Fonction de récompense $\mathcal{R}(s, a, s')$

La récompense reflète les objectifs opérationnels. Le rendement global du système (tonnage par unité de temps) peut être décomposé en plusieurs objectifs :

$$R_t = w_1 \cdot R_{\text{rendement}}(s_t, s'_t) + w_2 \cdot R_{\text{équité}}(s_t) + w_3 \cdot R_{\text{coût}}(a_t) \quad (3.7)$$

Exemple numérique : Si $w_1 = 1,0$, $w_2 = 0,1$, $w_3 = 0,05$, $R_{\text{rendement}} = 280$ tonnes, $R_{\text{équité}} = -5,2$ (pénalité due à files inégales), $R_{\text{coût}} = -120$ (pénalité de distance), alors $R_t = 1,0 \times 280 + 0,1 \times (-5,2) + 0,05 \times (-120) = 280 - 0,52 - 6 = 273,48$.

où :

- $R_{\text{rendement}}$: Récompense proportionnelle au tonnage livré à la destination au cours du pas de temps Δt . C'est l'objectif principal.

$$D_t = \{c \in \text{Camions} \mid c \text{ est déchargé dans } [t, t + \Delta t]\} \quad (3.8)$$

$$R_{\text{rendement}}(s_t, s'_t) = \sum_{c \in D_t} \text{capacité}(c) \quad (3.9)$$

Exemple numérique : Si 2 camions sont déchargés dans l'intervalle $[t, t + \Delta t]$ avec des capacités de 140 tonnes chacun, alors $R_{\text{rendement}} = 140 + 140 = 280$ tonnes.

- $R_{\text{équité}}$: Récompense encourageant une utilisation équilibrée des ressources (prévenir la surcharge d'une pelle au détriment d'autres).

$$R_{\text{équité}}(s_t) = -\lambda \cdot \phi(\{q_p\}_{p \in \text{Pelles}}) \quad (3.10)$$

Exemple numérique : Si $\lambda = 0,5$ et les files d'attente sont $\{q_p\} = \{2, 5, 3\}$ camions, la variance est $\phi(\{2, 5, 3\}) = \text{Var}(\{2, 5, 3\}) = 2,33$, alors $R_{\text{équité}} = -0,5 \times 2,33 = -1,17$.

où

$$\phi(\{q_p\}_{p \in \text{Pelles}}) = \begin{cases} \text{Var}(\{q_p\}_{p \in \text{Pelles}}), & \text{si } |\text{Pelles}| \geq 2, \\ 0, & \text{si } |\text{Pelles}| = 1. \end{cases} \quad (3.11)$$

Cette définition garantit que le terme d'équité reste bien défini, même lorsqu'une seule pelle est présente.

- $R_{\text{coût}}$: Pénalité liée aux décisions (Pour décourager les affectations inefficaces ou les trajets excessifs).

$$R_{\text{coût}}(a_t) = - \sum_{(c \rightarrow p) \in a_t} C(\text{pos}(c), \text{pos}(p)) \quad (3.12)$$

Exemple numérique : Si l'action a_t assigne 2 camions avec des coûts de trajet $C = 8,41$ et $C = 6,25$, alors $R_{\text{coût}} = -(8,41 + 6,25) = -14,66$.

Les poids w_1, w_2, w_3 permettent de moduler l'importance relative de chaque objectif selon les priorités métier.




FIGURE 3.4 – Structure multi-objectif de la fonction de récompense globale.

Propriété markovienne et implications

L'hypothèse clé est que l'état s_t contient toute l'information nécessaire pour prédire l'évolution future du système indépendamment du passé (propriété markovienne). Cette hypothèse est raisonnable si :

- Les décisions passées ont déjà eu leur effet sur l'état courant (les camions sont soit en transit, soit en file d'attente, soit libres).
- Les seules sources d'incertitude future sont les variations stochastiques des temps de trajet et les arrivées de nouveaux travaux (qui suivent une distribution connue).

Cette propriété justifie l'application d'algorithmes d'apprentissage par renforcement standards qui supposent un MDP, plutôt que d'exiger une mémoire d'observations passées.

3.5 Conclusion

Ce chapitre a établi le cadre formel de la modélisation du problème de transport minier, depuis la description du système camion-pelle jusqu'à sa formulation en processus de décision markovien. Il a structuré les composantes essentielles du problème, notamment l'état, l'action, la dynamique de transition et la fonction de récompense, afin de représenter de manière cohérente la logique décisionnelle du dispatching en environnement minier.

La modélisation proposée articule réalisme opérationnel et tractabilité algorithmique, en intégrant les contraintes du terrain (congestion, disponibilité des ressources, variabilité des temps de cycle) tout en restant exploitable par des méthodes d'apprentissage par renforcement. Ce socle conceptuel et mathématique sert de base directe au chapitre suivant, consacré à la méthodologie, à la conception de l'environnement de simulation, à l'agent d'apprentissage et au protocole d'évaluation.

Chapitre 4

Méthodologie, conception et choix algorithmique de la solution proposée

Introduction

Ce chapitre constitue la passerelle entre la modélisation formelle du problème, présentée au Chapitre 3, et l’implémentation expérimentale qui sera détaillée au Chapitre 5. L’objectif est de rendre la progression scientifique lisible : partir de la méthodologie CRISP-RL, construire l’environnement de simulation, introduire les algorithmes classiques d’apprentissage par renforcement, puis justifier le passage vers le Deep Reinforcement Learning.

Nous présentons d’abord le cadre méthodologique CRISP-RL qui a structuré l’ensemble du projet. Ensuite, nous détaillons la conception du simulateur de mine, l’architecture générale de l’approche proposée, puis nous introduisons les algorithmes classiques d’apprentissage par renforcement (Q-Learning, TD Learning, SARSA) comme bases théoriques et modèles comparatifs. Nous justifions ensuite le passage au Deep Reinforcement Learning via DQN, puis le choix de PPO comme approche finale. Enfin, nous définissons la stratégie d’évaluation comparative et les indicateurs de performance.

4.1 Méthodologie

Pour garantir la rigueur scientifique et la reproductibilité de notre approche, nous adoptons le cadre méthodologique CRISP-RL (CRoss-Industry Standard Process for Reinforcement Learning Applications), tel que proposé par [9]. Ce standard est une évolution du CRISP-DM traditionnel, spécifiquement repensée pour les systèmes apprenant par interaction dynamique.

4.1.1 Justification du choix de CRISP-RL

Le choix du CRISP-RL s’appuie sur la nature interactive et incertaine de la logistique minière. Contrairement à une analyse de données statiques où l’on cherche à prédire une

cible, le dispatching minier exige de piloter un système en temps réel. La logistique minière est un problème dynamique, séquentiel et incertain : les décisions de dispatching sont prises de manière répétée, les résultats de chaque décision dépendent de l'état courant du système, et les perturbations stochastiques (pannes, congestion, dégradation des routes) modifient continuellement les conditions opérationnelles.

Le CRISP-RL est le seul cadre permettant de gérer efficacement la boucle de rétroaction entre l'agent (le système de dispatching) et son environnement (la mine). Il intègre les phases de modélisation du simulateur comme une étape centrale du projet, assurant que l'agent n'apprend pas sur des données mortes, mais sur une dynamique de flux vivante et stochastique.

4.1.2 Adaptation des étapes CRISP-RL au contexte minier

Conformément aux travaux de Szatmári [9], nous suivons un cycle de vie en six étapes itératives, adaptées au contexte de la logistique minière :

- **Compréhension du problème métier** : Identification des enjeux de dispatching, routage, files d'attente, consommation de carburant et coûts opérationnels.
- **Modélisation de l'environnement** : Construction d'un simulateur fidèle représentant les camions, pelles, routes, points de chargement et de déchargement.
- **Formulation MDP** : Définition formelle des espaces d'états $\mathcal{S}$ et d'actions $\mathcal{A}$, ainsi que de la fonction de transition $\mathcal{P}$ et de la récompense $\mathcal{R}$ (développées au Chapitre 3).
- **Développement des agents RL** : Implémentation progressive des algorithmes : Q-Learning, TD Learning, SARSA, DQN, puis PPO.
- **Entraînement et test** : Phase d'apprentissage intensif où l'agent explore des milliers de scénarios de dispatching dans le simulateur.
- **Évaluation comparative** : Vérification de la performance de l'agent par rapport aux heuristiques industrielles et aux méthodes RL classiques, selon des indicateurs opérationnels quantitatifs.




FIGURE 4.1 – Cycle de vie CRISP-RL adapté à la logistique minière.

4.1.3 Positionnement de l'approche proposée dans le cycle CRISP-RL

L'approche proposée ne relève pas seulement d'un choix algorithmique. Elle s'inscrit dans un cycle complet : compréhension métier, simulation, formalisation MDP, apprentissage, expérimentation et validation par indicateurs opérationnels. Chaque étape du cycle CRISP-RL alimente la suivante et permet un retour itératif : si les résultats de l'évaluation révèlent des insuffisances, le cycle permet de revenir à la modélisation de l'environnement ou à la formulation MDP pour affiner le système.

4.2 Présentation générale de l'approche proposée

4.2.1 Principe général de la solution

La solution proposée consiste à concevoir un agent intelligent capable d'observer l'état courant du système minier (positions des camions, files d'attente aux pelles, disponibilité des dumps, état des routes), de choisir une décision de dispatching optimale (affectation camion-pelle-dump), puis d'améliorer progressivement sa politique de décision à partir des récompenses reçues. Cette approche se distingue des heuristiques statiques par sa capacité d'adaptation : l'agent apprend à réagir aux perturbations dynamiques (pannes, congestion, dégradation des routes) sans nécessiter de reprogrammation manuelle.

4.2.2 Architecture fonctionnelle de l’approche

L’architecture fonctionnelle de la solution repose sur quatre blocs principaux, synthétisés dans le Tableau 4.1.

TABLE 4.1 – Architecture fonctionnelle de l’approche proposée

Bloc fonctionnel	Rôle
Environnement minier simulé	Représenter les camions, pelles, routes, files d’attente et perturbations stochastiques.
Agent RL	Prendre les décisions de dispatching (affectation camion-pelle-dump).
Fonction de récompense	Évaluer la qualité des décisions selon les objectifs métier (rendement, équité, coût).
Module d’évaluation	Comparer les performances avec les baselines industrielles et les méthodes RL classiques.

Ces blocs interagissent de manière cyclique pour permettre l’apprentissage par renforcement. À chaque instant t , l’environnement minier simulé fournit à l’agent RL une observation de l’état du système (files d’attente, positions des camions, disponibilité des ressources). L’agent sélectionne alors une action de dispatching (affectation camion-pelle-dump), qui est exécutée par l’environnement. La fonction de récompense évalue immédiatement cette action selon les objectifs métier (maximisation du tonnage, minimisation des temps d’attente, réduction de la consommation de carburant). Cette récompense guide l’agent pour ajuster sa politique de décision. Enfin, le module d’évaluation permet de comparer les performances de l’agent RL avec des baselines industrielles (FIFO, Fixed Assignment, Nearest Shovel, Shortest Path) et des méthodes RL classiques (Q-Learning, SARSA, DQN) afin de valider l’efficacité de l’approche proposée. Ce flux d’interaction est schématisé dans l’architecture fonctionnelle présentée à la Figure 4.2 ci-dessous.




FIGURE 4.2 – Architecture fonctionnelle de la solution proposée.

4.2.3 Positionnement de l'agent dans le système de gestion de flotte

L'agent d'apprentissage par renforcement est conçu comme une couche intelligente d'aide à la décision. Il ne remplace pas entièrement le Fleet Management System (FMS), mais propose des décisions de dispatching optimisées à partir de l'état courant de la mine et des objectifs opérationnels. Le FMS reste responsable de la communication avec les équipements, de la sécurité et du suivi en temps réel, tandis que l'agent RL se concentre sur l'optimisation des affectations camion-pelle-dump.

4.3 Conception de l'environnement de simulation

L'environnement est le monde dans lequel l'agent va évoluer. Sa fidélité par rapport à la réalité minière est indispensable pour la validité des résultats, l'usage de la simulation étant reconnu comme l'approche standard pour évaluer ces systèmes complexes [29].

4.3.1 Architecture générale du simulateur

Nous avons développé un simulateur adapté en langage Python, en utilisant l'interface standardisée Gymnasium [30]. Gymnasium fournit un cadre rigoureux représentant un processus de décision markovien (MDP) via une classe de haut niveau nommée `Env`. La structure de notre simulateur repose sur quatre fonctions et attributs clés :

- **observation_space & action_space** : Ces attributs définissent le format des données. Nous utilisons l'espace `Box` pour les observations continues (positions, files) et `Discrete` pour les décisions de dispatching.
- **reset(seed, options)** : Initialise la mine pour un nouvel épisode de travail. Cette méthode renvoie l'observation initiale s_0 accompagnée d'un dictionnaire `info` pour le débogage.
- **step(action)** : C'est le cœur de la boucle Agent-Environnement. À partir d'une décision de dispatching, elle fait évoluer la mine de Δt et renvoie cinq valeurs cruciales : l'observation suivante (s_{t+1}), la récompense (r_t), ainsi que les signaux `terminated` (but atteint/échec), `truncated` (limite de temps du poste atteinte) et `info`.
- **render()** : Permet la visualisation de l'état de la flotte et des pelles pour le suivi humain.




FIGURE 4.3 – Architecture modulaire du simulateur Gymnasium.

4.3.2 Modélisation des entités minières

Le simulateur repose sur une architecture orientée objet (POO) où chaque entité physique est reliée aux variables formelles du MDP défini au Chapitre 3. La correspondance entre les classes logicielles et les composantes de l'espace d'état s_t (Eq. 3.3) est établie dans le Tableau 4.2.

TABLE 4.2 – Correspondance entre les classes logicielles et les variables du MDP

Classe	Rôle dans le MDP	Variable(s) encodée(s)	Eq.
Truck	Entité mobile, collecte KPIs	x_c (localisation, statut)	Eq. 3.3
Shovel	Ressource de chargement	q_p (file d'attente), z_r	Eq. 3.3
DumpSite	Ressource de déchargement	z_r (disponibilité)	Eq. 3.3
RoadGraph	Réseau routier paramétrable	Arcs (u, v) , distances, pentes	Eq. 3.2
Environment	Orchestrateur, logique $f(s_t, a_t)$	Transition s'_t (Eq. 3.6)	Eq. 3.5–3.6

Camions (Truck) : La classe `Truck` encode la composante x_c de l'espace d'état s_t , représentant la localisation et le statut courant de chaque camion $c \in \text{Camions}$. Elle suit en temps réel l'état de disponibilité, les cycles complétés, le tonnage transporté, le carburant consommé et les temps d'attente cumulés.

Pelles (Shovel) : La classe `Shovel` encode la composante q_p de l’espace d’état, soit la file d’attente à chaque pelle $p \in \text{Pelles}$. Les paramètres de chargement $(\bar{T}, \sigma)$ permettent d’échantillonner des durées stochastiques (Eq. 3.2).

Points de déchargement (DumpSite) : La classe `DumpSite` encode la disponibilité z_r des ressources de déchargement dans s_t . Les paramètres de déchargement introduisent la même stochasticté, simulant les goulots d’étranglement potentiels en fin de parcours.

Réseau routier (RoadGraph) : Le graphe routier $G = (V, E)$ est paramétrable : le nombre de pelles, de dumps et d’intersections est configurable. Chaque arête encode la distance, la pente, l’état de la route et les temps de trajet stochastiques.

Environnement (MineEnv) : Cette classe implémente la fonction de transition $f(s_t, a_t)$ augmentée des perturbations stochastiques η_t (Eq. 3.6). Elle orchestre les interactions entre entités et expose l’interface standardisée `reset()` / `step()` / `render()` de Gymnasium [30].

4.3.3 Définition de l’espace d’observation

L’espace d’observation encode l’état complet du système minier dans un vecteur normalisé $s_t \in [0, 1]^n$. Il comprend :

- **Position des camions :** localisation dans le graphe routier.
- **Statut des camions :** libre, en route vers pelle, en chargement, en route vers dump, en déchargement, en retour.
- **Disponibilité des pelles :** temps estimé avant disponibilité (proxy de la longueur de file).
- **Disponibilité des dumps :** temps estimé avant disponibilité au point de déchargement.
- **Temps courant :** progression de l’épisode, normalisée par la durée totale du poste.

Cette normalisation dans $[0, 1]$ est cruciale pour stabiliser l’apprentissage et éviter l’explosion du gradient lors de la rétropropagation [1].

4.3.4 Définition de l’espace d’action

À chaque étape de décision, l’agent choisit une action a_t dans un espace discret :

$$\mathcal{A} = \text{Discrete}(|\mathcal{P}| \times |\mathcal{D}| + 1) \tag{4.1}$$

où $|\mathcal{P}|$ est le nombre de pelles et $|\mathcal{D}|$ le nombre de dumps. Chaque action encode une paire (pelle, dump) par division entière :

Exemple numérique : Pour 3 pelles et 2 dumps, $|\mathcal{P}| \times |\mathcal{D}| + 1 = 3 \times 2 + 1 = 7$ actions possibles (indices 0 à 6). Si $a_t = 4$, alors `shovel_idx` = $4 \div 2 = 2$ (pelle 3) et `dump_idx` = $4 \bmod 2 = 0$ (dump 1). Si $a_t = 6$, c’est l’action ATTENDRE.

- `shovel_idx` = $a_t \div |\mathcal{D}|$: indice de la pelle choisie.
- `dump_idx` = $a_t \bmod |\mathcal{D}|$: indice du dump choisi.

- Si $a_t = |\mathcal{P}| \times |\mathcal{D}|$: action ATTENDRE (la pelle et le dump les plus tôt disponibles sont sélectionnés automatiquement).

Ce codage permet à l'agent de choisir simultanément la pelle de chargement et le point de déchargement, offrant une flexibilité décisionnelle plus grande que les approches classiques qui ne choisissent que la pelle.

4.3.5 Fonction de récompense multi-objectif

La fonction de récompense traduit les objectifs métier en un signal scalaire guidant l'apprentissage de l'agent. Conformément à l'Eq. 3.7, elle combine trois composantes pondérées :

$$R_t = w_1 \cdot R_{\text{rendement}} + w_2 \cdot R_{\text{équité}} + w_3 \cdot R_{\text{coût}} \quad (4.2)$$

- **Récompense de rendement** ($R_{\text{rendement}}$) : tonnage transporté lors du cycle, normalisé par la capacité du camion. Récompense positive liée à la productivité.
- **Récompense d'équité** ($R_{\text{équité}}$) : pénalité proportionnelle à la variance des files d'attente aux pelles. Favorise une utilisation équilibrée des ressources de chargement.
- **Récompense de coût** ($R_{\text{coût}}$) : pénalité proportionnelle à la distance parcourue. Réduit les trajets inutiles et la consommation de carburant.

4.4 Algorithmes classiques d'apprentissage par renforcement

Avant de présenter l'approche Deep Reinforcement Learning retenue, il est essentiel de comprendre les algorithmes fondamentaux de l'apprentissage par renforcement tabulaire. Ces méthodes constituent la base théorique sur laquelle reposent les approches plus avancées et servent de modèles comparatifs dans notre évaluation.

4.4.1 Q-Learning pour le dispatching minier

Le Q-Learning est une méthode d'apprentissage par renforcement tabulaire qui apprend une fonction $Q(s, a)$ estimant la qualité d'une action a dans un état s donné. L'agent met à jour cette fonction après chaque transition selon la règle :

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[r_t + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t) \right] \quad (4.3)$$

où α est le taux d'apprentissage, γ le facteur d'actualisation et r_t la récompense reçue.

Exemple numérique : Si $Q(s_t, a_t) = 50$, $r_t = 10$, $\gamma = 0,99$, $\max_{a'} Q(s_{t+1}, a') = 55$, $\alpha = 0,1$, alors $Q(s_t, a_t) \leftarrow 50 + 0,1 \times (10 + 0,99 \times 55 - 50) = 50 + 0,1 \times 14,45 = 51,45$.

Dans le contexte du dispatching minier, la correspondance est la suivante :

TABLE 4.3 – Correspondance Q-Learning $\leftrightarrow$ dispatching minier

Élément Q-Learning	Correspondance minière
État s	Situation actuelle de la flotte (files, positions, disponibilités)
Action a	Affectation camion-pelle-dump ou choix d'attendre
Récompense r	Gain de tonnage, réduction du coût, équité des files
Politique π	Règle apprise de dispatching

L'Algorithme 1 formalise l'application du Q-Learning au dispatching minier.

Algorithm 1 Q-Learning pour le dispatching minier

Require: Environnement minier $\mathcal{E}$, taux d'apprentissage α , facteur d'actualisation γ

Require: Taux d'exploration initial $\epsilon = 1,0$, décroissance $\epsilon_{\min} = 0,01$

```

1: Initialiser  $Q(s, a) \leftarrow 0$  pour tout  $(s, a) \in \mathcal{S} \times \mathcal{A}$ 
2: for épisode = 1, 2, ...,  $N_{\text{épisodes}}$  do
3:    $s_0 \leftarrow \text{reset}(\mathcal{E})$  {Initialiser la mine}
4:   while épisode non terminé do
5:     Choisir  $a_t$  par  $\epsilon$ -greedy :
6:       Avec probabilité  $\epsilon$  :  $a_t \sim \text{Uniforme}(\mathcal{A})$  {Exploration}
7:       Sinon :  $a_t \leftarrow \arg \max_a Q(s_t, a)$  {Exploitation}
8:     Décoder  $a_t$  en paire (pelle  $p_i$ , dump  $d_j$ )
9:     Exécuter  $a_t$  dans  $\mathcal{E}$  : observer  $r_t, s_{t+1}$ 
10:    Mettre à jour :
11:       $Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha[r_t + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t)]$ 
12:       $s_t \leftarrow s_{t+1}$ 
13:    end while
14:     $\epsilon \leftarrow \max(\epsilon_{\min}, \epsilon - \Delta\epsilon)$  {Décroissance linéaire}
15:  end for
16: return Politique  $\pi^*(s) = \arg \max_a Q(s, a)$ 

```

Le Q-Learning est une méthode *off-policy* : il estime la valeur de l'action optimale ($\max_{a'}$) indépendamment de la politique d'exploration effectivement suivie. Cette caractéristique le rend théoriquement convergent vers la politique optimale dans des environnements tabulaires [31].

4.4.2 Temporal Difference Learning

Le TD Learning (apprentissage par différence temporelle) est le principe général qui sous-tend Q-Learning, SARSA et d'autres méthodes RL. Il met à jour les estimations de valeur à partir de l'écart entre une estimation actuelle et une estimation future, sans attendre la fin complète de l'épisode :

$$V(s_t) \leftarrow V(s_t) + \alpha[r_t + \gamma V(s_{t+1}) - V(s_t)] \quad (4.4)$$

Exemple numérique : Si $V(s_t) = 40$, $r_t = 8$, $\gamma = 0,99$, $V(s_{t+1}) = 45$, $\alpha = 0,1$, alors $V(s_t) \leftarrow 40 + 0,1 \times (8 + 0,99 \times 45 - 40) = 40 + 0,1 \times 12,55 = 41,26$.

L'erreur $\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$ est appelée *erreur de différence temporelle* (TD error). Ce mécanisme est particulièrement adapté aux environnements séquentiels comme la logistique minière, où les décisions sont prises de manière continue tout au long d'un poste de travail de 8 heures.

Algorithm 2 TD Learning pour le dispatching minier

Require: Environnement minier $\mathcal{E}$, taux d'apprentissage α , facteur d'actualisation γ

Require: Fonction de valeur $V(s)$ à estimer

```

1: Initialiser  $V(s) \leftarrow 0$  pour tout  $s \in \mathcal{S}$ 
2: for épisode = 1, 2, ...,  $N_{\text{épisodes}}$  do
3:    $s_0 \leftarrow \text{reset}(\mathcal{E})$  {Initialiser la mine}
4:   while épisode non terminé do
5:     Choisir  $a_t$  selon la politique  $\pi$  (ou aléatoirement pour l'évaluation)
6:     Décoder  $a_t$  en paire (pelle  $p_i$ , dump  $d_j$ )
7:     Exécuter  $a_t$  dans  $\mathcal{E}$  : observer  $r_t, s_{t+1}$ 
8:     Calculer l'erreur TD :  $\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$ 
9:     Mettre à jour :  $V(s_t) \leftarrow V(s_t) + \alpha \delta_t$ 
10:     $s_t \leftarrow s_{t+1}$ 
11:   end while
12: end for
13: return Fonction de valeur  $V(s)$ 

```

Le TD Learning constitue la base théorique de plusieurs méthodes RL : Q-Learning utilise le TD error pour mettre à jour $Q(s, a)$, et cette même notion sera reprise dans le calcul du GAE (Generalized Advantage Estimation) utilisé par PPO.

4.4.3 SARSA comme variante TD orientée politique

SARSA (State-Action-Reward-State-Action) est une variante *on-policy* du TD Learning. Contrairement au Q-Learning qui estime la valeur de l'action optimale, SARSA apprend la valeur des actions réellement suivies par l'agent :

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha [r_t + \gamma Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t)] \quad (4.5)$$

Exemple numérique : Si $Q(s_t, a_t) = 50$, $r_t = 10$, $\gamma = 0,99$, $Q(s_{t+1}, a_{t+1}) = 52$ (action effectivement prise), $\alpha = 0,1$, alors $Q(s_t, a_t) \leftarrow 50 + 0,1 \times (10 + 0,99 \times 52 - 50) = 50 + 0,1 \times 11,48 = 51,15$.

La différence clé avec le Q-Learning réside dans le terme $Q(s_{t+1}, a_{t+1})$ au lieu de $\max_{a'} Q(s_{t+1}, a')$: SARSA utilise l'action effectivement prise (a_{t+1}) et non l'action optimale hypothétique. Cette distinction entre approches on-policy et off-policy est fondamentale en RL [31].

Dans le contexte du dispatching minier, SARSA tend à produire des politiques plus conservatrices, car il tient compte de l'exploration effectivement réalisée. Cette propriété peut être

avantageuse dans un environnement où les décisions sous-optimales (par exemple, envoyer un camion vers une pelle congestionnée) ont des conséquences coûteuses.

L'Algorithme 3 formalise l'application de SARSA au dispatching minier.

Algorithm 3 SARSA pour le dispatching minier

Require: Environnement minier $\mathcal{E}$, taux d'apprentissage α , facteur d'actualisation γ

Require: Taux d'exploration initial $\epsilon = 1,0$, décroissance $\epsilon_{\min} = 0,01$

```

1: Initialiser  $Q(s, a) \leftarrow 0$  pour tout  $(s, a) \in \mathcal{S} \times \mathcal{A}$ 
2: for épisode = 1, 2, ...,  $N_{\text{épisodes}}$  do
3:    $s_0 \leftarrow \text{reset}(\mathcal{E})$  {Initialiser la mine}
4:   Choisir  $a_0$  par  $\epsilon$ -greedy à partir de  $Q(s_0, \cdot)$ 
5:   while épisode non terminé do
6:     Décoder  $a_t$  en paire (pelle  $p_i$ , dump  $d_j$ )
7:     Exécuter  $a_t$  dans  $\mathcal{E}$  : observer  $r_t, s_{t+1}$ 
8:     Choisir  $a_{t+1}$  par  $\epsilon$ -greedy à partir de  $Q(s_{t+1}, \cdot)$ 
9:     Mettre à jour (on-policy) :
10:       $Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha[r_t + \gamma Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t)]$ 
11:       $s_t \leftarrow s_{t+1}, \quad a_t \leftarrow a_{t+1}$ 
12:   end while
13:    $\epsilon \leftarrow \max(\epsilon_{\min}, \epsilon - \Delta\epsilon)$  {Décroissance linéaire}
14: end for
15: return Politique  $\pi^*(s) = \arg \max_a Q(s, a)$ 

```

La différence structurelle entre les Algorithmes 1 et 3 se situe à la ligne de mise à jour : Q-Learning utilise $\max_{a'} Q(s_{t+1}, a')$ (off-policy) tandis que SARSA utilise $Q(s_{t+1}, a_{t+1})$ (on-policy), où a_{t+1} est l'action effectivement choisie par la politique ϵ -greedy.

4.4.4 Limites des méthodes tabulaires

Les méthodes tabulaires (Q-Learning, SARSA) deviennent rapidement limitées lorsque l'espace d'état augmente. Dans le cas de la logistique minière, les combinaisons entre :

- les positions de N_c camions (12 camions dans notre configuration),
- les files d'attente de N_p pelles (3 pelles),
- les disponibilités de N_d dumps (2 dumps),
- les niveaux de congestion sur le réseau routier,
- les événements stochastiques (pannes, dégradation des routes),

rendent impossible le stockage explicite de toutes les valeurs $Q(s, a)$ dans une table. L'espace d'état est continu et de haute dimension, ce qui provoque une explosion combinatoire incompatible avec l'approche tabulaire. Cette limitation fondamentale justifie le passage vers le Deep Reinforcement Learning, où un réseau de neurones approxime la fonction de valeur ou la politique.

4.5 Passage au Deep Reinforcement Learning

4.5.1 Justification du recours au Deep Learning

Le recours au Deep Learning pour approximer les fonctions de valeur ou les politiques est justifié par plusieurs caractéristiques de notre problème :

- **Espaces d'état larges** : le vecteur d'observation contient des dizaines de variables continues.
- **Observations continues** : les files d'attente, positions et temps ne sont pas discrétisables efficacement.
- **Interactions complexes** : les décisions pour un camion affectent les files d'attente de tous les autres.
- **Perturbations dynamiques** : pannes, dégradation des routes, variations de chargement/déchargement.
- **Généralisation** : un réseau de neurones peut généraliser à des états non rencontrés pendant l'entraînement, contrairement à une table Q qui ne couvre que les états visités.

4.5.2 Deep Q-Network (DQN) comme extension du Q-Learning

Le Deep Q-Network (DQN) [1] remplace la table Q par un réseau de neurones $Q_{\theta}(s, a)$ chargé d'approximer la fonction de valeur-action. Il constitue donc une extension profonde du Q-Learning (Eq. 4.3), adaptée aux environnements où la représentation tabulaire devient impossible.

DQN introduit deux mécanismes clés pour stabiliser l'apprentissage :

- **Experience Replay** : stockage des transitions (s, a, r, s') dans un buffer mémoire, d'où sont tirés des mini-batches pour l'entraînement, brisant les corrélations temporelles.
- **Target Network** : un réseau cible Q_{θ^-} mis à jour périodiquement, évitant les oscillations de l'apprentissage.

Bien que DQN représente une avancée majeure par rapport au Q-Learning tabulaire, il présente des limitations dans notre contexte : il est structurellement limité aux espaces d'actions discrets de faible dimension, et la gestion simultanée de plusieurs unités de chargement peut rendre l'apprentissage instable [1]. DQN joue néanmoins un rôle important dans notre travail comme modèle de transition vers les approches actor-critic.

Algorithm 4 DQN pour le dispatching minier

Require: Environnement minier $\mathcal{E}$, réseau Q_θ , réseau cible Q_{θ^-}

Require: Buffer mémoire $\mathcal{B}$ (capacité C), taille de batch B , taux de mise à jour cible τ

Require: Taux d'apprentissage α , facteur d'actualisation γ , taux d'exploration ϵ

```

1: Initialiser  $\theta$  et  $\theta^-$  aléatoirement,  $\theta^- \leftarrow \theta$ 
2: Initialiser  $\mathcal{B} \leftarrow \emptyset$ 
3: for épisode = 1, 2, ...,  $N_{\text{épisodes}}$  do
4:    $s_0 \leftarrow \text{reset}(\mathcal{E})$  {Initialiser la mine}
5:   while épisode non terminé do
6:     Choisir  $a_t$  par  $\epsilon$ -greedy :
7:       Avec probabilité  $\epsilon$  :  $a_t \sim \text{Uniforme}(\mathcal{A})$ 
8:       Sinon :  $a_t \leftarrow \arg \max_a Q_\theta(s_t, a)$ 
9:     Décoder  $a_t$  en paire (pelle  $p_i$ , dump  $d_j$ )
10:    Exécuter  $a_t$  dans  $\mathcal{E}$  : observer  $r_t, s_{t+1}$ 
11:    Stocker  $(s_t, a_t, r_t, s_{t+1})$  dans  $\mathcal{B}$ 
12:    Si  $|\mathcal{B}| > C$  : supprimer la transition la plus ancienne
13:    Échantillonner mini-batch  $\{(s_i, a_i, r_i, s'_i)\}_{i=1}^B$  depuis  $\mathcal{B}$ 
14:    Calculer les cibles :  $y_i = r_i + \gamma \max_{a'} Q_{\theta^-}(s'_i, a')$ 
15:    Mettre à jour  $\theta$  par descente de gradient sur  $\frac{1}{B} \sum_i (Q_\theta(s_i, a_i) - y_i)^2$ 
16:    Périodiquement :  $\theta^- \leftarrow \tau\theta + (1 - \tau)\theta^-$ 
17:     $s_t \leftarrow s_{t+1}$ 
18:  end while
19:   $\epsilon \leftarrow \max(\epsilon_{\min}, \epsilon - \Delta\epsilon)$ 
20: end for
21: return Politique  $\pi(s) = \arg \max_a Q_\theta(s, a)$ 

```

4.5.3 Architecture du réseau de neurones

L'agent repose sur une architecture de type Perceptron Multicouche (MLP) comprenant :

- **Couche d'entrée** : sa dimension correspond au nombre de variables dans l'état s_t (positions, charges, temps, files).
- **Couches cachées** : deux couches denses de 128 neurones chacune, utilisant la fonction d'activation **ReLU** ($f(x) = \max(0, x)$) pour capturer les relations non linéaires complexes entre le trafic et la production.
- **Couche de sortie** : une couche de dimension $|\mathcal{A}|$ utilisant une fonction **Softmax** pour transformer les activations en probabilités d'action.




FIGURE 4.4 – Architecture du réseau de neurones (MLP) de l'agent PPO.

4.5.4 Choix de l'algorithme final : PPO

Le choix de l'algorithme final est le résultat d'une progression scientifique : Q-Learning et TD Learning servent de bases théoriques, DQN assure la transition vers le Deep Reinforcement Learning, et PPO (Proximal Policy Optimization) [1] est retenu comme approche finale en raison de sa stabilité et de sa robustesse dans les environnements dynamiques.

La comparaison naturelle s'établit entre DQN et PPO, ces deux algorithmes représentant respectivement l'approche basée sur la valeur et l'approche basée sur la politique dans le spectre du Deep Reinforcement Learning.

Limites de DQN dans notre contexte : DQN constitue l'extension profonde du Q-Learning : il remplace la table Q par un réseau de neurones et introduit l'Experience Replay ainsi que le Target Network pour stabiliser l'apprentissage [1]. Cependant, dans le contexte du dispatching minier, DQN présente deux limitations structurelles. D'une part, il est conçu pour des espaces d'actions discrets et de faible dimension ; or notre espace d'action $\mathcal{A} = \text{Discrete}(|\mathcal{P}| \times |\mathcal{D}| + 1)$ croît combinatoirement avec le nombre de pelles et de dumps. D'autre part, DQN est une méthode off-policy qui peut diverger dans les environnements fortement stochastiques, précisément là où le bruit η_t sur les temps de trajet (Eq. 3.2) perturbe l'estimation des Q-valeurs [1].

Avantages déterminants de PPO : PPO est une méthode actor-critic on-policy qui surmonte directement ces deux limitations :

- **Stabilité par objectif tronqué :** le mécanisme de Clipped Surrogate Objective limite l'amplitude des mises à jour de politique, empêchant les divergences causées par les perturbations stochastiques de l'environnement minier [1].
- **Apprentissage on-policy :** PPO apprend directement à partir de ses interactions actuelles avec le simulateur, sans nécessiter de replay buffer, ce qui le rend plus adapté aux environnements dont la dynamique évolue en cours d'épisode.
- **Robustesse au réglage :** PPO est peu sensible aux hyperparamètres, ce qui garantit la reproductibilité des expériences [1, 9].

TABLE 4.4 – Comparaison DQN et PPO pour le dispatching minier (adapté de [1])

Critère	DQN	PPO
Type d’approche	Basée sur la valeur (off-policy)	Basée sur la politique (on-policy)
Espace d’action	Discret de faible dimension	Discret, scalable
Stabilité	Moyenne — risque de divergence	Élevée — objectif tronqué
Robustesse au bruit η	Faible	Élevée
Replay buffer	Requis	Non requis
Réglage des hyperparamètres	Simple	Simple et robuste
Verdict	Intermédiaire de comparaison	Approche finale retenue

4.5.5 Justification du choix de PPO par rapport aux alternatives

PPO est retenu comme approche finale pour notre système de dispatching minier selon trois critères validés par la littérature récente :

1. PPO est plus stable dans les environnements complexes que DQN et ses variantes, grâce à son objectif tronqué qui empêche les mises à jour trop radicales.
2. Il est adapté aux politiques stochastiques, ce qui convient aux environnements dynamiques et bruités comme la mine.
3. Il permet une stratégie de décision adaptative, compatible avec les contraintes opérationnelles de la logistique minière (pannes, congestion, dégradation des routes).

La Figure 4.5 illustre concrètement comment ces propriétés se traduisent dans l’architecture retenue : les observations brutes de la mine sont normalisées, transmises au réseau de neurones PPO, qui produit une décision d’affectation optimale renvoyée à l’environnement simulateur.




FIGURE 4.5 – Pipeline du flux de données entre la mine et l’agent DRL.

4.6 Configuration expérimentale des modèles d’apprentissage

4.6.1 Hyperparamètres du Q-Learning

Les hyperparamètres du Q-Learning tabulaire sont définis dans le Tableau 4.5.

TABLE 4.5 – Hyperparamètres du Q-Learning

Hyperparamètre	Valeur	Justification
Taux d'apprentissage (α)	0.2	Vitesse de mise à jour de la Q-table.
Facteur d'actualisation (γ)	0.99	Équilibre récompenses immédiates et futures.
Taux d'exploration (ϵ)	1.0 $\rightarrow$ 0.01	Décroissance linéaire (exploration $\rightarrow$ exploitation).
Nombre d'épisodes	30 000	Nécessaire pour la convergence effective de la Q-table.

4.6.2 Hyperparamètres du TD Learning / SARSA

Les hyperparamètres de SARSA suivent les mêmes conventions que le Q-Learning, la seule différence étant la règle de mise à jour on-policy (Eq. 4.5).

TABLE 4.6 – Hyperparamètres du TD Learning / SARSA

Hyperparamètre	Valeur	Justification
Taux d'apprentissage (α)	0.2	Identique au Q-Learning pour comparabilité.
Facteur d'actualisation (γ)	0.99	Cohérent avec les autres méthodes.
Stratégie ϵ -greedy	1.0 $\rightarrow$ 0.01	Décroissance identique au Q-Learning.
Nombre d'épisodes	30 000	Critère de convergence identique.

4.6.3 Hyperparamètres du modèle Deep Reinforcement Learning

Les hyperparamètres retenus pour PPO correspondent aux valeurs par défaut de la bibliothèque Stable-Baselines3 (version 2.x) [32]. Ces valeurs ont été optimisées pour offrir une convergence stable sur une large gamme d'environnements Gymnasium.

TABLE 4.7 – Hyperparamètres de l’agent PPO

Hyperparamètre	Valeur	Justification
Learning Rate (α)	0.0003	Vitesse d’apprentissage recommandée par défaut.
Gamma (γ)	0.99	Équilibre récompenses immédiates et futures.
Batch Size	64	Taille du lot pour chaque mise à jour du réseau.
GAE Lambda (λ)	0.95	Generalized Advantage Estimation, réduit la variance.
Clip Range (ϵ_{clip})	0.2	Objectif tronqué empêchant les mises à jour trop radicales.
Architecture	MLP 128×128	Deux couches cachées de 128 neurones, activation ReLU.

4.6.4 Stratégie exploration / exploitation

Les stratégies d’exploration diffèrent selon les algorithmes :

- **Q-Learning et SARSA** : exploration ϵ -greedy avec décroissance linéaire. L’agent choisit une action aléatoire avec probabilité ϵ et l’action gloutonne avec probabilité $1 - \epsilon$. ϵ décroît de 1.0 (exploration pure) à 0.01 (exploitation quasi-totale) au cours de l’entraînement.
- **PPO** : exploration stochastique intégrée dans la politique. L’acteur π_θ produit une distribution de probabilités sur les actions, et l’exploration est naturellement régulée par l’entropie de cette distribution. Un coefficient d’entropie encourage l’exploration en début d’entraînement.

L’exploration stochastique de PPO est plus nuancée que le ϵ -greedy : au lieu de choisir aléatoirement parmi toutes les actions avec probabilité ϵ , PPO attribue des probabilités proportionnelles à la qualité estimée de chaque action, permettant une exploration dirigée et plus efficace.

4.7 Stratégie d’évaluation comparative

4.7.1 Heuristiques de référence

Pour démontrer la plus-value de l’agent RL, nous le comparons aux quatre heuristiques industrielles de référence suivantes :

- **FIFO (First In, First Out)** (`fifo_policy.py`) : le camion disponible est affecté à la pelle dont la file d’attente est la plus courte, c’est-à-dire celle dont `available_at_min` est minimal (idle depuis le plus longtemps). Simple et équitable, cette règle ne tient compte ni de la distance ni de la charge globale [4].

- **Nearest Shovel (Pelle la plus proche)** (`nearest_policy.py`) : le camion est affecté à la pelle géographiquement la plus proche via Dijkstra, puis au dump le plus proche de cette pelle. Minimise le trajet à vide mais ignore les files d’attente [4].
- **Shortest Path (Chemin le plus court)** (`shortest_path_policy.py`) : choisit la paire (pelle, dump) minimisant le coût de cycle complet $C_{\text{cycle}} = \alpha T + \beta D + \gamma E$ (Eq. 3.1) sur les trois segments camion→pelle→dump→pelle, avec $\alpha = 0,5$, $\beta = 0,3$, $\gamma = 0,2$ [4].
- **Fixed Assignment (Affectation fixe)** (`fixed_policy.py`) : chaque camion est dédié à une pelle selon un schéma round-robin statique (`truck_id % num_shovels`). Aucune adaptation dynamique n’est possible [13].

Ces quatre heuristiques représentent le spectre des pratiques industrielles courantes : de la règle la plus rigide (Fixed Assignment) à la règle la plus réactive localement (Nearest Shovel). Leur comparaison avec les agents RL permettra de quantifier le gain apporté par l’apprentissage sur chacun des KPIs définis en Section 4.7.4.

4.7.2 Modèles RL classiques de comparaison

En complément des heuristiques, les trois algorithmes RL classiques présentés en Section 4.4 servent de modèles comparatifs :

- **Q-Learning** : baseline tabulaire off-policy. L’agent apprend la fonction $Q(s, a)$ en estimant toujours l’action optimale (Eq. 4.3), indépendamment de la politique d’exploration suivie.
- **TD Learning** : baseline tabulaire fondée sur l’apprentissage par différence temporelle (Eq. 4.4). Il sert de référence théorique intermédiaire, illustrant le principe de mise à jour bootstrappée commun à Q-Learning, SARSA et PPO via le GAE.
- **SARSA** : baseline tabulaire on-policy. L’agent met à jour $Q(s, a)$ en tenant compte de l’action effectivement choisie (Eq. 4.5), produisant des politiques plus conservatrices que Q-Learning dans les environnements stochastiques.

Ces trois modèles permettent de quantifier le gain apporté par le passage au Deep Reinforcement Learning à deux niveaux : d’abord entre méthodes tabulaires (Q-Learning vs SARSA), puis entre le meilleur tabulaire et l’approche profonde (PPO), conformément à la progression méthodologique du chapitre.

4.7.3 Modèle Deep Reinforcement Learning proposé

DQN peut être testé comme modèle profond intermédiaire, tandis que PPO constitue l’approche finale proposée. La comparaison DQN vs PPO permet d’évaluer l’avantage des méthodes actor-critic par rapport aux méthodes basées sur la valeur pure dans le contexte spécifique du dispatching minier.

4.7.4 Indicateurs de performance (KPIs)

L’évaluation repose sur un ensemble d’indicateurs de performance opérationnels et algorithmiques :

TABLE 4.8 – Indicateurs de performance pour l’évaluation comparative

KPI	Signification
Tonnage transporté (P_h)	Productivité globale : $P_h = \frac{\sum \text{Tonnage}(c)}{T_{\text{total}}}$
Temps d’attente moyen (E_t)	Fluidité du système, temps moyen en file par cycle
Consommation spécifique (E_e)	Efficacité énergétique (litres par tonne transportée)
Coût moyen par cycle	Performance économique
Récompense cumulée	Performance RL globale de l’agent
Temps de convergence	Efficacité d’apprentissage (nombre de steps)
Robustesse aux perturbations	Adaptabilité de l’agent face aux pannes et congestion

4.8 Synthèse de la solution proposée

Le Tableau 4.9 récapitule les choix méthodologiques et techniques retenus pour la solution proposée.

TABLE 4.9 – Synthèse de la solution proposée

Élément	Choix retenu
Méthodologie	CRISP-RL
Environnement	Simulateur minier compatible Gymnasium
Formalisation	Processus de décision markovien (MDP)
Méthodes classiques	Q-Learning, TD Learning, SARSA
Transition Deep Reinforcement Learning	DQN
Approche finale	PPO (Proximal Policy Optimization)
Baselines	Heuristiques industrielles + RL classiques
Évaluation	KPIs opérationnels + récompense cumulée

4.8.1 Pseudocode de l’algorithme proposé

L’Algorithme 5 formalise la procédure complète d’entraînement de l’agent PPO appliquée à notre problème de dispatching minier. Ce pseudocode intègre les éléments définis dans les sections précédentes : l’état s_t (Eq. 3.1), l’espace d’action $\mathcal{A}$ (Section 4.3.4), la récompense pondérée R_t (Eq. 3.7), le réseau MLP 128×128 (Section 4.5.3) et les hyperparamètres du Tableau 4.7.

Algorithm 5 PPO pour le dispatching minier camion-pelle-dump

Require: Environnement minier $\mathcal{E}$ (graphe G , camions $\mathcal{C}$, pelles $\mathcal{P}$, dumps $\mathcal{D}$)

Require: Réseau acteur π_θ et critique V_ϕ (MLP 128×128, ReLU)

Require: Hyperparamètres : $\alpha = 0,0003$, $\gamma = 0,99$, $\lambda_{\text{GAE}} = 0,95$, $\epsilon_{\text{clip}} = 0,2$, T_{max} steps

```

1: Initialiser  $\theta$  et  $\phi$  aléatoirement
2: for  $k = 1, 2, \dots, T_{\text{max}}/N$  do
3:   Collecter  $N$  transitions en suivant  $\pi_{\theta_k}$  :
4:   for  $t = 1, \dots, N$  do
5:     Observer l'état  $s_t = (\{q_p\}, \{x_c\}, \{z_r\}, t_{\text{courant}})$ 
6:     Normaliser  $s_t$  dans  $[0, 1]$  (Section 4.3.3)
7:     Échantillonner l'action  $a_t \sim \pi_\theta(\cdot | s_t)$ 
8:     Décoder  $a_t$  en paire (pelle  $p_i$ , dump  $d_j$ ) :
9:        $i \leftarrow \lfloor a_t / |\mathcal{D}| \rfloor$ ,  $j \leftarrow a_t \bmod |\mathcal{D}|$ 
10:      Si  $a_t = |\mathcal{P}| \times |\mathcal{D}|$  : ATTENDRE
11:      Simuler le cycle complet du camion courant  $c$  :
12:        Trajet  $c \rightarrow p_i$  (temps log-normal, Eq. 3.2)
13:        Attente + chargement à  $p_i$ 
14:        Trajet chargé  $p_i \rightarrow d_j$ 
15:        Attente + déchargement à  $d_j$ 
16:        Retour à vide  $d_j \rightarrow p_i$ 
17:      Calculer la récompense (Eq. 3.7) :
18:         $R_t = w_1 \cdot R_{\text{rendement}} + w_2 \cdot R_{\text{équité}} + w_3 \cdot R_{\text{coût}}$ 
19:      Observer le nouvel état  $s_{t+1}$ 
20:      Stocker  $(s_t, a_t, R_t, s_{t+1}, \log \pi_\theta(a_t | s_t))$ 
21:   end for
22:   Calculer les avantages GAE :  $\hat{A}_t = \sum_{l=0}^{T-t} (\gamma \lambda_{\text{GAE}})^l \delta_{t+l}$ 
23:   où  $\delta_t = R_t + \gamma V_\phi(s_{t+1}) - V_\phi(s_t)$ 
24:   for chaque époque d'optimisation (mini-batches de taille 64) do
25:     Calculer le ratio :  $r_t(\theta) = \frac{\pi_\theta(a_t | s_t)}{\pi_{\theta_k}(a_t | s_t)}$ 
26:     Mettre à jour l'acteur par l'objectif tronqué :
27:      $L^{\text{CLIP}}(\theta) = \mathbb{E}[\min(r_t \hat{A}_t, \text{clip}(r_t, 1 - \epsilon_{\text{clip}}, 1 + \epsilon_{\text{clip}}) \hat{A}_t)]$ 
28:     Mettre à jour le critique :
29:      $L^V(\phi) = \mathbb{E}[(V_\phi(s_t) - R_t^{\text{cible}})^2]$ 
30:      $\theta \leftarrow \theta + \alpha \nabla_\theta L^{\text{CLIP}}$ ,  $\phi \leftarrow \phi - \alpha \nabla_\phi L^V$ 
31:   end for
32: end for
33: return Politique entraînée  $\pi_\theta^*$ 

```

Cet algorithme illustre comment les composantes théoriques définies au Chapitre 3 (MDP, récompense pondérée, stochasticité) s'articulent avec les choix techniques du présent chapitre (PPO, architecture réseau, hyperparamètres) pour former une boucle d'apprentissage complète et cohérente. La ligne 9 montre en particulier l'encodage de l'espace d'action

$\mathcal{A} = \text{Discrete}(|\mathcal{P}| \times |\mathcal{D}| + 1)$ qui permet à l'agent de choisir simultanément la pelle et le point de déchargement. Le terme $+1$ représente l'action neutre (ATTENDRE), permettant à l'agent de temporiser si aucune affectation n'est productive à l'instant t .

4.9 Conclusion

Ce chapitre a présenté la méthodologie complète de notre solution, depuis le cadre CRISP-RL jusqu'au choix algorithmique final. Le passage des méthodes classiques (Q-Learning, TD Learning, SARSA) vers le Deep Reinforcement Learning est méthodologiquement justifié par la complexité du problème minier : espaces d'état continus de haute dimension, perturbations stochastiques et interactions complexes entre entités. Q-Learning et TD Learning sont introduits comme bases théoriques et modèles comparatifs ; DQN joue le rôle de transition vers les réseaux de neurones ; PPO est retenu comme approche finale proposée pour sa stabilité et son adéquation aux environnements dynamiques et stochastiques. Le chapitre suivant présentera l'implémentation technique de ce système, le protocole expérimental, les scénarios de simulation et l'analyse des résultats.

Chapitre 5

Implémentation et expérimentation

Introduction

L’implémentation et l’expérimentation constituent l’étape de validation opérationnelle de la méthodologie proposée. Elles permettent de vérifier, dans un cadre contrôlé, la faisabilité technique de la solution et sa capacité à produire des résultats mesurables sur des scénarios représentatifs de la logistique minière.

5.1 Architecture globale du système proposé

Le système implémenté repose sur une architecture modulaire en Python, organisée autour de cinq composantes principales interconnectées (Figure 5.1) :

- **Simulateur Gymnasium (MineEnv)** : implémente la boucle Agent–Environnement conforme à l’interface standardisée Gymnasium [30], exposant les méthodes `reset()`, `step()` et `render()`.
- **Module de simulation physique** : modélise les entités minières (`Truck`, `Shovel`, `DumpSite`, `RoadGraph`), les temps de trajet stochastiques (distribution log-normale, Eq. 3.2) et les pannes aléatoires des camions.
- **Module d’agents RL** : implémente les quatre algorithmes d’apprentissage — Q-Learning tabulaire, SARSA, DQN et PPO — via la bibliothèque Stable-Baselines3 [32] pour les agents Deep RL.
- **Module des heuristiques de référence** : implémente les quatre baselines industrielles (FIFO, Fixed Assignment, Nearest Shovel, Shortest Path) avec une interface unifiée compatible avec l’environnement Gymnasium.
- **Module d’évaluation et d’analyse** : orchestre les benchmarks sur l’ensemble des scénarios, calcule les KPIs définis au Tableau 4.8 et génère les tableaux et figures comparatifs.

L’ensemble du code source est structuré selon le principe de séparation des responsabilités, garantissant la reproductibilité des expériences : chaque agent est entraîné avec une graine fixe (*seed*), sauvegardé dans un répertoire dédié, puis rechargé pour l’évaluation.




FIGURE 5.1 – Architecture globale du projet.

5.2 Détails d’implémentation de l’environnement

5.2.1 Modélisation physique du simulateur

L’environnement `MineEnv` simule un poste de travail complet de 8 heures ($T = 480$ minutes) pour une flotte de N_c camions circulant entre N_p pelles et N_d points de déchargement. À chaque décision, le simulateur exécute un cycle complet pour le camion le plus tôt disponible, selon la séquence suivante :

1. Trajet à vide vers la pelle assignée (temps log-normal, $\sigma = 0,12$) ;
2. Attente en file si la pelle est occupée ;
3. Chargement (durée moyenne 2 min, $\sigma = 0,3$ min) ;
4. Trajet chargé vers le dump assigné ;
5. Déchargement (durée moyenne 1 min, $\sigma = 0,2$ min) ;
6. Retour à vide vers la pelle ;
7. Panne aléatoire avec probabilité p_b par cycle (durée uniforme $\mathcal{U}[10, 30]$ minutes).

5.2.2 Graphe routier

Le réseau routier $G = (V, E)$ comprend 7 nœuds pour la configuration nominale : 1 yard, 1 jonction, 3 pelles et 2 dumps (Figure 5.2). Les distances varient de 1,5 à 3,2 km selon les segments, avec des pentes de 3 à 8%, conformément aux paramètres opérationnels réalistes issus de la littérature [2]. La dégradation progressive des routes est modélisée par une réduction stochastique de l’attribut `road_state` à chaque passage (probabilité 5%, réduction de 2%).

5.2.3 Vecteur d’observation

Le vecteur d’observation $s_t \in [0, 1]^{147}$ encode l’état complet du système (Tableau 5.1). Par rapport à la formulation initiale, deux blocs de features géométriques ont été ajoutés : la distance du camion courant vers chaque pelle (3 valeurs) et la distance de chaque pelle vers chaque dump (6 valeurs), permettant à l’agent de disposer de la même information de proximité que les heuristiques Nearest Shovel et Shortest Path.

TABLE 5.1 – Composition du vecteur d’observation (configuration nominale)

Composante	Dimension	Description
Attente pelles (q_p)	3	Temps normalisé avant disponibilité
Attente dumps (z_r)	2	Temps normalisé avant disponibilité
Statut camions	12	Normalisé dans $[0, 1]$
Disponibilité camions	12	Temps normalisé avant disponibilité
Tonnage camions	12	Normalisé par 2 000 t
Carburant camions	12	Normalisé par 500 L
Position camions (one-hot)	84	12 camions $\times$ 7 nœuds
Distance camion courant $\rightarrow$ pelles	3	Distance Dijkstra normalisée par 10 km
Distance pelles $\rightarrow$ dumps	6	3×2 paires, normalisées par 10 km
Temps courant	1	Progression normalisée de l’épisode
Total	147	

5.2.4 Fonction de récompense implémentée

La fonction de récompense finale, issue du processus de calibration expérimental (Section 5.3), étend la formulation théorique (Eq. 3.7) par un terme de pénalité d’attente directe :

$$R_t = w_1 \cdot \frac{\Delta_{\text{tonnage}}}{140} + w_2 \cdot \frac{-\text{Var}(\{q_p\})}{100} + w_3 \cdot \frac{-d_{\text{trajet}}}{5} + w_4 \cdot \left(-\min\left(\frac{q_{p_i}}{30}, 1\right) \right) \quad (5.1)$$

avec $w_1 = 1,0$, $w_2 = 0,1$, $w_3 = 0,05$, $w_4 = 0,3$. Le terme w_4 pénalise l’attente opérationnelle, créant un signal de récompense différencié entre les actions.

La valeur $w_4 = 0,3$ résulte d’une recalibration itérative : une valeur initiale de $w_4 = 1,0$ rendait l’action ATTENDRE compétitive vis-à-vis d’un cycle productif en contexte de congestion (récompense de cycle ≈ 0 contre pénalité d’attente $= -0,167$), conduisant les agents à apprendre systématiquement à ne rien faire. Avec $w_4 = 0,3$, un cycle productif vaut structurellement $+0,7$ même avec attente maximale, garantissant que travailler surpasse toujours attendre.

Le *principe* d’ajouter $w_4 > 0$ a été validé par un diagnostic empirique : sans ce terme, la différence de récompense entre actions était inférieure à 6×10^{-4} , rendant tout apprentissage tabulaire impossible (Tableau 5.2).

TABLE 5.2 – Diagnostic du signal de récompense avant et après ajout de w_4

Configuration	Moy. action 0	Moy. action 1	Différence
Sans w_4 (originale)	0.939	0.939	6×10^{-4}
Avec $w_4 = 1,0$	0.755	0.787	$3,2 \times 10^{-2}$




FIGURE 5.2 – Graphe routier du simulateur minier.

5.3 Paramètres et protocoles d'entraînement

5.3.1 Protocole général

Tous les agents sont entraînés avec une graine fixe $\text{seed} = 42$ sur le scénario cible, puis évalués sur 10 répliques indépendantes (seeds 42 à 51) pour estimer la moyenne et l'écart-type des KPIs. Les modèles sont sauvegardés après convergence et réutilisés pour l'évaluation sans réentraînement.

5.3.2 Paramètres des méthodes tabulaires

Pour Q-Learning et SARSA, la discrétisation de l'espace d'état continu est réalisée par extraction des 5 features décisionnelles essentielles (attentes des 3 pelles et 2 dumps), renormalisées par un facteur 50 pour étaler les valeurs sur $[0, 1]$, puis discrétisées en $n_{\text{bins}} = 8$ intervalles par dimension. L'espace d'état effectif couvre ainsi $8^5 = 32\,768$ états théoriques, dont 6 401 effectivement visités en 30 000 épisodes.

TABLE 5.3 – Paramètres d’entraînement des méthodes tabulaires

Paramètre	Q-Learning	SARSA
Épisodes	30 000	30 000
Taux d’apprentissage (α)	0.2	0.2
Facteur d’actualisation (γ)	0.99	0.99
Bins de discrétisation (n_{bins})	8	8
Features d’état	5	5
ϵ initial / final	1.0 / 0.01	1.0 / 0.01

5.3.3 Paramètres des agents Deep RL

DQN et PPO sont entraînés sur 2 000 000 steps (≈ 9677 épisodes) via Stable-Baselines3 avec un réseau MLP 128×128 et activation ReLU.

TABLE 5.4 – Paramètres d’entraînement des agents Deep RL

Paramètre	DQN	PPO
Steps totaux	2 000 000	2 000 000
Learning rate (α)	3×10^{-4}	3×10^{-4}
Batch size	64	64
Buffer / n_steps	200 000	1 024
Gamma (γ)	0.99	0.99
Exploration / Entropie	$\epsilon : 1.0 \rightarrow 0.02$	coef. 0.02
Architecture	MLP [128, 128]	MLP [128, 128]
GAE Lambda	—	0.95
Clip range	—	0.2

La convergence de PPO est confirmée par la métrique `explained_variance = 0.999` en fin d’entraînement, indiquant que le réseau critique prédit avec précision les retours futurs.

5.4 Scénarios expérimentaux

Trois scénarios sont retenus pour couvrir les conditions opérationnelles représentatives d’une mine à ciel ouvert. Chaque scénario est évalué sur 10 répliques indépendantes.

TABLE 5.5 – Paramètres des scénarios expérimentaux

Scénario	Camions	Pelles	Dumps	p_b	Description
Nominal	12	3	2	2%	Conditions stables
High Load	18	3	2	2%	Surcharge (6 camions/pelle)
High Breakdown	12	3	2	10%	Pannes fréquentes

Le scénario **nominal** sert de référence pour calibrer les agents et valider la cohérence du simulateur. Le scénario **high_load** teste la capacité des algorithmes à équilibrer la charge entre pelles lorsque le nombre de camions dépasse le Match Factor optimal. Le scénario **high_breakdown** évalue la robustesse des politiques face aux perturbations stochastiques fréquentes, directement lié à l’hypothèse centrale H1.

5.4.1 Validation du simulateur

La cohérence du simulateur a été vérifiée par la commande `gymnasium.utils.check_env()`, qui valide la conformité des espaces d’observation et d’action, la reproductibilité avec graine fixe et l’absence d’erreurs dans la boucle `reset/step`.

5.5 Métriques d’évaluation

Les KPIs calculés à l’issue de chaque épisode sont les suivants :

- **Productivité horaire** (P_h , t/h) : tonnage total livré divisé par la durée du poste (8 heures). C’est l’indicateur principal de performance opérationnelle.
- **Temps d’attente moyen par camion** (E_t , min) : total des attentes en file divisé par le nombre de camions. Reflète directement la fluidité du dispatching et les coûts d’immobilisation.
- **Consommation spécifique** (E_e , L/t) : carburant total consommé divisé par le tonnage transporté. Indicateur d’efficacité énergétique et environnementale.
- **Coût moyen par cycle** (L/cycle) : carburant total divisé par le nombre de cycles complétés.
- **Taux d’utilisation** (%) : rapport du temps productif des camions sur le temps total disponible de la flotte.

Les résultats sont présentés sous forme de moyenne $\pm$ écart-type sur les 10 répliques, permettant d’apprécier la stabilité de chaque politique. Un écart-type élevé pour un agent Deep RL signale une convergence incomplète.

5.6 Conclusion

Ce chapitre a présenté l’architecture logicielle, la modélisation de l’environnement, le protocole d’entraînement et les scénarios expérimentaux retenus. La conception modulaire et la validation du simulateur constituent la base nécessaire à l’analyse comparative qui suit dans le chapitre des résultats.

Chapitre 6

Résultats et analyse

Introduction

L’analyse des résultats est essentielle pour apprécier la validité de la solution proposée et mesurer sa capacité à répondre aux objectifs du mémoire. Au-delà de la performance brute, cette étape vise à évaluer la robustesse de l’approche, sa sensibilité aux perturbations et ses limites dans des contextes opérationnels variés.

6.1 Résultats expérimentaux

6.1.1 Scénario nominal

Le Tableau 6.1 présente les performances moyennes sur 10 répliques pour le scénario de référence (12 camions, 3 pelles, 2 dumps, $p_b = 2\%$).

TABLE 6.1 – Résultats comparatifs — Scénario nominal

Algorithme	Prod. (t/h)	Wait (min)	Fuel (L/t)	Util. (%)
PPO	4208.8 $\pm$ 49	31.8 $\pm$ 3.3	0.0412 $\pm$ 0.0005	94.6
DQN	4168.5 $\pm$ 66	40.2 $\pm$ 2.7	0.0405 $\pm$ 0.0006	92.3
Fixed Assignment	4074.0 $\pm$ 40	27.9 $\pm$ 3.7	0.0431 $\pm$ 0.0003	96.5
Shortest Path	3872.8 $\pm$ 32	74.2 $\pm$ 7.2	0.0431 $\pm$ 0.0004	87.2
Nearest Shovel	3830.8 $\pm$ 55	72.6 $\pm$ 7.4	0.0429 $\pm$ 0.0003	87.8
Q-Learning	3591.0 $\pm$ 85	56.3 $\pm$ 5.2	0.0481 $\pm$ 0.0012	91.1
FIFO	3290.0 $\pm$ 42	33.2 $\pm$ 6.2	0.0532 $\pm$ 0.0005	96.2
SARSA	3081.8 $\pm$ 64	66.8 $\pm$ 5.3	0.0556 $\pm$ 0.0007	89.1

6.1.2 Scénario high_load

TABLE 6.2 – Résultats comparatifs — Scénario high_load (18 camions)

Algorithmme	Prod. (t/h)	Wait (min)	Fuel (L/t)	Util. (%)
Fixed Assignment	5874.8 ± 53	43.0 ± 3.8	0.0444 ± 0.0003	94.0
DQN	5664.8 ± 65	46.8 ± 2.6	0.0444 ± 0.0004	90.6
PPO	5244.8 ± 332	92.8 ± 21.6	0.0466 ± 0.0018	80.8
Q-Learning	4795.0 ± 106	69.1 ± 4.1	0.0537 ± 0.0009	88.9
FIFO	4747.8 ± 70	44.2 ± 3.4	0.0546 ± 0.0006	93.9
SARSA	4042.5 ± 67	119.8 ± 12.1	0.0613 ± 0.0011	78.6
Shortest Path	3956.8 ± 40	204.7 ± 6.9	0.0588 ± 0.0006	61.1
Nearest Shovel	3939.3 ± 42	200.2 ± 10.4	0.0580 ± 0.0007	62.0

6.1.3 Scénario high_breakdown

TABLE 6.3 – Résultats comparatifs — Scénario high_breakdown ($p_b = 10\%$)

Algorithmme	Prod. (t/h)	Wait (min)	Fuel (L/t)	Util. (%)
DQN	3991.8 ± 56	68.7 ± 5.5	0.0416 ± 0.0003	86.3
PPO	3946.3 ± 63	65.1 ± 7.0	0.0422 ± 0.0008	87.2
Fixed Assignment	3860.5 ± 38	53.1 ± 6.0	0.0451 ± 0.0004	91.7
Shortest Path	3702.3 ± 40	91.0 ± 5.5	0.0444 ± 0.0004	84.3
Nearest Shovel	3692.5 ± 42	90.1 ± 6.2	0.0441 ± 0.0004	84.4
Q-Learning	3176.3 ± 94	88.2 ± 7.1	0.0539 ± 0.0013	84.8
FIFO	3115.0 ± 74	53.0 ± 11.6	0.0556 ± 0.0009	92.2
SARSA	2973.3 ± 89	77.5 ± 8.8	0.0588 ± 0.0010	87.3

Figures à insérer ici : les barplots générés par `analyze_results.py` pour chaque scénario.

6.2 Comparaison avec les approches de référence

6.2.1 Analyse comparative globale

Le Tableau 6.4 présente une synthèse transversale des performances sur les trois scénarios.

TABLE 6.4 – Synthèse comparative multi-scénarios (productivité t/h / attente min)

Algorithme	Nominal	High Load	High Breakdown	Rang wait moyen
PPO	4209 / 31.8	5245 / 92.8	3946 / 65.1	1er prod. (2/3)
DQN	4169 / 40.2	5665 / 46.8	3992 / 68.7	1er prod. (1/3)
Fixed	4074 / 27.9	5875 / 43.0	3861 / 53.1	1er wait (2/3)
Q-Learn.	3591 / 56.3	4795 / 69.1	3176 / 88.2	4ème
FIFO	3290 / 33.2	4748 / 44.2	3115 / 53.0	5ème
SARSA	3082 / 66.8	4043 / 119.8	2973 / 77.5	6ème
Nearest	3831 / 72.6	3939 / 200.2	3693 / 90.1	dernier

6.2.2 Analyse par scénario

Scénario nominal. PPO (4 208.8 t/h) et DQN (4 168.5 t/h) surpassent tous deux Fixed Assignment (4 074.0 t/h) en productivité, démontrant que les agents Deep RL ont appris une politique d’affectation plus efficace que le schéma round-robin statique. Ce résultat valide directement l’hypothèse H1 en conditions stables.

Fixed Assignment conserve le meilleur temps d’attente (27.9 min) grâce au Match Factor parfait (12/3 = 4 camions/pelle), ce qui minimise structurellement les files d’attente. PPO présente le meilleur temps d’attente parmi les agents RL (31.8 min), confirmant qu’il a appris à équilibrer les files de manière adaptative.

Shortest Path (3 872.8 t/h) se distingue désormais de Nearest Shovel (3 830.8 t/h) grâce à l’implémentation du coût de cycle complet $C = \alpha T + \beta D + \gamma E$ (Eq. 3.1), validant l’apport de la formulation multi-critère.

Scénario high_load. Avec 18 camions pour 3 pelles, Fixed Assignment reste dominant (5 874.8 t/h), son Match Factor $18/3 = 6$ camions/pelle restant optimal. DQN (5 664.8 t/h, –3,6% vs Fixed) se positionne comme la meilleure alternative RL avec un écart modéré et une faible variance.

PPO affiche une performance variable ($5\,244.8 \pm 332$ t/h) : certaines répliques atteignent 5 687 t/h (proches de Fixed) tandis que d’autres n’atteignent que 4 882 t/h. Cette instabilité en surcharge traduit la sensibilité de la politique on-policy aux configurations de départ.

Les heuristiques myopes (Nearest Shovel, Shortest Path) s’effondrent : temps d’attente ≥ 200 minutes, pires que toutes les autres politiques. Ce phénomène confirme la congestion systématique prévue au Chapitre 3 : en l’absence d’équilibrage de charge, la flotte sature la pelle géographiquement la plus proche.

Scénario high_breakdown. C’est le scénario déterminant pour la validation de H1. DQN (3 991.8 t/h) et PPO (3 946.3 t/h) surpassent tous deux Fixed Assignment (3 860.5 t/h) en productivité, confirmant la supériorité des agents Deep RL face aux perturbations stochastiques fréquentes.

Fixed Assignment conserve le meilleur temps d’attente (53.1 min) : son schéma cyclique génère peu d’attente grâce à la distribution régulière des camions. PPO (65.1 min) et DQN

(68.7 min) ont un temps d’attente légèrement supérieur mais produisent davantage, car ils exploitent les pelles disponibles plus agressivement dès qu’une panne libère une ressource.

L’écart de productivité PPO – Fixed (+86 t/h, +2,2%) représente, extrapolé sur un poste de 8 heures, un gain de 688 tonnes supplémentaires transportées malgré un taux de pannes 5 fois plus élevé que le scénario nominal.

Figure à insérer ici : une figure comparative montrant les temps d’attente des 3 scénarios côte à côte pour Fixed, PPO et DQN.

6.3 Analyse critique des résultats

6.3.1 Convergence des agents d’apprentissage

La courbe d’apprentissage de Q-Learning montre une progression claire de la récompense cumulée, passant de 155 à 175 sur le scénario nominal (+12,5%) et de 213 à 225 sur le scénario high_load (+5,4%). La Q-table couvre 17 034 états effectifs sur 30 000 épisodes en nominal (espace théorique : $8^6 = 262\,144$), confirmant que l’enrichissement du vecteur d’état (ajout de la pelle la plus proche du camion courant) a permis une couverture suffisante pour une politique compétitive.

SARSA converge vers une valeur inférieure (≈ 145 contre 175 pour Q-Learning en nominal), conformément au comportement théorique prédit : en tant que méthode on-policy, SARSA intègre le coût de l’exploration dans ses estimations, produisant une politique conservatrice mais sous-optimale par rapport à Q-Learning off-policy.

La convergence de PPO est confirmée par `explained_variance = 0.999`, indiquant que le réseau critique prédit avec précision les retours futurs. Cette valeur proche de 1.0 signifie que l’agent a pleinement exploité le signal de récompense disponible dans le budget d’entraînement alloué (2M steps $\approx 9\,677$ épisodes).

6.3.2 Limites identifiées

Plusieurs limites méritent d’être explicitées pour une interprétation rigoureuse des résultats.

Limite 1 : Signal de récompense initialement non discriminant. Une analyse diagnostique préalable a révélé que la formulation originale de la récompense (sans terme w_4) produisait une différence inter-actions inférieure à 6×10^{-4} , rendant tout apprentissage tabulaire impossible. L’ajout du terme de pénalité d’attente directe ($w_4 = 0,3$, calibré expérimentalement) a multiplié ce signal par un facteur suffisant pour permettre la convergence effective de Q-Learning et SARSA. Cette découverte illustre l’importance de la calibration de la fonction de récompense dans la conception d’agents RL applicatifs.

Limite 2 : Espace d’observation surdimensionné pour les méthodes tabulaires. Le vecteur d’observation de 147 dimensions n’est pas discrétisable efficacement pour Q-Learning et SARSA. La solution retenue — extraire 6 features décisionnelles (attentes pelles/dumps + pelle la plus proche) et les renormaliser — a permis de réduire l’espace à 17 034 états

effectifs sur 30 000 épisodes. Cette réduction introduit néanmoins une perte d’information : des nuances d’état (positions exactes des camions, niveaux de carburant) ne sont pas capturées, limitant la finesse des politiques tabulaires.

Limite 3 : Variabilité de PPO en high_load. PPO présente un écart-type élevé en high_load ($5\,244.8 \pm 332$ t/h) : selon la graine d’évaluation, la performance varie de 4 882 à 5 687 t/h. Cette instabilité traduit la sensibilité de la politique on-policy aux configurations d’initialisation en contexte de surcharge. DQN, par son mécanisme d’expérience replay, offre une performance plus stable ($5\,664.8 \pm 65$ t/h). Un budget d’entraînement plus élevé ou un curriculum de difficulté progressive permettrait probablement de réduire cette variance.

Limite 4 : Fixed Assignment bénéficie d’un Match Factor parfait. La supériorité de Fixed Assignment en conditions nominales est structurelle : avec $N_c = 12$ camions et $N_p = 3$ pelles, le schéma round-robin distribue exactement 4 camions par pelle, correspondant au Match Factor optimal théorique. Cette propriété disparaît en high_load ($6 \neq 4$ camions/pelle) et en high_breakdown (camions immobilisés par pannes). La comparaison avec Fixed Assignment en nominal est donc délibérément défavorable pour le RL : elle teste les agents dans les conditions les plus avantageuses pour l’heuristique statique.

Limite 5 : Non-généralisation entre configurations de flotte. Chaque agent Deep RL (DQN, PPO) est entraîné sur une configuration spécifique (nombre de camions, pelles, dumps). La dimension du vecteur d’observation dépend directement de N_c : un modèle entraîné sur 12 camions (147 dimensions) ne peut pas être déployé sur une flotte de 18 camions (213 dimensions) sans réentraînement complet. Cette contrainte s’inscrit en tension avec le terme « *dynamique* » du titre : un système véritablement adaptatif s’ajusterait à une modification de la flotte sans réentraînement. Des architectures à taille variable (attention, graph neural networks) ou le transfer learning constitueraient les pistes de résolution les plus prometteuses [10].

Limite 6 : Approximation séquentielle de l’optimisation holistique. À chaque étape de décision, l’agent dispatche le camion le plus tôt disponible, sans optimiser simultanément l’affectation de tous les camions libres. Cette granularité séquentielle est une approximation tractable du problème d’affectation global, qui serait de complexité combinatoire exponentielle ($|\mathcal{A}|^{N_c}$) dans sa formulation complète. Elle s’inscrit dans la même logique que les heuristiques classiques qui traitent également un camion à la fois, mais l’agent RL bénéficie d’une observation globale de la flotte pour guider ses décisions. Une extension multi-agent (chaque camion comme agent, entraînement centralisé et exécution décentralisée) permettrait de s’approcher d’une optimisation véritablement holistique [26].

Limite 7 : Validation exclusivement en simulation. L’ensemble des résultats repose sur un simulateur paramétré à partir de la littérature (Afrapoli 2017, Mohtasham 2023). Aucune confrontation avec des données de terrain réelles n’a été réalisée. Les performances

observées peuvent différer des conditions opérationnelles réelles, où des phénomènes non modélisés interviennent : météo, état variable des routes, comportement des opérateurs, pannes de pelles ou d'infrastructures. Une validation sur données historiques d'une mine partenaire constituerait l'étape naturelle suivante pour consolider les conclusions de ce travail.

6.4 Discussion

6.4.1 Validation de l'hypothèse centrale H1

L'hypothèse centrale de ce mémoire stipule qu'un agent basé sur l'apprentissage par renforcement peut surpasser les approches heuristiques classiques en réduisant les temps d'attente et en améliorant l'adaptabilité aux perturbations.

Les résultats obtenus permettent une **validation partielle et différenciée** de H1 :

- **Sur le critère productivité en conditions stables** (nominal) : PPO (4 208.8 t/h) et DQN (4 168.5 t/h) surpassent tous deux Fixed Assignment (4 074.0 t/h). H1 est **validée** sur ce critère.
- **Sur le critère productivité en conditions perturbées** (high_breakdown) : DQN (3 991.8 t/h) et PPO (3 946.3 t/h) surpassent Fixed Assignment (3 860.5 t/h). H1 est **validée** sur ce critère. En revanche, Fixed Assignment conserve les meilleurs temps d'attente (53.1 min vs 65.1 min pour PPO), reflétant un compromis productivité/réactivité.
- **Sur le critère robustesse aux surcharges** (high_load) : Nearest Shovel s'effondre à 201 minutes d'attente, validant la prémisse du titre que les heuristiques statiques ont des limites structurelles. DQN (5 664.8 t/h) reste compétitif face à Fixed Assignment (5 874.8 t/h, -3,6%). H1 est **partiellement validée**.

Cette nuance est scientifiquement cohérente avec la littérature. Hazrathosseini et Afrapoli [22] soulignent que le RL n'est pas universellement supérieur aux heuristiques, mais apporte un avantage spécifique dans les contextes dynamiques et perturbés. Nos résultats confirment exactement cette conclusion.

6.4.2 Apports de la progression algorithmique

La progression Q-Learning → SARSA → DQN → PPO révèle plusieurs enseignements méthodologiques.

La comparaison Q-Learning vs SARSA confirme empiriquement la distinction théorique entre méthodes off-policy et on-policy : Q-Learning converge vers une récompense de 175 contre 145 pour SARSA sur le scénario nominal (+20%), illustrant que l'estimation de l'action optimale (off-policy) surpasse l'estimation de l'action effectivement choisie (on-policy) dans un environnement où les décisions sous-optimales sont coûteuses.

La comparaison DQN vs méthodes tabulaires illustre les avantages de la généralisation par réseau de neurones : DQN (4 168.5 t/h en nominal) surpasse Q-Learning (3 591.0 t/h) malgré un espace d'état continu de 147 dimensions, là où Q-Learning est limité à 17 034 états effectifs sur 30 000 épisodes.

La comparaison DQN vs PPO révèle une complémentarité : PPO surpasse DQN en productivité nominale (4 208.8 vs 4 168.5 t/h) et obtient de meilleurs temps d'attente (31.8 vs 40.2 min) grâce à sa politique on-policy adaptative. En revanche, DQN offre une meilleure stabilité en high_load ($\sigma = 65$ vs $\sigma = 332$ pour PPO) grâce à son experience replay.

6.4.3 Perspectives d'intégration industrielle

Conformément à la question Q5 de l'introduction, l'agent RL développé est conçu comme une couche d'intelligence additionnelle au-dessus des FMS existants. Il ne nécessite pas de remplacement de l'infrastructure, mais peut être déployé comme module de recommandation d'affectation, proposant à l'opérateur une décision optimisée à chaque cycle camion. Cette architecture hybride (FMS + agent RL) permettrait de bénéficier simultanément de la fiabilité opérationnelle des systèmes industriels et de l'adaptabilité apprise par le RL face aux perturbations.

6.5 Conclusion

Ce chapitre a analysé les performances de huit stratégies de dispatching sur trois scénarios représentatifs de la logistique minière à ciel ouvert.

Les résultats confirment trois conclusions majeures. Premièrement, les heuristiques statiques myopes (Nearest Shovel, Shortest Path) montrent des limites structurelles en conditions de surcharge : leurs temps d'attente atteignent 201 minutes, validant la problématique du mémoire. Deuxièmement, PPO et DQN surpassent Fixed Assignment en productivité dans deux scénarios sur trois (nominal : +3,3% et +2,3%; high_breakdown : +2,2% et +3,4%), validant l'hypothèse centrale H1. Troisièmement, la progression algorithmique Q-Learning $\rightarrow$ SARSA $\rightarrow$ DQN $\rightarrow$ PPO confirme les prédictions théoriques : Q-Learning surpasse SARSA (+20% de récompense), et PPO surpasse DQN en temps d'attente nominal (31.8 vs 40.2 min) tandis que DQN offre plus de stabilité en surcharge.

Ces résultats ouvrent des perspectives directes : l'augmentation du budget d'entraînement pour les agents Deep RL, l'introduction de scénarios de panne de pelles (et non seulement de camions), et l'évaluation sur des graphes routiers plus complexes constituerait les prochaines étapes naturelles pour confirmer et étendre les contributions de ce travail.

Conclusion générale et perspectives

Glossaire

CRISP-RL C'ross-Industry Standard Process for Reinforcement Learning applications.

CSV Comma-Separated Values (valeurs séparées par des virgules).

DQN Deep Q-Network.

FIFO First In, First Out (premier entré, premier sorti).

FMS Fleet Management System (système de gestion de flotte).

GAE Generalized Advantage Estimation.

GPU Graphics Processing Unit (unité de traitement graphique).

JSSP Job Shop Scheduling Problem (problème d'ordonnancement d'ateliers).

KPI Key Performance Indicator (indicateur clé de performance).

MARL Multi-Agent Reinforcement Learning (apprentissage par renforcement multi-agent).

MDP Markov Decision Process (processus de décision markovien).

MF Match Factor (facteur d'équilibre flotte-pelles).

MILP Mixed Integer Linear Programming (programmation linéaire en nombres entiers mixtes).

MLP Multi-Layer Perceptron (perceptron multicouche).

PPO Proximal Policy Optimization.

RL Reinforcement Learning (apprentissage par renforcement).

SARSA State-Action-Reward-State-Action.

SB3 Stable-Baselines3 (bibliothèque d'implémentation d'algorithmes RL).

TD Temporal Difference (différence temporelle).

VRP Vehicle Routing Problem (problème de tournées de véhicules).

Bibliographie

- [1] M. Krichen, “Apprentissage par renforcement profond,” 2022.
- [2] A. Afrapoli and H. Askari-Nasab, “Mining fleet management systems : a review of models and algorithms,” *International Journal of Mining, Reclamation and Environment*, pp. 1–20, 6 2017.
- [3] A. M. Newman, E. Rubio, A. W. R. Caro, and K. Eurek, “A review of operations research in mine planning,” *Interfaces*, vol. 40, pp. 222–245, 4 2010.
- [4] S. Alarie and M. Gamache, “Overview of solution strategies used in truck dispatching systems for open pit mines,” *International Journal of Surface Mining, Reclamation and Environment*, vol. 16, pp. 59–76, 2002.
- [5] M. M. Fioroni, L. A. G. Franzese, T. J. Bianchi, L. Ezawa, L. R. Pinto, and G. de Miranda Jr., “Concurrent simulation and optimization models for mining planning,” *Winter Simulation Conference*, 2008.
- [6] S. P. Upadhyay and H. Askari-Nasab, “Simulation and optimization approach for uncertainty-based short-term planning in open pit mines,” *International Journal of Mining Science and Technology*, vol. 28, pp. 153–166, 12 2017.
- [7] M. Abolghasemian, A. G. Kanafi, and M. Daneshmandmehr, “A two-phase simulation-based optimization of hauling system in open-pit mine,” *Iranian Journal of Management Studies (IJMS)*, vol. 13, pp. 705–732, 5 2020.
- [8] B. Ozdemir and M. Kumral, “Simulation based optimization of truck shovel material handling systems in multi pit surface mines,” *Simulation Modelling Practice and Theory*, vol. 95, pp. 36–48, 4 2019.
- [9] K. Szatmari, T. Chovan, S. nemeth, and A. Kummer, “How to support decision making with reinforcement learning in hierarchical chemical process control?” *Chemical Engineering Journal Advances*, vol. 22, p. 100753, 2025.
- [10] W. Zeng, E. Baafi, and H. Fan, “A simulation model to study truck- allocation options,” *School of Civil, Mining and Environmental Engineering, University of Wollongong, Australia*, vol. 122, pp. 741–750, 12 2022.
- [11] M. Nazari, A. Oroojlooy, M. Takáč, and L. V. Snyder, “Reinforcement learning for solving the vehicle routing problem,” *NeurIPS*, 5 2018.

- [12] F. Soumis, J. Ethier, and J. Elbrond, "Truck dispatching in an open pit mine," *International Journal of Surface Mining, Reclamation and Environment*, vol. 3, pp. 115–119, 1989.
- [13] M. Munirathinam and J. C. Yingling, "A review of computer-based truck dispatching strategies for surface mining operations," *International Journal of Surface Mining, Reclamation and Environment*, 1994.
- [14] M. Mohtasham and H. Mirzaei-Nasirabad, "Evaluating the performance of the dispatch algorithm, a commercial software, in the sungun copper mine," *Journal of Geomines*, pp. 117–122, 2023.
- [15] M. Souza, I. Coelho, S. Ribas, H. Santos, and L. Merschmann, "A hybrid heuristic algorithm for the open-pit-mining operational planning problem," *European Journal of Operational Research*, pp. 1041–1051, 6 2010.
- [16] R. Subtil, D. M. Silva, and J. C. Alves, "A practical approach to truck dispatch for open pit mines," *Proceedings of the 35th International Symposium on the Application of Computers and Operations Research in the Mineral Industry (APCOM)*, 2011.
- [17] D. Ahangaran, A. Yasrebi, A. Wetherelt, and P. Foster, "Real-time dispatching modelling for trucks with different capacities in open pit mines," *Archives of Mining Sciences*, vol. 52, pp. 39–52, 2012.
- [18] A. Smith, J. Linderorth, and J. Luedtke, "Optimization-based dispatching policies for open-pit mining," *Springer*, pp. 1–39, 2 2020.
- [19] C. H. Ta, A. Ingolfsson, and J. Doucette, "A linear model for surface mining haul truck allocation incorporating shovel idle probabilities," *European Journal of Operational Research*, pp. 770–778, 6 2013.
- [20] Z. Wang, J. Wang, M. Zhao, Q. Guo, X. Zeng, F. Xin, and H. Zhou, "Truck dispatching optimization model and algorithm based on 0-1 decision variables," *Mathematical Problems in Engineering*, vol. 2022, pp. 1–9, 2 2022.
- [21] C. Zhang, W. Song, Z. Cao, J. Zhang, P. S. Tan, and C. Xu, "Learning to dispatch for job shop scheduling via deep reinforcement learning," *NeurIPS*, pp. 1–17, 10 2020.
- [22] A. Hazrathosseini and A. M. Afrapoli, "Transition to intelligent fleet management systems in open pit mines : A critical review on application of reinforcement-learning-based systems," *Mining Technology*, 2024.
- [23] S. Pei, J. Yang, and Z. Gong, "Learning-based dispatching system with trajectory optimisation for autonomous mining transportation," *International Journal of Mining, Reclamation and Environment*, 2025.
- [24] J. P. de Carvalho and R. Dimitrakopoulos, "Production planning updating with mining fleet management in industrial mining complexes : an actor-critic reinforcement learning approach," *Applied Intelligence*, 2023.

- [25] G. Liu and S. Chai, “Optimizing open-pit truck route based on minimization of time-varying transport energy consumption,” *Mathematical Problems in Engineering*, vol. 2019, pp. 1–12, 8 2019.
- [26] K. Zhao, Z. Liu, W. Du, H. Lu, B. Zhou, and G. Yu, “Hierarchical multiagent reinforcement learning for sustainable truck dispatching in open-pit mining,” *Transportmetrica A : Transport Science*, 2025.
- [27] F. ROSALES and A. DIAZ, “Interpretable deep reinforcement learning for dynamic truck dispatching in open-pit mining,” *International Journal of Mining, Reclamation and Environment*, 2025.
- [28] C. Banerjee, K. Nguyen, and C. Fookes, “Mining-gym : A configurable rl benchmarking environment for truck dispatch scheduling,” 2025.
- [29] N. Çetin, “Open pit truck/shovel haulage system simulation,” Ph.D. dissertation, Middle East Technical University, 9 2004.
- [30] M. Towers, A. Kwiatkowski, J. Terry, J. U. Balis, G. D. Cola, T. Deleu, M. Goulão, A. Kallinteris, M. Krimmel, A. KG, R. Perez-Vicente, A. Pierré, S. Schulhoff, J. J. Tai, H. Tan, and O. G. Younis, “Gymnasium : A standard interface for reinforcement learning environments,” *NeurIPS*, 2025.
- [31] R. S. Sutton and A. G. Barto, *Reinforcement Learning : An Introduction*, 2018.
- [32] A. Raffin, A. Hill, A. Gleave, A. Kanervisto, M. Ernestus, and N. Dormann, “Stable-baselines3 : Reliable reinforcement learning implementations,” *Journal of Machine Learning Research*, vol. 22, no. 268, pp. 1–8, 2021. [Online]. Available : <https://jmlr.org/papers/v22/20-1364.html>

Annexe A

Détails d'implémentation

À compléter...

Annexe B

Hyperparamètres des modèles

À compléter...

Annexe C

Scénarios de simulation

À compléter...

Annexe D

Architecture logicielle et structure du projet

À compléter...

Annexe E

Interfaces et démonstrations

À compléter...