

UNIVERSITÉ DON BOSCO DE LUBUMBASHI

FACULTÉ DES SCIENCES INFORMATIQUES

Lubumbashi

www.udbl.ac.cd



Au-delà des heuristiques statiques :

**Conception et mise en œuvre d'un agent
d'apprentissage par renforcement pour
l'optimisation holistique et dynamique de la
logistique minière**

Présenté par : **Jean-Luc MUPASA KALUNGA**

Dirigé par : **Dr. Olfa FERCHICHI**

Master 2 Data Science — Spécialité Logistique

Année académique 2025–2026

Février, 2026

Dédicace

À compléter...

Remerciements

À compléter...

Résumé

Dans le secteur minier, l'optimisation des coûts opérationnels et la réduction de l'empreinte environnementale sont des enjeux majeurs. Les systèmes de gestion de flotte (FMS) industriels, bien qu'efficaces dans des conditions stables, montrent leurs limites face à la variabilité des conditions réelles (trafic, météo, état des routes). Ce mémoire propose de dépasser ces limites en développant un agent autonome basé sur l'Apprentissage par Renforcement (RL), capable d'apprendre une politique de navigation adaptative pour optimiser simultanément l'itinéraire et le rythme de déplacement des véhicules. L'approche est validée par une comparaison rigoureuse avec des heuristiques classiques, en s'appuyant sur une modélisation réaliste de l'environnement minier et des métriques quantitatives pertinentes. Les résultats attendus sont une réduction de la consommation de carburant, des temps d'attente et une meilleure adaptation aux perturbations dynamiques.

Mots-clés : Apprentissage par renforcement, logistique minière, optimisation dynamique, fleet management system, dispatching, mine à ciel ouvert.

Abstract

In the mining sector, optimizing operational costs and reducing environmental impact are major challenges. Industrial Fleet Management Systems (FMS), while effective under stable conditions, show limitations when facing real-world variability (traffic, weather, road conditions). This thesis proposes to overcome these limits by developing an autonomous agent based on Reinforcement Learning (RL), able to learn an adaptive navigation policy to simultaneously optimize vehicle routing and speed. The approach is validated through rigorous comparison with classical heuristics, relying on realistic mining environment modeling and relevant quantitative metrics. Expected results include reduced fuel consumption, waiting times, and improved adaptation to dynamic disturbances.

Keywords : Reinforcement learning, mining logistics, dynamic optimization, fleet management system, dispatching, open-pit mining.

Table des matières

Remerciements	ii
Résumé	iii
Abstract	iv
Liste des figures	viii
Liste des tableaux	ix
Introduction générale	1
1 Contexte général et problématique	2
1.1 Logistique minière et transport en mine à ciel ouvert	2
1.2 Systèmes de gestion de flotte minière (FMS)	2
1.3 Approches heuristiques classiques de dispatching	2
1.4 Limites des approches existantes	3
1.5 Problématique scientifique et motivation du travail	3
2 État de l’art	4
2.1 Systèmes de gestion de flotte minière industriels	4
2.1.1 Caterpillar MineStar	4
2.1.2 Komatsu Jigsaw	4
2.2 Optimisation du transport et du dispatching minier	4
2.2.1 Problèmes de routage de véhicules (VRP)	4
2.2.2 Approches heuristiques et méta-heuristiques	5
2.3 Apprentissage par renforcement	5
2.3.1 Fondements de l’apprentissage par renforcement	5
2.3.2 Apprentissage par renforcement profond	5
2.4 Apprentissage par renforcement appliqué à la logistique	5
2.4.1 RL pour le routage et le transport	5
2.4.2 RL en environnements dynamiques et stochastiques	6
2.5 Synthèse critique et positionnement du travail	6

3	Modélisation du problème	7
3.1	Description du système de transport minier	7
3.2	Hypothèses et contraintes de modélisation	7
3.3	Modélisation du réseau routier minier	7
3.4	Formulation du problème en tant que processus de décision markovien (MDP)	7
3.4.1	Espace d'états	7
3.4.2	Espace d'actions	7
3.4.3	Fonction de transition	7
3.4.4	Fonction de récompense	8
4	Méthodologie et conception de la solution	9
4.1	Méthodologie adoptée (CRISP-DM adaptée au RL)	9
4.2	Conception de l'environnement de simulation	9
4.3	Conception de l'agent d'apprentissage par renforcement	9
4.4	Choix des algorithmes d'apprentissage	9
4.5	Conception des modèles de référence (baselines)	9
5	Implémentation et expérimentation	10
5.1	Architecture globale du système proposé	10
5.2	Détails d'implémentation de l'environnement	10
5.3	Paramètres et protocoles d'entraînement	10
5.4	Scénarios expérimentaux	10
5.5	Métriques d'évaluation	10
6	Résultats et analyse	11
6.1	Résultats expérimentaux	11
6.2	Comparaison avec les approches de référence	11
6.3	Analyse critique des résultats	11
6.4	Discussion	11
	Conclusion générale et perspectives	12
	Bibliographie	13
	Annexes	15
A	Détails d'implémentation	16
B	Hyperparamètres des modèles	17
C	Scénarios de simulation	18

D	Architecture logicielle et structure du projet	19
E	Interfaces et démonstrations	20

Table des figures

Liste des tableaux

Introduction générale

Chapitre 1

Contexte général et problématique

1.1 Logistique minière et transport en mine à ciel ouvert

La logistique minière constitue un enjeu majeur pour l'industrie extractive, notamment dans les mines à ciel ouvert où le transport des matériaux représente une part significative des coûts opérationnels et de l'empreinte environnementale [1]. Les opérations de chargement, transport et déchargement sont organisées autour de systèmes complexes impliquant des flottes de camions et de pelles, des réseaux routiers dynamiques, des zones tampons et des contraintes de production et de qualité [2].

1.2 Systèmes de gestion de flotte minière (FMS)

Les systèmes de gestion de flotte minière (Fleet Management Systems - FMS) sont devenus incontournables pour la coordination des opérations de transport en mine à ciel ouvert [2]. Des solutions industrielles telles que Caterpillar MineStar Dispatch ou Komatsu Jigsaw permettent de suivre en temps réel la localisation des véhicules, d'optimiser les affectations camion-pelle et de gérer les files d'attente [3].

1.3 Approches heuristiques classiques de dispatching

Les approches classiques de dispatching minier s'appuient sur des heuristiques statiques, des règles de priorité et des modèles déterministes pour affecter les camions aux pelles et gérer les files d'attente [3]. Ces méthodes, bien qu'efficaces dans des environnements peu perturbés, peinent à anticiper les variations stochastiques du trafic, la dégradation des routes ou les pannes imprévues [4].

1.4 Limites des approches existantes

Les limites des approches existantes résident dans leur incapacité à optimiser globalement la flotte en temps réel et à s'adapter dynamiquement aux micro-conditions évolutives [5]. Un camion suivant une règle statique peut arriver trop tôt dans une zone tampon, gaspillant carburant et temps, ou attendre inutilement à la pelle [6]. De plus, la sous-utilisation des équipements, les congestions et la variabilité des conditions routières restent mal gérées [7].

1.5 Problématique scientifique et motivation du travail

Face à ces limites, ce mémoire propose de dépasser les performances des systèmes heuristiques actuels en développant un agent autonome basé sur l'Apprentissage par Renforcement (RL). L'objectif est d'apprendre une politique de navigation adaptative qui minimise la consommation de carburant, réduit le temps d'attente improductif et s'adapte en temps réel aux conditions changeantes de l'environnement minier [8, 9].

Chapitre 2

État de l’art

2.1 Systèmes de gestion de flotte minière industriels

2.1.1 Caterpillar MineStar

Le système Caterpillar MineStar Dispatch est l’une des solutions industrielles les plus répandues pour la gestion de flotte minière. Il permet le suivi en temps réel des véhicules, l’optimisation des affectations camion-pelle, la gestion des files d’attente et la collecte de données opérationnelles [2]. L’intégration de technologies telles que le GPS et les moniteurs embarqués améliore la prise de décision et la réactivité du système face aux perturbations [1, 3].

2.1.2 Komatsu Jigsaw

Komatsu Jigsaw propose une plateforme similaire, axée sur la coordination dynamique des flottes, la planification des itinéraires et la gestion des ressources. Ces systèmes industriels reposent principalement sur des heuristiques statiques et des règles prédéfinies, assurant une efficacité dans des conditions stables mais montrant leurs limites en environnement dynamique [2, 3].

2.2 Optimisation du transport et du dispatching minier

2.2.1 Problèmes de routage de véhicules (VRP)

Le problème de routage de véhicules (VRP) est central dans la logistique minière. Il s’agit de déterminer les itinéraires optimaux pour une flotte de camions afin de mini-

miser les coûts de transport, les temps d'attente et d'assurer le respect des contraintes de production et de qualité [1, 4]. Les approches classiques incluent la programmation linéaire, la programmation par contraintes et les méthodes de recherche opérationnelle.

2.2.2 Approches heuristiques et méta-heuristiques

Les heuristiques (règles de priorité, dispatching statique) et méta-heuristiques (algorithmes génétiques, recuit simulé, colonies de fourmis) sont largement utilisées pour résoudre les problèmes de dispatching minier [3, 10, 11]. Elles permettent de trouver rapidement des solutions satisfaisantes dans des environnements complexes, mais peinent à garantir l'optimalité globale et à s'adapter aux perturbations en temps réel [5–7].

2.3 Apprentissage par renforcement

2.3.1 Fondements de l'apprentissage par renforcement

L'apprentissage par renforcement (RL) est un paradigme d'intelligence artificielle où un agent apprend à prendre des décisions séquentielles en interagissant avec un environnement, dans le but de maximiser une récompense cumulative. Les concepts clés incluent les processus de décision markoviens (MDP), les politiques, la fonction de valeur et la fonction de récompense [12, 13].

2.3.2 Apprentissage par renforcement profond

L'avènement du deep learning a permis de combiner RL et réseaux de neurones profonds (Deep RL), rendant possible l'apprentissage de politiques complexes dans des environnements à grande dimensionnalité. Les algorithmes tels que DQN, PPO, SAC ou A3C sont aujourd'hui utilisés pour des tâches de contrôle avancées, y compris en logistique et transport [8, 12, 13].

2.4 Apprentissage par renforcement appliqué à la logistique

2.4.1 RL pour le routage et le transport

Des travaux récents montrent que le RL peut surpasser les heuristiques classiques pour le routage de véhicules, l'optimisation des itinéraires et la gestion dynamique des flottes [8, 12]. L'agent RL apprend à anticiper les congestions, à adapter le rythme de déplacement et à optimiser l'utilisation des ressources, même en présence d'incertitude [9].

2.4.2 RL en environnements dynamiques et stochastiques

L'un des atouts majeurs du RL est sa capacité à s'adapter à des environnements dynamiques et stochastiques, caractéristiques des mines à ciel ouvert. Les agents RL peuvent apprendre des politiques robustes face aux variations du trafic, à la dégradation des routes ou aux pannes, là où les approches classiques échouent [2, 5, 6].

2.5 Synthèse critique et positionnement du travail

La littérature montre que, malgré les avancées des FMS industriels et des heuristiques, l'optimisation globale et dynamique de la flotte minière reste un défi [4, 7]. Les approches RL offrent un potentiel inédit pour dépasser ces limites, en permettant une adaptation en temps réel, une optimisation holistique et une meilleure gestion de l'incertitude [8, 9, 12].

Chapitre 3

Modélisation du problème

3.1 Description du système de transport minier

À compléter...

3.2 Hypothèses et contraintes de modélisation

À compléter...

3.3 Modélisation du réseau routier minier

À compléter...

3.4 Formulation du problème en tant que processus de décision markovien (MDP)

3.4.1 Espace d'états

À compléter...

3.4.2 Espace d'actions

À compléter...

3.4.3 Fonction de transition

À compléter...

3.4.4 Fonction de récompense

À compléter...

Chapitre 4

Méthodologie et conception de la solution

4.1 Méthodologie adoptée (CRISP-DM adaptée au RL)

À compléter...

4.2 Conception de l'environnement de simulation

À compléter...

4.3 Conception de l'agent d'apprentissage par renforcement

À compléter...

4.4 Choix des algorithmes d'apprentissage

À compléter...

4.5 Conception des modèles de référence (baselines)

À compléter...

Chapitre 5

Implémentation et expérimentation

5.1 Architecture globale du système proposé

À compléter...

5.2 Détails d'implémentation de l'environnement

À compléter...

5.3 Paramètres et protocoles d'entraînement

À compléter...

5.4 Scénarios expérimentaux

À compléter...

5.5 Métriques d'évaluation

À compléter...

Chapitre 6

Résultats et analyse

6.1 Résultats expérimentaux

À compléter...

6.2 Comparaison avec les approches de référence

À compléter...

6.3 Analyse critique des résultats

À compléter...

6.4 Discussion

À compléter...

Conclusion générale et perspectives

Bibliographie

- [1] A. M. Newman, E. Rubio, A. W. R. Caro, and K. Eurek, “A review of operations research in mine planning,” *Interfaces*, vol. 40, pp. 222–245, 4 2010.
- [2] A. Afrapoli and H. Askari-Nasab, “Mining fleet management systems : a review of models and algorithms,” *International Journal of Mining, Reclamation and Environment*, pp. 1–20, 6 2017.
- [3] S. Alarie and M. Gamache, “Overview of solution strategies used in truck dispatching systems for open pit mines,” *International Journal of Surface Mining, Reclamation and Environment*, vol. 16, pp. 59–76, 2002.
- [4] M. M. Fioroni, L. A. G. Franzese, T. J. Bianchi, L. Ezawa, L. R. Pinto, and G. de Miranda Jr., “Concurrent simulation and optimization models for mining planning,” *Winter Simulation Conference*, 2008.
- [5] S. P. Upadhyay and H. Askari-Nasab, “Simulation and optimization approach for uncertainty-based short-term planning in open pit mines,” *International Journal of Mining Science and Technology*, vol. 28, pp. 153–166, 12 2017.
- [6] M. Abolghasemian, A. G. Kanafi, and M. Daneshmandmehr, “A two-phase simulation-based optimization of hauling system in open-pit mine,” *Iranian Journal of Management Studies (IJMS)*, vol. 13, pp. 705–732, 5 2020.
- [7] B. Ozdemir and M. Kumral, “Simulation based optimization of truck shovel material handling systems in multi pit surface mines,” *Simulation Modelling Practice and Theory*, vol. 95, pp. 36–48, 4 2019.
- [8] S. Choudhury and D. H. Naik, “Use of machine learning algorithm models to optimize the fleet management system in opencast mines,” *International conference for Convergence in Technology*, 9 2022.
- [9] W. Zeng, E. Baafi, and H. Fan, “A simulation model to study truck- allocation options,” *School of Civil, Mining and Environmental Engineering, University of Wollongong, Australia*, vol. 122, pp. 741–750, 12 2022.

- [10] R. Subtil, D. M. Silva, and J. C. Alves, “A practical approach to truck dispatch for open pit mines,” *Proceedings of the 35th International Symposium on the Application of Computers and Operations Research in the Mineral Industry (APCOM)*, 2011.
- [11] M. Souza, I. Coelho, S. Ribas, H. Santos, and L. Merschmann, “A hybrid heuristic algorithm for the open-pit-mining operational planning problem,” *European Journal of Operational Research*, pp. 1041–1051, 6 2010.
- [12] M. Nazari, A. Oroojlooy, M. Takáč, and L. V. Snyder, “Reinforcement learning for solving the vehicle routing problem,” *NeurIPS*, 5 2018.
- [13] C. Zhang, W. Song, Z. Cao, J. Zhang, P. S. Tan, and C. Xu, “Learning to dispatch for job shop scheduling via deep reinforcement learning,” *NeurIPS*, pp. 1–17, 10 2020.
- [14] M. Mohtasham and H. Mirzaei-Nasirabad, “Evaluating the performance of the dispatch algorithm, a commercial software, in the sungun copper mine,” *Journal of Geomines*, pp. 117–122, 2023.
- [15] M. Munirathinam and J. C. Yingling, “A review of computer-based truck dispatching strategies for surface mining operations,” *International Journal of Surface Mining, Reclamation and Environment*, 1994.
- [16] D. Ahangaran, A. Yasrebi, A. Wetherelt, and P. Foster, “Real-time dispatching modelling for trucks with different capacities in open pit mines,” *Archives of Mining Sciences*, vol. 52, pp. 39–52, 2012.
- [17] C. H. Ta, A. Ingolfsson, and J. Doucette, “A linear model for surface mining haul truck allocation incorporating shovel idle probabilities,” *European Journal of Operational Research*, pp. 770–778, 6 2013.
- [18] Z. Wang, J. Wang, M. Zhao, Q. Guo, X. Zeng, F. Xin, and H. Zhou, “Truck dispatching optimization model and algorithm based on 0-1 decision variables,” *Mathematical Problems in Engineering*, vol. 2022, pp. 1–9, 2 2022.
- [19] G. Liu and S. Chai, “Optimizing open-pit truck route based on minimization of time-varying transport energy consumption,” *Mathematical Problems in Engineering*, vol. 2019, pp. 1–12, 8 2019.
- [20] A. Smith, J. Linderroth, and J. Luedtke, “Optimization-based dispatching policies for open-pit mining,” *Springer*, pp. 1–39, 2 2020.
- [21] N. Çetin, “Open pit truck/shovel haulage system simulation,” Ph.D. dissertation, Middle East Technical University, 9 2004.

-
- [22] F. Soumis, J. Ethier, and J. Elbrond, “Truck dispatching in an open pit mine,” *International Journal of Surface Mining, Reclamation and Environment*, vol. 3, pp. 115–119, 1989.

Annexe A

Détails d'implémentation

À compléter...

Annexe B

Hyperparamètres des modèles

À compléter...

Annexe C

Scénarios de simulation

À compléter...

Annexe D

Architecture logicielle et structure du projet

À compléter...

Annexe E

Interfaces et démonstrations

À compléter...