

UNIVERSITÉ DON BOSCO DE LUBUMBASHI

FACULTÉ DES SCIENCES INFORMATIQUES

Lubumbashi

www.udbl.ac.cd



Au-delà des heuristiques statiques :

Conception et mise en œuvre d'un agent d'apprentissage par
renforcement pour l'optimisation holistique et dynamique de
la logistique minière

Présenté par : **Jean-Luc MUPASA KALUNGA**

Dirigé par : **Dr. Olfa FERCHICHI**

Master 2 Data Science — Spécialité Logistique

Année académique 2025–2026

Février, 2026

Dédicace

À compléter...

Remerciements

À compléter...

Résumé

Dans le secteur minier, l'optimisation des coûts opérationnels et la réduction de l'empreinte environnementale sont des enjeux majeurs. Les systèmes de gestion de flotte (FMS) industriels, bien qu'efficaces dans des conditions stables, montrent leurs limites face à la variabilité des conditions réelles (trafic, météo, état des routes). Ce mémoire propose de dépasser ces limites en développant un agent autonome basé sur l'Apprentissage par Renforcement (RL), capable d'apprendre une politique de navigation adaptative pour optimiser simultanément l'itinéraire et le rythme de déplacement des véhicules. L'approche est validée par une comparaison rigoureuse avec des heuristiques classiques, en s'appuyant sur une modélisation réaliste de l'environnement minier et des métriques quantitatives pertinentes. Les résultats attendus sont une réduction de la consommation de carburant, des temps d'attente et une meilleure adaptation aux perturbations dynamiques.

Mots-clés : Apprentissage par renforcement, logistique minière, optimisation dynamique, fleet management system, dispatching, mine à ciel ouvert.

Abstract

In the mining sector, optimizing operational costs and reducing environmental impact are major challenges. Industrial Fleet Management Systems (FMS), while effective under stable conditions, show limitations when facing real-world variability (traffic, weather, road conditions). This thesis proposes to overcome these limits by developing an autonomous agent based on Reinforcement Learning (RL), able to learn an adaptive navigation policy to simultaneously optimize vehicle routing and speed. The approach is validated through rigorous comparison with classical heuristics, relying on realistic mining environment modeling and relevant quantitative metrics. Expected results include reduced fuel consumption, waiting times, and improved adaptation to dynamic disturbances.

Keywords : Reinforcement learning, mining logistics, dynamic optimization, fleet management system, dispatching, open-pit mining.

Table des matières

Remerciements	ii
Résumé	iii
Abstract	iv
Liste des figures	vii
Liste des tableaux	viii
Introduction générale	1
Questions de recherche	1
Hypothèse	2
Objectifs	2
Méthodologie	2
Organisation du mémoire	3
1 Contexte général et problématique	4
1.1 Logistique minière et transport en mine à ciel ouvert	4
1.2 Systèmes de gestion de flotte minière (FMS)	4
1.3 Approches heuristiques classiques de dispatching	4
1.4 Limites des approches existantes	4
1.5 Problématique scientifique et motivation du travail	5
1.6 Conclusion	5
2 État de l’art	6
2.1 Des heuristiques simples aux systèmes industriels	6
2.2 L’évolution académique : méta-heuristiques et optimisation avancée	6
2.3 L’arrivée du paradigme RL	6
2.4 Synthèse critique et positionnement du travail	7
2.5 Conclusion	8
3 Modélisation du problème	9
3.1 Description du système de transport minier	9
3.2 Hypothèses et contraintes de modélisation	9
3.3 Modélisation du réseau routier minier	9

3.4	Formulation du problème en tant que processus de décision markovien (MDP)	9
3.4.1	Espace d'états	9
3.4.2	Espace d'actions	9
3.4.3	Fonction de transition	9
3.4.4	Fonction de récompense	9
4	Méthodologie et conception de la solution	10
4.1	Méthodologie adoptée (CRISP-DM adaptée au RL)	10
4.2	Conception de l'environnement de simulation	10
4.3	Conception de l'agent d'apprentissage par renforcement	10
4.4	Choix des algorithmes d'apprentissage	10
4.5	Conception des modèles de référence (baselines)	10
5	Implémentation et expérimentation	11
5.1	Architecture globale du système proposé	11
5.2	Détails d'implémentation de l'environnement	11
5.3	Paramètres et protocoles d'entraînement	11
5.4	Scénarios expérimentaux	11
5.5	Métriques d'évaluation	11
6	Résultats et analyse	12
6.1	Résultats expérimentaux	12
6.2	Comparaison avec les approches de référence	12
6.3	Analyse critique des résultats	12
6.4	Discussion	12
	Conclusion générale et perspectives	13
	Bibliographie	14
	Annexes	15
A	Détails d'implémentation	16
B	Hyperparamètres des modèles	17
C	Scénarios de simulation	18
D	Architecture logicielle et structure du projet	19
E	Interfaces et démonstrations	20

Table des figures

Liste des tableaux

2.1	Synthèse des grandes familles d’approches et opportunités pour le RL	7
2.2	Détail des contributions et limites des articles majeurs de l’état de l’art . . .	8

Introduction générale

Représentant jusqu'à 60% des coûts opérationnels d'une mine à ciel ouvert, la logistique de transport est l'enjeu financier et environnemental majeur de l'industrie minière moderne [1]. Chaque pourcentage d'efficacité gagné se traduit par des millions de dollars d'économies. C'est dans ce contexte que ce mémoire explore l'apport de l'apprentissage par renforcement pour l'optimisation dynamique de la logistique minière. Malgré l'adoption généralisée des systèmes de gestion de flotte (FMS), les exploitations minières se heurtent à la complexité croissante et à la variabilité des environnements réels [1, 2]. L'objectif est de concevoir un agent autonome capable d'adapter ses décisions en temps réel, afin de réduire les coûts, améliorer l'efficacité et minimiser l'impact environnemental. La méthodologie adoptée combine une analyse approfondie de l'état de l'art, une modélisation réaliste du problème et une validation expérimentale des solutions proposées. Ce travail vise ainsi à dépasser les approches classiques et à ouvrir de nouvelles perspectives pour la gestion intelligente des flottes minières.

La logistique minière englobe l'ensemble des opérations visant à assurer le transport efficace des matériaux, du site d'extraction jusqu'aux zones de traitement ou de stockage. Dans les mines à ciel ouvert, le transport représente une part prépondérante des coûts opérationnels et de l'empreinte environnementale [2]. La gestion optimale des flux de camions, la coordination avec les équipements de chargement et le respect des contraintes de production sont des enjeux majeurs pour garantir la rentabilité et la durabilité des exploitations minières [1]. L'optimisation des flottes minières consiste à affecter dynamiquement les camions aux différentes tâches (chargement, transport, déchargement) tout en minimisant les temps d'attente, la consommation de carburant et l'usure des équipements [3]. Cette problématique est rendue complexe par la variabilité des conditions réelles (trafic, météo, état des routes), la multiplicité des contraintes opérationnelles et la nécessité d'adapter les décisions en temps réel pour maximiser la productivité globale [4]. Les systèmes de gestion de flotte industriels reposent principalement sur des heuristiques statiques et des règles prédéfinies [3]. Bien qu'efficaces dans des environnements stables, ils montrent leurs limites face à la variabilité et à l'incertitude du terrain [5]. Ils peinent à anticiper les congestions, à s'adapter aux perturbations imprévues et à optimiser globalement la flotte en temps réel, ce qui conduit à des pertes d'efficacité et à une sous-utilisation des ressources [6, 7].

Questions de recherche

Ce mémoire s'articule autour des questions suivantes :

1. Comment modéliser l'environnement minier complexe (réseau routier, zones tampons,

événements stochastiques) dans un cadre RL compatible avec les standards industriels ?

2. Quelle architecture d'agent RL est la plus adaptée pour apprendre une politique de navigation holistique intégrant à la fois le choix d'itinéraire et le contrôle de vitesse ?
3. Comment concevoir une fonction de récompense qui capture fidèlement les coûts réels (carburant, usure, temps) tout en pénalisant les comportements non souhaitables ?
4. Quelles métriques et protocoles d'évaluation permettront de démontrer quantitativement la supériorité de l'approche RL par rapport aux approches classiques, notamment dans des scénarios de perturbation ?
5. Comment intégrer un tel système RL comme couche d'intelligence additionnelle dans l'écosystème des FMS existants, sans nécessiter un remplacement complet de l'infrastructure ?

Hypothèse

L'hypothèse centrale de ce mémoire est qu'un agent autonome basé sur l'apprentissage par renforcement peut surpasser les approches heuristiques classiques pour l'optimisation dynamique de la logistique minière, en réduisant la consommation de carburant, les temps d'attente et en améliorant l'adaptabilité aux perturbations [8–10].

Objectifs

Les objectifs principaux de ce travail sont :

- Concevoir un environnement de simulation réaliste pour la logistique minière à ciel ouvert [1, 2] ;
- Développer un agent d'apprentissage par renforcement capable d'optimiser les décisions de dispatching et de routage [8, 10] ;
- Comparer les performances de l'agent RL avec celles des heuristiques classiques sur des scénarios variés [3, 7] ;
- Analyser l'impact de l'approche RL sur les indicateurs clés (coût, temps, consommation, robustesse) [5, 9].

Méthodologie

La méthodologie suivie s'appuie sur une adaptation du cadre CRISP-DM au contexte du RL : compréhension du problème et des données [2], modélisation de l'environnement, conception et entraînement de l'agent, expérimentation et analyse comparative [8, 10]. Chaque étape est guidée par une validation rigoureuse des hypothèses et une évaluation quantitative des résultats.

Organisation du mémoire

Le mémoire est structuré comme suit :

- L'introduction générale présente le contexte, la problématique et les objectifs du travail ;
- Le chapitre 1 détaille le contexte général et la problématique de la logistique minière ;
- Le chapitre 2 propose un état de l'art des approches existantes et du RL appliqué à la logistique ;
- Le chapitre 3 décrit la modélisation du problème et les hypothèses retenues ;
- Le chapitre 4 expose la méthodologie et la conception de la solution RL ;
- Le chapitre 5 présente l'implémentation, les protocoles expérimentaux et les résultats obtenus ;
- Le chapitre 6 analyse et discute les résultats ;
- Enfin, la conclusion générale synthétise les apports et ouvre sur des perspectives futures.

Chapitre 1

Contexte général et problématique

1.1 Logistique minière et transport en mine à ciel ouvert

La logistique minière constitue un enjeu majeur pour l'industrie extractive, notamment dans les mines à ciel ouvert où le transport des matériaux représente une part significative des coûts opérationnels et de l'empreinte environnementale [2]. Les opérations de chargement, transport et déchargement sont organisées autour de systèmes complexes impliquant des flottes de camions et de pelles, des réseaux routiers dynamiques, des zones tampons et des contraintes de production et de qualité [1].

1.2 Systèmes de gestion de flotte minière (FMS)

Les systèmes de gestion de flotte minière (Fleet Management Systems - FMS) sont devenus incontournables pour la coordination des opérations de transport en mine à ciel ouvert [1]. Des solutions industrielles telles que Caterpillar MineStar, Dispatch ou Komatsu Jigsaw permettent de suivre en temps réel la localisation des véhicules, d'optimiser les affectations camion-pelle et de gérer les files d'attente [3].

1.3 Approches heuristiques classiques de dispatching

Les approches classiques de dispatching minier s'appuient sur des heuristiques statiques, des règles de priorité et des modèles déterministes pour affecter les camions aux pelles et gérer les files d'attente [3]. Ces méthodes, bien qu'efficaces dans des environnements peu perturbés, peinent à anticiper les variations stochastiques du trafic, la dégradation des routes ou les pannes imprévues [4].

1.4 Limites des approches existantes

Les limites des approches existantes résident dans leur incapacité à optimiser globalement la flotte en temps réel et à s'adapter dynamiquement aux micro-conditions évolutives [5]. Un exemple frappant de ces limites est le « syndrome de l'arrivée précoce » : un camion, suivant aveuglément l'instruction « aller au chemin le plus court », peut arriver à une pelle qui n'est

pas encore prête. Il doit alors attendre, moteur tournant, gaspillant du carburant, du temps et créant une congestion inutile. Le système a pris une décision localement optimale (le chemin le plus court) qui s'avère globalement inefficace [6]. De plus, la sous-utilisation des équipements, les congestions et la variabilité des conditions routières restent mal gérées [7].

1.5 Problématique scientifique et motivation du travail

Face à ces limites, ce mémoire propose de dépasser les performances des systèmes heuristiques actuels en développant un agent autonome basé sur l'Apprentissage par Renforcement (RL). L'objectif est d'apprendre une politique de navigation adaptative qui minimise la consommation de carburant, réduit le temps d'attente improductif et s'adapte en temps réel aux conditions changeantes de l'environnement minier [8, 9].

1.6 Conclusion

Ce premier chapitre a permis de poser les bases du mémoire en détaillant le contexte industriel et scientifique de la logistique minière, les spécificités des systèmes de gestion de flotte, les approches heuristiques classiques et leurs limites face à la complexité et à la variabilité des environnements réels. Il a mis en évidence la nécessité d'explorer de nouvelles approches, capables d'adapter dynamiquement les décisions de dispatching et de routage pour optimiser la performance globale des flottes minières. Cette réflexion ouvre naturellement sur l'état de l'art des méthodes avancées, notamment l'apprentissage par renforcement, qui sera présenté dans le chapitre suivant.

Chapitre 2

État de l’art

2.1 Des heuristiques simples aux systèmes industriels

L’histoire de l’optimisation de la logistique minière débute avec des heuristiques simples, telles que l’assignation du camion le plus proche ou la règle du premier arrivé, premier servi [3, 11]. Si ces méthodes sont faciles à mettre en œuvre, elles restent « myopes » : elles optimisent localement sans anticiper les conséquences globales sur la flotte. Cette limitation a conduit à l’émergence de systèmes industriels comme DISPATCH, Caterpillar MineStar ou Komatsu Jigsaw, qui intègrent des modules de planification et de suivi en temps réel [1, 12]. Ces systèmes ont permis d’augmenter la productivité et de réduire les temps d’attente, mais restent largement déterministes et rigides, peinant à s’adapter aux perturbations et à la dynamique réelle du terrain.

2.2 L’évolution académique : méta-heuristiques et optimisation avancée

L’apparition des systèmes industriels comme DISPATCH marque une première rupture, en intégrant la planification et le suivi en temps réel. Cependant, ces solutions restent déterministes et peu flexibles face à la variabilité du terrain.

Pour dépasser les limites des systèmes industriels, la recherche académique a proposé des approches plus sophistiquées : méta-heuristiques (algorithmes génétiques, colonies de fourmis, recuit simulé) [13, 14], modèles MILP ou programmation par contraintes [15–18]. Ces méthodes offrent de meilleures performances sur des cas complexes, mais leur capacité d’adaptation en temps réel reste limitée, notamment face à l’incertitude et à la variabilité opérationnelle [4, 5, 7].

2.3 L’arrivée du paradigme RL

Face aux limites persistantes de ces approches, un nouveau paradigme issu de l’intelligence artificielle s’est imposé : l’apprentissage par renforcement (RL). Le RL permet à un agent d’apprendre une politique de décision séquentielle en interagissant avec un environnement simulé ou réel, optimisant ainsi la flotte de manière holistique et adaptative [8, 10, 19]. Les

travaux récents montrent que le RL peut surpasser les heuristiques classiques pour le routage de véhicules, la gestion dynamique des files d'attente et l'optimisation des ressources, même en présence d'incertitude [6, 9].

2.4 Synthèse critique et positionnement du travail

La littérature montre que, malgré les avancées des FMS industriels et des heuristiques, l'optimisation globale et dynamique de la flotte minière reste un défi [4, 7]. Les approches RL offrent un potentiel inédit pour dépasser ces limites, en permettant une adaptation en temps réel, une optimisation holistique et une meilleure gestion de l'incertitude [8–10]. Ce mémoire s'inscrit dans cette dynamique, en proposant une solution RL adaptée aux contraintes et aux spécificités de la logistique minière moderne.

TABLE 2.1 – Synthèse des grandes familles d'approches et opportunités pour le RL

Référence	Approche	Limites principales / Opportunité pour le RL
Alarie & Gamache (2002)	Heuristiques statiques	Approche myope, peu adaptative, ne gère pas l'incertitude. Opportunité : Le RL peut apprendre une politique globale et adaptative.
DISPATCH, MineStar, Jigsaw	Systèmes industriels	Déterministes, rigides, peu réactifs aux perturbations. Opportunité : Le RL permet l'adaptation dynamique.
Souza et al. (2010), Subtil et al. (2011)	Méta-heuristiques	Performantes mais peu robustes en temps réel, optimisation hors-ligne. Opportunité : Le RL gère l'incertitude et l'adaptation continue.
Ahangaran et al. (2012), Amanda Smith (2020)	MILP, optimisation avancée	Complexité computationnelle, difficilement scalable, peu flexible. Opportunité : Le RL offre une solution scalable et flexible.
Nazari et al. (2018), Zhang et al. (2020)	RL pour VRP/JSSP	Complexité de la modélisation, besoin de simulateur. Inspiration : Fournit un cadre état/action/récompense pour le RL minier.
W. Zeng et al. (2022), Abolghasemian et al. (2020)	RL appliqué à la logistique minière	RL montre des gains sur la robustesse et l'adaptation, mais nécessite une modélisation réaliste et des données de simulation.

TABLE 2.2 – Détail des contributions et limites des articles majeurs de l'état de l'art

Référence	Domaine / Approche	Principales contributions / Limites
Newman	FMS, optimisation minière	Modélisation des flux, contraintes industrielles, limites des heuristiques
Afrapoli	FMS industriels	Suivi en temps réel, gestion des files, limites en environnement dynamique
Alarie	Heuristiques classiques	Règles de dispatching, efficacité en conditions stables, manque d'adaptabilité
Fioroni	Heuristiques, VRP	Variabilité du trafic, limites des modèles déterministes
Ozdemir	Méta-heuristiques	Colonies de fourmis, optimisation partielle, adaptation limitée
Nazari	RL pour VRP	RL pour routage, surpasse heuristiques, besoin de données, temps d'entraînement
Choudhury	RL appliqué à la logistique	RL pour dispatching, robustesse, adaptation aux perturbations
Zeng	RL en environnement stochastique	Politiques robustes, gestion de l'incertitude, limites pratiques
Upadhyay	Limites des heuristiques	Incapacité à gérer la variabilité, sous-utilisation des ressources
Zhang	RL fondements	Concepts MDP, politiques, fonctions de valeur
Subtil, Souza	Méta-heuristiques	Algorithmes génétiques, recuit simulé, optimisation locale

2.5 Conclusion

Ce chapitre a retracé l'évolution des approches d'optimisation de la logistique minière, depuis les heuristiques simples jusqu'aux systèmes industriels, en passant par les méta-heuristiques et l'optimisation avancée. Il a mis en évidence les limites des méthodes traditionnelles face à la complexité, la variabilité et l'incertitude des environnements miniers. L'apprentissage par renforcement (RL) apparaît comme un paradigme innovant, capable d'apporter une adaptation dynamique, une optimisation holistique et une robustesse accrue. Ce positionnement ouvre la voie à une nouvelle génération de solutions pour la logistique minière. Le chapitre suivant présentera la modélisation du problème et les choix méthodologiques pour concevoir un agent RL adapté à la logistique minière.

Chapitre 3

Modélisation du problème

3.1 Description du système de transport minier

À compléter...

3.2 Hypothèses et contraintes de modélisation

À compléter...

3.3 Modélisation du réseau routier minier

À compléter...

3.4 Formulation du problème en tant que processus de décision markovien (MDP)

3.4.1 Espace d'états

À compléter...

3.4.2 Espace d'actions

À compléter...

3.4.3 Fonction de transition

À compléter...

3.4.4 Fonction de récompense

À compléter...

Chapitre 4

Méthodologie et conception de la solution

4.1 Méthodologie adoptée (CRISP-DM adaptée au RL)

À compléter...

4.2 Conception de l'environnement de simulation

À compléter...

4.3 Conception de l'agent d'apprentissage par renforcement

À compléter...

4.4 Choix des algorithmes d'apprentissage

À compléter...

4.5 Conception des modèles de référence (baselines)

À compléter...

Chapitre 5

Implémentation et expérimentation

5.1 Architecture globale du système proposé

À compléter...

5.2 Détails d'implémentation de l'environnement

À compléter...

5.3 Paramètres et protocoles d'entraînement

À compléter...

5.4 Scénarios expérimentaux

À compléter...

5.5 Métriques d'évaluation

À compléter...

Chapitre 6

Résultats et analyse

6.1 Résultats expérimentaux

À compléter...

6.2 Comparaison avec les approches de référence

À compléter...

6.3 Analyse critique des résultats

À compléter...

6.4 Discussion

À compléter...

Conclusion générale et perspectives

Bibliographie

- [1] A. Afrapoli and H. Askari-Nasab, “Mining fleet management systems : a review of models and algorithms,” *International Journal of Mining, Reclamation and Environment*, pp. 1–20, 6 2017.
- [2] A. M. Newman, E. Rubio, A. W. R. Caro, and K. Eurek, “A review of operations research in mine planning,” *Interfaces*, vol. 40, pp. 222–245, 4 2010.
- [3] S. Alarie and M. Gamache, “Overview of solution strategies used in truck dispatching systems for open pit mines,” *International Journal of Surface Mining, Reclamation and Environment*, vol. 16, pp. 59–76, 2002.
- [4] M. M. Fioroni, L. A. G. Franzese, T. J. Bianchi, L. Ezawa, L. R. Pinto, and G. de Miranda Jr., “Concurrent simulation and optimization models for mining planning,” *Winter Simulation Conference*, 2008.
- [5] S. P. Upadhyay and H. Askari-Nasab, “Simulation and optimization approach for uncertainty-based short-term planning in open pit mines,” *International Journal of Mining Science and Technology*, vol. 28, pp. 153–166, 12 2017.
- [6] M. Abolghasemian, A. G. Kanafi, and M. Daneshmandmehr, “A two-phase simulation-based optimization of hauling system in open-pit mine,” *Iranian Journal of Management Studies (IJMS)*, vol. 13, pp. 705–732, 5 2020.
- [7] B. Ozdemir and M. Kumral, “Simulation based optimization of truck shovel material handling systems in multi pit surface mines,” *Simulation Modelling Practice and Theory*, vol. 95, pp. 36–48, 4 2019.
- [8] S. Choudhury and D. H. Naik, “Use of machine learning algorithm models to optimize the fleet management system in opencast mines,” *International conference for Convergence in Technology*, 9 2022.
- [9] W. Zeng, E. Baafi, and H. Fan, “A simulation model to study truck- allocation options,” *School of Civil, Mining and Environmental Engineering, University of Wollongong, Australia*, vol. 122, pp. 741–750, 12 2022.
- [10] M. Nazari, A. Oroojlooy, M. Takáč, and L. V. Snyder, “Reinforcement learning for solving the vehicle routing problem,” *NeurIPS*, 5 2018.

- [11] M. Munirathinam and J. C. Yingling, "A review of computer-based truck dispatching strategies for surface mining operations," *International Journal of Surface Mining, Reclamation and Environment*, 1994.
- [12] M. Mohtasham and H. Mirzaei-Nasirabad, "Evaluating the performance of the dispatch algorithm, a commercial software, in the sungun copper mine," *Journal of Geomines*, pp. 117–122, 2023.
- [13] M. Souza, I. Coelho, S. Ribas, H. Santos, and L. Merschmann, "A hybrid heuristic algorithm for the open-pit-mining operational planning problem," *European Journal of Operational Research*, pp. 1041–1051, 6 2010.
- [14] R. Subtil, D. M. Silva, and J. C. Alves, "A practical approach to truck dispatch for open pit mines," *Proceedings of the 35th International Symposium on the Application of Computers and Operations Research in the Mineral Industry (APCOM)*, 2011.
- [15] D. Ahangaran, A. Yasrebi, A. Wetherelt, and P. Foster, "Real-time dispatching modelling for trucks with different capacities in open pit mines," *Archives of Mining Sciences*, vol. 52, pp. 39–52, 2012.
- [16] A. Smith, J. Linderroth, and J. Luedtke, "Optimization-based dispatching policies for open-pit mining," *Springer*, pp. 1–39, 2 2020.
- [17] C. H. Ta, A. Ingolfsson, and J. Doucette, "A linear model for surface mining haul truck allocation incorporating shovel idle probabilities," *European Journal of Operational Research*, pp. 770–778, 6 2013.
- [18] Z. Wang, J. Wang, M. Zhao, Q. Guo, X. Zeng, F. Xin, and H. Zhou, "Truck dispatching optimization model and algorithm based on 0-1 decision variables," *Mathematical Problems in Engineering*, vol. 2022, pp. 1–9, 2 2022.
- [19] C. Zhang, W. Song, Z. Cao, J. Zhang, P. S. Tan, and C. Xu, "Learning to dispatch for job shop scheduling via deep reinforcement learning," *NeurIPS*, pp. 1–17, 10 2020.

Annexe A

Détails d'implémentation

À compléter...

Annexe B

Hyperparamètres des modèles

À compléter...

Annexe C

Scénarios de simulation

À compléter...

Annexe D

Architecture logicielle et structure du projet

À compléter...

Annexe E

Interfaces et démonstrations

À compléter...