

UNIVERSITÉ DON BOSCO DE LUBUMBASHI

FACULTÉ DES SCIENCES INFORMATIQUES

Lubumbashi

www.udbl.ac.cd



Au-delà des heuristiques statiques :

Conception et mise en œuvre d'un agent d'apprentissage par
renforcement pour l'optimisation holistique et dynamique de
la logistique minière

Présenté par : **Jean-Luc MUPASA KALUNGA**

Dirigé par : **Dr. Olfa FERCHICHI**

Master 2 Data Science — Spécialité Logistique

Année académique 2025–2026

Février, 2026

Dédicace

À compléter...

Remerciements

À compléter...

Résumé

Dans le secteur minier, l'optimisation des coûts opérationnels et la réduction de l'empreinte environnementale sont des enjeux majeurs. Les systèmes de gestion de flotte (FMS) industriels, bien qu'efficaces dans des conditions stables, montrent leurs limites face à la variabilité des conditions réelles (trafic, météo, état des routes). Ce mémoire propose de dépasser ces limites en développant un agent autonome basé sur l'apprentissage par renforcement, capable d'apprendre une politique de navigation adaptative pour optimiser simultanément l'itinéraire et le rythme de déplacement des véhicules. L'approche est validée par une comparaison rigoureuse avec des heuristiques classiques, en s'appuyant sur une modélisation réaliste de l'environnement minier et des métriques quantitatives pertinentes. Les résultats attendus sont une réduction de la consommation de carburant, des temps d'attente et une meilleure adaptation aux perturbations dynamiques.

Mots-clés : apprentissage par renforcement, logistique minière, optimisation dynamique, fleet management system, dispatching, mine à ciel ouvert.

Abstract

In the mining sector, optimizing operational costs and reducing environmental impact are major challenges. Industrial Fleet Management Systems (FMS), while effective under stable conditions, show limitations when facing real-world variability (traffic, weather, road conditions). This thesis proposes to overcome these limits by developing an autonomous agent based on Reinforcement Learning, able to learn an adaptive navigation policy to simultaneously optimize vehicle routing and speed. The approach is validated through rigorous comparison with classical heuristics, relying on realistic mining environment modeling and relevant quantitative metrics. Expected results include reduced fuel consumption, waiting times, and improved adaptation to dynamic disturbances.

Keywords : Reinforcement learning, mining logistics, dynamic optimization, fleet management system, dispatching, open-pit mining.

Table des matières

Remerciements	II
Résumé	III
Abstract	IV
Liste des figures	VII
Liste des tableaux	VIII
Introduction générale	1
1 Concepts fondamentaux de la logistique minière	3
1.1 Logistique minière et transport en mine à ciel ouvert	3
1.2 Systèmes de gestion de flotte minière (FMS)	3
1.3 Concepts de dispatching et de routage minier	4
1.4 Principes opérationnels et contraintes du transport minier	4
1.5 Conclusion partielle et transition	5
2 État de l’art des méthodes d’optimisation	6
2.1 Les heuristiques classiques	6
2.2 Les méta-heuristiques	6
2.3 Les approches basées sur l’apprentissage par renforcement	6
2.4 Synthèse critique et positionnement du travail	7
2.5 Conclusion partielle	9
3 Modélisation du problème	11
3.1 Description du système de transport minier	11
3.2 Hypothèses et contraintes de modélisation	11
3.3 Modélisation du réseau routier minier	11
3.4 Formulation du problème en tant que processus de décision markovien (MDP)	11
4 Méthodologie et conception de la solution	12
4.1 Méthodologie adoptée (CRISP-DM adaptée à l’apprentissage par renforcement)	12
4.2 Conception de l’environnement de simulation	12
4.3 Conception de l’agent d’apprentissage par renforcement	12

4.4	Choix des algorithmes d'apprentissage	12
4.5	Conception des modèles de référence (baselines)	12
5	Implémentation et expérimentation	13
5.1	Architecture globale du système proposé	13
5.2	Détails d'implémentation de l'environnement	13
5.3	Paramètres et protocoles d'entraînement	13
5.4	Scénarios expérimentaux	13
5.5	Métriques d'évaluation	13
6	Résultats et analyse	14
6.1	Résultats expérimentaux	14
6.2	Comparaison avec les approches de référence	14
6.3	Analyse critique des résultats	14
6.4	Discussion	14
	Conclusion générale et perspectives	15
	Bibliographie	16
	Annexes	17
A	Détails d'implémentation	18
B	Hyperparamètres des modèles	19
C	Scénarios de simulation	20
D	Architecture logicielle et structure du projet	21
E	Interfaces et démonstrations	22

Table des figures

Liste des tableaux

2.1	Synthèse des grandes familles d’approches et opportunités pour l’apprentissage par renforcement	8
2.2	Détail des contributions et limites des articles majeurs de l’état de l’art . . .	9

Introduction générale

La logistique de transport constitue l'un des piliers financiers et environnementaux les plus critiques de l'industrie minière moderne. Bien que son optimisation puisse générer des économies se chiffrant en millions de dollars, elle représente souvent une part prépondérante, pouvant atteindre 60%, des coûts opérationnels totaux d'une mine à ciel ouvert [1]. C'est dans ce cadre que ce mémoire analyse l'apport de l'apprentissage par renforcement pour l'optimisation dynamique de la logistique minière. Malgré l'adoption généralisée des systèmes de gestion de flotte (FMS), les exploitations minières se heurtent à la complexité croissante et à la variabilité des environnements réels [1, 2]. La logistique minière englobe l'ensemble des opérations visant à assurer le transport efficace des matériaux, du site d'extraction jusqu'aux zones de traitement ou de stockage. Dans ce contexte, la gestion des flux de camions, la coordination avec les équipements de chargement et le respect des contraintes de production sont déterminants pour la rentabilité et la durabilité [1]. L'optimisation des flottes consiste à affecter dynamiquement les camions aux tâches de chargement, transport et déchargement tout en minimisant les temps d'attente, la consommation de carburant et l'usure des équipements [3]. Cette problématique est difficile en raison de la variabilité des conditions réelles (trafic, météo, état des routes), de la multiplicité des contraintes opérationnelles et de la nécessité d'adapter les décisions en temps réel pour maintenir la productivité globale [4]. Les approches industrielles dominantes reposent encore largement sur des heuristiques statiques et des règles prédéfinies [3] qui, bien qu'efficaces dans des contextes stables, montrent des limites marquées face à l'incertitude du terrain [5]. Elles peinent à anticiper les congestions, à réagir aux perturbations et à optimiser la flotte de manière holistique, ce qui entraîne des pertes d'efficacité et une sous-utilisation des ressources [6, 7]. Face à ces limites, l'objectif de ce mémoire est de concevoir un agent autonome capable d'adapter ses décisions en temps réel afin de réduire les coûts, améliorer l'efficacité opérationnelle et limiter l'impact environnemental.

L'étude s'articule autour des questions suivantes :

1. Comment modéliser l'environnement minier complexe (réseau routier, zones tampons, événements stochastiques) dans un cadre d'apprentissage par renforcement compatible avec les standards industriels ? (Chapitre 3)
2. Quelle architecture d'agent d'apprentissage par renforcement est la plus adaptée pour apprendre une politique de navigation holistique intégrant à la fois le choix d'itinéraire et le contrôle de vitesse ? (Chapitre 4)
3. Comment concevoir une fonction de récompense qui capture fidèlement les coûts réels (carburant, usure, temps) tout en pénalisant les comportements non souhaitables ?

(Chapitre 4)

4. Quelles métriques et quels protocoles d'évaluation permettront de démontrer quantitativement la supériorité de l'approche d'apprentissage par renforcement par rapport aux approches classiques, notamment dans des scénarios de perturbation ? (Chapitre 5 et Chapitre 6)
5. Comment intégrer un tel système d'apprentissage par renforcement comme couche d'intelligence additionnelle dans l'écosystème des FMS existants, sans nécessiter un remplacement complet de l'infrastructure ? (Chapitre 6)

L'hypothèse centrale est qu'un agent autonome basé sur l'apprentissage par renforcement peut surpasser les approches heuristiques classiques pour l'optimisation dynamique de la logistique minière, en réduisant la consommation de carburant, les temps d'attente et en améliorant l'adaptabilité aux perturbations [8–10]. Les objectifs principaux de ce travail sont les suivants :

- Concevoir un environnement de simulation réaliste pour la logistique minière à ciel ouvert [1, 2] ;
- Développer un agent d'apprentissage par renforcement capable d'optimiser les décisions de dispatching et de routage [8, 10] ;
- Comparer les performances de l'agent d'apprentissage par renforcement avec celles des heuristiques classiques sur des scénarios variés [3, 7] ;
- Analyser l'impact de l'approche d'apprentissage par renforcement sur les indicateurs clés (coût, temps, consommation, robustesse) [5, 9].

La méthodologie suivie s'appuie sur une adaptation du cadre CRISP-DM au contexte de l'apprentissage par renforcement : compréhension du problème et des données [2], modélisation de l'environnement, conception et entraînement de l'agent, expérimentation et analyse comparative [8, 10]. Chaque étape est guidée par une validation rigoureuse des hypothèses et une évaluation quantitative des résultats. Le mémoire est structuré comme suit :

- L'introduction générale présente le contexte, la problématique et les objectifs du travail ;
- Le chapitre 1 détaille le contexte général et la problématique de la logistique minière ;
- Le chapitre 2 propose un état de l'art des approches existantes et de l'apprentissage par renforcement appliqué à la logistique ;
- Le chapitre 3 décrit la modélisation du problème et les hypothèses retenues ;
- Le chapitre 4 expose la méthodologie et la conception de la solution d'apprentissage par renforcement ;
- Le chapitre 5 présente l'implémentation, les protocoles expérimentaux et les résultats obtenus ;
- Le chapitre 6 analyse et discute les résultats ;
- Enfin, la conclusion générale synthétise les apports et ouvre sur des perspectives futures.

Chapitre 1

Concepts fondamentaux de la logistique minière

Ce chapitre présente le vocabulaire et les notions structurantes mobilisés dans tout le mémoire. L'objectif est d'établir une base conceptuelle homogène avant l'analyse de la littérature et la modélisation.

1.1 Logistique minière et transport en mine à ciel ouvert

La logistique minière regroupe l'ensemble des activités de planification, d'organisation et de pilotage des flux de matériaux, d'équipements et d'informations nécessaires à l'exploitation d'une mine. Dans une mine à ciel ouvert, elle est centrée sur le système camion-pelle, où les matériaux sont extraits, chargés, transportés puis déchargés vers des destinations opérationnelles [1, 2].

Les concepts fondamentaux de ce système sont les suivants :

- **Mine à ciel ouvert** : exploitation dans laquelle le minerai est extrait par gradins successifs depuis la surface.
- **Système camion-pelle** : organisation de production où les pelles/chargeuses alimentent des camions qui assurent le transport du matériau.
- **Cycle camion-pelle** : séquence *affectation* $\rightarrow$ *chargement* $\rightarrow$ *transport* $\rightarrow$ *déchargement* $\rightarrow$ *retour*.
- **Point de chargement** : zone de prélèvement du matériau (pelle, chargeuse, front de taille).
- **Point de déchargement** : destination de livraison (concasseur, halde, stock intermédiaire).
- **Zone tampon** : espace de régulation des flux où les camions attendent avant affectation ou service.

1.2 Systèmes de gestion de flotte minière (FMS)

Les Systèmes de Gestion de Flotte (FMS) sont des plateformes de supervision et d'aide à la décision qui orchestrent les opérations de transport en temps réel. Leur rôle est d'assu-

rer la coordination entre ressources mobiles (camions) et ressources fixes (pelles, points de déchargement), tout en respectant les contraintes de production et de sécurité [1, 3].

Dans ce cadre, les notions de base sont :

- **Disponibilité des ressources** : capacité effective d'un équipement à réaliser une tâche à un instant donné.
- **Affectation** : décision d'envoyer un camion vers une destination donnée selon les priorités opérationnelles.
- **File d'attente** : ensemble des camions en attente de service à une ressource contrainte.
- **Synchronisation camion-pelle** : ajustement des arrivées de camions au rythme de chargement pour réduire l'attente improductive.

1.3 Concepts de dispatching et de routage minier

Le dispatching et le routage constituent les deux leviers décisionnels centraux du transport minier. Le dispatching détermine *la destination* d'un camion, alors que le routage détermine *l'itinéraire* suivi pour y parvenir. Leur couplage conditionne la performance globale du système [3, 4].

Leur formalisation conceptuelle s'appuie sur les éléments suivants :

- **Dispatching** : règle d'affectation dynamique des camions aux points de chargement ou déchargement.
- **Routage** : choix du chemin entre deux nœuds en fonction de critères de coût, de temps et de risque.
- **Réseau routier minier** : structure de transport du site, modélisable sous forme de graphe orienté pondéré.
- **Nœud** : entité du réseau (pelle, concasseur, halte, intersection, zone tampon).
- **Arc** : segment orienté reliant deux nœuds et porteur d'attributs (distance, pente, état de route).
- **Congestion** : saturation locale des capacités de service provoquant une hausse des temps d'attente.

1.4 Principes opérationnels et contraintes du transport minier

Le transport minier est gouverné par des contraintes opérationnelles, énergétiques et de sécurité qui doivent être représentées explicitement dans le modèle conceptuel du système. La variabilité des temps de service et les perturbations imposent en outre une vision stochastique de l'exploitation [1, 5, 7].

Les concepts fondamentaux associés sont :

- **Temps de cycle** : durée totale d'un cycle camion-pelle.
- **Temps d'attente** : temps improductif passé en file ou en attente de ressource.
- **Taux d'utilisation** : part du temps pendant lequel un équipement est effectivement productif.
- **Match Factor** : indicateur d'équilibre entre capacité de transport et capacité de chargement.

- **Consommation spécifique** : litres de carburant consommés par tonne transportée.
- **Coût opérationnel par tonne** : coût total de transport rapporté au tonnage utile.

Enfin, la base conceptuelle du sujet inclut aussi le cadre décisionnel séquentiel de l'Apprentissage par Renforcement :

- **Processus de décision markovien (MDP)** : formalisation d'un problème séquentiel par un quadruplet (S, A, P, R) .
- **État** : représentation synthétique de la situation opérationnelle observée.
- **Action** : décision admissible appliquée à l'état courant.
- **Récompense** : signal scalaire traduisant la qualité immédiate d'une décision au regard des objectifs métier.
- **Politique** : règle de décision associant des actions aux états.

1.5 Conclusion partielle et transition

Ce chapitre a posé un socle conceptuel complet pour le sujet traité, en clarifiant les notions métier de la logistique minière, les mécanismes opérationnels du système camion-pelle, les principes de dispatching et de routage, les contraintes et indicateurs clés de performance, ainsi que le cadre décisionnel séquentiel mobilisé par l'Apprentissage par Renforcement. Cette base terminologique et conceptuelle sert de référence pour la revue de littérature du chapitre suivant.

Chapitre 2

État de l’art des méthodes d’optimisation

2.1 Les heuristiques classiques

L’histoire de l’optimisation de la logistique minière débute avec des heuristiques simples, telles que l’assignation du camion le plus proche ou la règle du premier arrivé, premier servi [3, 11]. Si ces méthodes sont faciles à mettre en œuvre, elles restent « myopes » : elles optimisent localement sans anticiper les conséquences globales sur la flotte. Cette limitation a conduit à l’émergence de systèmes industriels comme DISPATCH, Caterpillar MineStar ou Komatsu Jigsaw, qui intègrent des modules de planification et de suivi en temps réel [1, 12]. Ces systèmes ont permis d’augmenter la productivité et de réduire les temps d’attente, mais restent largement déterministes et rigides, peinant à s’adapter aux perturbations et à la dynamique réelle du terrain.

2.2 Les méta-heuristiques

L’apparition des systèmes industriels comme DISPATCH marque une première rupture, en intégrant la planification et le suivi en temps réel. Cependant, ces solutions restent déterministes et peu flexibles face à la variabilité du terrain.

Pour dépasser les limites des systèmes industriels, la recherche académique a proposé des approches plus sophistiquées : méta-heuristiques (algorithmes génétiques, colonies de fourmis, recuit simulé) [13, 14], modèles MILP ou programmation par contraintes [15–18]. Ces méthodes offrent de meilleures performances sur des cas complexes, mais leur capacité d’adaptation en temps réel reste limitée, notamment face à l’incertitude et à la variabilité opérationnelle [4, 5, 7].

2.3 Les approches basées sur l’apprentissage par renforcement

Face aux limites persistantes de ces approches, un nouveau paradigme issu de l’intelligence artificielle s’est imposé : l’apprentissage par renforcement. L’apprentissage par renforcement permet à un agent d’apprendre une politique de décision séquentielle en interagissant avec un

environnement simulé ou réel, optimisant ainsi la flotte de manière holistique et adaptative [8, 10, 19]. Les travaux récents montrent que l'apprentissage par renforcement peut surpasser les heuristiques classiques pour le routage de véhicules, la gestion dynamique des files d'attente et l'optimisation des ressources, même en présence d'incertitude [6, 9].

2.4 Synthèse critique et positionnement du travail

La littérature montre que, malgré les avancées des Systèmes de Gestion de Flotte (FMS) industriels et des heuristiques, l'optimisation globale et dynamique de la flotte minière reste un défi [4, 7]. Les approches d'apprentissage par renforcement offrent un potentiel inédit pour dépasser ces limites, en permettant une adaptation en temps réel, une optimisation holistique et une meilleure gestion de l'incertitude [8–10]. Ce mémoire s'inscrit dans cette dynamique, en proposant une solution d'apprentissage par renforcement adaptée aux contraintes et aux spécificités de la logistique minière moderne.

TABLE 2.1 – Synthèse des grandes familles d'approches et opportunités pour l'apprentissage par renforcement

Référence	Approche	Limites principales / Opportunité pour l'apprentissage par renforcement
[3]	Heuristiques statiques	Approche myope, peu adaptative, ne gère pas l'incertitude. Opportunité : L'apprentissage par renforcement peut apprendre une politique globale et adaptative.
[1, 12]	Systèmes industriels	Déterministes, rigides, peu réactifs aux perturbations. Opportunité : L'apprentissage par renforcement permet l'adaptation dynamique.
[13, 14]	Méta-heuristiques	Performantes mais peu robustes en temps réel, optimisation hors-ligne. Opportunité : L'apprentissage par renforcement gère l'incertitude et l'adaptation continue.
[15, 16]	MILP, optimisation avancée	Complexité computationnelle, difficilement scalable, peu flexible. Opportunité : L'apprentissage par renforcement offre une solution scalable et flexible.
[10, 19]	apprentissage par renforcement pour VRP/-JSSP	Complexité de la modélisation, besoin de simulateur. Inspiration : Fournit un cadre état/action/récompense pour l'apprentissage par renforcement minier.
[6, 9]	apprentissage par renforcement appliqué à la logistique minière	L'apprentissage par renforcement montre des gains sur la robustesse et l'adaptation, mais nécessite une modélisation réaliste et des données de simulation.

TABLE 2.2 – Détail des contributions et limites des articles majeurs de l'état de l'art

Référence	Domaine / Approche	Principales contributions / Limites
[2]	FMS, optimisation minière	Modélisation des flux, contraintes industrielles, limites des heuristiques
[1]	FMS industriels	Suivi en temps réel, gestion des files, limites en environnement dynamique
[3]	Heuristiques classiques	Règles de dispatching, efficacité en conditions stables, manque d'adaptabilité
[4]	Heuristiques, VRP	Variabilité du trafic, limites des modèles déterministes
[7]	Méta-heuristiques	Colonies de fourmis, optimisation partielle, adaptation limitée
[10]	apprentissage par renforcement pour VRP	apprentissage par renforcement pour routage, surpasse heuristiques, besoin de données, temps d'entraînement
[8]	apprentissage par renforcement appliqué à la logistique	apprentissage par renforcement pour dispatching, robustesse, adaptation aux perturbations
[9]	apprentissage par renforcement en environnement stochastique	Politiques robustes, gestion de l'incertitude, limites pratiques
[5]	Limites des heuristiques	Incapacité à gérer la variabilité, sous-utilisation des ressources
[19]	apprentissage par renforcement : fondements	Concepts MDP, politiques, fonctions de valeur
[13, 14]	Méta-heuristiques	Algorithmes génétiques, recuit simulé, optimisation locale

2.5 Conclusion partielle

Ce chapitre a retracé l'évolution des approches d'optimisation de la logistique minière, depuis les heuristiques simples jusqu'aux systèmes industriels, en passant par les méta-heuristiques et l'optimisation avancée. Il a mis en évidence les limites des méthodes traditionnelles face à la complexité, la variabilité et l'incertitude des environnements miniers. L'apprentissage par renforcement apparaît comme un paradigme innovant, capable d'apporter une adaptation dynamique, une optimisation holistique et une robustesse accrue. Ce posi-

tionnement ouvre la voie à une nouvelle génération de solutions pour la logistique minière. Le chapitre suivant présentera la modélisation du problème et les choix méthodologiques pour concevoir un agent d'apprentissage par renforcement adapté à la logistique minière.

Chapitre 3

Modélisation du problème

3.1 Description du système de transport minier

À compléter...

3.2 Hypothèses et contraintes de modélisation

À compléter...

3.3 Modélisation du réseau routier minier

À compléter...

3.4 Formulation du problème en tant que processus de décision markovien (MDP)

À compléter...

Chapitre 4

Méthodologie et conception de la solution

4.1 Méthodologie adoptée (CRISP-DM adaptée à l'apprentissage par renforcement)

À compléter...

4.2 Conception de l'environnement de simulation

À compléter...

4.3 Conception de l'agent d'apprentissage par renforcement

À compléter...

4.4 Choix des algorithmes d'apprentissage

À compléter...

4.5 Conception des modèles de référence (baselines)

À compléter...

Chapitre 5

Implémentation et expérimentation

5.1 Architecture globale du système proposé

À compléter...

5.2 Détails d'implémentation de l'environnement

À compléter...

5.3 Paramètres et protocoles d'entraînement

À compléter...

5.4 Scénarios expérimentaux

À compléter...

5.5 Métriques d'évaluation

À compléter...

Chapitre 6

Résultats et analyse

6.1 Résultats expérimentaux

À compléter...

6.2 Comparaison avec les approches de référence

À compléter...

6.3 Analyse critique des résultats

À compléter...

6.4 Discussion

À compléter...

Conclusion générale et perspectives

Bibliographie

- [1] A. Afrapoli and H. Askari-Nasab, “Mining fleet management systems : a review of models and algorithms,” *International Journal of Mining, Reclamation and Environment*, pp. 1–20, 6 2017.
- [2] A. M. Newman, E. Rubio, A. W. R. Caro, and K. Eurek, “A review of operations research in mine planning,” *Interfaces*, vol. 40, pp. 222–245, 4 2010.
- [3] S. Alarie and M. Gamache, “Overview of solution strategies used in truck dispatching systems for open pit mines,” *International Journal of Surface Mining, Reclamation and Environment*, vol. 16, pp. 59–76, 2002.
- [4] M. M. Fioroni, L. A. G. Franzese, T. J. Bianchi, L. Ezawa, L. R. Pinto, and G. de Miranda Jr., “Concurrent simulation and optimization models for mining planning,” *Winter Simulation Conference*, 2008.
- [5] S. P. Upadhyay and H. Askari-Nasab, “Simulation and optimization approach for uncertainty-based short-term planning in open pit mines,” *International Journal of Mining Science and Technology*, vol. 28, pp. 153–166, 12 2017.
- [6] M. Abolghasemian, A. G. Kanafi, and M. Daneshmandmehr, “A two-phase simulation-based optimization of hauling system in open-pit mine,” *Iranian Journal of Management Studies (IJMS)*, vol. 13, pp. 705–732, 5 2020.
- [7] B. Ozdemir and M. Kumral, “Simulation based optimization of truck shovel material handling systems in multi pit surface mines,” *Simulation Modelling Practice and Theory*, vol. 95, pp. 36–48, 4 2019.
- [8] S. Choudhury and D. H. Naik, “Use of machine learning algorithm models to optimize the fleet management system in opencast mines,” *International conference for Convergence in Technology*, 9 2022.
- [9] W. Zeng, E. Baafi, and H. Fan, “A simulation model to study truck- allocation options,” *School of Civil, Mining and Environmental Engineering, University of Wollongong, Australia*, vol. 122, pp. 741–750, 12 2022.
- [10] M. Nazari, A. Oroojlooy, M. Takáč, and L. V. Snyder, “Reinforcement learning for solving the vehicle routing problem,” *NeurIPS*, 5 2018.

- [11] M. Munirathinam and J. C. Yingling, "A review of computer-based truck dispatching strategies for surface mining operations," *International Journal of Surface Mining, Reclamation and Environment*, 1994.
- [12] M. Mohtasham and H. Mirzaei-Nasirabad, "Evaluating the performance of the dispatch algorithm, a commercial software, in the sungun copper mine," *Journal of Geomines*, pp. 117–122, 2023.
- [13] M. Souza, I. Coelho, S. Ribas, H. Santos, and L. Merschmann, "A hybrid heuristic algorithm for the open-pit-mining operational planning problem," *European Journal of Operational Research*, pp. 1041–1051, 6 2010.
- [14] R. Subtil, D. M. Silva, and J. C. Alves, "A practical approach to truck dispatch for open pit mines," *Proceedings of the 35th International Symposium on the Application of Computers and Operations Research in the Mineral Industry (APCOM)*, 2011.
- [15] D. Ahangaran, A. Yasrebi, A. Wetherelt, and P. Foster, "Real-time dispatching modelling for trucks with different capacities in open pit mines," *Archives of Mining Sciences*, vol. 52, pp. 39–52, 2012.
- [16] A. Smith, J. Linderroth, and J. Luedtke, "Optimization-based dispatching policies for open-pit mining," *Springer*, pp. 1–39, 2 2020.
- [17] C. H. Ta, A. Ingolfsson, and J. Doucette, "A linear model for surface mining haul truck allocation incorporating shovel idle probabilities," *European Journal of Operational Research*, pp. 770–778, 6 2013.
- [18] Z. Wang, J. Wang, M. Zhao, Q. Guo, X. Zeng, F. Xin, and H. Zhou, "Truck dispatching optimization model and algorithm based on 0-1 decision variables," *Mathematical Problems in Engineering*, vol. 2022, pp. 1–9, 2 2022.
- [19] C. Zhang, W. Song, Z. Cao, J. Zhang, P. S. Tan, and C. Xu, "Learning to dispatch for job shop scheduling via deep reinforcement learning," *NeurIPS*, pp. 1–17, 10 2020.

Annexe A

Détails d'implémentation

À compléter...

Annexe B

Hyperparamètres des modèles

À compléter...

Annexe C

Scénarios de simulation

À compléter...

Annexe D

Architecture logicielle et structure du projet

À compléter...

Annexe E

Interfaces et démonstrations

À compléter...