Disponibilité des ressources : Pour chaque pelle ou section de route, on enregistre si elle est disponible, en maintenance ou indisponible.

Temps courant : L'heure de la journée ou l'étape de simulation, qui peut in uencer la dynamique (sauf au sein d'un épisode stationnaire).

Espace d'action A

À chaque étape de décision, l'agent doit décider d'assigner certains camions libres à des pelles disponibles. L'espace d'action dépend de l'état courant et est construit comme suit :

$$a_t = \text{Assignment}(c_1 \,!\, p_j ; c_2 \,!\, p_k ; : : :) \quad \text{ou} \quad a_t = \text{ATTENDRE} \tag{3.4}$$

Une action valide est un ensemble d'appairements camion-pelle qui respectent les contraintes :

Le camion doit être libre (non actuellement en transit, en charge ou en décharge).

La pelle doit être disponible et produire un type de minerai compatible avec la capacité du camion.

L'action peut aussi être d'attendre (pas de changement) si attendre est plus pro table à long terme.

L'ensemble A(s) des actions possibles dans l'état s peut être très large (combinatoire exponentiel). Pour rendre le problème traitable, on peut limiter l'espace à un nombre réduit d'actions par exemple assigner au maximum k camions par étape, ou sélectionner les n meilleures paires candidate selon une heuristique.

Cette restriction constitue un compromis assumé : une action décrite comme une a ectation complète de la otte serait plus expressive, mais elle rendrait l'espace de recherche nettement moins maniable. Le modèle retient donc une granularité su sante pour capturer l'essentiel du dispatching sans faire basculer le problème dans une complexité disproportionnée.

Modèle de transition $P(s' \,|\, s, a)$

Le modèle de transition décrit comment le système évolue suite à une action. Étant donné un état s et une action a, le nouvel état s' est déterminé par :

$$s'_t = \text{Simuler}(s_t ; a_t ; \Delta t) \tag{3.5}$$

où Δt est l'intervalle de temps entre deux décisions.

Figure 3.3 Schéma d'interaction entre l'agent RL (politique) et l'environnement (simulateur minier).

La simulation inclut :

Avancement des camions en transit : Les camions se déplacent selon les matrices de temps du réseau, avec perturbations stochastiques.

Mise à jour des les d'attente de chargement : Les camions arrivent aux pelles, se joignent à la le ou commencent le chargement.

Événements de déchargement : Les camions qui atteignent les points de déchargement sont marqués comme déchargés et reviennent en état libre.

Dynamique des pelles : Chaque pelle continue de servir les camions selon un ordre FIFO ou de priorité.

Formellement, le modèle de transition est une fonction déterministe augmentée de sources de stochasticité (variation des temps de trajet). Cette représentation est alignée avec les environnements de benchmark con gurables récemment proposés pour le dispatching minier et avec les travaux de simulation dédiés à l'évaluation de règles de dispatching sous incertitude [9, 26] :

$$s_t^0 = f(s_t; a_t) + \quad _t; \qquad _t \quad N(0; \ ) \tag{3.6}$$

où $f(s_t; a_t)$ est la transition déterministe et $_t$ représente les perturbations stochastiques.

Fonction de récompense $R(s; a; s^0)$

La récompense re ète les objectifs opérationnels. Le rendement global du système (tonnage par unité de temps) peut être décomposé en plusieurs objectifs :

$$R_t = w_1 \quad R_{\text{rendement}}(s_t; s_t^0) + w_2 \quad R_{\text{équité}}(s_t) + w_3 \quad R_{\text{coût}}(a_t) \tag{3.7}$$

où :

$R_{\text{rendement}}$: Récompense proportionnelle au tonnage livré à la destination au cours du